O método de Hannan-Rissanen no seu ARIMA

como ele funciona, passo a passo, e o que ele fez no robô

Material de estudo para os autores do TG (não faz parte do texto)

30 de outubro de 2026

Em uma página

O que é. Uma forma de estimar os coeficientes de um ARIMA usando só duas regressões de mínimos quadrados (MQO), sem otimização iterativa.
O problema que resolve. O termo de médias móveis (MA) do ARIMA usa o *erro* de ontem, e o erro não aparece nos dados. Sem ele não dá para montar a regressão.
A solução, em duas frases. Primeiro estima-se um modelo autorregressivo longo, cujos resíduos servem de estimativa dos erros (estágio 1). Depois esses erros estimados entram como mais uma coluna numa segunda regressão, que dá os coeficientes do modelo (estágio 2).
No seu robô. Refazendo fora do robô a estimação de dois pregões reais, os coeficientes e a previsão saíram *idênticos* aos que o robô registrou (diferença zero). No traço de jul/2019 a jun/2021, os dois estágios rodaram em 105 dos 496 pregões (21%). Nos outros, o modelo escolhido não tinha termo MA e o método se reduz a um MQO comum. Mas na escolha das ordens, a cada 21 pregões, 20 dos 25 modelos candidatos passam pelos dois estágios.
O que se descobriu. Em séries simuladas o método acerta perto do valor verdadeiro, com um pouco mais de erro que a máxima verossimilhança. Para um θ do tamanho do que o robô estimou no pregão detalhado, o erro de estimação é quase do tamanho do próprio coeficiente.

Sumário

1 O problema: o erro de ontem não está nos dados **1**

2 A ideia que destrava tudo: um ARMA é um AR comprido **2**

3 Estágio 1: o AR longo que estima os erros **3**

3.1 Quantas defasagens . . . 3

3.2 A regressão . . . 3

3.3 O que sai dele . . . 3

4 Estágio 2: a regressão que dá os coeficientes **3**

5 Depois dos dois estágios: os resíduos finais **4**

6 Um pregão real do seu robô: 13/05/2021 **5**

6.1 Passo a passo . . . 5

6.2 O que esse dia ensina . . . 5

7 Onde o Hannan-Rissanen trabalha no robô **5**

8 Quão bem ele estima: mil simulações **7**

9 O seu código comparado ao método da literatura **8**

9.1 Um ponto para pensar: a ordem do AR longo numa amostra pequena 8

10 Perguntas que a banca pode fazer **9**

1 O problema: o erro de ontem não está nos dados

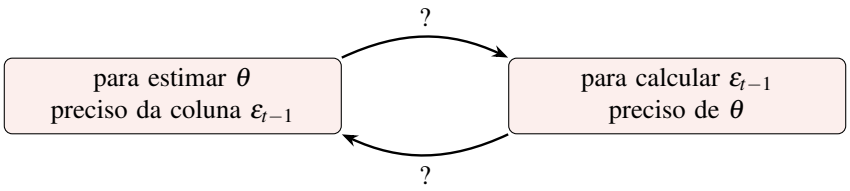
O ARIMA do robô, depois de diferenciar o log-preço ($d = 1$), descreve o log-retorno z_t de cada dia assim (é a convenção do código, `Arima.mqh`):

$$z_t \;=\; c \;+\; \underbrace{\phi_1 z_{t-1} + \cdots + \phi_p z_{t-p}}_{\text{parte AR: retornos passados}} \;+\; \underbrace{\theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}}_{\text{parte MA: erros passados}} \;+\; \varepsilon_t .$$

O ε_t é o erro do dia: a parte do retorno que o modelo não consegue prever.

Se o modelo só tivesse a parte AR, a estimação seria uma regressão comum. Cada linha da tabela seria um dia, a coluna da esquerda seria z_t e as da direita seriam $z_{t-1}, z_{t-2}, \ldots$, todos números conhecidos. O MQO escolhe os ϕ que deixam a soma dos erros ao quadrado a menor possível, numa conta fechada.

Com a parte MA aparece o problema: para montar a coluna ε_{t-1} é preciso saber o erro de ontem, e o erro depende dos próprios coeficientes que se quer estimar. É uma volta em círculo:



Há duas saídas. A primeira é a **máxima verossimilhança**: chutar coeficientes, calcular os erros, medir quão plausíveis eles são e repetir até não melhorar mais. Funciona, mas é iterativa: precisa de ponto de partida, de critério de parada e pode não convergir. A segunda é o **Hannan-Rissanen**, que quebra o círculo estimando os erros *antes*, por um caminho que não depende de θ.

E se simplesmente ignorar a parte MA?

Numa simulação com $\phi = 0{,}6$ e $\theta = 0{,}4$ verdadeiros (seção 8), um AR(1) por MQO que ignora o MA estimou, em média, $\phi = 0{,}746$ em vez de 0,6. O efeito do MA não some: ele vai parar dentro do coeficiente AR e o distorce.

2 A ideia que destrava tudo: um ARMA é um AR comprido

Se a parte MA for *invertível* ($|\theta| < 1$ no caso de um termo), dá para reescrever o erro de hoje como uma soma de retornos passados. Para um ARMA(1,1), substituindo ε_{t-1} pela própria equação de ontem, e depois ε_{t-2}, e assim por diante, chega-se a

$$z_t = \pi_1 z_{t-1} + \pi_2 z_{t-2} + \pi_3 z_{t-3} + \cdots + \varepsilon_t, \qquad \pi_j = (\phi + \theta)\,(-\theta)^{\,j-1}.$$

Ou seja, um ARMA(1,1) é um AR com infinitos termos, cujos pesos π_j encolhem a cada defasagem. Um AR *comprido, mas finito* chega bem perto dele. E um AR se estima por MQO, sem precisar de ε.

A Figura 1 mostra isso numa série simulada com $\phi = 0{,}6$ e $\theta = 0{,}4$, do mesmo tamanho da janela do robô (239 retornos). As barras azuis são os pesos verdadeiros; os pontos laranja, o que o AR longo do estágio 1 estimou a partir dos dados.

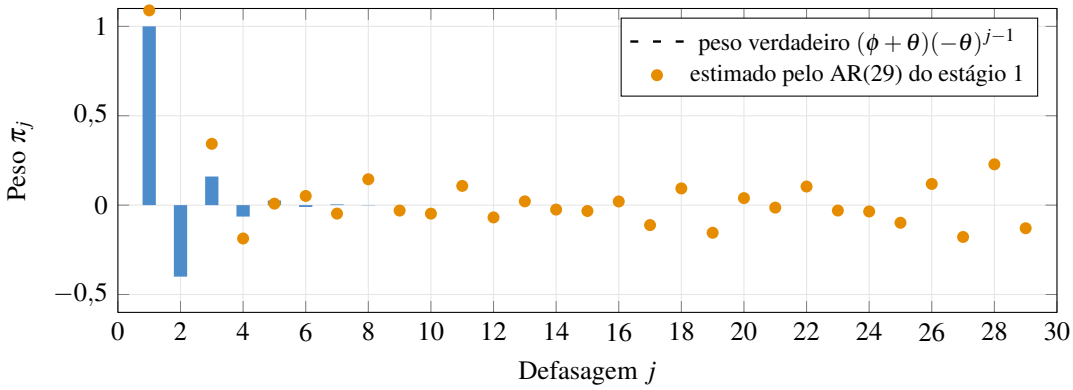


Figura 1: Série simulada: o AR longo recupera os primeiros pesos, que são os que importam. Depois da quinta defasagem os pesos verdadeiros são quase zero, e o que o AR estima ali é ruído.

3 Estágio 1: o AR longo que estima os erros

3.1 Quantas defasagens

O código escolhe a ordem m do AR longo pela regra

$$m = \lfloor (\ln N)^2 \rfloor, \qquad \text{limitada por baixo a } p+q+1 \text{ e por cima a } N/5,$$

em que N é o número de retornos. A janela do robô tem 240 fechamentos e portanto $N = 239$ retornos. Com isso, $m = 29$. A regra vem da literatura: Gómez e Maravall (1998, p. 28) usam $\lfloor \log^2 N \rfloor$, apoiados em Hannan e Rissanen (1982, p. 88), que pedem que m cresça com o tamanho da série, mas devagar.

3.2 A regressão

Cada linha é um dia t a partir do $(m+1)$-ésimo, porque os primeiros m dias não têm m dias anteriores. São $N - m = 210$ linhas e $m + 1 = 30$ colunas (a constante e os 29 retornos anteriores). A tabela mostra as primeiras linhas no pregão real que será detalhado na seção 6 (retornos em %):

dia t	z_t	1	z_{t-1}	z_{t-2}	z_{t-3}	$\cdots$	z_{t-29}
07/07/2020	−1,252	1	2,383	−0,363	1,599	$\cdots$	0,971
08/07/2020	1,872	1	−1,252	2,383	−0,363	$\cdots$	1,313
09/07/2020	−2,277	1	1,872	−1,252	2,383	$\cdots$	−0,806
10/07/2020	1,657	1	−2,277	1,872	−1,252	$\cdots$	2,842
		⋮	(210 linhas)				

Repare na diagonal: o z_t de uma linha reaparece como z_{t-1} na linha de baixo. É a mesma série, deslocada.

3.3 O que sai dele

O MQO dá os 29 coeficientes do AR longo. Com eles, o resíduo de cada dia,

$$\hat{\varepsilon}_t = z_t - \left(\hat{a}_0 + \hat{a}_1 z_{t-1} + \cdots + \hat{a}_m z_{t-m}\right),$$

é a **estimativa do erro** daquele dia. Isso é tudo o que se quer do estágio 1: os coeficientes do AR longo são jogados fora.

Na série simulada dá para conferir, porque ali o erro verdadeiro é conhecido (Figura 2). A correlação entre o erro estimado e o verdadeiro foi de 0,922.

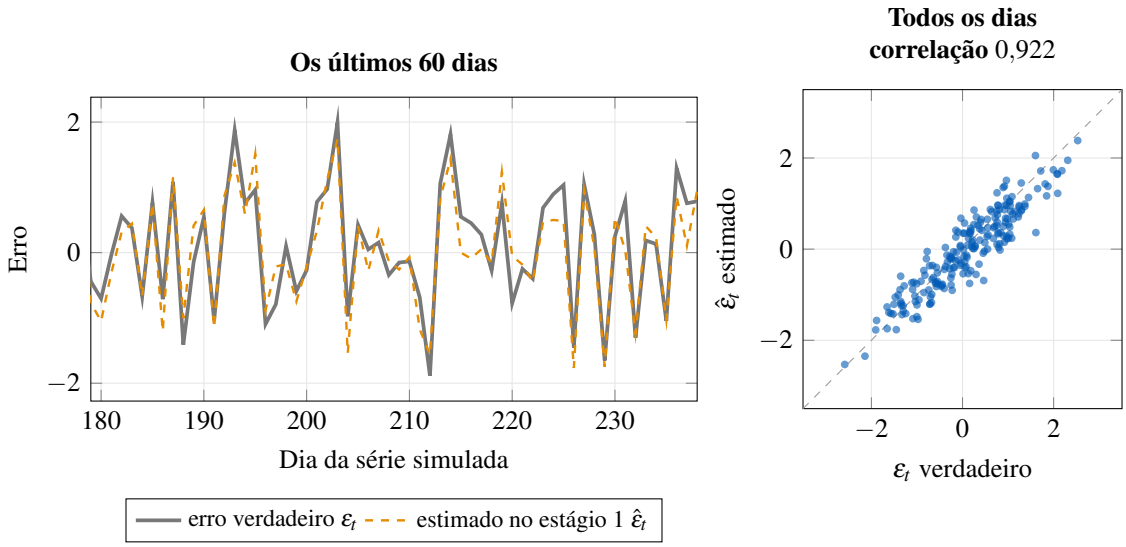


Figura 2: Série simulada: os erros estimados pelo AR longo seguem os verdadeiros de perto. Não são iguais, e é por isso que o resultado do Hannan-Rissanen é uma aproximação.

4 Estágio 2: a regressão que dá os coeficientes

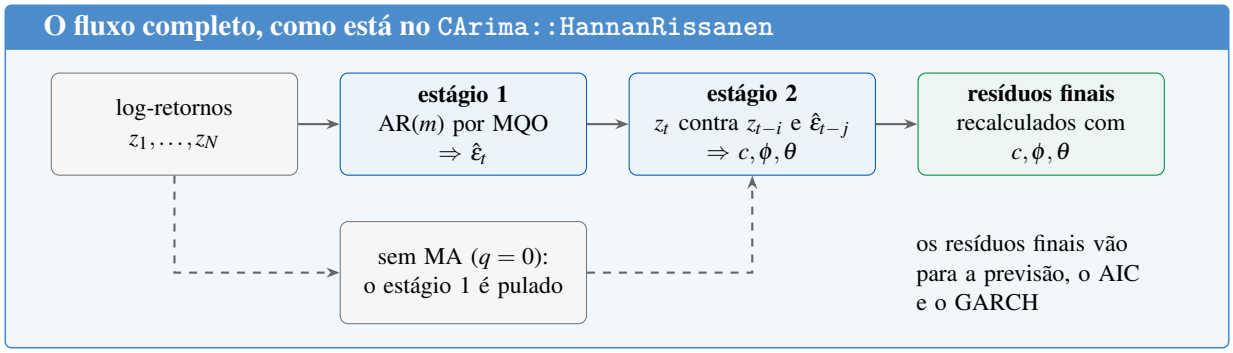
Agora a coluna que faltava existe. O estágio 2 regride z_t contra a constante, os retornos passados e os *erros estimados* passados:

$$z_t = c + \phi_1 z_{t-1} + \cdots + \phi_p z_{t-p} + \theta_1 \hat{\varepsilon}_{t-1} + \cdots + \theta_q \hat{\varepsilon}_{t-q} + \text{resto}.$$

É de novo um MQO comum, com $1 + p + q$ colunas. Os primeiros $m + q$ retornos ficam de fora (no código, `primeiro = max(m + q, p)`), porque antes deles não há $\hat{\varepsilon}$ suficientes. No pregão real, com $q = 1$, ficam de fora os primeiros 30 retornos e a regressão tem 209 linhas:

dia t	z_t	1	$\hat{\varepsilon}_{t-1}$
08/07/2020	1,872	1	−0,582
09/07/2020	−2,277	1	1,533
10/07/2020	1,657	1	−2,351
13/07/2020	−1,567	1	1,630
⋮	(209 linhas)		

Os coeficientes dessa regressão são o resultado: c, os ϕ e os θ do modelo. Na série simulada deram $\hat{\phi} = 0{,}629$ e $\hat{\theta} = 0{,}474$, contra 0,6 e 0,4 verdadeiros. É uma única amostra: a seção 8 mostra o comportamento em mil.



5 Depois dos dois estágios: os resíduos finais

Um detalhe que costuma passar despercebido. Os $\hat{\varepsilon}_t$ do estágio 1 *não* são os resíduos que o robô usa depois. Com os coeficientes finais em mãos, o código (`CArima::CalcularResiduos`) recalcula todos os erros do início, um dia de cada vez:

$$e_t = z_t - \big(c + \phi_1 z_{t-1} + \cdots + \theta_1 e_{t-1} + \ldots\big),$$

começando com $e = 0$ nos primeiros dias. São esses e_t que vão para três lugares: a previsão do dia seguinte, a verossimilhança que o AIC compara na escolha das ordens e o GARCH, que estima a volatilidade em cima deles.

Na série simulada, os resíduos finais tiveram correlação de 0,995 com o erro verdadeiro, mais do que os do estágio 1 (0,922). Com o modelo certo e poucos coeficientes, a conta recursiva acerta mais que o AR longo, que carrega o ruído de 29 coeficientes.

6 Um pregão real do seu robô: 13/05/2021

Este é o pregão de 13/05/2021 da configuração ARIMA-GARCH Sharpe, no traço da refação de 05/10/2026. Nesse dia o modelo em uso era um **ARIMA(0,1,1) com constante**: nenhum retorno passado, um erro passado. É o caso mais simples em que os dois estágios rodam, e por isso o estágio 2 cabe num gráfico.

6.1 Passo a passo

1. **Dados.** Os 240 fechamentos antes do pregão, de 25/05/2020 a 12/05/2021 (último: R$ 24,78). O log de cada um, e a diferença: $N = 239$ log-retornos.
2. **Estágio 1.** AR(29) com constante, por MQO, em 210 linhas. O desvio-padrão dos resíduos foi de 2,91% ao dia. A Figura 3(c) mostra os 29 coeficientes.
3. **Estágio 2.** $z_t = c + \theta\,\hat{\varepsilon}_{t-1}$, em 209 linhas. Com uma coluna só além da constante, é uma reta num gráfico de dispersão (Figura 3b): $c = 0{,}0524\%$ e $\theta = -0{,}0929$.
4. **Resíduos finais.** Recalculados com c e θ. O do último dia da janela foi $e_N = -1{,}358\%$.
5. **Previsão.**

$$\hat{z}_{N+1} = c + \theta\, e_N = 0{,}0524\% + (-0{,}0929) \times (-1{,}358\%) = 0{,}0524\% + 0{,}1261\% = 0{,}1785\%.$$

Positiva, então o ARIMA deu sinal de compra.

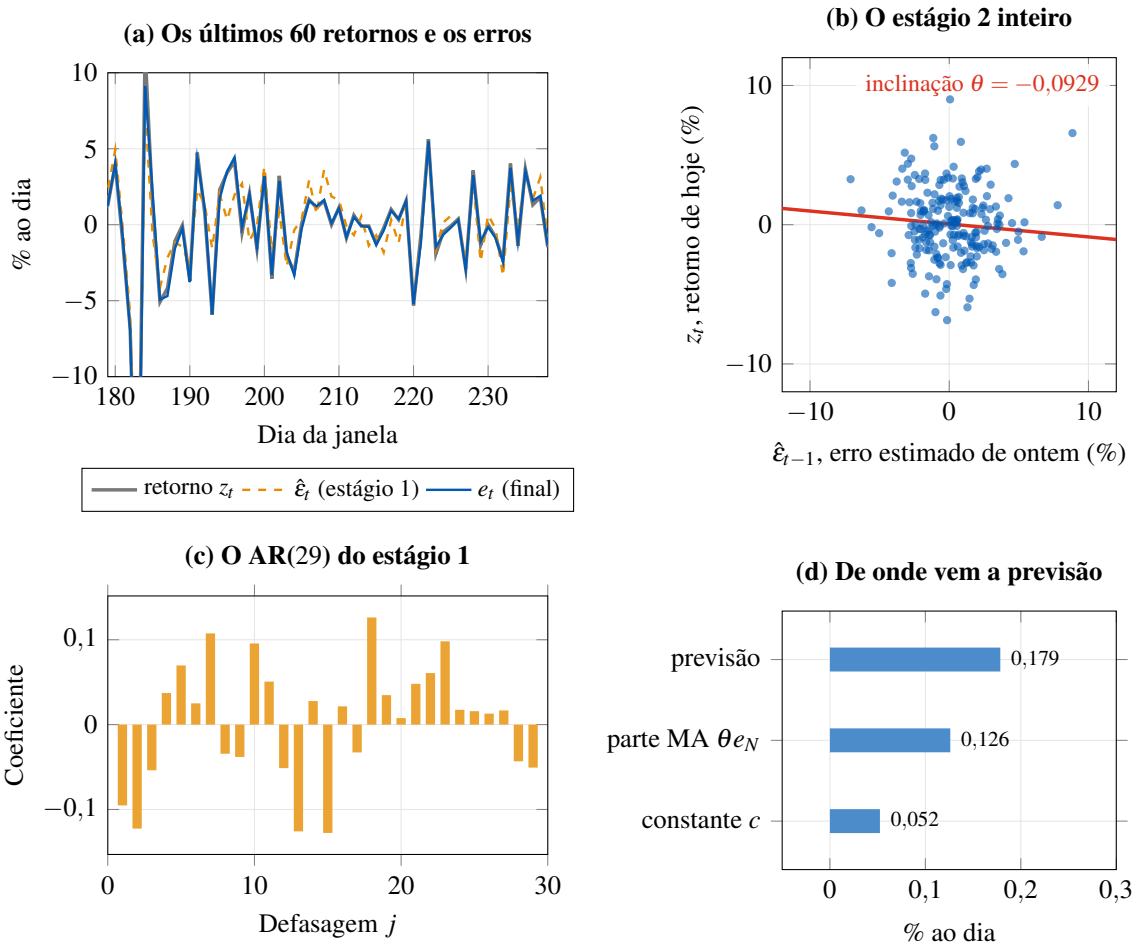


Figura 3: O pregão de 13/05/2021, refeito com as mesmas regras do robô. Em (b), cada ponto é um dia: o erro estimado do dia anterior contra o retorno do dia. A nuvem é quase redonda e a reta, quase deitada: o erro de ontem diz pouco sobre o retorno de hoje. Em (a), um dia de queda forte sai cortado na escala.

6.2 O que esse dia ensina

O θ é pequeno e a nuvem da Figura 3(b) é quase redonda. Ainda assim, nesse pregão a parte MA pesou *mais* que a constante na previsão (0,1261% contra 0,0524%), porque o erro de ontem foi grande ($-1{,}358\%$) e o θ negativo transforma um erro negativo em empurrão para cima. É a leitura de "reversão": depois de um dia pior que o esperado, o modelo espera uma pequena compensação.

A máxima verossimilhança, na mesma janela, daria $\theta = -0{,}1248$ e previsão de 0,2646%: números diferentes, mesmo sinal, mesma decisão.

Conferência

Os valores de c, θ e da previsão refeitos aqui são **idênticos**, em todas as casas gravadas, aos que o robô registrou no traço desse pregão (`refeito_2026-10-05/traco_demo/traco_demo_GARCH.csv`). O mesmo vale para o pregão de 05/06/2020, com um ARIMA(0,1,4) e quatro θ. O relatório descreve o que o robô de fato fez.

7 Onde o Hannan-Rissanen trabalha no robô

O método entra em dois momentos, com pesos bem diferentes.

Todo pregão, na estimação do modelo em uso. Aqui os dois estágios só rodam se o modelo tiver termo MA ($q > 0$). Com $q = 0$ o código pula o estágio 1 e faz um MQO direto, e com $p = q = 0$ a constante é só a média dos retornos da janela. No traço de jul/2019 a jun/2021, os dois estágios rodaram em 105 pregões e o atalho em 391 (Figura 4).

A cada 21 pregões, na escolha das ordens. A grade testa os 25 modelos com p e q de 0 a 4. Os 20 que têm $q \geq 1$ passam pelos dois estágios, e o AIC de cada um é calculado com os resíduos finais da seção anterior. É aqui que o método mais trabalha: ele decide, indiretamente, se o robô vai usar um modelo com MA ou não.

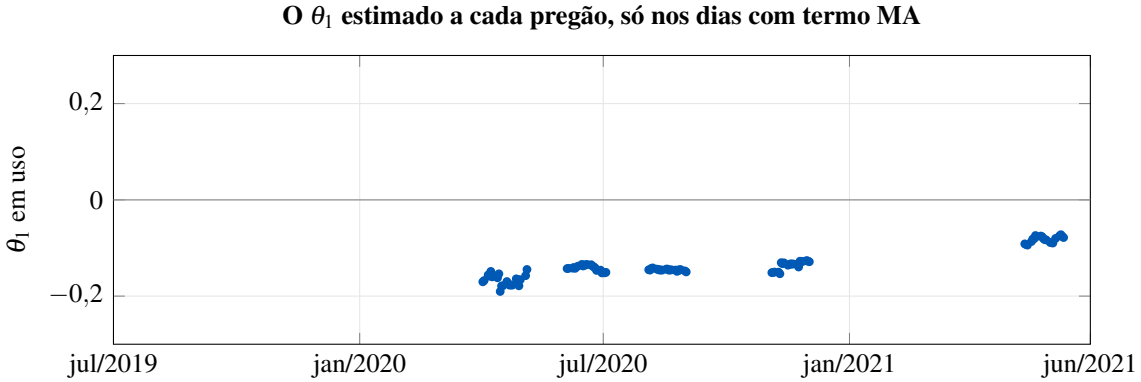


Figura 4: Traço da configuração ARIMA-GARCH Sharpe. Cada ponto é um pregão em que o modelo em uso tinha termo MA e os dois estágios rodaram. Os blocos correspondem aos períodos entre duas escolhas de ordem. Nos dias sem ponto o modelo não tinha MA.

8 Quão bem ele estima: mil simulações

Uma série só não diz se o método é bom. Para isso, gerou-se mil séries com coeficientes conhecidos, cada uma do tamanho da janela do robô (239 retornos), e estimou-se cada uma de três jeitos: Hannan-Rissanen (o do robô), máxima verossimilhança (a opção experimental `MetodoARIMA=1`, que parte do Hannan-Rissanen e refina) e um AR(1) que ignora o MA.

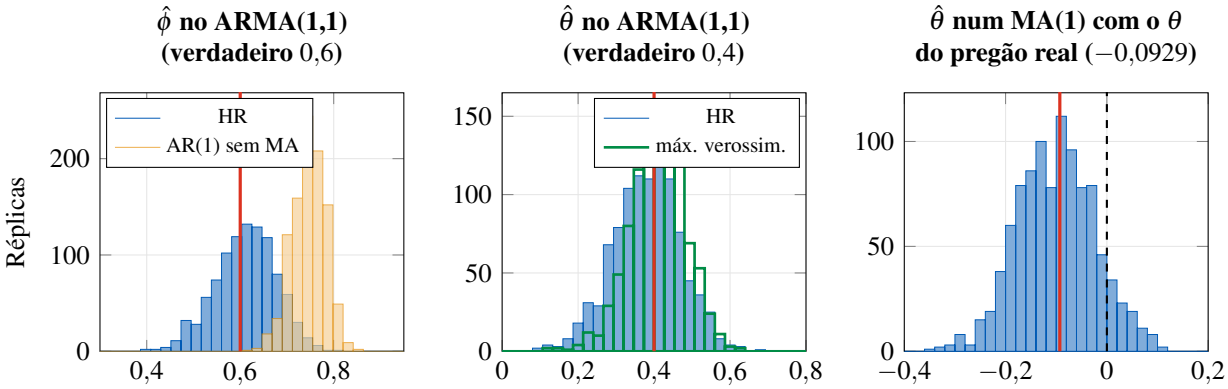


Figura 5: Distribuição das estimativas em 1000 séries simuladas. A linha vermelha é o valor verdadeiro; a tracejada preta, no gráfico da direita, é o zero.

	ARMA(1,1), $\phi = 0{,}6$, $\theta = 0{,}4$		MA(1), $\theta = -0{,}0929$
Método	$\hat{\phi}$ média (desvio)	$\hat{\theta}$ média (desvio)	$\hat{\theta}$ média (desvio)
Hannan-Rissanen (robô)	0,612 (0,065)	0,380 (0,089)	−0,100 (0,077)
Máxima verossimilhança	0,584 (0,066)	0,410 (0,074)	−0,099 (0,069)
AR(1) ignorando o MA	0,746 (0,036)	–	–

Ignorar o MA distorce. O AR(1) sem MA erra o ϕ de forma sistemática (média 0,746 para um verdadeiro de 0,6). É a justificativa para ter o termo MA e, portanto, um método que o estime.

O HR chega perto, com um pouco mais de erro que a máxima verossimilhança. No θ, o desvio do HR foi 0,089 e o da máxima verossimilhança, 0,074, e a média do HR ficou um pouco abaixo do verdadeiro. É o comportamento descrito na literatura: Gómez e Maravall (1998, p. 29) dizem que os estimadores do segundo estágio são consistentes, mas têm viés e não são os mais eficientes.

No tamanho dos coeficientes do robô, o erro de estimação é do tamanho do coeficiente. Com $\theta = -0{,}0929$ (o valor que o robô estimou em 13/05/2021), o desvio da estimativa foi 0,077, quase igual ao próprio θ. Em 90% das séries o HR acertou o sinal, e nas demais estimou um θ com o sinal trocado. Isso não é defeito do método: com 239 retornos, um efeito desse tamanho mal se distingue do zero, e a máxima verossimilhança tem o mesmo problema (0,069).

9 O seu código comparado ao método da literatura

O código segue a ideia de Hannan e Rissanen, mas com algumas escolhas próprias. Comparando com a descrição de Gómez e Maravall (1998, p. 28–29):

Ponto	Gómez e Maravall (1998)	O seu código (`Arima.mqh`)
Estágio 1 só com MA	sim	sim (com $q = 0$, MQO direto)
Como estima o AR longo	autocorrelações e recursão de Durbin-Levinson	MQO com constante
Ordem do AR longo	$\max(\lfloor \log^2(N) \rfloor,\ 2\max(p,q))$	$\max(\lfloor \ln^2 N \rfloor,\ p+q+1)$, no máximo $N/5$
Terceiro passo (correção do viés)	sim, quando há MA	**não**
Critério para escolher (p,q)	BIC	AIC sobre amostra comum
Invertibilidade ($\lvert\theta\rvert < 1$)	–	não é verificada

O que isso significa na prática:

- **Sem o terceiro passo**, o robô usa os coeficientes do estágio 2 como estão. É de onde vem o pequeno viés do θ nas simulações. A máxima verossimilhança faria o papel desse refinamento, e foi testada como opção em 15/10/2026 e não adotada.
- **MQO no lugar de Durbin-Levinson** dá coeficientes parecidos, mas não iguais, para o AR longo. Os dois são formas aceitas de estimar um AR.
- **A invertibilidade não é imposta.** Nos dias do traço os θ ficaram pequenos (Figura 4), longe de 1, então isso não pesou ali.

9.1 Um ponto para pensar: a ordem do AR longo numa amostra pequena

A regra $\ln^2 N$ vem de resultados para amostras grandes. Com $N = 239$ ela dá 29 defasagens, estimadas com 210 linhas. Na série simulada, refazendo tudo com cada ordem de 1 a 47, a qualidade dos erros estimados caiu à medida que a ordem cresceu (Figura 6). Com poucas defasagens o AR longo já capta um ARMA(1,1). Cada defasagem a mais acrescenta um coeficiente estimado com ruído.

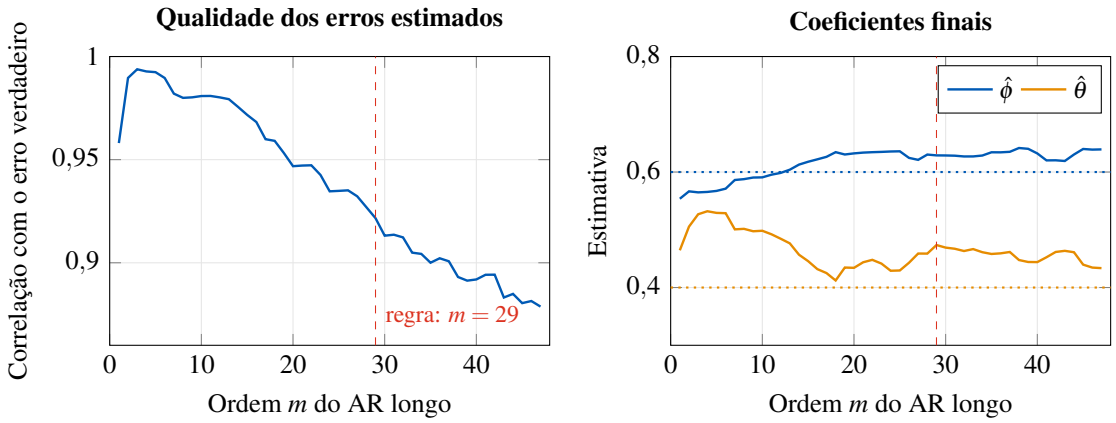


Figura 6: Uma única série simulada (ARMA(1,1), $\phi = 0{,}6$, $\theta = 0{,}4$), refeita com cada ordem do AR longo. As linhas pontilhadas são os valores verdadeiros. A correlação foi medida sobre os mesmos dias em todas as ordens.

Até onde isso vale

É uma série só, com coeficientes bem maiores que os da PETR4. Não se testou se uma ordem menor mudaria alguma decisão do robô. Fica registrado como ponto em aberto (`ia/INCERTEZAS.md`, item 84), não como defeito.

10 Perguntas que a banca pode fazer

Se a banca perguntar

Por que Hannan-Rissanen e não máxima verossimilhança?
Porque o modelo é reestimado todo pregão e, na escolha das ordens, 25 vezes de uma vez. O Hannan-Rissanen são duas regressões lineares: não precisa de ponto de partida, de taxa de aprendizado nem de número de iterações, não depende da escala dos preços e não tem problema de convergência. A literatura o usa justamente na identificação automática de modelos (Gómez e Maravall, 1998, p. 10). O custo é uma estimativa um pouco menos precisa: nas simulações, o desvio do θ foi 0,089, contra 0,074 da máxima verossimilhança.

O que é o estágio 1, em uma frase?
Um modelo autorregressivo longo, ajustado por mínimos quadrados, cujos resíduos servem de estimativa dos erros que o termo de médias móveis precisa e que não podem ser observados.

Por que um AR longo consegue estimar os erros de um modelo com MA?
Porque todo ARMA invertível pode ser escrito como um AR de ordem infinita, com pesos que diminuem. Um AR longo, mas finito, aproxima bem esse AR infinito.

O "MA" do ARIMA é a média móvel da análise técnica?
Não. O MA do ARIMA é uma combinação dos *erros* passados, não dos preços. A ponte com a média móvel de Almeida (2016) é pela parte AR, não pela parte MA.

Como vocês sabem que a implementação está certa?
Duas conferências. Em série simulada com coeficientes conhecidos, o método recupera os valores verdadeiros dentro do erro esperado. E a estimação de pregões reais, refeita fora do robô com os mesmos passos, dá os mesmos coeficientes e a mesma previsão que o robô registrou.

Glossário rápido

MQO	Mínimos quadrados ordinários: escolhe os coeficientes de uma regressão que tornam mínima a soma dos erros ao quadrado. Conta fechada, sem iteração.
AR(p)	Modelo autorregressivo: o valor de hoje depende dos p valores anteriores.
MA(q)	Médias móveis (de erros): o valor de hoje depende dos q erros anteriores.
Invertível	Um MA cujos erros podem ser reescritos como soma de valores passados ($\|\theta\| < 1$ num termo).
Resíduo	A diferença entre o valor observado e o que o modelo ajustado previa. É a estimativa do erro.
Viés	Tendência de uma estimativa a errar sempre para o mesmo lado.
Monte Carlo	Repetir um experimento muitas vezes com dados simulados, para ver como um método se comporta em média.

Procedência. Dados gerados por `ferramentas/HannanRissanenDetalhado.mq5` (rodado por `ferramentas/scripts/hannan_rissanen.sh`) em `dados/resultados/hannan_rissanen_2026-10-30/`, e o traço da refação de 05/10/2026 resumido em `dados/resultados/robo_em_acao_2026-10-30/`. Semente das simulações: 20261030. Obras citadas: Gómez e Maravall (1998), em `bibliografia/pdfs/Gomez-1998.pdf`; Hannan e Rissanen (1982) é citado através deles (o artigo original não foi lido). Material de estudo, não faz parte do TG.