A otimização prevê o teste?

as 312 configurações da PETR4, na otimização e no teste

Material de estudo para os autores do TG (não faz parte do texto)

2 de novembro de 2026 · parte 1 de 3

Em uma página

A pergunta. A configuração escolhida como a melhor na otimização continua entre as melhores no período de teste? Se continuar, a otimização serve para escolher. Se não, a escolha foi em boa parte sorte.
Como se responde. No período de teste, o robô só executou a configuração escolhida. Mas na refação de 05/10/2026 a grade inteira também foi rodada no teste, então dá para ver como teriam ido *todas* as 312 configurações e onde a escolhida ficou entre elas.
A resposta curta. Pelo Sharpe, a otimização não prevê o teste: nos três períodos, a escolhida ficou abaixo da mediana no teste. Pelo Calmar, prevê um pouco: a escolhida ficou acima da mediana em dois dos três.

1 O que o gráfico mostra

O MetaTrader tem uma aba chamada *Gráfico de otimização*, que desenha o resultado de cada passagem da grade. A Figura 1 usa a mesma ideia, com uma diferença: cada configuração aparece com *dois* resultados, um em cada eixo.

- **Cada ponto é uma configuração** da grade do TG (só compra, sem o intervalo de confiança): 312 no total, 304 com GARCH (cinza) e 8 sem GARCH (laranja).
- **Eixo horizontal:** o resultado nos três anos de otimização, que foi o que se usou para escolher.
- **Eixo vertical:** o resultado no período de teste, que a escolha não viu.
- **Estrela vermelha:** a configuração escolhida (o ARIMA-GARCH Sharpe na coluna da esquerda, o ARIMA-GARCH Calmar na da direita). Por definição, ela é o ponto mais à direita entre os cinza.
- **Linha azul tracejada:** a mediana do teste. Metade das configurações ficou acima dela e metade abaixo. É o que se esperaria, em média, escolhendo uma configuração ao acaso.

Como ler. Se a otimização previsse o teste, a nuvem subiria da esquerda para a direita, como uma diagonal, e a estrela ficaria lá no alto. Se a nuvem não tem inclinação, ir bem na otimização não diz nada sobre o teste.

2 O que deu

A Tabela 1 resume os seis painéis. A *posição* é o lugar da escolhida quando as 312 configurações são ordenadas pelo resultado no teste: 1ª é a melhor, 312ª é a pior.

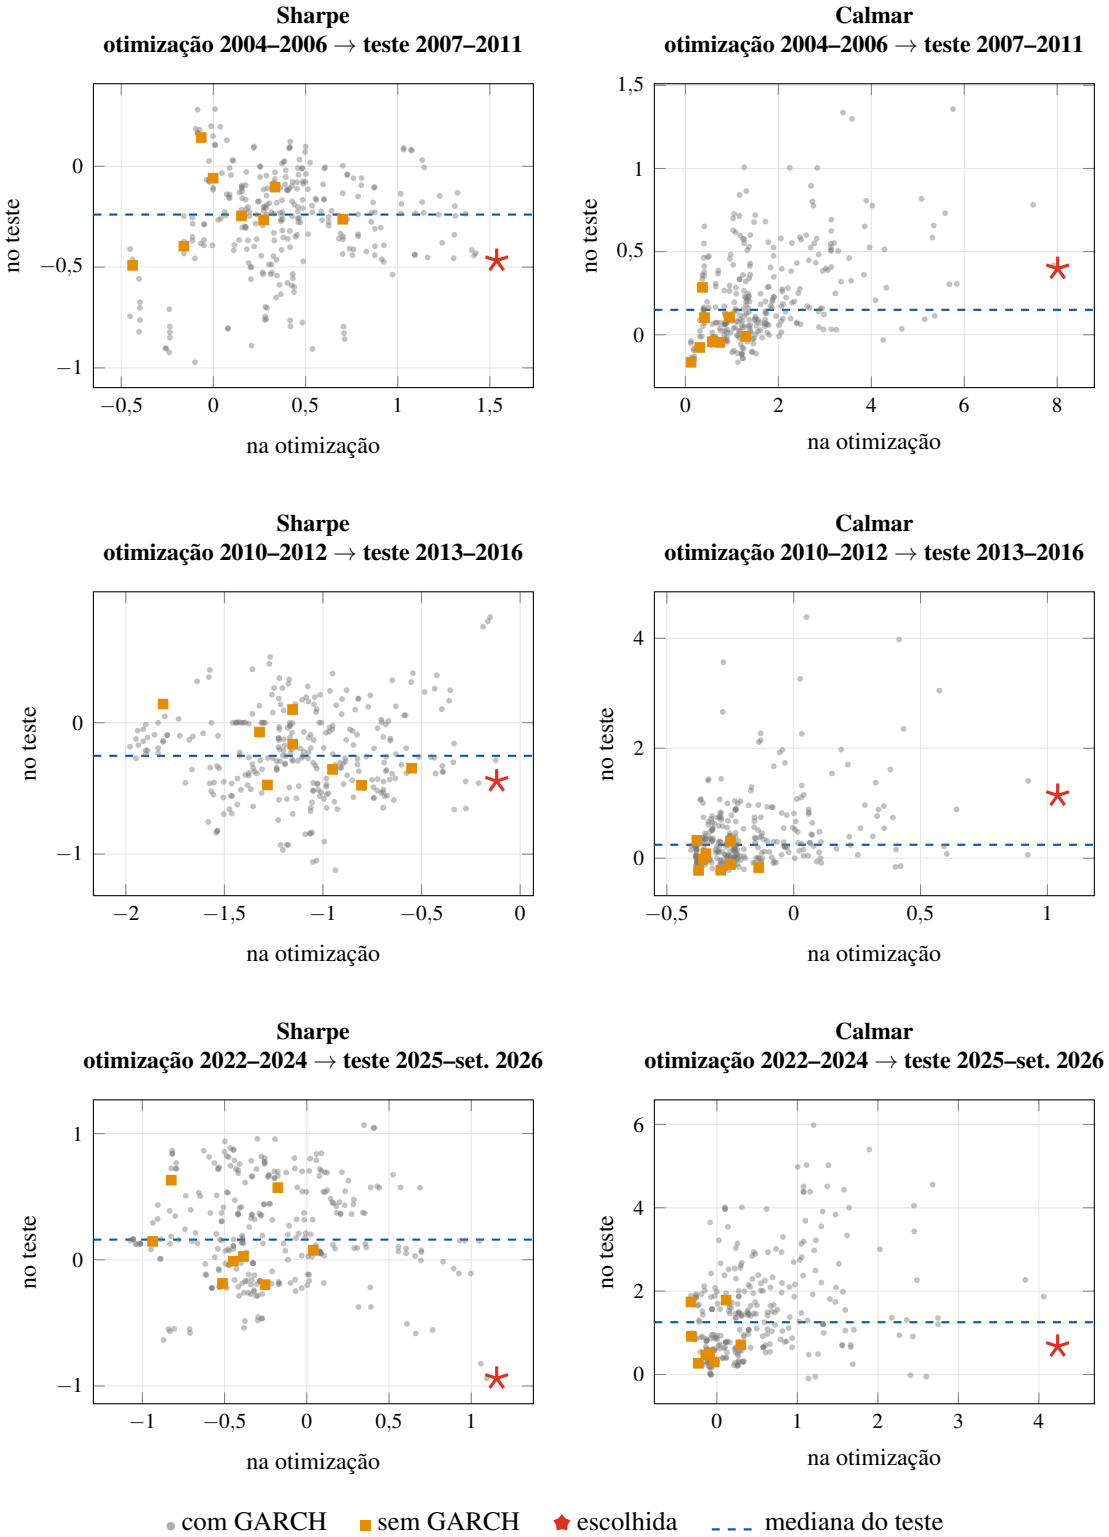


Figura 1: Cada configuração na otimização (horizontal) e no teste (vertical), PETR4. Sharpe e Calmar calculados com custos e caixa parado na Selic, como na escolha.

Tabela 1: Onde a escolhida ficou no teste, entre 312 configurações

	Escolha pelo Sharpe			Escolha pelo Calmar		
Teste	posição	acima da mediana?	ρ	posição	acima da mediana?	ρ
2007–2011	258ª	não	0,04	76ª	sim	0,43
2013–2016	230ª	não	−0,03	29ª	sim	0,29
2025–set. 2026	311ª	não	0,00	226ª	não	0,38

ρ: correlação de Spearman entre a ordem na otimização e a ordem no teste, nas 312 configurações.

O que é o ρ (correlação de Spearman). Ordenam-se as configurações duas vezes, pela otimização e pelo teste, e mede-se o quanto as duas listas concordam. Vale 1 se a ordem é a mesma, 0 se não há relação nenhuma e -1 se uma é o inverso da outra. Ele resume numa conta a inclinação da nuvem.

Pelo Sharpe, ρ fica entre $-0{,}03$ e 0,04: nenhuma relação. A escolhida ficou abaixo da mediana nos três testes. No mais recente, ficou em 311ª de 312, quase a última. Isso não quer dizer que o Sharpe seja um critério ruim em si. Quer dizer que, nesta grade e neste ativo, o Sharpe de três anos não carrega informação sobre o Sharpe dos anos seguintes.

Pelo Calmar, ρ fica entre 0,29 e 0,43: uma relação fraca, mas no sentido certo. A escolhida ficou acima da mediana em 2007–2011 e em 2013–2016 (29ª de 312), e abaixo em 2025–2026. O Calmar mede ganho por unidade de queda máxima, e a queda depende muito de *como* o robô reduz a posição, que é uma característica da configuração e não do acaso do período. Essa é uma explicação provável para ele se manter mais, não algo que o gráfico prove.

Os pontos laranja (sem GARCH) não concorrem à escolha do ARIMA-GARCH, que é feita só entre os cinza. Estão no gráfico para comparação. Com só 8 pontos, não dá para dizer mais nada sobre eles aqui.

Se a banca perguntar

"O resultado de vocês não é só a sorte de ter escolhido a melhor configuração?"
É exatamente por isso que o teste foi feito num período que a escolha não viu. E este gráfico mostra que a preocupação tem fundamento: escolhida pelo Sharpe, a melhor da otimização ficou abaixo da mediana nos três testes. Por isso o Cap. III mede o desempenho em períodos posteriores à escolha, com a configuração congelada. A única exceção é 2005–2026, e o texto já avisa que esse teste inclui os anos da escolha.
"Então por que usar o Sharpe?" Porque é a medida padrão de ganho por risco, e o critério foi definido antes de ver os resultados. O gráfico mostra que o Calmar, que olha para a queda máxima, se mantém mais entre períodos. Isso combina com o foco do trabalho em risco: a parte que a otimização consegue prever é a proteção, não o retorno.

O que este gráfico não diz

- São **três pares de períodos de um ativo só**. O padrão aparece nos três, mas três é pouco.
- Sharpe e Calmar aqui são os da **escolha** (com custos e caixa na Selic). O Cap. III mostra o resultado bruto, então os valores do eixo não são os números das tabelas do TG.
- O período 2014–2016 → 2017–2024 (o teste principal) **não está aqui**, porque a grade não foi rodada inteira em 2017–2024. Só os robôs escolhidos e as referências foram.
- Em 2007–2011 a escolha pelo Sharpe e pelo Calmar deu **a mesma configuração**, por isso as duas estrelas de cima representam o mesmo robô.
- O TG hoje não fala de persistência entre otimização e teste. Se o autor quiser levar isto ao texto, é decisão dele, e as frases saem daqui só depois de ele dominar o gráfico.

De onde vêm os números

Script `ferramentas/scripts/otimizacao_teste.sh`, que lê `dados/resultados/refeito_2026-10-05/pareados/PETR4_C`n`_T`n`.csv` e grava em `dados/resultados/otimizacao_teste_2026-11-02/`. Conferências: (1) a escolha refeita pelo script coincide com a oficial (`escolhas/r3_C`n`.txt`) nos três períodos; (2) o Sharpe e o Calmar da escolhida no teste coincidem com os do teste individual dela (`testes/metricas_R3_T`n`_G*.csv`); (3) com as 32 configurações do intervalo de confiança de volta (344), o ρ reproduz o bloco 5 de `analise_grades.txt` (0,10; $-0{,}05$; $-0{,}02$ e 0,46; 0,28; 0,37).