CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA
FACULDADE DE TECNOLOGIA DE INDAIATUBA
DR. ARCHIMEDES LAMOGLIA
CURSO DE TECNOLOGIA
EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Previsão e análise de tendências no mercado de ativos: desenvolvimento de ferramenta algorítmica com modelos estatísticos no MetaTrader 5

Indaiatuba
2026

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Previsão e análise de tendências no mercado de ativos: desenvolvimento de ferramenta algorítmica com modelos estatísticos no MetaTrader 5

Trabalho de graduação apresentado por Bruno Rocha Pereira e Giovanni Silva Loose como pré-requisito para a conclusão do Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Faculdade de Tecnologia de Indaiatuba, elaborado sob a orientação da Profa. Simone Mendes da Silva.

Indaiatuba

2026

RESUMO

Este trabalho retoma um estudo desenvolvido na Faculdade de Tecnologia de Indaiatuba em 2016, no qual um robô de negociação para a plataforma MetaTrader 5, guiado pelo cruzamento de médias móveis, obteve bons resultados em períodos de mercado estável, mas acumulou prejuízo no período que inclui a crise financeira de 2008. Ao final daquele estudo, o autor sugeriu que modelos capazes de medir a volatilidade poderiam ajudar a contornar essa limitação. Partindo dessa sugestão, desenvolveu-se um novo robô que reúne dois modelos estatísticos com papéis distintos. O primeiro, chamado ARIMA, procura antecipar a direção dos preços. O segundo, chamado GARCH, estima o quanto o mercado deve oscilar e decide se vale a pena operar. Os dois modelos foram programados na própria linguagem da plataforma, conferidos em dados com resposta conhecida e testados sobre o histórico oficial da bolsa brasileira, em períodos de crise e de calma, sempre em comparação com a estratégia original e com uma versão do robô sem o controle de volatilidade. Os resultados mostram que esse controle tornou o robô mais seguro. As perdas nos piores momentos foram menores em todos os períodos analisados, e em boa parte deles o ganho final também foi maior. A capacidade de acertar a direção do mercado, porém, continuou próxima do acaso, e, diante das médias móveis e da taxa Selic, os ganhos variaram conforme o período, dentro da margem que o próprio acaso também explicaria. Conclui-se que o modelo de volatilidade funciona como um instrumento de proteção, especialmente útil nos períodos de crise, e não como uma forma de prever melhor o mercado.

Palavras-chave: ARIMA-GARCH; negociação algorítmica; MetaTrader 5.

ABSTRACT

This work revisits a study carried out at the Faculdade de Tecnologia de Indaiatuba in 2016, in which a trading robot for the MetaTrader 5 platform, guided by moving average crossovers, performed well in stable market periods but accumulated losses over the period that includes the 2008 financial crisis. At the end of that study, the author suggested that models able to measure volatility could help overcome this limitation. Building on that suggestion, a new robot was developed that brings together two statistical models with distinct roles. The first, called ARIMA, tries to anticipate the direction of prices. The second, called GARCH, estimates how much the market is likely to fluctuate and decides whether it is worth trading. Both models were programmed in the platform's own language, checked on data with known answers and tested on the official history of the Brazilian stock exchange, in periods of crisis and of calm, always in comparison with the original strategy and with a version of the robot without the volatility control. The results show that this control made the robot safer. Losses in the worst moments were smaller in every period analysed, and in many of them the final gain was also larger. The ability to predict market direction, however, remained close to chance, and, against the moving averages and the Selic rate, gains varied from period to period, within the margin that chance alone would also explain. The conclusion is that the volatility model works as a protective instrument, especially useful in times of crisis, and not as a way of predicting the market better.

Keywords: ARIMA-GARCH; algorithmic trading; MetaTrader 5.

LISTA DE ILUSTRAÇÕES

Figura 1 – Cruzamento de médias móveis 12
Figura 2 – Interface do MetaTrader 5 12
Figura 3 – Ciclo de funcionamento de um *Expert Advisor* 13
Figura 4 – Etapas de aplicação do modelo ARIMA 15
Figura 5 – Retroalimentação da variância no modelo GARCH 16
Quadro 1 – Características dos estudos relacionados 19
Gráfico 1 – Evolução do patrimônio e da queda acumulada, 2007 a 2011 31
Gráfico 2 – Retorno por ano, 2007 a 2011 32

LISTA DE TABELAS

Tabela 1 – Recuperação de parâmetros em séries sintéticas 24
Tabela 2 – Reprodução dos testes de Almeida (2016) 27
Tabela 3 – Comparação nas condições originais, 2013 a 2016 28
Tabela 4 – Desempenho no período de teste, 2017 a 2024 29
Tabela 5 – Desempenho por janela de teste 30
Tabela 6 – Efeito do GARCH sobre o risco nos quatro ativos 31
Tabela 7 – Desempenho das configurações fixas 32
Tabela 8 – Comparação entre cada configuração com GARCH e sua gêmea 33
Tabela 9 – Comparação entre o ARIMA isolado e o ARIMA-GARCH 34

LISTA DE SIGLAS

ADF	*Augmented Dickey-Fuller*
AIC	*Akaike Information Criterion*
AR	Autorregressivo
ARCH	*Autoregressive Conditional Heteroskedasticity*
ARIMA	*Autoregressive Integrated Moving Average*
ARMA	*Autoregressive Moving Average*
B3	Brasil, Bolsa, Balcão
COTAHIST	Arquivo de Cotações Históricas da B3
EA	*Expert Advisor*
EGARCH	*Exponential* GARCH
FATEC	Faculdade de Tecnologia
GARCH	*Generalized Autoregressive Conditional Heteroskedasticity*
LSTM	*Long Short-Term Memory*
MQL5	*MetaQuotes Language* 5
PETR4	Código de negociação das ações preferenciais da Petrobras
SARIMA	*Seasonal Autoregressive Integrated Moving Average*
Selic	Sistema Especial de Liquidação e de Custódia
TGARCH	*Threshold* GARCH

SUMÁRIO

INTRODUÇÃO 8
CAPÍTULO I 10
1 Fundamentação teórica 10
1.1 Mercado de ações 10
1.2 Análise técnica 10
1.2.1 Médias móveis 11
1.3 MetaTrader 5 11
1.4 Modelos estatísticos de séries temporais 13
1.4.1 ARIMA 14
1.4.2 GARCH 15
1.4.3 Integração entre ARIMA e GARCH 16
1.5 Medidas de desempenho e risco 17
1.6 Trabalhos relacionados 18
CAPÍTULO II 20
2 Percurso metodológico 20
2.1 Caracterização da pesquisa 20
2.1.1 Quanto aos objetivos 20
2.1.2 Quanto ao delineamento 20
2.2 Caracterização do lugar e da amostra de pesquisa 20
2.3 Procedimentos para coleta e análise de dados 21
2.3.1 Técnicas para coleta de dados 21
2.3.2 Natureza da análise de dados 22
2.4 Implementação e validação dos modelos 22
2.5 Plano experimental 25
2.6 Obstáculos encontrados 26
CAPÍTULO III 27
3 Análise e discussão dos dados 27
3.1 Reprodução e comparação com o estudo de referência 27
3.2 Resultado principal: teste fora da amostra 29
3.3 Robustez entre períodos e entre ativos 29
3.4 Horizonte longo 32
3.5 Significância das diferenças 33
3.6 O mecanismo do efeito 34
3.7 Limitações dos resultados 35
CONSIDERAÇÕES FINAIS 36
REFERÊNCIAS 38
APÊNDICE A – Código do *Expert Advisor* 41

INTRODUÇÃO

Este trabalho dá continuidade ao estudo de Almeida (2016), desenvolvido nesta mesma instituição. O autor programou em MQL5, para a plataforma MetaTrader 5, um robô de negociação para a PETR4, chamado na plataforma de *Expert Advisor*, isto é, um programa que compra e vende o ativo automaticamente segundo regras definidas previamente. A regra escolhida foi o cruzamento de duas médias móveis do preço: quando a média de curto prazo cruza a de longo prazo, o robô interpreta o movimento como início de uma tendência e abre a posição. Avaliado sobre dados históricos, o robô obteve lucro entre 2013 e 2016, mas prejuízo entre 2007 e 2011, período que inclui a crise financeira de 2008. Ao discutir esse resultado, o próprio autor alertou para as limitações da técnica em mercados de alta volatilidade e indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa.

A dificuldade apontada por ele continua atual, porque as crises voltam a acontecer, e é nelas que as maiores perdas se concentram. Em março de 2020, no início da pandemia de covid-19, o Ibovespa, principal índice de ações da bolsa brasileira, caiu 29,9% em um único mês (Máximo, 2020). A própria PETR4 perdeu 48,6% do seu valor entre o fim de 2019 e o início de abril de 2020, segundo as cotações oficiais da bolsa (B3, 2026). Uma estratégia baseada apenas no cruzamento de médias responde a uma única pergunta, a de para que lado o preço parece estar indo, e nada diz sobre o quanto ele pode oscilar no caminho. Por isso, ela entra no mercado com a mesma convicção em um dia calmo e em um dia de forte turbulência.

Os modelos estatísticos de séries temporais permitem separar essas duas perguntas. O modelo ARIMA estima a direção esperada do preço a partir do comportamento passado da própria série, de forma parecida com uma média móvel, mas com pesos ajustados aos dados. O modelo GARCH estima a volatilidade esperada para o período seguinte. Reunidos em um mesmo algoritmo, o primeiro indicaria o lado da operação e o segundo poderia atuar como um filtro de risco, evitando operar quando a oscilação esperada fosse alta. É essa a proposta que este trabalho investiga, retomando a sugestão de Almeida (2016) dez anos depois, sobre o mesmo ativo e na mesma plataforma.

Resta saber, porém, o que efetivamente se ganha ao acrescentar essa camada de modelagem. Acrescentar um modelo de volatilidade torna o algoritmo mais complexo, exige a estimação de parâmetros adicionais a cada operação e reduz o número de negócios realizados, e nada garante, de antemão, que o resultado compense esse custo. Coloca-se, assim, a questão norteadora deste trabalho: em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis?

Duas hipóteses foram formuladas antes dos experimentos. A primeira é a de que a integração entre a previsão de séries temporais pelo ARIMA e a modelagem de volatilidade condicional pelo GARCH gera sinais de negociação mais eficazes, tanto em acerto direcional quanto em adequação ao risco, do que o emprego isolado do ARIMA. A ideia de combinar

técnicas com funções distintas para obter resultados superiores encontra respaldo em trabalhos como o de Batista (2024), que integrou indicadores técnicos em um mesmo robô de negociação. A segunda é a de que essa combinação representa um avanço em relação às análises baseadas em médias móveis. Ambas são confrontadas com os resultados nas considerações finais.

O objetivo geral foi desenvolver, em MQL5, um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar o efeito do GARCH sobre o desempenho e o risco das operações, em comparação com o ARIMA isolado e com a estratégia de Almeida (2016). Os objetivos específicos foram implementar e validar os modelos ARIMA e GARCH na própria linguagem da plataforma, automatizar a escolha das ordens do ARIMA, reproduzir a estratégia de médias móveis de Almeida (2016) e comparar os três algoritmos quanto a retorno e risco em diferentes períodos do mercado, incluindo períodos de crise.

A pesquisa se justifica, em primeiro lugar, por retomar uma recomendação deixada em aberto em um estudo da própria instituição. Justifica-se, também, por ter sido conduzida no mercado brasileiro, com o histórico oficial da B3 e atravessando as crises que atingiram a bolsa do país. Há, ainda, uma contribuição técnica. Como a biblioteca padrão da linguagem MQL5 não traz modelos de séries temporais, os estimadores foram construídos e validados para este trabalho, e o controle de risco feito pelo GARCH, separado da previsão de direção, pode ser reaproveitado em outras estratégias para torná-las mais protetivas.

Quanto à natureza, a pesquisa é empírica, por investigar fenômenos observáveis por meio da experiência e da observação (Wazlawick, 2014), e aplicada, por voltar esse conhecimento a um problema concreto de decisão. Quanto aos objetivos, é explicativa, quanto ao delineamento, é quase experimental, e a análise dos dados é quantitativa. Os algoritmos foram testados por simulação no MetaTrader 5, sobre o histórico oficial de preços da B3, conforme detalhado no Capítulo II.

O trabalho está organizado em três capítulos, seguidos das considerações finais. O Capítulo I apresenta a fundamentação teórica, que parte do mercado de ações e da plataforma MetaTrader 5, passa pela análise técnica e pelas médias móveis, chega aos modelos ARIMA e GARCH e às medidas de desempenho e risco, e encerra-se com os trabalhos relacionados. O Capítulo II descreve o percurso metodológico, isto é, a caracterização da pesquisa, a amostra, a coleta dos dados, a implementação e a validação dos modelos, o plano experimental e os obstáculos encontrados. O Capítulo III apresenta a análise e a discussão dos dados. As considerações finais respondem à questão norteadora, retomam as hipóteses e avaliam o cumprimento dos objetivos.

CAPÍTULO I

1 Fundamentação teórica

Este capítulo reúne os conceitos sobre os quais o trabalho se apoia. Parte do ambiente em que as operações acontecem, isto é, a bolsa de valores e a plataforma de negociação, passa pela análise técnica e pelas médias móveis empregadas por Almeida (2016) e chega aos modelos estatísticos ARIMA e GARCH e às medidas usadas para avaliar uma estratégia. Ao final, são apresentados os trabalhos relacionados.

1.1 Mercado de ações

De acordo com o Banco Central do Brasil (2025a), as bolsas de valores são sociedades anônimas ou associações civis que mantêm local ou sistema adequado à realização de operações de compra e venda de títulos e valores mobiliários, em mercado livre e aberto, organizado e fiscalizado por seus membros e pela Comissão de Valores Mobiliários. No Brasil, esse papel é exercido pela B3.

Para a empresa, a abertura de capital é uma forma de obter recursos de terceiros. Em troca do capital recebido, ela cede aos acionistas uma participação no negócio proporcional ao valor investido. Para o investidor, a ação passa a ser um ativo cujo preço varia a cada pregão conforme a oferta e a procura, e é essa variação que as estratégias de negociação procuram aproveitar.

O investidor não negocia diretamente na bolsa. O acesso se dá por meio de corretoras, instituições que intermediam as operações e oferecem serviços como plataformas de negociação pela internet, custódia dos títulos e financiamento para a compra de ações, cobrando por isso comissões e taxas (Banco Central do Brasil, 2025b). É pela corretora que uma plataforma como o MetaTrader 5 se conecta ao mercado.

Toda decisão de investimento envolve um compromisso entre risco e retorno, uma vez que os recursos são limitados e precisam ser distribuídos entre alternativas (Elder, 2002). No Brasil, a principal referência para essa comparação é a taxa Selic, a taxa básica de juros da economia, que serve de base para as demais taxas praticadas no mercado e influencia tanto o custo do crédito quanto o retorno das aplicações financeiras (Banco Central do Brasil, 2025c). Por esse motivo, o capital que uma estratégia mantém fora do mercado costuma ser comparado ao que renderia se estivesse aplicado a essa taxa.

1.2 Análise técnica

A análise técnica busca antecipar o comportamento dos preços a partir do estudo do seu próprio histórico, procurando padrões e tendências que possam indicar o movimento seguinte. Sua origem remonta ao comércio de arroz, e hoje ela é aplicada a ações, moedas e outros ativos.

Para essa abordagem, o que importa é o comportamento do preço, sem considerar notícias ou outros fatores que possam influenciar o mercado (Fernandes, 2014).

Fernandes (2014) distingue duas vertentes. A empírica, ou clássica, é a mais antiga: o analista observa o gráfico e identifica tendências, suportes, resistências e padrões que, segundo essa abordagem, tendem a se repetir. Por depender da interpretação de quem observa, ela é sujeita a conclusões diferentes sobre o mesmo ativo. A estatística, ou moderna, substitui a interpretação visual por cálculos aplicados à série de preços, o que torna a análise reproduzível e permite que ela seja executada por um programa de computador.

É na segunda vertente que este trabalho se insere. Tanto a estratégia de médias móveis de Almeida (2016) quanto os modelos ARIMA e GARCH são regras matemáticas aplicadas ao histórico de preços, e por isso podem ser programados, testados sobre dados passados e comparados entre si sob as mesmas condições.

1.2.1 Médias móveis

A média móvel é um dos instrumentos mais utilizados da análise técnica. Ela calcula o preço médio de um ativo nos últimos n períodos e é recalculada a cada novo período, descartando o valor mais antigo e incorporando o mais recente. Com isso, suaviza as oscilações de curto prazo e evidencia a direção predominante dos preços (Fernandes, 2014). Na média móvel simples, todos os preços da janela recebem o mesmo peso, de modo que a média de dez períodos atribui peso de um décimo a cada um dos dez últimos fechamentos.

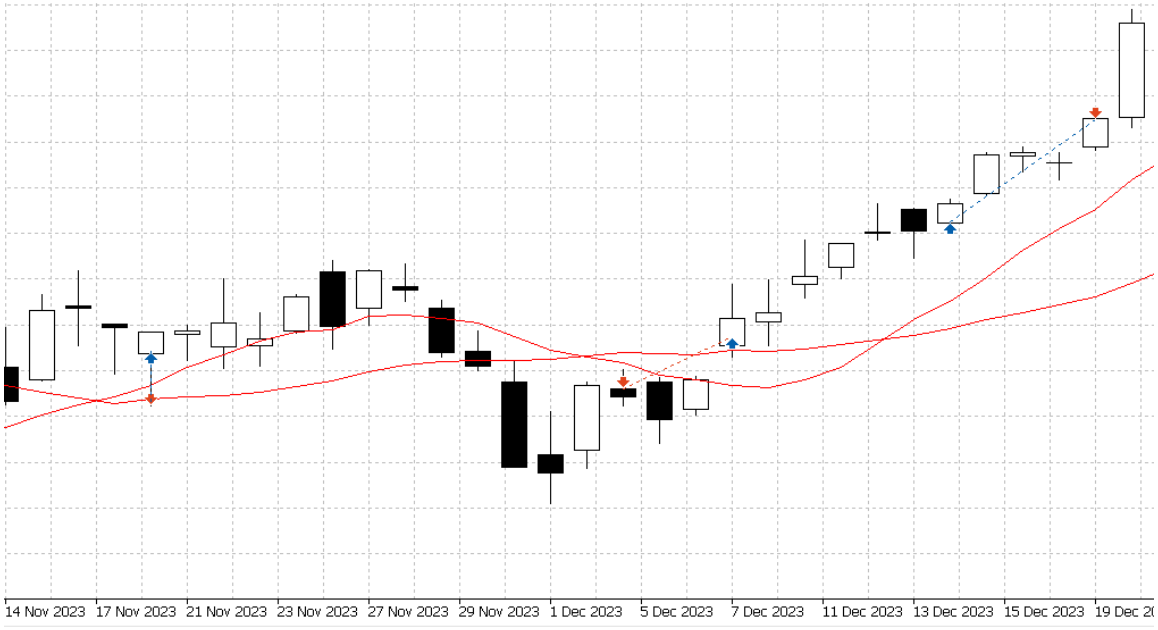
O tamanho da janela determina o comportamento da média. Janelas curtas reagem rapidamente a mudanças de preço, mas produzem mais sinais falsos, enquanto janelas longas filtram melhor o ruído, à custa de reconhecer uma nova tendência com atraso (Fernandes, 2014). A estratégia de cruzamento combina as duas: utiliza uma média rápida, de janela curta, e uma lenta, de janela longa, e interpreta o cruzamento entre elas como sinal de compra ou de venda, como ilustra a Figura 1.

Foi essa a estratégia adotada por Almeida (2016). O autor utilizou duas médias móveis simples, uma de dez e outra de vinte períodos, calculadas sobre o preço de fechamento, e operou nos dois sentidos, comprando quando a média rápida cruzava a lenta para cima e vendendo no cruzamento inverso. Seu algoritmo previa ainda parâmetros de limite de perda e de realização de lucro, embora os testes relatados tenham sido conduzidos com ambos nulos. O próprio autor alertou para as limitações de se usar apenas essa técnica em mercados de alta volatilidade (Almeida, 2016).

1.3 MetaTrader 5

O MetaTrader 5 é uma plataforma de negociação multimercado desenvolvida pela MetaQuotes, que reúne em um mesmo ambiente a execução de ordens, a análise gráfica e o desenvolvimento de sistemas automatizados para ações, futuros, moedas e outros instrumentos

Figura 1 – Cruzamento de médias móveis



Fonte: Elaboração própria com dados e interface do MetaTrader 5.

(MetaQuotes Ltd., 2024). Sua interface, mostrada na Figura 2, organiza em janelas as cotações em tempo real, os gráficos de preços e o navegador, que dá acesso às contas, aos indicadores e aos programas instalados.

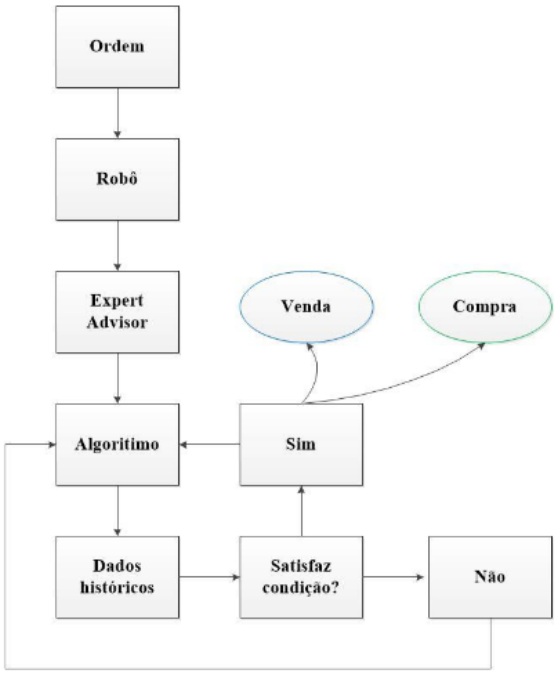
Figura 2 – Interface do MetaTrader 5



Fonte: MetaQuotes Ltd. (2024).

Os programas que negociam de forma automática na plataforma são chamados de *Expert Advisors* (EAs), também conhecidos como robôs de negociação. Um EA abre, modifica e encerra posições segundo regras programadas, sem intervenção manual (Almeida, 2016). A Figura 3 apresenta o ciclo de funcionamento de um EA.

Figura 3 – Ciclo de funcionamento de um *Expert Advisor*



Fonte: Almeida (2016).

Os EAs são escritos em MQL5, linguagem própria da plataforma, de sintaxe próxima à do C++. O ambiente de desenvolvimento, chamado MetaEditor, oferece editor, compilador e depurador integrados. Para avaliar uma estratégia antes de usá-la, a plataforma dispõe do testador de estratégias, o *Strategy Tester*, que executa o EA sobre dados históricos, simulando as ordens como se o mercado estivesse aberto, e produz relatórios de desempenho (MetaQuotes Ltd., 2024). Esse procedimento é conhecido como *backtesting*, e foi por meio dele que todos os experimentos deste trabalho foram conduzidos.

1.4 Modelos estatísticos de séries temporais

Uma série temporal é uma sequência de observações ordenadas no tempo, como os preços de fechamento diários de uma ação. Os modelos de séries temporais procuram descrever a estrutura dessa sequência, isto é, de que forma cada observação se relaciona com as anteriores, e utilizam essa descrição para projetar valores futuros. Neste trabalho são empregados dois desses modelos, com funções diferentes. O ARIMA descreve o valor esperado da série, e o GARCH descreve o tamanho esperado dos erros em torno desse valor.

1.4.1 ARIMA

O modelo autorregressivo integrado de médias móveis, conhecido pela sigla ARIMA, do inglês *Autoregressive Integrated Moving Average*, é um dos modelos mais empregados na previsão de séries temporais, inclusive em séries financeiras (Xing *et al.*, 2024). Ele é composto por três partes, cada uma associada a uma ordem.

A parte autorregressiva, de ordem p, expressa o valor atual da série como combinação dos seus p valores anteriores. A parte de médias móveis, de ordem q, acrescenta a influência dos q erros de previsão anteriores, isto é, das diferenças entre o que o modelo previu e o que de fato ocorreu. A parte integrada, de ordem d, indica quantas vezes a série precisa ser diferenciada, ou seja, substituída pela variação entre uma observação e a anterior, para se tornar estacionária (Xing *et al.*, 2024). Uma série é estacionária quando sua média e sua variância não se alteram ao longo do tempo, condição exigida pelas partes autorregressiva e de médias móveis.

Convém registrar que a média móvel do ARIMA não é a mesma média móvel da análise técnica. Na análise técnica, a média é calculada sobre os preços. No ARIMA, o termo de médias móveis é uma combinação dos erros de previsão passados. Os dois conceitos têm o mesmo nome, mas descrevem coisas diferentes.

Representando por y_t a série já diferenciada d vezes, o modelo pode ser escrito como

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \tag{1.1}$$

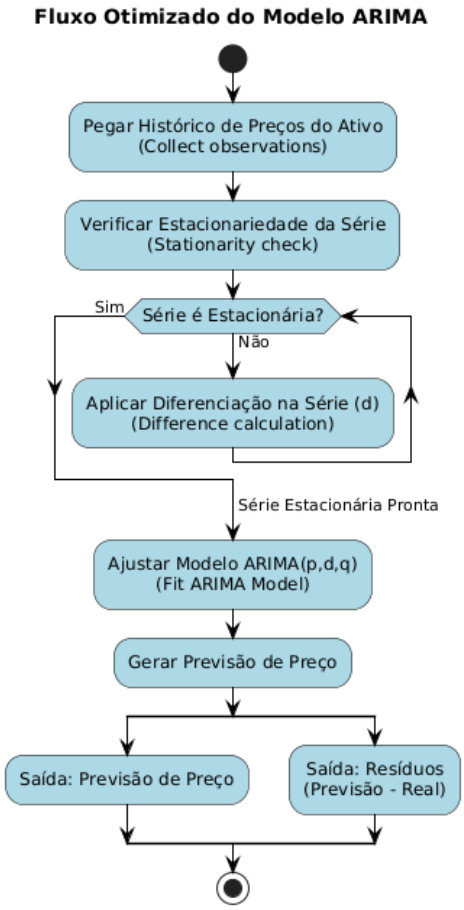
em que c é uma constante, os coeficientes ϕ ponderam os valores passados da série, os coeficientes θ ponderam os erros passados e ε_t é o erro do período atual, que o modelo não consegue prever.

Há uma relação direta entre essa equação e a estratégia de Almeida (2016). A média móvel simples de dez períodos é um filtro linear que atribui pesos fixos, iguais a um décimo, aos últimos preços. A parte autorregressiva do ARIMA também é um filtro linear sobre os valores passados, mas seus pesos ϕ são estimados a partir dos dados, em vez de fixados por convenção. Nesse sentido, o ARIMA pode ser visto como uma generalização da média móvel: mantém a mesma família de operação e ajusta os coeficientes ao ativo e ao período analisados.

As etapas de aplicação do modelo estão representadas na Figura 4. A primeira é verificar se a série é estacionária e, caso não seja, diferenciá-la até que se torne. Essa verificação é feita, em geral, pelo teste de Dickey-Fuller aumentado (ADF), que tem como hipótese nula a existência de uma raiz unitária, isto é, a não estacionariedade da série. No estudo de Xing *et al.* (2024) sobre as ações da NVIDIA, o teste aplicado aos preços resultou em valor-p de 0,998773, o que impediu a rejeição da hipótese nula. Após uma diferenciação, o valor-p ficou próximo de zero, e a ordem de integração foi definida como $d = 1$.

Definido d, resta escolher p e q. Como várias combinações são possíveis, Xing *et al.* (2024) testaram valores de zero a quatro para cada ordem e selecionaram a combinação de menor critério de informação de Akaike (AIC). O AIC mede o equilíbrio entre a qualidade do ajuste e a quantidade de parâmetros do modelo, penalizando especificações com parâmetros em excesso,

Figura 4 – Etapas de aplicação do modelo ARIMA



Fonte: Elaboração própria.

que tenderiam a reproduzir o ruído dos dados passados sem melhorar a previsão. Com o modelo ajustado, obtêm-se a previsão para o período seguinte e os resíduos, que são os erros de previsão observados na amostra.

A principal limitação do ARIMA é tratar apenas relações lineares e supor que a variância dos erros é constante (Xing *et al.*, 2024; Araya; Araya, 2024). Em séries financeiras essa segunda suposição raramente se verifica, e é dela que trata o modelo GARCH.

1.4.2 GARCH

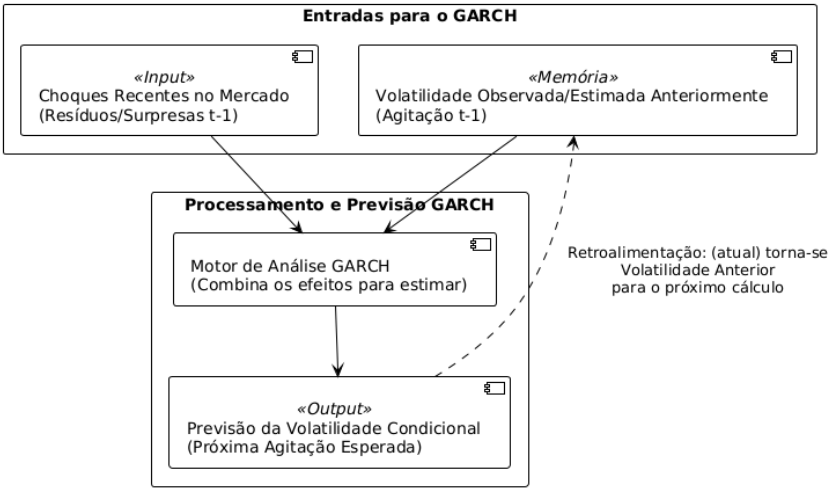
Nas séries de retornos de ações, períodos de grande oscilação tendem a ser seguidos por outros de grande oscilação, e períodos calmos por outros calmos. A volatilidade, que mede o grau de variação dos preços ao longo do tempo, não é constante, e conhecê-la é fundamental para a gestão de risco (Araya; Araya, 2024). Engle (1982) propôs o modelo ARCH, em que a variância do erro de cada período depende dos erros dos períodos anteriores. Bollerslev (1986) generalizou essa proposta no modelo GARCH, do inglês *Generalized Autoregressive Conditional Heteroskedasticity*, em que a variância passa a depender também das próprias variâncias anteriores.

Na especificação GARCH(1,1), adotada neste trabalho, a variância condicional σ_t^2 do erro no período t é dada por

$$\sigma_t^2 = \omega + \alpha\,\varepsilon_{t-1}^2 + \beta\,\sigma_{t-1}^2, \tag{1.2}$$

em que ε_{t-1} é o erro do período anterior, σ_{t-1}^2 é a variância estimada para o período anterior e ω, α e β são os parâmetros do modelo. O termo com α representa a reação da volatilidade a um choque recente, e o termo com β representa a persistência da volatilidade passada (Bollerslev, 1986). A Figura 5 ilustra esse processo de retroalimentação.

Figura 5 – Retroalimentação da variância no modelo GARCH



Fonte: Elaboração própria.

Para que o modelo faça sentido, os parâmetros precisam respeitar restrições: ω deve ser positivo, α e β não podem ser negativos e a soma $\alpha+\beta$ deve ser menor que um. A última condição garante que a variância tenha um valor de longo prazo finito, igual a $\omega/(1-\alpha-\beta)$, para o qual a volatilidade retorna depois de um choque (Bollerslev, 1986).

O GARCH padrão trata de forma simétrica os choques positivos e os negativos de mesma magnitude. Nos mercados de ações, porém, as quedas costumam elevar a volatilidade mais do que as altas. Para representar essa assimetria foram propostas variações do modelo, como o EGARCH e o TGARCH, que acrescentam à equação termos capazes de fazer a volatilidade reagir de forma diferente a choques positivos e negativos (Araya; Araya, 2024). Este trabalho emprega a especificação simétrica, e as variações assimétricas são retomadas nas considerações finais como possibilidade de continuação.

1.4.3 Integração entre ARIMA e GARCH

Os dois modelos se complementam. O ARIMA estima a média condicional da série, ou seja, o valor esperado para o período seguinte. O GARCH estima a variância condicional dos erros desse valor esperado. Na forma combinada, os resíduos gerados pelo ARIMA servem de entrada para o GARCH, que modela a variância desses resíduos ao longo do tempo (Araya; Araya, 2024).

Em uma estratégia de negociação, essa combinação permite separar duas perguntas. A direção da operação é dada pelo sinal da previsão do ARIMA, e o risco associado a ela é dado pela volatilidade prevista pelo GARCH. Como o GARCH não fornece nenhuma informação sobre a direção dos preços, ele não pode, sozinho, gerar uma ordem de compra ou de venda. O que ele pode fazer é condicionar a operação indicada pelo ARIMA ao nível de risco esperado.

Há três formas de fazer esse condicionamento. Na primeira, chamada de filtro de volatilidade, a operação só é realizada quando a volatilidade prevista está abaixo de um limiar. Na segunda, conhecida como *volatility targeting*, o tamanho da posição é ajustado de forma inversamente proporcional à volatilidade prevista, de modo que a posição diminui quando a incerteza aumenta. Na terceira, a volatilidade prevista é usada para construir um intervalo de confiança em torno da previsão do ARIMA, e a operação só é realizada quando a previsão se afasta de zero o suficiente para sair desse intervalo. As três formas foram implementadas neste trabalho, além de uma quarta que combina o filtro com o ajuste do tamanho da posição. Como se verá no Capítulo III, a diferença que mais pesou nos resultados foi entre as variantes que reduzem a posição diante de uma volatilidade alta e as que apenas impedem novas entradas.

1.5 Medidas de desempenho e risco

Avaliar uma estratégia de negociação apenas pelo lucro final esconde o caminho percorrido até ele. Duas estratégias com o mesmo retorno podem ter exposto o investidor a riscos muito diferentes. Por isso, o relatório do testador de estratégias do MetaTrader 5 apresenta, ao lado do lucro, medidas de risco e índices que relacionam as duas coisas (MetaQuotes Ltd., 2026).

O risco pode ser medido de duas formas complementares. A volatilidade é o desvio-padrão dos retornos e mede o quanto o patrimônio oscila no dia a dia. A queda máxima, que o relatório da plataforma chama de rebaixamento relativo, é a maior queda percentual entre um máximo local do patrimônio e o mínimo local seguinte (MetaQuotes Ltd., 2026). Ela responde a outra pergunta, a de qual foi o pior tombo que um investidor que seguisse a estratégia teria sofrido.

O índice de Sharpe relaciona o retorno de uma estratégia à sua volatilidade. Ele divide o retorno diferencial, isto é, a diferença entre o retorno da estratégia e o de uma referência, pelo desvio-padrão dessa diferença (Sharpe, 1994),

$$S = \frac{\bar{d}}{\sigma_d}, \tag{1.3}$$

em que $\bar{d}$ é a média do retorno diferencial e σ_d o seu desvio-padrão. O índice indica quanto se ganhou além da referência por unidade de oscilação, e quanto maior, melhor a relação. Um índice negativo indica que a estratégia rendeu menos que a referência. O testador do MetaTrader 5 usa como referência um rendimento livre de risco igual a zero (MetaQuotes Ltd., 2026). O próprio autor observa que o índice está ligado à estatística t da média do retorno diferencial, que é igual a ele multiplicado pela raiz do número de observações (Sharpe, 1994). Por isso, um mesmo valor de índice é estatisticamente mais forte quando medido em um período mais longo.

O índice de Calmar relaciona o retorno à queda máxima. Ele divide o retorno anualizado pela queda máxima do período,

$$C = \frac{\text{retorno anualizado}}{\text{queda máxima}}, \tag{1.4}$$

e segue a mesma ideia do fator de recuperação do relatório da plataforma, que divide o lucro obtido pelo rebaixamento máximo (MetaQuotes Ltd., 2026), com a diferença de usar o retorno anualizado, o que permite comparar períodos de durações diferentes. O índice indica quanto se ganhou por unidade do pior tombo e, por isso, favorece estratégias que evitam perdas grandes. Os dois índices medem coisas diferentes. O Sharpe penaliza toda oscilação, para cima ou para baixo, e o Calmar considera apenas a pior queda.

1.6 Trabalhos relacionados

Os trabalhos relacionados foram selecionados entre pesquisas sobre o desenvolvimento de robôs de negociação na plataforma MetaTrader 5 e sobre a aplicação dos modelos ARIMA e GARCH à previsão de séries de preços de ações.

O estudo de Almeida (2016), desenvolvido na FATEC Indaiatuba, é o ponto de partida deste trabalho. O autor desenvolveu em MQL5 um robô de negociação para a PETR4 baseado no cruzamento de médias móveis simples de dez e vinte períodos e o avaliou por *backtesting* em períodos de crise, entre 2007 e 2011, e fora de crise, entre 2013 e 2016. A estratégia apresentou lucro no período fora de crise e prejuízo no período de crise. Ao discutir os limites do trabalho, o autor indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa. É essa indicação que o presente trabalho retoma, mantendo o ativo, a plataforma e a linguagem.

Batista (2024) também desenvolveu um *Expert Advisor* em MQL5 para a B3, combinando três indicadores técnicos, a média móvel exponencial, a convergência e divergência de médias móveis e o índice de força relativa. Os testes, realizados sobre o ativo BBAS3F em 2023, compararam os indicadores isoladamente, em pares e em conjunto, e a combinação dos três apresentou o melhor resultado. O estudo mostra que a integração de técnicas com funções distintas em um mesmo algoritmo pode melhorar a decisão, ideia que este trabalho aplica aos modelos estatísticos.

Xing *et al.* (2024) compararam o ARIMA, o ARIMA-GARCH e dois modelos de redes neurais na previsão do preço de fechamento das ações da NVIDIA, com dados diários de abril de 2019 a abril de 2024. As ordens dos modelos ARIMA foram definidas pelo teste ADF e pelo menor AIC, com p e q variando de zero a quatro, procedimento semelhante ao adotado neste trabalho. O ARIMA-GARCH apresentou a menor raiz do erro quadrático médio, e o ARIMA com janela expansiva teve o melhor desempenho geral, superando as redes neurais. Os autores atribuem esse resultado, possivelmente, ao comportamento predominantemente linear da série.

Araya e Araya (2024) estudaram a previsão da volatilidade das ações da Apple. No modelo proposto, os resíduos de um modelo SARIMA, versão do ARIMA com componentes

sazonais, alimentam um modelo GARCH, e a volatilidade estimada por essa combinação é depois utilizada como entrada de redes neurais. A etapa que interessa a este trabalho é a primeira, em que os resíduos do modelo de média servem de entrada para o modelo de variância, mesma arquitetura adotada no algoritmo aqui desenvolvido.

O Quadro 1 resume as características desses estudos e as deste trabalho.

Quadro 1 – Características dos estudos relacionados

Estudo	Ativo	Fonte de dados	Periodicidade	Método
Almeida (2016)	PETR4	MetaTrader 5	diário	Cruzamento de médias móveis simples (10 e 20)
Batista (2024)	BBAS3F	MetaTrader 5	30 minutos	Combinação de três indicadores técnicos
Xing *et al.* (2024)	NVIDIA	Yahoo Finance	diário	ARIMA e ARIMA-GARCH, comparados a redes neurais
Araya e Araya (2024)	Apple	Yahoo Finance	diário	Resíduos do SARIMA como entrada do GARCH, seguidos de redes neurais
Este trabalho	PETR4 e outras três ações	B3 (COTAHIST)	diário	ARIMA e ARIMA-GARCH, comparados às médias móveis de Almeida (2016)

Fonte: Elaboração própria.

CAPÍTULO II

2 Percurso metodológico

Este capítulo descreve como a pesquisa foi conduzida. Apresenta a caracterização do estudo, o ambiente e os dados utilizados, a forma como os modelos foram implementados e validados, o plano experimental e os obstáculos que influenciaram as decisões metodológicas.

2.1 Caracterização da pesquisa

2.1.1 Quanto aos objetivos

Quanto aos objetivos, a pesquisa é explicativa, com uma parte descritiva. É descritiva ao registrar como cada algoritmo se comportou em diferentes períodos do mercado, e explicativa ao investigar por que a inclusão de um modelo de volatilidade altera o desempenho de uma estratégia cuja previsão de direção permanece a mesma. O interesse está em medir a diferença entre os modelos e também em identificar o mecanismo que a produz.

2.1.2 Quanto ao delineamento

Quanto ao delineamento, trata-se de uma pesquisa quase experimental. Esse delineamento abrange, entre seus casos mais frequentes, o desenvolvimento de softwares e a análise de algoritmos, que é a natureza deste trabalho. Ele se caracteriza pela manipulação controlada de variáveis e pela observação dos efeitos resultantes, sem que haja distribuição aleatória dos sujeitos, uma vez que a série histórica de um ativo é única e não pode ser sorteada.

O percurso seguiu as etapas previstas para esse delineamento. O problema e as hipóteses foram formulados na introdução. As variáveis foram operacionalizadas na forma dos parâmetros configuráveis do algoritmo, descritos na seção 2.4, e o plano experimental, descrito na seção 2.5, foi definido antes da observação dos resultados. Os sujeitos são as séries históricas dos ativos, e o ambiente é a plataforma de simulação. A coleta e a análise dos dados ocupam o Capítulo III, e as conclusões são apresentadas nas considerações finais.

2.2 Caracterização do lugar e da amostra de pesquisa

O lugar da pesquisa é computacional. Todos os experimentos foram conduzidos no testador de estratégias da plataforma MetaTrader 5, executada em ambiente Linux por meio da camada de compatibilidade Wine. A plataforma simula a execução de ordens sobre séries históricas, aplicando as mesmas regras de negociação que usaria em tempo real, e foi escolhida por ser a mesma utilizada no estudo que este trabalho continua (Almeida, 2016).

A amostra é composta por séries históricas diárias de ações negociadas na B3. O ativo principal é a PETR4, ação preferencial da Petrobras, escolhida por três motivos. É o ativo

estudado por Almeida (2016), o que permite a comparação direta. Apresenta volatilidade acentuada, característica que dá sentido à aplicação de um modelo de variância condicional. E possui série longa e contínua no arquivo histórico da bolsa. A série utilizada cobre 5.881 pregões, de 2 de janeiro de 2003 a 21 de setembro de 2026.

Para verificar se os resultados se repetem fora do ativo principal, foram incluídas outras três ações de setores distintos, VALE3, da mineração, USIM5, da siderurgia, e POMO4, de bens de capital. O critério de escolha foi a existência de série contínua no mesmo período e a ausência de mudanças de fator de cotação que impedissem a reconstrução dos preços.

O recorte temporal foi dividido em janelas, e não tratado como um período único, porque o comportamento de uma estratégia depende do regime de mercado. Foram examinadas uma janela de crise, de 2007 a 2011, uma de queda prolongada seguida de recuperação, de 2013 a 2016, o intervalo de 2017 a 2024, o período mais recente, de 2025 a 2026, e o período mais longo disponível, de 2005 a 2026.

2.3 Procedimentos para coleta e análise de dados

2.3.1 Técnicas para coleta de dados

Os dados principais foram obtidos de fontes públicas oficiais, e não do servidor da corretora. O servidor consultado disponibiliza cotações apenas a partir de setembro de 2021, enquanto os experimentos exigem séries que retrocedem a 2003. Além disso, o histórico fornecido por uma corretora pode ser alterado sem aviso, o que comprometeria a reprodutibilidade do estudo.

As cotações vieram do arquivo COTAHIST, série histórica publicada pela própria B3, que registra, para cada pregão e cada papel, os preços de abertura, máximo, mínimo e fechamento e o volume negociado. A taxa Selic diária foi obtida da série 11 do Sistema Gerenciador de Séries Temporais (Banco Central do Brasil, 2026).

Sobre as cotações foi aplicada uma única transformação, a correção por desdobramentos. Quando uma ação é desdobrada, o preço de tela cai na proporção do número de novas ações, sem que o investidor tenha perdido nada. Sem a correção, o modelo interpretaria o evento como uma queda abrupta. Na PETR4 há dois desdobramentos no período, em setembro de 2005 e em abril de 2008, e os preços anteriores a cada um foram divididos pelo fator correspondente. Os dois eventos aparecem como saltos de preço no próprio arquivo da bolsa e foram confirmados no registro de eventos corporativos da B3 e, para o de 2005, que esse registro não alcança, na base do Yahoo Finance (Yahoo Finance, 2026). Os proventos não foram incorporados à série que os modelos observam. Eles foram usados apenas em duas verificações, a da reprodução do estudo de Almeida (2016) e a do efeito de deixá-los fora da medida de desempenho, também a partir do Yahoo Finance, fonte não oficial.

As séries preparadas foram importadas para a plataforma como símbolos personalizados, recurso que permite ao testador operar sobre dados próprios em vez dos dados da corretora. A

conferência consistiu em comparar a quantidade de barras processadas pela plataforma com a quantidade de pregões da série de origem e em reconstruir preços isolados a partir das linhas originais do arquivo da bolsa.

2.3.2 Natureza da análise de dados

A análise é quantitativa. O desempenho de cada algoritmo foi medido sobre a série diária de patrimônio produzida pela simulação, e não apenas sobre o resultado final, o que permite calcular medidas de risco e aplicar testes estatísticos.

No cenário principal, as simulações partiram de um capital de R$ 100 mil e aplicaram a cada operação 95% do patrimônio, operando apenas na ponta compradora. As exceções, que são a reprodução do estudo de Almeida (2016) e o teste da venda a descoberto, são indicadas no Capítulo III onde aparecem. A cada execução de ordem foi descontado um custo de 0,03% do valor negociado, adotado como aproximação das taxas praticadas, e o capital fora do mercado foi remunerado pela taxa Selic diária. Essa remuneração não é uma meta a ser superada. Ela existe para que a comparação seja justa entre algoritmos que passam tempos diferentes fora do mercado, já que um capital parado sem rendimento penalizaria justamente as estratégias mais seletivas. Os proventos ficaram fora dessa medida, tanto para os algoritmos quanto para a compra e manutenção do ativo, que foi medida apenas pela variação do preço. O efeito dessa escolha é discutido nas limitações dos resultados, no Capítulo III.

Sobre essa série de patrimônio foram calculados o retorno acumulado e o anualizado, a volatilidade, a queda máxima e os índices de Sharpe e de Calmar, apresentados na seção 1.5. No índice de Sharpe, a referência foi a taxa Selic, e não o rendimento nulo que o testador da plataforma adota, de modo que o índice indica quanto a estratégia rendeu além da Selic por unidade de oscilação. A Selic, por definição, tem índice zero. O índice foi calculado sobre os retornos diários e anualizado, prática comum para permitir a comparação entre estratégias (Sharpe, 1994),

$$S = \frac{\bar{d}}{\sigma_d}\sqrt{252}, \tag{2.1}$$

em que d é a diferença diária entre o retorno da estratégia e o da Selic e 252 é o número aproximado de pregões em um ano. Cada índice foi acompanhado do valor-p do teste de que ele é maior que zero.

Foram registrados ainda a quantidade de operações e a taxa de acerto, isto é, a proporção das operações encerradas com lucro, já descontados os custos. A comparação entre dois algoritmos sobre os mesmos dias foi feita pelo teste de diferença entre índices de Sharpe e pelo teste t pareado dos retornos diários.

2.4 Implementação e validação dos modelos

A biblioteca padrão da linguagem MQL5 oferece médias móveis, osciladores e demais indicadores de análise técnica, mas não traz modelos de séries temporais como o ARIMA e

o GARCH. Ambos foram escritos para este trabalho. Da biblioteca numérica ALGLIB, que acompanha a instalação da plataforma, foram aproveitadas apenas as rotinas de álgebra linear e de otimização com restrições.

O ARIMA da equação (1.1) foi estimado pelo método de Hannan-Rissanen, que resolve o problema em dois estágios de mínimos quadrados. A dificuldade de estimar um modelo com termos de médias móveis é que os erros passados não são observáveis, pois dependem dos coeficientes que se quer estimar. O primeiro estágio contorna essa dificuldade ajustando um modelo autorregressivo longo, cujos resíduos servem de estimativa para os erros. O segundo estágio regride a série contra seus próprios valores defasados e contra os erros estimados.

Esse método foi preferido a um procedimento iterativo de descida de gradiente, que exige a definição de uma taxa de aprendizado. Como o gradiente de uma regressão cresce com o quadrado da escala dos dados, a mesma taxa que converge para um ativo cotado a trinta reais pode divergir para um cotado a cinco. O método de Hannan-Rissanen é exato em cada estágio, dispensa taxa de aprendizado e número de iterações e não depende da escala dos preços.

O modelo foi aplicado ao logaritmo do preço. Com uma diferenciação, a série modelada passa a ser o retorno logarítmico diário, e a volatilidade estimada pelo GARCH sai em proporção do preço. Uma volatilidade de 0,02 significa uma oscilação típica de 2% ao dia, qualquer que seja o nível de preço do ativo.

A ordem de integração d foi determinada pela aplicação sequencial do teste ADF. Testa-se a série original e, se a hipótese de raiz unitária não for rejeitada, testa-se a série diferenciada, e assim por diante. As ordens p e q foram escolhidas por busca em grade, variando ambas de zero a quatro e selecionando a combinação de menor AIC, procedimento semelhante ao de Xing *et al.* (2024). Na busca, todos os candidatos foram avaliados sobre exatamente a mesma amostra. Isso foi necessário porque modelos de ordem mais alta consomem mais observações iniciais, e o AIC soma uma parcela por observação avaliada. Comparados sem esse ajuste, os modelos mais simples teriam mais parcelas somadas e venceriam por construção.

O GARCH da equação (1.2) foi estimado por máxima verossimilhança. As restrições do modelo, isto é, ω positivo, α e β não negativos e $\alpha + \beta$ menor que um, foram informadas ao otimizador como limites da região de busca, e não aplicadas como correção depois de cada passo. Corrigir o valor depois do passo faz o otimizador empurrar o parâmetro contra o limite sem convergir, enquanto a restrição declarada mantém a busca dentro da região válida desde o início.

Os dois modelos foram reunidos em um único *Expert Advisor*, com um parâmetro que liga e desliga o componente GARCH. A escolha tem motivo metodológico. Com o componente desligado, o programa percorre o mesmo caminho de previsão, a mesma janela de estimação e a mesma rotina de envio de ordens, de modo que qualquer diferença observada entre as duas execuções só pode ter origem no GARCH.

A divisão de papéis entre os dois modelos é estrita. O ARIMA estima a média condicional e é o único responsável por indicar o lado da operação. O GARCH estima a variância condicional

dos resíduos do ARIMA e nunca gera sinal de direção. Sua função é vetar a operação ou redimensioná-la, de acordo com a forma de uso escolhida entre as descritas no Capítulo I.

A cada novo pregão, o algoritmo carrega a janela de preços já encerrados, ajusta o ARIMA, obtém a previsão do retorno do dia, extrai os resíduos, ajusta o GARCH sobre eles e obtém a volatilidade prevista. Na forma de filtro, se a volatilidade prevista ultrapassa o limiar, a operação é vetada. O limiar pode ser um valor fixo ou um percentil da volatilidade estimada dentro da própria janela. No segundo caso, o limiar vem da volatilidade ajustada aos pregões passados da janela, enquanto a comparação é feita com a previsão para o dia, que reflete as condições mais recentes. Por isso, em períodos agitados, a proporção de sinais vetados pode ser bem maior do que o percentil sugere. Quando não há veto, o sinal da previsão do ARIMA determina a direção, e a ordem é executada na abertura do pregão. A janela de dados nunca inclui a barra em formação, o que evita que o modelo utilize, na decisão de hoje, uma informação que só estaria disponível ao final do dia.

Um detalhe da implementação tem efeito direto nos resultados. Por padrão, o veto impede a abertura de uma nova posição, mas não encerra a posição já aberta. Da mesma forma, nas formas de uso que ajustam o tamanho da posição à volatilidade, o ajuste é feito no momento da entrada, e uma posição já aberta não é reduzida se a volatilidade aumentar depois. Uma opção do algoritmo permite que o veto também encerre a posição, retirando o capital do mercado enquanto a volatilidade prevista estiver alta. As duas alternativas foram testadas, e o Capítulo III mostra que elas se comportam de maneira diferente quanto ao risco.

Antes dos experimentos com dados reais, as implementações foram submetidas a um teste de recuperação de parâmetros. O procedimento consiste em gerar séries sintéticas a partir de parâmetros conhecidos e verificar se o estimador os recupera. Como a resposta correta é conhecida de antemão, o teste distingue um estimador correto de um que apenas produz números plausíveis. Os resultados estão na Tabela 1.

Tabela 1 – Recuperação de parâmetros em séries sintéticas

Parâmetro	Valor verdadeiro	Valor estimado
ARMA(1,1), ϕ_1	0,600	0,5799
ARMA(1,1), θ_1	0,400	0,4105
AR(2), ϕ_1	0,500	0,4815
AR(2), ϕ_2	$-0{,}300$	$-0{,}2891$
GARCH, ω	$1{,}00 \times 10^{-5}$	$1{,}17 \times 10^{-5}$
GARCH, α	0,090	0,0825
GARCH, β	0,890	0,8941

Fonte: Elaboração própria, a partir da execução do script de validação, com semente fixa.

Os coeficientes do ARIMA foram recuperados com desvio inferior a 4%. No GARCH, o parâmetro β, que responde pela persistência da volatilidade, ficou a menos de 1% do valor verdadeiro, enquanto ω e α se afastaram mais, cerca de 17% e 8%. Ainda assim, a soma $\alpha + \beta$, que determina quanto tempo um choque de volatilidade leva para se dissipar, foi estimada em 0,9765, contra 0,98 do valor verdadeiro.

O teste ADF passou pela mesma verificação. Aplicado a um passeio aleatório, produziu estatística de $-1{,}41$ e não rejeitou a hipótese de raiz unitária, como esperado. Aplicado a uma série autorregressiva estacionária, produziu $-26{,}87$ e rejeitou. Aplicado à primeira diferença do passeio aleatório, produziu $-46{,}19$ e também rejeitou. O teste, portanto, distinguiu corretamente os três casos.

Os procedimentos foram aplicados também aos 500 pregões da PETR4 encerrados até 18 de setembro de 2026, na mesma série da B3 usada nos experimentos, e se comportaram de forma coerente com a teoria. O teste ADF não rejeitou a hipótese de raiz unitária para o logaritmo do preço, com estatística de $-0{,}95$, e a rejeitou para o retorno logarítmico, com estatística de $-6{,}14$, o que é compatível com a ordem de integração $d = 1$.

Os resíduos dos dois modelos foram examinados pelo teste de Ljung-Box, que verifica se ainda há autocorrelação nos erros de um modelo, isto é, se restou nos dados algum padrão que ele não capturou. Seguindo o diagnóstico de modelos ARMA-GARCH feito por Thomaz (2019) em ações brasileiras, o teste foi aplicado em duas etapas, considerando dez defasagens. Nos resíduos do ARIMA, ele verifica se a previsão da média aproveitou a dependência entre os retornos. No quadrado dos resíduos padronizados pelo GARCH, verifica se ainda há agrupamento de volatilidade, ou seja, se os dias agitados continuam vindo em sequência depois que o modelo de volatilidade foi aplicado. Com um ARIMA(1,1,1) de ordens fixas, o teste nos resíduos resultou em valor-p de 0,009, o que indica autocorrelação remanescente e reforça a escolha das ordens por busca em grade, em vez de fixá-las. No quadrado dos resíduos padronizados pelo GARCH ajustado a esses resíduos, o valor-p foi de 0,75, sem indício de autocorrelação remanescente, o que indica que a variação da volatilidade presente nos resíduos do ARIMA foi capturada pelo modelo.

2.5 Plano experimental

O algoritmo tem parâmetros ajustáveis, como o limiar de veto e o tamanho da janela de estimação, e, olhando para o passado, sempre seria possível encontrar a combinação que teria dado o melhor resultado. Para que a escolha não fosse feita no mesmo período em que o desempenho é medido, cada período de teste foi precedido por um período de calibração de três anos. Na calibração foram simuladas 344 combinações de parâmetros, das quais foram escolhidas a de maior índice de Sharpe e a de maior índice de Calmar, e só então elas foram aplicadas ao período de teste.

Cada configuração escolhida foi comparada a uma versão gêmea, com o mesmo ARIMA e o GARCH desligado, de modo que a diferença entre as duas pode ser atribuída ao GARCH. Também foram avaliadas configurações fixas, mantidas sem nova escolha ao longo de períodos longos, e a estratégia de Almeida (2016) foi executada nos mesmos períodos e nas mesmas condições, para a comparação. Como o algoritmo decide uma vez por dia e executa na abertura, as simulações usaram os preços de abertura de cada pregão.

2.6 Obstáculos encontrados

O desenvolvimento enfrentou dois obstáculos que alteraram o cronograma original e influenciaram decisões metodológicas.

O primeiro foi a perda do ambiente Windows. O desenvolvimento começou em uma máquina com Windows e MetaTrader 5 instalado nativamente, e a perda desse equipamento obrigou a migração para Linux, onde a plataforma não tem suporte oficial e precisa ser executada por camada de compatibilidade. A solução funcionou, mas trouxe instabilidades ocasionais e exigiu que a automação dos experimentos fosse refeita em linha de comando.

O segundo foi o acesso aos dados históricos pela corretora. A corretora utilizada inicialmente, a Rico, deixou de oferecer suporte ao MetaTrader 5, o que exigiu a abertura de conta em outra instituição. A segunda corretora, a Clear, oferece a plataforma, mas disponibiliza cotações apenas a partir de setembro de 2021, o que não atendia aos períodos de teste, que retrocedem a 2003. Esse obstáculo levou à adoção do arquivo oficial da bolsa como fonte, o que tornou a série pública, verificável e livre de alterações posteriores.

CAPÍTULO III

3 Análise e discussão dos dados

Este capítulo apresenta e discute os resultados dos experimentos. Começa pela reprodução do estudo de Almeida (2016), que garante que a estratégia usada como termo de comparação é de fato a do autor. Em seguida, apresenta o experimento principal, examina se o comportamento observado se repete em outros períodos e em outros ativos e avalia a significância estatística das diferenças. Por fim, discute o mecanismo que produz o efeito observado e as limitações dos resultados.

3.1 Reprodução e comparação com o estudo de referência

Para que a comparação com Almeida (2016) fosse legítima, era necessário verificar que a estratégia de médias móveis reimplementada se comporta como a original. Os testes do autor foram repetidos com as mesmas datas, o mesmo capital de R$ 50 mil, as mesmas médias de 10 e 20 períodos, sem custos e com operações de compra e venda, como declarado em seu trabalho.

Duas condições, porém, não puderam ser repetidas exatamente. A primeira é a série de preços. O autor utilizou o histórico fornecido pela corretora por meio do próprio MetaTrader 5, sem informar se e como os preços foram ajustados, enquanto este trabalho utilizou o arquivo COTAHIST da B3 corrigido apenas pelos desdobramentos, conforme descrito na seção 2.3.1. A segunda é o volume. O autor declara mil ações para o teste de 2013 a 2016, mas não informa o volume dos testes de crise. Como ele menciona cem ações como volume mínimo e afirma que o volume de mil foi adotado no período de 2013 a 2016, a reprodução dos testes de crise utilizou cem ações. Além disso, o código publicado no anexo do trabalho traz ligada uma opção de gestão de capital cujo arquivo não foi incluído, de modo que não é possível saber se o volume dele era de fato fixo. Os resultados estão na Tabela 2.

Tabela 2 – Reprodução dos testes de Almeida (2016)

	Almeida (2016)		Reprodução	
Período	Operações	Resultado	Operações	Resultado
2013 a 2016	38	+R$ 10.430	37	+R$ 10.050
2008 a 2010	37	−R$ 1.595	38	−R$ 575
2007 a 2011	52	−R$ 2.542	63	−R$ 1.274

Fonte: Elaboração própria e Almeida (2016).

Nota: Médias móveis simples de 10 e 20 períodos, capital de R$ 50 mil, sem custos, compra e venda. Volume de mil ações em 2013 a 2016 e de cem ações nos testes de crise.

No período fora de crise, a reprodução difere do original em uma operação e em 3,6% do lucro, o que indica que a lógica da estratégia foi reproduzida. No subperíodo de 2008 a 2010, a quantidade de operações praticamente coincide, mas os valores em reais divergem, e no período completo de crise coincidem apenas o sinal e a ordem de grandeza do resultado.

A divergência em reais tem uma explicação provável. O resultado em reais de uma estratégia com lote fixo é proporcional ao nível de preço da série, de modo que uma série vinte por cento mais baixa produz variações em reais vinte por cento menores, ainda que os retornos percentuais sejam idênticos. Uma verificação com a série ajustada também por proventos, obtidos do Yahoo Finance, deslocou o lucro bruto de 2008 a 2010 na direção do valor relatado pelo autor, o que indica que boa parte da diferença decorre do critério de ajuste da série. A diferença na quantidade de operações de 2007 a 2011, porém, não foi explicada. O mesmo ajuste por proventos afastou a contagem do valor do autor, em vez de aproximá-la. Restam duas possibilidades que não podem ser verificadas sem os dados originais: a série usada pelo autor diferia da série da bolsa também na forma, e não só no nível, ou a simulação dele, feita negócio a negócio, gerou entradas diferentes das obtidas aqui com preços de abertura, já que o arquivo da bolsa traz apenas o resumo diário de cada pregão.

Conclui-se que a reprodução confirma o comportamento do algoritmo de referência, mas não os seus valores financeiros. Isso basta para o propósito desta etapa, que é garantir que a estratégia usada como termo de comparação nas seções seguintes é de fato a de Almeida (2016). A reprodução exata dos valores dependeria do critério de ajuste da série e do volume dos testes de crise, que o estudo original não registra.

Validada a reimplementação, os modelos deste trabalho foram executados nas mesmas condições declaradas por Almeida (2016) para o período de 2013 a 2016, com capital de R$ 50 mil, volume fixo de mil ações, sem custos e com operações de compra e venda. Para o ARIMA-GARCH foi usada a configuração padrão do *Expert Advisor*, com o GARCH como filtro, limiar no percentil 50 da volatilidade estimada e janela de 120 pregões. A Tabela 3 apresenta o resultado.

Tabela 3 – Comparação nas condições originais, 2013 a 2016

Algoritmo	Operações	Resultado	Queda máx.
Médias móveis, relatado por Almeida	38	+R$ 10.430	–
Médias móveis, reproduzido	37	+R$ 10.050	15,0%
ARIMA isolado	397	−R$ 8.100	30,9%
ARIMA-GARCH	173	+R$ 24.020	8,7%

Fonte: Elaboração própria e Almeida (2016).

Nota: Sem custos de execução, conforme o estudo original.

Nas mesmas condições em que o estudo de referência obteve lucro de R$ 10.430, equivalente a 20,9% do capital, o ARIMA-GARCH obteve R$ 24.020, ou 48,0%, com queda máxima de 8,7%, contra 15,0% das médias móveis reproduzidas. A linha reproduzida é o que torna a comparação interpretável. A diferença entre as duas primeiras linhas decorre dos dados, e a diferença entre a segunda e a quarta decorre do modelo. Cabe registrar que, nessas condições, o ARIMA isolado realizou 397 operações, contra 173 do ARIMA-GARCH e 37 das médias móveis. Como o estudo original não considera custos de execução, esse giro não tem custo na simulação, o que não ocorreria na prática.

3.2 Resultado principal: teste fora da amostra

O experimento central testou o ARIMA-GARCH no período de 2017 a 2024, seguindo o plano da seção 2.5. As configurações foram escolhidas nos três anos anteriores, de 2014 a 2016, e cada uma foi comparada à sua gêmea, com o mesmo ARIMA e o GARCH desligado. Os resultados estão na Tabela 4.

Tabela 4 – Desempenho no período de teste, 2017 a 2024

Algoritmo	Retorno	Ao ano	Sharpe	p	Queda máx.	Oper.
ARIMA-GARCH, escolha por Sharpe	+273,8%	18,2%	0,49	0,085	26,1%	238
gêmea sem GARCH	+114,6%	10,2%	0,22	0,268	40,6%	244
ARIMA-GARCH, escolha por Calmar	+114,1%	10,2%	0,19	0,295	38,1%	223
gêmea sem GARCH	−46,5%	−7,6%	−0,34	0,831	78,4%	469
Médias móveis de Almeida	+90,4%	8,5%	0,17	0,319	36,7%	56
Taxa Selic	+86,1%	8,2%	–	–	–	–
Compra e manutenção da PETR4	+143,6%	12,0%	–	–	–	–

Fonte: Elaboração própria.

Nota: Valores com custos de execução e remuneração do caixa pela Selic, sem proventos. A compra e manutenção é medida pela variação do preço. O valor-p refere-se à hipótese de índice de Sharpe positivo. O ARIMA isolado escolhido na calibração coincidiu com a gêmea da escolha por Sharpe.

Nos dois pares, a versão com GARCH obteve retorno maior e queda máxima menor que a sua gêmea. Na configuração escolhida por Sharpe, o retorno passou de 114,6% para 273,8%, e a queda máxima caiu de 40,6% para 26,1%. Na escolhida por Calmar, a diferença foi maior, de um prejuízo de 46,5% para um lucro de 114,1%, com a queda máxima caindo de 78,4% para 38,1%. Como cada par parte do mesmo modelo de previsão e difere apenas na presença do GARCH, a diferença dentro do par pode ser atribuída ao componente de volatilidade.

A configuração escolhida por Sharpe também teve retorno maior que o das médias móveis de Almeida (2016), que o da Selic e que o da compra e manutenção do ativo no mesmo período. Essas diferenças, porém, não são estatisticamente significativas, como se discute na seção 3.5, e dependem de os proventos ficarem fora da medida, como se discute nas limitações. Por isso o resultado deve ser lido como retorno superior no período observado, e não como superioridade demonstrada.

O critério de escolha por Calmar não se manteve do período de calibração para o de teste. A configuração escolhida por esse critério tinha, na calibração, índice de Calmar de 2,83 e queda máxima de 8,4%, e no teste apresentou 0,27 e 38,1%.

3.3 Robustez entre períodos e entre ativos

O mesmo procedimento foi aplicado a outras três janelas, cada uma com escolha própria, para verificar se o comportamento observado depende do período. A Tabela 5 resume os resultados.

Tabela 5 – Desempenho por janela de teste

Janela	Algoritmo	Retorno	Queda máx.	Sharpe (p)
2007 a 2011	ARIMA-GARCH	+28,7%	13,3%	−0,47 (0,85)
	gêmea sem GARCH	+19,8%	35,1%	−0,10 (0,59)
	ARIMA isolado	−2,1%	44,3%	−0,26 (0,72)
	Médias móveis	−11,6%	57,5%	−0,31 (0,76)
2013 a 2016	ARIMA-GARCH, por Sharpe	+15,8%	17,7%	−0,44 (0,81)
	ARIMA-GARCH, por Calmar	+34,0%	6,8%	−0,46 (0,82)
	gêmea sem GARCH	−3,7%	50,9%	−0,16 (0,63)
	ARIMA isolado	−30,5%	51,9%	−0,35 (0,75)
	Médias móveis	+150,9%	38,4%	0,50 (0,16)
2025 a 2026	ARIMA-GARCH, por Sharpe	−0,4%	13,7%	−0,94 (0,89)
	ARIMA-GARCH, por Calmar	+9,6%	8,2%	−0,82 (0,86)
	ARIMA isolado	+24,1%	19,0%	0,08 (0,46)
	Médias móveis	+31,3%	28,2%	0,23 (0,38)

Fonte: Elaboração própria.

Nota: Em 2007 a 2011, os dois critérios escolheram a mesma configuração. Em 2013 a 2016, as duas escolhas têm a mesma gêmea. Em 2025 e 2026, a gêmea das duas escolhas é o próprio ARIMA isolado. Referências: Selic de +68,1%, +53,9% e +25,7%, e PETR4, pela variação do preço, de −14,0%, −25,6% e +33,2%, respectivamente.

O padrão que se repete é o da redução de risco. Em todas as janelas, a menor queda máxima pertence a uma variante com GARCH, e nas duas janelas de turbulência a diferença é grande. Em 2007 a 2011, a queda máxima foi de 13,3%, contra 44,3% do ARIMA isolado e 57,5% das médias móveis. Em 2013 a 2016, foi de 6,8%, contra 51,9% e 38,4%.

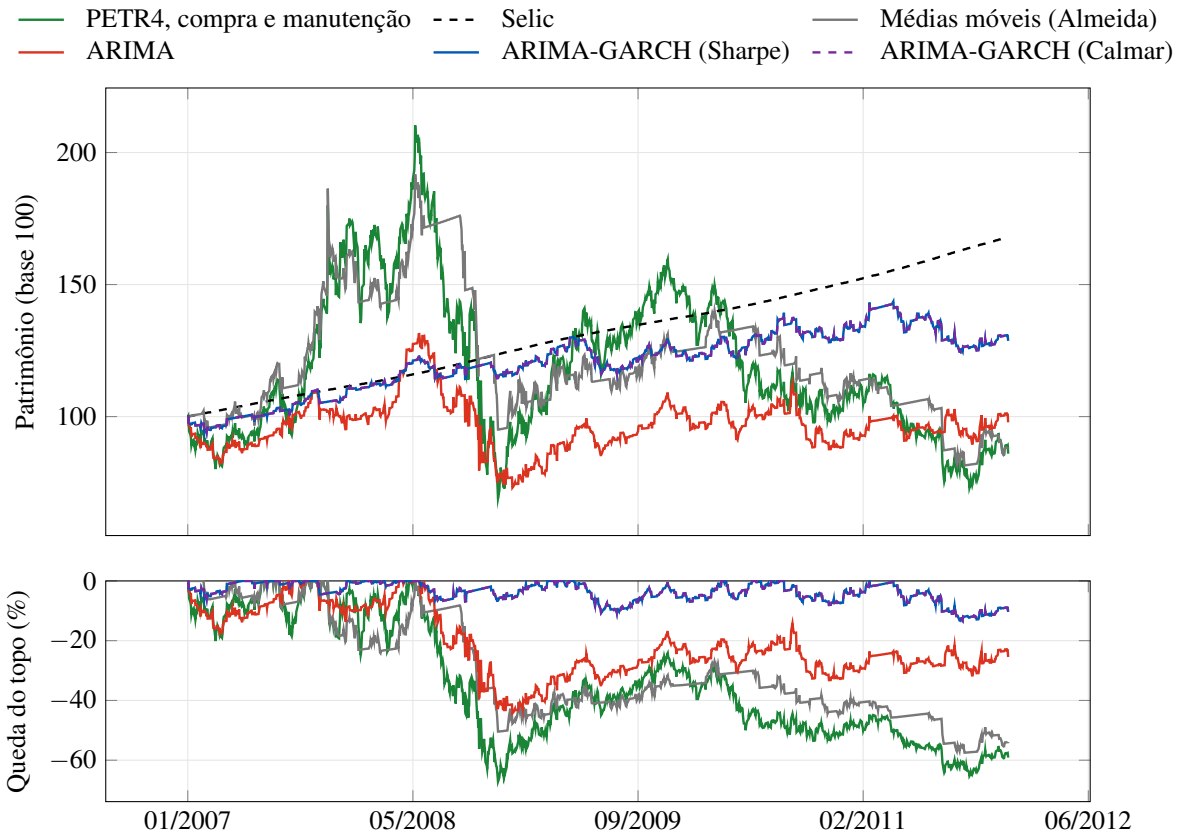
O retorno, ao contrário, não segue um padrão. Em 2007 a 2011, a variante com GARCH teve o maior retorno entre os algoritmos, mas em 2013 a 2016 e em 2025 e 2026 as médias móveis superaram os modelos estatísticos, e no período mais recente o ARIMA isolado também rendeu mais que as variantes com GARCH.

O ano de 2008 ilustra o comportamento em uma crise. Enquanto a PETR4 recuou 47,3% no ano, o ARIMA-GARCH encerrou com ganho de 5,0%, contra perdas de 24,8% do ARIMA isolado e de 36,6% das médias móveis. O Gráfico 1 mostra a evolução do patrimônio de cada algoritmo entre 2007 e 2011, e o Gráfico 2, o retorno de cada ano.

Para verificar se o efeito é específico da PETR4, o procedimento foi repetido nas ações VALE3, USIM5 e POMO4, totalizando 16.512 simulações. A análise foi feita por pares. Cada configuração com GARCH foi comparada à sua gêmea, e contou-se em que proporção dos pares o GARCH reduziu a queda máxima. A Tabela 6 apresenta o resultado para as variantes que limitam a exposição, isto é, as que dimensionam a entrada pela volatilidade prevista ou encerram a posição no veto.

O efeito sobre o risco se confirma nos quatro ativos, com uma condição. Ele pertence às variantes que limitam a exposição. As variantes que apenas impedem novas entradas, mantendo a posição já aberta, reduziram a queda máxima em 23% a 67% dos pares, conforme o ativo e o período, com variação mediana próxima de zero. Já o efeito sobre o índice de Sharpe ficou

Gráfico 1 – Evolução do patrimônio e da queda acumulada, 2007 a 2011



Fonte: Elaboração própria.

Tabela 6 – Efeito do GARCH sobre o risco nos quatro ativos

	2007 a 2011	2013 a 2016	2025 a 2026
Pares em que reduziu a queda máxima	85% a 93%	92% a 98%	52% a 96%
Variação da queda máxima (p.p.)	−17 a −29	−20 a −40	0 a −22
Variação do retorno (p.p.)	+7 a +27	+29 a +41	+2 a +16
Variação do índice de Sharpe	−0,08 a −0,02	−0,08 a +0,05	−0,12 a +0,10

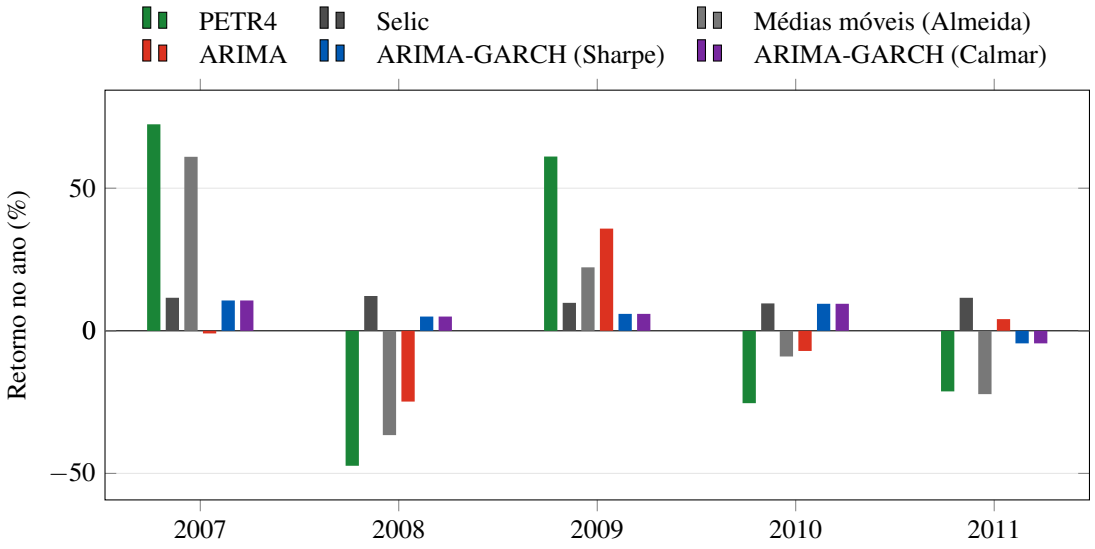
Fonte: Elaboração própria.

Nota: As faixas correspondem aos quatro ativos. As variações são medianas das diferenças entre cada configuração com GARCH e sua gêmea.

próximo de zero em todos os casos.

As mesmas simulações permitiram testar a venda a descoberto, prevista como possibilidade no início do trabalho. O resultado foi negativo. Em nove dos doze casos de ativo e período, a mediana do retorno piorou quando se permitiu operar vendido, em dois melhorou e em um não se alterou, e menos de 1% das configurações levou o capital à ruína nas janelas de crise. Com o modelo acertando a direção em taxa próxima ao acaso, operar nos dois sentidos dobra a exposição ao erro em vez de aproveitar as quedas.

Gráfico 2 – Retorno por ano, 2007 a 2011



Fonte: Elaboração própria.

3.4 Horizonte longo

Também foram testadas configurações fixas, mantidas sem nova escolha ao longo do tempo, da mesma forma que Almeida (2016) manteve fixas as suas médias de 10 e 20 períodos. Foram usadas as duas configurações escolhidas na calibração de 2010 a 2012, pelos critérios de Sharpe e de Calmar. As duas usam o GARCH como filtro e para dimensionar a entrada, encerram a posição no veto e diferem apenas na volatilidade de referência para o tamanho da posição, de 2% e de 1% ao dia. Elas foram aplicadas ao período mais longo disponível, de 2005 a 2026, e ao período de 2017 a 2024, sempre ao lado da sua gêmea sem GARCH. Como a calibração está dentro do primeiro período, ainda que corresponda a apenas três dos vinte e um anos, o teste de 2017 a 2024, inteiramente posterior a ela, é o mais limpo dos dois. A Tabela 7 apresenta o resultado.

Tabela 7 – Desempenho das configurações fixas

Período	Algoritmo	Retorno	Ao ano	Sharpe (p)	Queda máx.
2005 a 2026	ARIMA-GARCH, por Sharpe	+602,4%	9,6%	−0,01 (0,514)	29,7%
	ARIMA-GARCH, por Calmar	+669,9%	10,0%	−0,05 (0,600)	14,2%
	gêmea sem GARCH	+79,9%	2,8%	−0,11 (0,702)	80,7%
	Médias móveis de Almeida	+985,2%	11,8%	0,18 (0,198)	67,5%
2017 a 2024	ARIMA-GARCH, por Sharpe	+67,3%	6,8%	0,01 (0,492)	28,1%
	ARIMA-GARCH, por Calmar	+72,9%	7,2%	−0,06 (0,572)	12,6%
	gêmea sem GARCH	+11,9%	1,4%	−0,03 (0,533)	57,8%
	Médias móveis de Almeida	+90,4%	8,5%	0,17 (0,319)	36,7%

Fonte: Elaboração própria.

Nota: As duas escolhas têm a mesma gêmea. Selic de +795,8% (10,8% ao ano) e +86,1% (8,2% ao ano), e compra e manutenção da PETR4, pela variação do preço, de +298,8% (6,7% ao ano) e +143,6% (12,0% ao ano), respectivamente.

O resultado mais forte da Tabela 7 é a diferença entre o mesmo ARIMA com e sem o GARCH. Sem o GARCH, o ARIMA rendeu 79,9% em vinte e um anos e 11,9% entre 2017 e 2024, com quedas máximas de 80,7% e 57,8%. Com o GARCH, a mesma previsão rendeu 602,4% e 669,9% no período longo, com quedas máximas de 29,7% e 14,2%, e de 67,3% a 72,9% no período de 2017 a 2024, com quedas de 28,1% e 12,6%.

Ainda assim, nenhuma das configurações fixas superou a Selic no período longo, e as médias móveis de Almeida (2016) tiveram o maior retorno nos dois períodos, com quedas máximas maiores. O retorno das variantes com GARCH também é concentrado. Na escolha por Sharpe, os cinco melhores anos respondem por 67,5% do retorno acumulado, e um único ano, 2018, por 19,2%.

3.5 Significância das diferenças

As seções anteriores mostram que o GARCH alterou o desempenho do ARIMA em quase todos os testes. Resta saber se essas diferenças são grandes o bastante para não serem atribuídas ao acaso. Para isso, cada configuração com GARCH foi comparada à sua gêmea sobre os mesmos dias, pelo teste de diferença entre índices de Sharpe. A Tabela 8 reúne as onze comparações realizadas.

Tabela 8 – Comparação entre cada configuração com GARCH e sua gêmea

Período	Configuração	Sharpe com GARCH	Sharpe da gêmea	p
2007 a 2011	escolha por Sharpe e por Calmar	−0,47	−0,10	0,259
2013 a 2016	escolha por Sharpe	−0,44	−0,16	0,540
2013 a 2016	escolha por Calmar	−0,46	−0,16	0,521
2017 a 2024	escolha por Sharpe	0,49	0,22	0,281
2017 a 2024	escolha por Calmar	0,19	−0,34	0,020
2025 a 2026	escolha por Sharpe	−0,94	0,08	0,128
2025 a 2026	escolha por Calmar	−0,82	0,08	0,179
2005 a 2026	escolha por Sharpe, fixa	−0,01	−0,11	0,587
2005 a 2026	escolha por Calmar, fixa	−0,05	−0,11	0,764
2017 a 2024	escolha por Sharpe, fixa	0,01	−0,03	0,907
2017 a 2024	escolha por Calmar, fixa	−0,06	−0,03	0,913

Fonte: Elaboração própria.

Nota: Teste de diferença entre índices de Sharpe com a correção de Memmel, sobre os retornos diários dos mesmos pregões.

Em uma das onze comparações, a do período de 2017 a 2024 com a escolha por Calmar, a versão com GARCH foi significativamente melhor que a gêmea, ao nível de 5%, e em nenhuma foi significativamente pior. Nas demais, a diferença de índice de Sharpe não pode ser distinguida do acaso, mesmo quando a diferença de retorno e de queda máxima é grande.

Há uma razão para isso. O índice de Sharpe deste trabalho é medido em relação à Selic, e, quando um algoritmo rende menos que ela, o índice é negativo. Nesse caso, reduzir a oscilação torna o índice ainda mais negativo, mesmo que o retorno tenha aumentado. Foi o que ocorreu

em 2007 a 2011 e em 2013 a 2016. A versão com GARCH rendeu mais que a gêmea e oscilou bem menos, mas, como as duas ficaram abaixo da Selic, o índice da versão com GARCH ficou mais negativo. O índice de Sharpe, portanto, mede a vantagem sobre a Selic, e não a proteção contra quedas, que aparece na queda máxima.

A mesma análise foi feita entre os modelos deste trabalho e as médias móveis de Almeida (2016), nas doze comparações possíveis entre as quatro janelas de teste com escolha na calibração, incluído o período de 2017 a 2024, e nenhuma diferença foi significativa, com valores-p entre 0,11 e 0,95. Os dados, portanto, permitem afirmar que o GARCH reduziu o risco do ARIMA, mas não permitem afirmar que o ARIMA-GARCH superou a estratégia de médias móveis.

A comparação com a Selic segue a mesma lógica. Como o índice de Sharpe deste trabalho é medido em relação à Selic, um índice positivo indica que o algoritmo rendeu mais que ela, e o valor-p que acompanha cada índice indica se essa vantagem pode ser distinguida do acaso. Os valores-p das Tabelas 4, 5 e 7 mostram que, em nenhum dos casos, ela pode. A configuração principal de 2017 a 2024 rendeu 273,8% contra 86,1% da Selic, mas com valor-p de 0,085. Os algoritmos renderam mais que a Selic em alguns períodos, mas essa vantagem é compatível com o acaso. É por isso que a Selic é tratada neste trabalho como referência de medida, e não como meta.

3.6 O mecanismo do efeito

Os resultados anteriores mostram que o GARCH altera o desempenho do ARIMA. Como o modelo de volatilidade não fornece nenhuma informação sobre a direção dos preços, resta entender de que forma isso acontece. A Tabela 9 compara o ARIMA isolado e o ARIMA-GARCH em dois dos testes.

Tabela 9 – Comparação entre o ARIMA isolado e o ARIMA-GARCH

	ARIMA isolado	ARIMA-GARCH
Taxa de acerto, 2017 a 2024	55,7%	58,8%
Taxa de acerto, 2013 a 2016, condições originais	48,1%	51,4%
Operações, 2013 a 2016, condições originais	397	173
Sinais vetados, 2013 a 2016, condições originais	–	435 de 740

Fonte: Elaboração própria.

A capacidade de prever a direção permaneceu praticamente a mesma. As taxas de acerto diferem em cerca de três pontos percentuais, diferença que, com o número de operações envolvido, não é estatisticamente significativa. O que mudou foi a quantidade de vezes em que o algoritmo decidiu agir. Ao vetar as operações nos dias de volatilidade prevista elevada, o filtro descartou mais da metade dos sinais e manteve apenas os gerados em períodos de comportamento mais regular.

O efeito, portanto, é de seletividade, e não de previsão. O ARIMA continua acertando aproximadamente o mesmo que antes, e o GARCH decide em quais dias vale a pena agir sobre

essa previsão. Isso explica por que a redução de risco aparece de forma consistente em todos os experimentos, enquanto o ganho de retorno não. O filtro atua sobre a exposição ao mercado, e não sobre a qualidade do sinal, que permanece próxima do acaso.

Um episódio de 2020 mostra esse funcionamento. Na abertura de 3 de abril, durante a queda associada à pandemia, o ARIMA previa alta de 2,66% para o dia e, isoladamente, teria comprado. A volatilidade prevista pelo GARCH para aquele dia era de 7,58%, cerca de três vezes o limiar vigente, de 2,54%, e a operação foi vetada. Naquele momento, a ação acumulava queda de 48,6% em relação ao fechamento de 2019.

3.7 Limitações dos resultados

Os resultados apresentados têm limitações que restringem o alcance das conclusões.

A primeira é a significância estatística. Em relação à Selic, nenhum teste atingiu o nível de 5%. Na comparação com a gêmea, o GARCH foi significativamente melhor em um de onze casos. Na comparação com as médias móveis, nenhuma diferença foi significativa. As diferenças observadas são compatíveis com os dados, mas na maior parte dos casos não permitem afirmar superioridade em sentido estatístico.

A segunda é a instabilidade da escolha de configuração. A correlação de postos entre o índice de Sharpe medido na calibração e o medido no teste ficou próxima de zero, isto é, a configuração com melhor desempenho em um período não tende a repeti-lo no seguinte. A medida de risco mostrou correlação positiva, ainda que moderada, o que sugere que a característica que se mantém entre períodos é a proteção, e não o retorno.

A terceira é a concentração dos ganhos. No teste de horizonte longo, cinco anos respondem por cerca de dois terços do retorno acumulado, e ganhos concentrados em poucos períodos não constituem vantagem distribuída no tempo.

A quarta é a abrangência. Foram analisados quatro ativos de um único mercado, em janelas específicas, com operações apenas na ponta compradora no cenário principal e com um custo de execução único, aplicado a todo o período.

A quinta é a exclusão dos proventos. Como a medida não inclui os dividendos, ela favorece os algoritmos que passam menos tempo comprados, entre eles as variantes com GARCH. Quando os proventos são incluídos, com os valores obtidos do Yahoo Finance, a ordem do período de 2017 a 2024 muda. A compra e manutenção da PETR4 passa a render 726,5% e as médias móveis 396,1%, acima dos 353,4% da configuração escolhida por Sharpe. A comparação entre cada configuração com GARCH e a sua gêmea, porém, não muda de sentido. Com os proventos, a versão com GARCH continua com queda máxima menor nos onze pares e com retorno maior em nove deles, como sem os proventos.

CONSIDERAÇÕES FINAIS

Este trabalho investigou o efeito de acrescentar um modelo de volatilidade condicional a uma estratégia automatizada de negociação cuja previsão de direção permanece a mesma. A questão norteadora foi em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis.

Quanto ao risco, a resposta é clara. Em todos os períodos analisados, a versão do algoritmo com o GARCH sofreu quedas menores que a sua gêmea, que usa o mesmo ARIMA sem o modelo de volatilidade, e o efeito se repetiu nas outras três ações estudadas, sobretudo nos períodos de turbulência. O ano de 2008 resume bem esse comportamento. Enquanto a PETR4 perdia quase metade do seu valor, o ARIMA-GARCH encerrou o ano com um pequeno ganho.

Quanto ao desempenho, o efeito foi menos claro. Na maior parte dos testes, a versão com GARCH terminou com retorno maior que o da gêmea, mas essa vantagem só foi confirmada estatisticamente em uma das comparações, e em nenhuma delas o GARCH piorou o resultado de forma significativa. Em relação às médias móveis de Almeida (2016), o ARIMA-GARCH protegeu melhor nos momentos de queda, mas ganhou em alguns períodos e perdeu em outros, por diferenças que ficaram dentro da margem do acaso. Em relação à taxa Selic, o ARIMA-GARCH só rendeu mais no período de 2017 a 2024, e por uma margem que o acaso também explicaria. Nos demais períodos, rendeu menos.

A primeira hipótese afirmava que a integração entre ARIMA e GARCH gera sinais mais eficazes que o ARIMA isolado, tanto em acerto direcional quanto em adequação ao risco. Ela foi parcialmente confirmada. A adequação ao risco foi confirmada pelas quedas menores em todos os períodos, ainda que o desempenho ajustado ao risco, medido em relação à Selic, só tenha melhorado de forma significativa em uma das comparações. O acerto direcional, por outro lado, não melhorou e permaneceu próximo do acaso. Esse resultado é coerente com a teoria, pois o GARCH descreve o tamanho das oscilações, e não a direção dos preços. O ganho veio da seletividade. Ao deixar de operar nos dias de maior volatilidade prevista, o algoritmo agiu menos vezes e em condições mais regulares.

A segunda hipótese afirmava que a combinação representa um avanço em relação às análises baseadas em médias móveis. Ela foi confirmada apenas quanto ao risco. Em todos os períodos, houve uma variante com GARCH que protegeu mais do que as médias móveis, e a diferença foi grande sobretudo nos períodos de crise. Ainda assim, nem toda variante protegeu mais, e as que mantêm a posição aberta durante o veto chegaram a ter quedas maiores. Quanto ao retorno, as diferenças entre os dois algoritmos ficaram dentro da margem do acaso.

O objetivo geral, desenvolver em MQL5 um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar experimentalmente o efeito da inclusão do GARCH, foi alcançado. Os dois modelos foram implementados na própria linguagem da plataforma e validados por recuperação de parâmetros em séries com resposta conhecida. A escolha das ordens do ARIMA

foi automatizada pelo teste ADF e pelo critério de Akaike. A estratégia de Almeida (2016) foi reimplementada, e a reprodução dos seus testes confirmou o comportamento do algoritmo original, embora não os seus valores em reais, que dependem de informações que o estudo original não registra. Por fim, o protocolo com períodos de calibração e de teste separados foi definido antes da observação dos resultados e executado sobre dados oficiais, e os três algoritmos foram comparados quanto a retorno, risco e desempenho ajustado ao risco, com testes estatísticos.

Os resultados têm as limitações discutidas ao final do Capítulo III. A maior parte das diferenças não atinge significância estatística, a configuração que se sai melhor em um período não tende a repetir o desempenho no seguinte, os ganhos se concentram em poucos anos, a análise se restringe a quatro ativos de um único mercado e a medida de desempenho não inclui os proventos, que, quando incluídos, favorecem as estratégias que permanecem mais tempo compradas. Além disso, os experimentos foram realizados por simulação sobre dados históricos, com execução no preço de abertura e sem considerar a falta de liquidez ou a diferença entre o preço pedido e o executado, condições que só podem ser verificadas em operação real.

Como continuação, o resultado indica que o caminho mais promissor está no controle de risco, que foi onde o modelo mostrou efeito. Uma possibilidade é empregar variações assimétricas do GARCH, que reagem mais às quedas do que às altas, comportamento comum nas séries de ações e não capturado pela especificação simétrica utilizada. Outra é aplicar o mesmo protocolo a um conjunto maior de ativos e acompanhar o algoritmo em conta de demonstração, em tempo real, o que permitiria também avaliar as ordens de limite de perda e de realização de lucro que Almeida (2016) previu em seu algoritmo, mas não utilizou em seus testes.

No eixo da previsão, a próxima etapa é a que estava prevista no projeto original deste trabalho e foi deixada de lado para que a implementação do ARIMA e do GARCH pudesse ser concluída e validada: substituir o ARIMA por uma rede neural recorrente do tipo LSTM, do inglês *Long Short-Term Memory*, capaz de representar relações não lineares, mantendo o GARCH como filtro de risco. A arquitetura do algoritmo, que separa a previsão da direção da avaliação do risco, permite essa troca sem alterar o restante. Os resultados deste trabalho, porém, recomendam cautela na expectativa, já que a taxa de acerto direcional do ARIMA ficou próxima do acaso e o ganho observado veio do controle de risco, e não da previsão.

REFERÊNCIAS

ALMEIDA, F. L. R. *Técnicas de previsão da bolsa com MetaTrader 5*. Monografia (Graduação em Tecnologia em Banco de Dados) – Faculdade de Tecnologia de Indaiatuba, Indaiatuba, 2016. No Repositório Institucional do Centro Paula Souza o trabalho está catalogado sob o título "Análise da ação PETR4 na Bolsa de Valores de São Paulo com MetaTrader 5". Disponível em: <https://ric.cps.sp.gov.br/handle/123456789/24287>. Acesso em: 20 fev. 2025.

ARAYA, T. H.; ARAYA, J. A. A hybrid GARCH and deep learning method for volatility prediction. *Journal of Mathematics*, Londres, Reino Unido, v. 2024, 2024. Article ID 6305525.

B3. *Séries históricas de cotações (COTAHIST): arquivos anuais de 2003 a 2026*. São Paulo, 2026. Disponível em: <https://bvmf.bmfbovespa.com.br/InstDados/SerHist/>. Acesso em: 21 set. 2026.

BANCO CENTRAL DO BRASIL. *Bolsas de valores*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/pre/composicao/bv.asp?frame=1>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Corretoras e distribuidoras*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/acessoinformacao/legado?url=https:%2F%2Fwww.bcb.gov.br%2Fpre%2Fcomposicao%2Fcorretoras_distribuidoras.asp>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Taxa Selic*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/estatisticas/detalhamentoGrafico/graficoshome/selic>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Sistema Gerenciador de Séries Temporais: série 11, taxa de juros Selic, % ao dia*. Brasília, DF, 2026. Disponível em: <https://api.bcb.gov.br/dados/serie/bcdata.sgs.11/dados>. Acesso em: 21 set. 2026.

BATISTA, C. B. *Desenvolvimento de robô para automação de investimentos na bolsa de valores utilizando indicadores técnicos*. Monografia (Graduação em Engenharia de Computação) – Pontifícia Universidade Católica de Goiás, Goiânia, 2024. Disponível em: <https://repositorio.pucgoias.edu.br/jspui/handle/123456789/8073>. Acesso em: 30 mar. 2025.

BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, Elsevier, Amsterdam, v. 31, n. 3, p. 307–327, 1986.

ELDER, A. *Come into my trading room: a complete guide to trading*. Nova Iorque, EUA: Wiley, 2002.

ENGLE, R. F. Autoregressive conditional heteroskedasticity with estimates of the variance of the United Kingdom inflation. *Econometrica*, The Econometric Society, New Jersey, EUA, v. 50, n. 4, p. 987–1008, 1982.

FERNANDES, A. *Fundamentos de análise técnica de ações*. 1. ed. Rio de Janeiro: Campus, 2014.

MÁXIMO, W. Bolsa cai 30%, e dólar sobe 16% em março com pandemia de coronavírus. *Agência Brasil*, Brasília, 31 mar. 2020. Disponível em: <https://agenciabrasil.ebc.com.br/economia/noticia/2020-03/bolsa-cai-30-e-dolar-sobe-16-em-marco-com-pandemia-de-coronavirus>. Acesso em: 05 out. 2026.

METAQUOTES LTD. *MetaTrader 5: plataforma de negociação para Forex, ações e futuros*. Limassol: MetaQuotes Ltd., 2024. Disponível em: <https://www.metatrader5.com/pt>. Acesso em: 01 mar. 2025.

METAQUOTES LTD. *Relatório de teste*. Limassol, 2026. Ajuda para o MetaTrader 5. Página da ajuda da plataforma, sem data de publicação. Disponível em: <https://www.metatrader5.com/pt/terminal/help/algotrading/testing_report>. Acesso em: 05 out. 2026.

SHARPE, W. F. The Sharpe ratio. *The Journal of Portfolio Management*, Nova Iorque, v. 21, n. 1, p. 49–58, 1994. Disponível em: <https://web.stanford.edu/~wfsharpe/art/sr/sr.htm>. Acesso em: 05 out. 2026.

THOMAZ, P. S. *Modelos ARMA-GARCH na modelagem da volatilidade de ações financeiras*. Dissertação (Mestrado em Modelagem Computacional) – Universidade Federal do Rio Grande, Rio Grande, 2019. Disponível em: <http://repositorio.furg.br/handle/1/10204>. Acesso em: 12 out. 2026.

WAZLAWICK, R. S. *Metodologia de pesquisa para ciência da computação*. 2. ed. Rio de Janeiro: Elsevier, 2014.

XING, Y. et al. *Predicting NVIDIA's next-day stock price: a comparative analysis of LSTM, MLP, ARIMA, and ARIMA-GARCH models*. 2024. ArXiv. Preprint. Disponível em: <https://arxiv.org/abs/2405.08284>. Acesso em: 09 abr. 2025.

YAHOO FINANCE. *PETR4.SA: histórico de dividendos e desdobramentos*. 2026. Disponível em: <https://finance.yahoo.com/quote/PETR4.SA/history/>. Acesso em: 21 set. 2026.

APÊNDICES

APÊNDICE A – Código do *Expert Advisor*

Este apêndice apresenta o código do *Expert Advisor* desenvolvido neste trabalho. Para facilitar a leitura, foram retirados os comentários e as rotinas que não participam da decisão de operar, isto é, as mensagens de registro, o diagnóstico por pregão e o cálculo das medidas de desempenho no testador de estratégias. A versão reduzida continua sendo um programa completo e compila sem erros. As rotinas de estimação do ARIMA e do GARCH, de seleção das ordens e das formas de uso do GARCH estão em arquivos de inclusão próprios, chamados pelas diretivas `#include` do início do código.

```
#include <Trade\Trade.mqh>
#include "..\Include\Arima.mqh"
#include "..\Include\Garch.mqh"
#include "..\Include\SelecaoModelo.mqh"
#include "..\Include\Estrategia.mqh"

enum ENUM_TRANSFORMACAO
  {
   TRANSF_LOG_PRECO = 0,
   TRANSF_PRECO = 1
  };

enum ENUM_MODO_VOLUME
  {
   VOLUME_FIXO = 0,
   VOLUME_CAPITAL = 1
  };

enum ENUM_MODO_ORDENS
  {
   ORDENS_AUTOMATICO = 0,
   ORDENS_MANUAL = 1
  };

input group "=== Modelo ==="
input bool               UsarGARCH            = true;
input ENUM_TRANSFORMACAO Transformacao        = TRANSF_LOG_PRECO;
input ENUM_MODO_ORDENS   ModoOrdens           = ORDENS_AUTOMATICO;

input group "=== Ordens manuais ==="
input int                ARIMA_p              = 1;
input int                ARIMA_d              = 1;
input int                ARIMA_q              = 1;

input group "=== Ordens automaticas ==="
input int                Max_p                = 4;
input int                Max_q                = 4;
input int                Max_d                = 2;
input int                Janela_Selecao       = 240;
input int                Barras_Entre_Reselecao = 21;
input bool               IncluirConstante     = false;

input group "=== Estimacao a cada barra ==="
input int                Janela_Estimacao     = 120;
input int                GARCH_p              = 1;
input int                GARCH_q              = 1;
input int                Iteracoes_GARCH      = 300;

input group "=== Estrategia de uso do GARCH ==="
```

```
50  input ENUM_ESTRATEGIA_GARCH Estrategia        = EST_FILTRO_VOLATILIDADE;
51  input ENUM_MODO_LIMIAR   ModoLimiar           = LIMIAR_PERCENTIL;
52  input double             Limiar_Absoluto      = 0.020;
53  input double             Limiar_Percentil     = 50.0;
54  input double             Vol_Alvo             = 0.015;
55  input double             K_Confianca          = 0.50;
56  input double             Limiar_Sinal         = 0.0;
57
58  input group "=== Negociacao ==="
59  input ENUM_MODO_VOLUME   ModoVolume           = VOLUME_CAPITAL;
60  input double             Fracao_Capital       = 0.95;
61  input double             Volume_Base          = 100;
62  input double             Frac_Volume_Min      = 0.25;
63  input double             Frac_Volume_Max      = 2.00;
64  input int                StopLoss_Points      = 0;
65  input int                TakeProfit_Points    = 0;
66  input bool               PermitirReversao     = true;
67  input bool               SomenteCompra        = true;
68  input bool               ZerarNoVeto          = false;
69
70  input group "=== Sistema ==="
71  input ulong              MagicNumber          = 20260803;
72  input int                Slippage             = 10;
73
74  CTrade   g_trade;
75  CArima   g_arima;
76  CGarch   g_garch;
77
78  int      g_p = 1, g_d = 1, g_q = 1;
79  int      g_digits;
80  double   g_ponto;
81  datetime g_ultima_barra = 0;
82  int      g_barras_desde_selecao = 0;
83  bool     g_ordens_definidas = false;
84
85  bool CarregarSerie(const int quantidade, double &saida[])
86    {
87     double fechamento[];
88     int copiados = CopyClose(_Symbol, _Period, 1, quantidade, fechamento);
89
90     if(copiados < quantidade)
91        return(false);
92
93     ArrayResize(saida, copiados);
94
95     for(int i = 0; i < copiados; i++)
96       {
97        if(Transformacao == TRANSF_LOG_PRECO)
98          {
99           if(fechamento[i] <= 0.0)
100             return(false);
101          saida[i] = MathLog(fechamento[i]);
102          }
103       else
104          saida[i] = fechamento[i];
105     }
106
107    return(true);
108  }
109
110 bool SelecionarOrdens()
111   {
112    double serie[];
```

```
113    int janela = MathMax(Janela_Selecao, Janela_Estimacao);
114
115    if(!CarregarSerie(janela, serie))
116      {
117       return(false);
118      }
119
120    ResultadoSelecao res;
121    string relatorio = "";
122
123    bool ok = SelecionarModelo(serie, Max_d, Max_p, Max_q,
124                               IncluirConstante, ADF_CONSTANTE,
125                               res, relatorio);
126
127    if(!ok)
128       return(false);
129
130    g_p = res.p;
131    g_d = res.d;
132    g_q = res.q;
133    g_ordens_definidas = true;
134    g_barras_desde_selecao = 0;
135
136    return(true);
137   }
138
139 int OnInit()
140   {
141    g_digits = (int)SymbolInfoInteger(_Symbol, SYMBOL_DIGITS);
142    g_ponto  = SymbolInfoDouble(_Symbol, SYMBOL_POINT);
143
144    g_trade.SetExpertMagicNumber(MagicNumber);
145    g_trade.SetDeviationInPoints(Slippage);
146    g_trade.SetTypeFillingBySymbol(_Symbol);
147
148    if(Janela_Estimacao < 80)
149      {
150       return(INIT_PARAMETERS_INCORRECT);
151      }
152
153    if(Frac_Volume_Min <= 0.0 || Frac_Volume_Max < Frac_Volume_Min)
154      {
155       return(INIT_PARAMETERS_INCORRECT);
156      }
157
158    if(ModoVolume == VOLUME_CAPITAL && (Fracao_Capital <= 0.0 || Fracao_Capital > 1.0))
159      {
160       return(INIT_PARAMETERS_INCORRECT);
161      }
162
163    if(ModoLimiar == LIMIAR_PERCENTIL &&
164       (Limiar_Percentil <= 0.0 || Limiar_Percentil >= 100.0))
165      {
166       return(INIT_PARAMETERS_INCORRECT);
167      }
168
169    if(ModoOrdens == ORDENS_MANUAL)
170      {
171       g_p = MathMax(0, ARIMA_p);
172       g_d = MathMax(0, MathMin(2, ARIMA_d));
173       g_q = MathMax(0, ARIMA_q);
174       g_ordens_definidas = true;
175      }
```

```
176     else
177       {
178
179        SelecionarOrdens();
180       }
181
182     g_arima.Definir(g_p, g_d, g_q, IncluirConstante);
183     g_garch.Definir(GARCH_p, GARCH_q);
184     g_garch.DefinirOtimizador(Iteracoes_GARCH);
185
186     return(INIT_SUCCEEDED);
187    }
188
189  void OnTick()
190    {
191
192     datetime barra = (datetime)SeriesInfoInteger(_Symbol, _Period, SERIES_LASTBAR_DATE);
193     if(barra == g_ultima_barra)
194        return;
195     g_ultima_barra = barra;
196
197     if(ModoOrdens == ORDENS_AUTOMATICO)
198       {
199        bool precisa = (!g_ordens_definidas) ||
200                       (Barras_Entre_Reselecao > 0 &&
201                        g_barras_desde_selecao >= Barras_Entre_Reselecao);
202
203        if(precisa)
204          {
205           if(SelecionarOrdens())
206             {
207              g_arima.Definir(g_p, g_d, g_q, IncluirConstante);
208             }
209          }
210        g_barras_desde_selecao++;
211       }
212
213     if(!g_ordens_definidas)
214        return;
215
216     double serie[];
217     if(!CarregarSerie(Janela_Estimacao, serie))
218        return;
219
220     if(!g_arima.Ajustar(serie))
221       {
222        return;
223       }
224
225     double previsao = (g_arima.D() == 1)
226                       ? g_arima.PreverDiferenciado()
227                       : g_arima.PreverNivel() - serie[ArraySize(serie) - 1];
228
229     if(!MathIsValidNumber(previsao))
230       {
231        return;
232       }
233
234     double vol_prevista = 0.0;
235     double limiar = Limiar_Absoluto;
236     bool   garch_ok = false;
237
238     if(UsarGARCH)
```

```
239       {
240        double residuos[];
241
242        if(!g_arima.ObterResiduos(residuos))
243          {
244           return;
245          }
246
247        if(g_garch.Ajustar(residuos))
248          {
249           vol_prevista = g_garch.VolatilidadeProximoPeriodo();
250           garch_ok = true;
251
252           if(ModoLimiar == LIMIAR_PERCENTIL)
253             {
254              double serie_vol[];
255              if(g_garch.ObterSerieVolatilidade(serie_vol))
256                 limiar = Percentil(serie_vol, Limiar_Percentil);
257              else
258                 limiar = Limiar_Absoluto;
259             }
260          }
261        else
262          {
263
264           return;
265          }
266       }
267
268     DecisaoOperacao dec;
269     DecidirOperacao(previsao, vol_prevista, UsarGARCH, Estrategia,
270                     limiar, Vol_Alvo, K_Confianca,
271                     Volume_Base, Frac_Volume_Min, Frac_Volume_Max,
272                     Limiar_Sinal, dec);
273
274     if(dec.sinal != 0)
275        Executar(dec);
276     else if(dec.bloqueou_garch && ZerarNoVeto)
277       {
278
279        ENUM_POSITION_TYPE posicao = PosicaoAtual();
280        if(posicao == POSITION_TYPE_BUY || posicao == POSITION_TYPE_SELL)
281           FecharPosicao(posicao);
282       }
283
284   }
285
286 void Executar(const DecisaoOperacao &dec)
287   {
288    MqlTick tick;
289    if(!SymbolInfoTick(_Symbol, tick) || tick.ask <= 0.0 || tick.bid <= 0.0)
290       return;
291
292    ENUM_POSITION_TYPE posicao = PosicaoAtual();
293
294    if(dec.sinal < 0 && SomenteCompra)
295      {
296       if(posicao == POSITION_TYPE_BUY)
297          FecharPosicao(POSITION_TYPE_BUY);
298       return;
299      }
300
301    double volume = AjustarVolume(VolumeDesejado(dec.volume,
```

```
302                                  (dec.sinal > 0) ? tick.ask : tick.bid));
303
304    if(volume <= 0.0)
305       return;
306
307    if(dec.sinal > 0)
308      {
309       if(posicao == POSITION_TYPE_SELL)
310         {
311          if(!PermitirReversao)
312             return;
313
314          if(!FecharPosicao(POSITION_TYPE_SELL))
315             return;
316          posicao = PosicaoAtual();
317         }
318
319       if(posicao == POSITION_TYPE_BUY)
320          return;
321
322       double sl = (StopLoss_Points > 0)
323                   ? NormalizeDouble(tick.ask - StopLoss_Points * g_ponto, g_digits) :
                        0.0;
324       double tp = (TakeProfit_Points > 0)
325                   ? NormalizeDouble(tick.ask + TakeProfit_Points * g_ponto, g_digits) :
                        0.0;
326
327       g_trade.Buy(volume, _Symbol, tick.ask, sl, tp, "ARIMA-GARCH BUY");
328
329       return;
330      }
331
332    if(posicao == POSITION_TYPE_BUY)
333      {
334       if(!PermitirReversao)
335          return;
336       if(!FecharPosicao(POSITION_TYPE_BUY))
337          return;
338       posicao = PosicaoAtual();
339      }
340
341    if(posicao == POSITION_TYPE_SELL)
342       return;
343
344    double sl = (StopLoss_Points > 0)
345                ? NormalizeDouble(tick.bid + StopLoss_Points * g_ponto, g_digits) : 0.0;
346    double tp = (TakeProfit_Points > 0)
347                ? NormalizeDouble(tick.bid - TakeProfit_Points * g_ponto, g_digits) : 0.0;
348
349    g_trade.Sell(volume, _Symbol, tick.bid, sl, tp, "ARIMA-GARCH SELL");
350   }
351
352 ENUM_POSITION_TYPE PosicaoAtual()
353   {
354    for(int i = PositionsTotal() - 1; i >= 0; i--)
355      {
356       ulong ticket = PositionGetTicket(i);
357       if(ticket == 0 || !PositionSelectByTicket(ticket))
358          continue;
359
360       if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
361          (ulong)PositionGetInteger(POSITION_MAGIC) == MagicNumber)
362          return((ENUM_POSITION_TYPE)PositionGetInteger(POSITION_TYPE));
```

```
363       }
364
365     return((ENUM_POSITION_TYPE)-1);
366    }
367
368  bool FecharPosicao(const ENUM_POSITION_TYPE tipo)
369    {
370     for(int i = PositionsTotal() - 1; i >= 0; i--)
371       {
372        ulong ticket = PositionGetTicket(i);
373        if(ticket == 0 || !PositionSelectByTicket(ticket))
374           continue;
375
376        if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
377           (ulong)PositionGetInteger(POSITION_MAGIC) == MagicNumber &&
378           PositionGetInteger(POSITION_TYPE) == tipo)
379          {
380           if(g_trade.PositionClose(ticket, Slippage))
381              return(true);
382
383           return(false);
384          }
385       }
386
387     return(true);
388    }
389
390  double VolumeDesejado(const double volume_decisao, const double preco)
391    {
392     if(ModoVolume == VOLUME_FIXO || preco <= 0.0)
393        return(volume_decisao);
394
395     double fator = (Volume_Base > 0.0) ? volume_decisao / Volume_Base : 1.0;
396     return(VolumePorCapital(_Symbol, Fracao_Capital * fator, preco));
397    }
398
399  double AjustarVolume(double volume)
400    {
401     double v_min  = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MIN);
402     double v_max  = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MAX);
403     double v_step = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_STEP);
404
405     if(v_step > 0.0)
406        volume = MathRound(volume / v_step) * v_step;
407
408     if(volume < v_min) volume = v_min;
409     if(v_max > 0.0 && volume > v_max) volume = v_max;
410
411     int casas = 0;
412     if(v_step > 0.0 && v_step < 1.0)
413        casas = (int)MathCeil(-MathLog10(v_step));
414
415     return(NormalizeDouble(volume, casas));
416    }
```