

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

**Previsão e Análise de Tendências no Mercado de Ativos:
Desenvolvimento de Ferramenta Algorítmica com Modelos
Estatísticos no MetaTrader 5**

Indaiatuba

2025

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

**Previsão e Análise de Tendências no Mercado de Ativos:
Desenvolvimento de Ferramenta Algorítmica com Modelos
Estatísticos no MetaTrader 5**

Trabalho de graduação apresentado por Bruno Rocha Pereira e Giovanni Silva Loose como pré-requisito para a conclusão do Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Faculdade de Tecnologia de Indaiatuba, elaborado sob a orientação do Prof. MsC. Michel Moron Munhoz.

Indaiatuba

2025

RESUMO

O cenário econômico brasileiro recente, caracterizado por instabilidade macroeconômica, inflação elevada e consequente aumento da taxa Selic, impõe desafios significativos aos investidores. A volatilidade do mercado financeiro, intensificada por fatores internos e externos, dificulta a tomada de decisões de investimento, especialmente em ativos como ações. Diante desse contexto e da crescente digitalização do setor financeiro, o trading algorítmico apresenta-se como uma alternativa promissora. Este trabalho apresenta o desenvolvimento de um algoritmo de negociação, escrito na linguagem MQL5 para a plataforma MetaTrader 5, para análise de padrões de tendência e volatilidade no mercado de ações brasileiro, tomando como base o ativo PETR4. O algoritmo integra análises técnicas estatísticas, combinando o uso de Médias Móveis para identificação de tendências e os modelos ARIMA para previsão de séries temporais de preços e GARCH para modelagem da volatilidade condicional dos resíduos do ARIMA. A premissa central deste trabalho é que essa abordagem integrada permite a geração de sinais de negociação com maior eficácia (potencial de acerto e adequação ao risco) em comparação com o uso isolado ou incompleto dessas técnicas. O estudo explorou modelos com dados atualizados, fornecendo análises que possam embasar estratégias de investimento adaptadas ao cenário de juros altos e investigando a robustez da combinação de modelos ARIMA e GARCH frente às flutuações do mercado, contribuindo para o conhecimento na área e oferecendo uma alternativa prática para investidores.

Palavras-chave: Trading Algorítmico. Modelos Estatísticos. ARIMA. GARCH. Mercado de Ações. Bolsa de Valores. Volatilidade. MetaTrader 5.

ABSTRACT

The recent Brazilian economic scenario, characterized by macroeconomic instability, high inflation, and a consequent increase in the Selic interest rate, poses significant challenges for investors. Financial market volatility, intensified by internal and external factors, hinders investment decision-making, especially in assets such as stocks. Given this context and the increasing digitalization of the financial sector, algorithmic trading presents itself as a promising alternative. This paper presents the development of a trading algorithm, written in the MQL5 language for the MetaTrader 5 platform, for analyzing trend and volatility patterns in the Brazilian stock market, focusing on the PETR4 asset. The algorithm integrates statistical technical analyses, combining the use of Moving Averages for trend identification with the ARIMA model for forecasting price time series and the GARCH model for modeling the conditional volatility of ARIMA residuals. The central premise of this work is that this integrated approach allows the generation of trading signals with greater effectiveness (potential accuracy and risk suitability) compared to the isolated or incomplete use of these techniques. The study explored models with updated data, providing analyses that can support investment strategies adapted to the high-interest-rate scenario, and investigated the robustness of the combined ARIMA and GARCH models against market fluctuations, contributing to knowledge in the field and offering a practical alternative for investors.

Keywords: Algorithmic Trading. Statistical Models. ARIMA. GARCH. Stock Market. Volatility. MetaTrader 5.

LISTA DE FIGURAS

Figura 1 – Interface MetaTrader	15
Figura 2 – Fluxograma do Funcionamento do EA	16
Figura 3 – Tendência de Alta com RSI	18
Figura 4 – Cruzamento de médias móveis	19
Figura 5 – Fluxo ARIMA	22
Figura 6 – Fluxo GARCH	24
Figura 7 – Modelo Completo	32
Figura 8 – Desempenho do modelo proposto (2º teste)	34
Figura 9 – Gráfico de dispersão da correlação de lucro (2º teste)	35

LISTA DE TABELAS

Tabela 1 – Variações da SELIC anual, Meta e Real (2020-2025*).....	8
Tabela 2 – Tabela Comparativa	28
Tabela 3 – Tabela Comparativa (Detalhada)	28
Tabela 4 – Comparação modelo proposto x ALMEIDA (2016)	34

LISTA DE SIGLAS

ADF	Augmented Dickey-Fuller
AIC	Akaike Information Criterion
API	Application Programming Interface
ARIMA	AutoRegressive Integrated Moving Average
Copom	Comitê de Política Monetária
EA	Expert Advisor
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
IFR	Índice de Força Relativa
MAE	Mean Absolute Error
MACD	Moving Average Convergence Divergence
MM	Média Móvel
MME	Média Móvel Exponencial
MMS	Média Móvel Simples
MQL5	MetaQuotes Language 5
MT5	MetaTrader 5
PETR4	Código de negociação das ações preferenciais da Petrobras
PIB	Produto Interno Bruto
RMSE	Root Mean Square Error
RSI	Relative Strength Index
SELIC	Sistema Especial de Liquidação e de Custódia
SL	Stop Loss
TG	Trabalho de Graduação
TP	Take Profit

SUMÁRIO

INTRODUÇÃO	8
CAPÍTULO I	12
1 Fundamentação Teórica.....	12
1.1 Macro, Microeconomia e Inflação	12
1.2 Corretora	12
1.3 Bolsa de Valores	13
1.4 Ativos	13
1.5 Tipos de Análise Técnica	13
1.6 MetaTrader 5	15
1.7 Indicadores.....	17
1.8 Modelos Estatísticos	21
1.9 Trabalhos Relacionados	25
CAPÍTULO II	29
2 Metodologia	29
2.1 Natureza da Pesquisa	29
2.2 Padrões para Pesquisa Experimental	29
2.3 Obstáculos Encontrados.....	30
2.4 Experimento de Pesquisa	31
2.5 Diagramas	31
2.6 Critérios para Avaliação.....	31
2.7 Resultados preliminares atingidos no PTG.....	32
2.8 Limitações e Trabalhos Futuros	35
CAPÍTULO III	37
3 Conclusão e Considerações Finais	37
3.1 Conclusão.....	37
3.2 Considerações Finais	38
REFERÊNCIAS.....	40

INTRODUÇÃO

Nos últimos anos, a economia brasileira tem enfrentado um cenário desafiador, marcado por instabilidade macroeconômica e oscilações no mercado financeiro. Para tentar controlar a inflação pressionada pela alta do dólar e pelos desafios nas contas públicas, o Banco Central tem buscado contê-la por meio do aumento da taxa Selic, que alcançou 14,25% ao ano e pode ultrapassar 15%. Definida periodicamente pelo Comitê de Política Monetária (Copom), essa taxa reflete as condições macroeconômicas do país e as expectativas para a inflação em 2025, segundo previsões de instituições financeiras como Citi, Itaú e XP (AYRES, 2025).

Esse aumento da Selic reflete preocupações com a inflação, que vem subindo não só pelo custo maior de produtos importados, consequência direta da desvalorização do Real, mas também por fatores internos, como o consumo elevado e a falta de confiança na estabilidade fiscal do país. Essa instabilidade do mercado financeiro está diretamente relacionada à política monetária adotada pelo Banco Central, com destaque para a taxa Selic. Como principal instrumento para o controle da inflação e a regulação da atividade econômica, a Selic influencia diretamente outras taxas de juros, como as de empréstimos, financiamentos e aplicações financeiras (BRASIL. Banco Central do Brasil, 2025d). Mudanças significativas na Selic podem alterar a dinâmica do mercado financeiro, impactando tanto o custo do crédito quanto o retorno dos investimentos.

Tabela 1 – Variações da SELIC anual, Meta e Real (2020-2025*)

Ano	SELIC Meta (%)	SELIC Real (%)
2025	14,25*	—
2024	12,25	12,15
2023	11,75	11,65
2022	13,75	13,65
2021	9,25	9,15
2020	2,00	1,90

Fonte: Banco Central do Brasil (2025).

Apesar do cenário desafiador, a economia brasileira continua crescendo, com um avanço de 3,3% em 2024 e previsão de 2,5% para 2025 no PIB (AYRES, 2024). Esse crescimento, porém, acontece em meio a dificuldades. A alta dos juros torna o crédito mais caro e desestimula novos investimentos, enquanto a queda do Real, ainda que favoreça os exportadores, encarece produtos e reduz o poder de compra da população.

Por outro lado, a crescente digitalização e modernização do mercado financeiro impulsiona o desenvolvimento de soluções tecnológicas que visam otimizar o processo de tomada de decisão e mitigar os riscos inerentes ao mercado, como o surgimento do trading algorítmico¹ (ALMEIDA, 2016; SILVA, 2022). Essa forma automatizada de investir ganha relevância ao executar operações a partir de modelos matemáticos e estatísticos, buscando maior eficiência operacional na identificação de padrões de tendência nos ativos financeiros. Embora o estudo

¹ Negociação de ativos automatizada por algoritmos.

de Almeida (2016) aponte desafios quanto à lucratividade em períodos de crise, seus resultados demonstram o potencial desse tipo de automação para apoiar a tomada de decisões e buscar resultados consistentes, sobretudo em cenários de mercado mais estáveis.

Conforme apontado em artigo da Forbes (COJOCARU, 2024), essa tendência digital, que já automatiza entre 60% e 73% das negociações de ações nos EUA, está se expandindo globalmente. Empresas como Trade Ideas, TrendSpider e Imperative Execution utilizam inteligência artificial para analisar grandes volumes de dados, prevendo tendências de mercado e padrões, e plataformas como TD Ameritrade, Interactive Brokers e TradeStation oferecem ferramentas e APIs para que investidores, inclusive de varejo, desenvolvam e implementem suas próprias estratégias. Diante desse cenário, este trabalho desenvolveu um algoritmo baseado em modelos estatísticos para analisar padrões de tendência no mercado de ativos, explorando as oportunidades geradas pela volatilidade.

Desse contexto decorre o problema investigado. A alta inflação é constante no mercado brasileiro da atualidade, amplamente estudada e divulgada pelo BCB, mais especificamente pelo órgão COPOM, que regula e configura a taxa mais adequada para os níveis inflacionários no país. Os sucessivos aumentos da taxa básica de juros tornam investimentos menos favoráveis e comprometem o poder de compra, o que representa um desafio central para a manutenção de patrimônio. Sobre isso pesa a instabilidade inerente aos ativos financeiros, que dificulta previsões confiáveis, enquanto a inflação persistente desvaloriza a moeda nacional e exige do investidor estratégias voltadas primordialmente à proteção do capital e, secundariamente, à obtenção de retornos reais positivos.

Nesse ambiente adverso, torna-se essencial buscar modalidades de investimento que sejam adaptadas à inflação vigente e resilientes às oscilações frequentes e, por vezes, abruptas do mercado. Os modelos tradicionais de análise de investimento se mostram complexos diante da dinâmica atual, o que amplia o desafio. Emerge, portanto, a necessidade de métodos analíticos mais avançados, capazes de auxiliar na identificação de padrões de tendência e em decisões de investimento mais informadas e potencialmente mais seguras neste contexto econômico particular.

Para responder a esse problema, o trabalho partiu de uma premissa central. A integração metodológica entre a previsão de séries temporais com o modelo ARIMA e a modelagem de volatilidade condicional com o modelo GARCH, reunidos em um único algoritmo, permite gerar sinais de negociação com maior eficácia, aferida em termos de potencial de acerto e adequação ao risco, do que abordagens que empregam essas técnicas de forma isolada ou incompleta. A viabilidade de combinar diferentes técnicas de análise para obter resultados superiores encontra respaldo em trabalhos como o de Batista (2024), que demonstrou resultados positivos ao integrar indicadores técnicos em um modelo de negociação.

Dessa premissa central decorreram outras duas. A primeira é a de que a combinação sequencial dos modelos ARIMA e GARCH constitui um avanço significativo em relação a

análises baseadas em Médias Móveis, como as exploradas por Almeida (2016). Esperava-se que o ARIMA capturasse a dinâmica temporal e fornecesse previsões de curto prazo da direção dos preços com maior refinamento do que as médias, e que o GARCH, aplicado aos resíduos gerados pelo ARIMA, detalhasse a volatilidade e o risco associados a essas previsões, permitindo uma avaliação mais ampla do cenário de mercado. A segunda é a de que a modelagem estatística da volatilidade, complementada por métricas quantitativas de risco, assegura uma leitura mais robusta das condições de mercado, de modo que a análise integrada de tendência e risco reduz a probabilidade de decisões inadequadas em momentos desfavoráveis e aumenta a seletividade e a segurança das operações identificadas.

Com base nessas premissas, o objetivo geral deste trabalho foi desenvolver e avaliar um algoritmo de negociação escrito em MQL5 para a plataforma MetaTrader 5, capaz de analisar e prever tendências no mercado de ações brasileiro. Para alcançá-lo, foi necessário aprofundar os conceitos teóricos do mercado financeiro, com ampla ênfase em volatilidade e tendências, e aplicá-los na automação de estratégias dentro dessa plataforma. Foi preciso também implementar os modelos estatísticos ARIMA e GARCH para previsão de séries temporais e modelagem de volatilidade, avaliar o desempenho obtido por meio de backtesting com dados históricos e documentar os obstáculos encontrados e as lições aprendidas durante a execução do projeto.

A pesquisa se justifica, inicialmente, pela revisitação e aplicação contemporânea do conceito explorado por Almeida (2016), cujo estudo demonstrou a viabilidade do uso de robôs de investimento em diferentes períodos sobre o ativo PETR4. Desde então, houve evolução significativa nos cenários econômicos e nas tecnologias disponíveis, o que motiva esta nova abordagem, alinhada às recomendações do próprio autor para aplicação em mercados de alta volatilidade.

Justifica-se, ainda, pela necessidade de identificar e avaliar alternativas de investimento viáveis e potencialmente lucrativas diante da inflação persistente e dos juros elevados no Brasil, contribuindo para mitigar os efeitos do congelamento financeiro que pode afetar investidores nesse contexto e oferecendo análises que embasem decisões de quem deseja diversificar seus portfólios. Por fim, o estudo busca agregar valor ao conhecimento acadêmico na área de finanças quantitativas e negociação automatizada no contexto brasileiro, podendo servir de base ou inspiração para futuros projetos relacionados.

Quanto à natureza e ao tipo, esta pesquisa é empírica e aplicada. É empírica porque se dedica à investigação de fenômenos observáveis do mundo real. Conforme Wazlawick (2014), a ciência empírica busca o conhecimento através da experiência e da observação, o que aqui se manifesta na análise de dados históricos de preços de ações para a identificação de padrões e tendências, cuja coleta e tratamento são fundamentais para a construção e a validação do que foi desenvolvido. É aplicada porque, ainda segundo o autor, a ciência aplicada se preocupa com a utilização prática do conhecimento científico na solução de problemas específicos, e um algoritmo voltado a auxiliar investidores atende a uma demanda concreta de tomada de decisão e

de gestão de riscos.

A pesquisa também se aproxima das ciências exatas, ainda que com ressalvas, e se alinha ao rigor metodológico das ciências hard. O uso de modelos estatísticos como ARIMA e GARCH e a adoção de métricas quantitativas para avaliar o desempenho refletem a busca por precisão e objetividade, enquanto a definição dessas métricas e a validação empírica por meio de backtesting demonstram a preocupação com a solidez e a replicabilidade dos resultados, características que Wazlawick (2014) atribui às ciências hard. É preciso reconhecer, porém, que o mercado financeiro é intrinsecamente marcado pela incerteza e pela volatilidade, elemento de inexatidão que o distingue dos sistemas puramente determinísticos com os quais as ciências exatas tradicionalmente lidam.

Há, por fim, um componente nomotético e um caráter explicativo. As ciências nomotéticas buscam estabelecer leis gerais ou princípios que expliquem classes de fenômenos (WAZLAWICK, 2014), e a análise de tendências e volatilidade procura identificar padrões que, dentro de certas limitações, auxiliem na previsão do comportamento futuro dos ativos. A pesquisa explicativa, por sua vez, busca as causas dos fenômenos e as relações entre variáveis. Neste caso, procurou-se explicar como a combinação de diferentes modelos estatísticos influencia a capacidade preditiva e a gestão de riscos no mercado de ações. Quanto aos procedimentos técnicos, o estudo combinou pesquisa bibliográfica, que forneceu a base teórica e conceitual sobre modelos estatísticos e negociação automatizada, e pesquisa experimental, conduzida por meio de backtesting, com a manipulação dos parâmetros dos modelos e a observação dos resultados de taxa de acerto e de lucro ou prejuízo.

Quanto à organização do texto, o Capítulo 1 apresenta a Fundamentação Teórica. Ele parte de conceitos introdutórios de economia e do mercado financeiro, como o funcionamento de corretoras, as bolsas de valores e as características dos ativos negociados, e avança para os temas técnicos, entre eles as diferentes abordagens da análise técnica, com foco nos métodos estatísticos, a plataforma MetaTrader 5 e a linguagem MQL5, os indicadores de mercado e os modelos estatísticos de séries temporais e de volatilidade. O capítulo se encerra com a revisão de pesquisas anteriores, que posiciona este estudo em relação ao que já existe na área.

O Capítulo 2 detalha a Metodologia, explicando como o algoritmo foi construído e validado. Nele são descritos a natureza da pesquisa, o ambiente dos experimentos, os programas utilizados e as fontes de dados do ativo em estudo, bem como a condução do experimento, que começou pelas análises baseadas em indicadores de tendência e avançou para a modelagem estatística dos preços e da volatilidade dos resíduos por meio dos modelos ARIMA e GARCH. O capítulo traz ainda os obstáculos encontrados durante a execução, os critérios de avaliação dos modelos, os resultados preliminares, as limitações e as perspectivas de trabalhos futuros. Por fim, o Capítulo 3 reúne a conclusão e as considerações finais.

CAPÍTULO I

1 Fundamentação Teórica

1.1 Macro, Microeconomia e Inflação

O cenário econômico global recente tem sido impactado por choques simultâneos: conflitos geopolíticos, problemas gerais nas cadeias produtivas e pressões inflacionárias de alto risco. Conforme o FUNDO MONETÁRIO INTERNACIONAL (FMI) (2024), esse cenário evidencia um problema estrutural do sistema internacional: a liquidez global supera, em alguns níveis, a produção real, criando distorções gerais nos preços e no crescimento econômico.

No Brasil, a microeconomia sofre os efeitos desse ambiente. A taxa Selic em 14,25% (BRASIL. Banco Central do Brasil, 2025d) desestimula investimentos em produção real, como comprovam os estudos do BRASIL. Banco Central do Brasil (2025c), que relacionam juros altos à migração do capital para aplicações financeiras, reduzindo posições no setor industrial.

A inflação, por fim, é um desafio em especial. O FUNDO MONETÁRIO INTERNACIONAL (FMI) (2024) alertou que as economias emergentes, assim como a brasileira, enfrentam o “trade-off” perverso: políticas monetárias com grande enfoque restritivo controlam os preços, mas sacrificam, no curto prazo, o crescimento do PIB.

Diante desse cenário geral, alternativas economicamente viáveis tornam-se uma prioridade, especialmente as menos atreladas às variáveis macroeconômicas. Essa contextualização servirá de pano de fundo para o estudo de estratégias de análise econômica, que serão detalhadas no decorrer do projeto.

1.2 Corretora

De acordo com o BCB (Banco Central do Brasil), as corretoras e distribuidoras, na atividade de intermediação, oferecem serviços como plataformas de investimento pela internet (home broker), consultoria financeira, clubes de investimentos, financiamento para compra de ações (conta margem) e administração e custódia de títulos e valores mobiliários dos clientes. Na remuneração pelos serviços, essas instituições podem cobrar comissões e taxas (BRASIL. Banco Central do Brasil, 2025b).

Portanto, a substancial necessidade de um serviço mediador para representação em ativos de capital aberto, ou seja, ativos que possuem participação em mercado anunciadas para o acesso do grande público. Além disso, existem séries de medidas formais que se demonstram necessárias para o processo burocrático da parte fiscal e jurídica na transação de participações em empresas, medidas essas que são assumidas por serviços de corretagem.

1.3 Bolsa de Valores

De acordo com o BCB (Banco Central do Brasil), as bolsas de valores são sociedades anônimas ou associações civis, com o objetivo de manter local ou sistema adequado ao encontro de seus membros e à realização entre eles de transações de compra e venda de títulos e valores mobiliários, em mercado livre e aberto, especialmente organizado e fiscalizado por seus membros e pela Comissão de Valores Mobiliários. Possuem autonomia financeira, patrimonial e administrativa (Resolução CMN 2.690, de 2000) (BRASIL. Banco Central do Brasil, 2025a).

Diante da necessidade de capital exógeno, as empresas possuem o mecanismo de capital aberto que possibilita a entrada de capital de fora da empresa por parte de investidores; em contrapartida, a empresa cede porcentagens do negócio proporcionais aos montantes investidos por parte dos acionistas. Concluindo, a prática é extremamente relevante para fomentar e financiar o escalonamento da empresa, mesmo que sejam cedidos percentuais do empreendimento, o montante geral escalonado é, geralmente, maior que o montante de capital fechado.

1.4 Ativos

De acordo com a Warren Magazine, os ativos são todos aqueles que possuem expectativa de superar o desempenho do mercado ou de um índice de referência. Utilizando-se de análises detalhadas, pesquisas de mercado e previsões econômicas, os gestores se alinham para decisões por posições em investimentos (WARREN MAGAZINE, 2025).

Por fim, os gestores buscam por oportunidades de investimento que possam gerar retornos acima da média do ativo e do mercado, alinhando-se ao princípio de alocação eficiente de capital. Assim como destacado por Elder (2002), cada decisão de investimento requer uma análise minuciosa do trade-off, escolha com custo de oportunidade, entre risco e retorno, uma vez que os recursos são limitados e devem ser distribuídos de forma otimizada. Todavia, em cenários adversos, pode-se demonstrar necessário o rebalanceamento da carteira, estrategicamente mitigando perdas de capital, prática comum em mercados voláteis, assim como foi apontado por Ayres (2025).

1.5 Tipos de Análise Técnica

Uma forma de tentar prever o que vai acontecer com os preços dos ativos no mercado financeiro é usar a análise técnica. Essa análise estuda o histórico dos preços para encontrar padrões e tendências que possam indicar o que pode acontecer no futuro. Essa ideia surgiu há muito tempo, com o comércio de arroz, e hoje é usada para analisar ações, moedas e outros ativos. O importante é olhar para os preços, sem se preocupar com notícias ou outras coisas que possam influenciar o mercado (FERNANDES, 2014).

A análise técnica pode ser usada em quase todos os mercados e mistura ciência com a forma como as pessoas pensam e agem nesses mercados. Para ter mais chances de sucesso, é bom se especializar em um mercado e escolher as ferramentas certas para analisar os dados. Existem dois jeitos principais de fazer análise técnica: a mais antiga, chamada empírica ou clássica, e a mais moderna, chamada estatística (FERNANDES, 2014).

1.5.1 Análise Técnica Empírica ou Clássica

A análise técnica empírica, ou clássica, é o método mais tradicional de analisar o mercado financeiro. Nessa abordagem, os analistas usavam seus gráficos impressos, observando cuidadosamente o movimento dos preços manualmente, com ferramentas mais simples e rudimentares como réguas e lápis (FERNANDES, 2014).

O objetivo dela é identificar tendências de alta ou de baixa nos preços, assim como encontrar áreas onde os preços geralmente encontram dificuldades para ultrapassar (resistências) ou onde encontram apoio e param de cair (suportes). Além disso, esse analista busca por padrões gráficos, que se repetem ao longo do tempo e que, segundo essa abordagem, podem sinalizar movimentos futuros dos preços (FERNANDES, 2014).

Apesar de sua tradição, essa análise pode ser um tanto subjetiva. A interpretação dos gráficos, a identificação dos padrões e a definição das áreas de suporte e resistência dependem muito da experiência e da percepção de cada analista, o que pode levar a conclusões diferentes sobre o mesmo ativo (FERNANDES, 2014).

1.5.2 Análise Técnica Estatística ou Moderna

A análise técnica estatística, ou moderna, representa uma abordagem mais científica para analisar o mercado financeiro. Em vez de depender da interpretação visual e subjetiva dos gráficos, os analistas utilizam modelos matemáticos e estatísticos para analisar os preços dos ativos (FERNANDES, 2014).

Para isso, utilizam programas de computador que calculam uma variedade de indicadores técnicos, como médias móveis (que suavizam os movimentos dos preços e ajudam a identificar tendências), osciladores (como o Índice de Força Relativa – RSI, que indica se um ativo está “sobrecomprado” ou “sobrevendido”) e muitos outros. Esses indicadores fornecem informações objetivas sobre o comportamento do mercado, auxiliando na tomada de decisões (FERNANDES, 2014).

Essa abordagem é considerada mais objetiva, pois minimiza a influência da subjetividade na interpretação dos dados, utilizando métodos quantitativos e modelos matemáticos para auxiliar na tomada de decisões (FERNANDES, 2014).

Neste trabalho, adotaremos a análise técnica estatística para criar uma ferramenta que utilize modelos avançados para identificar oportunidades de negociação no mercado. Essa

abordagem se adequa à utilização de modelos complexos e algoritmos que buscam aumentar a precisão e a eficiência na identificação de padrões e na avaliação de riscos, permitindo a criação de estratégias de negociação mais sofisticadas e adaptáveis às diferentes condições do mercado.

1.6 MetaTrader 5

O MetaTrader 5 (MT5) é plataforma de negociação multimercado avançada, projetada para atender às crescentes demandas dos mercados financeiros globais. Oferecendo um ambiente integrado para a negociação de Forex, ações, futuros e commodities, o MT5 proporciona uma experiência completa, que abrange desde a execução de ordens até a análise técnica avançada e o desenvolvimento de sistemas automatizados (METAQUOTES LTD., 2024).


Figura 1 – Interface MetaTrader



Fonte: METAQUOTES LTD. (2024).

A plataforma MetaTrader 5 (MT5), como se observa na imagem acima, oferece uma interface personalizável que permite aos usuários organizarem múltiplas janelas de acordo com suas preferências. A janela de Cotações exibe os preços em tempo real dos instrumentos financeiros selecionados, e os Gráficos de Preços permitem visualizar a evolução dos preços ao longo do tempo. O Navegador oferece acesso rápido a contas, indicadores técnicos e scripts, facilitando a análise e o acompanhamento do mercado (METAQUOTES LTD., 2024).

Um dos recursos mais poderosos do MT5 são os *Expert Advisors* (EAs), também conhecidos como robôs de negociação. EAs são programas que automatizam o processo de negociação,

Figura 2 – Fluxograma do Funcionamento do EA

Fonte: Almeida (2016).

permitindo que os usuários executem estratégias complexas sem a necessidade de intervenção manual. Esses robôs abrem, modificam e fecham ordens automaticamente, com base em algoritmos predefinidos, e podem ser criados tanto manualmente, para maior customização, quanto automaticamente, por meio do MQL5 (ALMEIDA, 2016).

A análise técnica é um componente fundamental do MT5, com um conjunto abrangente de ferramentas para a identificação de padrões e sinais de mercado. A plataforma oferece uma variedade de indicadores técnicos integrados, abrangendo todas as principais categorias, bem como objetos gráficos e ferramentas de desenho para uma análise visual detalhada dos gráficos. A capacidade de analisar dados em múltiplos períodos, desde M1 (1 minuto) até MN1 (1 mês), permite capturar padrões que podem não ser evidentes em uma única escala temporal, resultando em algoritmos de previsão mais robustos (METAQUOTES LTD., 2024).

A negociação algorítmica é um dos pilares do MT5, devido à linguagem MQL5, que permite criar EAs para a análise automatizada de dados de mercado, a geração de sinais de negociação e a execução de ordens. O MetaEditor oferece um ambiente de desenvolvimento completo, com recursos como destaque de sintaxe, compilador integrado e depurador. O Testador de Estratégias possibilita a validação e otimização de algoritmos utilizando dados históricos, com opções para testar em diferentes períodos para simulação precisa e analisar estatísticas de desempenho detalhadas (METAQUOTES LTD., 2024).

A integração com Python, através de uma API dedicada, amplia as capacidades do MT5, permitindo a utilização de bibliotecas de aprendizado de máquina e a criação de modelos preditivos sofisticados. Essa integração possibilita a combinação das funcionalidades nativas

da plataforma com o poder analítico do ecossistema Python, resultando em algoritmos de previsão mais precisos e adaptáveis. Adicionalmente, o MT5 oferece suporte nativo para redes neurais em MQL5 e computação paralela com OpenCL, fornecendo recursos avançados para o desenvolvimento de algoritmos computacionalmente intensivos (METAQUOTES LTD., 2024).

Em suma, o MetaTrader 5 se consolida como uma plataforma versátil e poderosa para o desenvolvimento e a implementação de algoritmos de previsão de mercado. Sua combinação de recursos nativos, integração com tecnologias externas e ecossistema maduro o tornam uma escolha estratégica para pesquisadores, desenvolvedores e traders que buscam criar sistemas preditivos sofisticados e eficientes para os mercados financeiros.

1.7 Indicadores

Indicadores Técnicos são ferramentas fundamentais na análise estatística de mercados financeiros, pois traduzem fórmulas matemáticas e gráficos de forma que auxiliam os traders na tomada de decisões. Utilizando dados históricos de preço, volume, ou a combinação de ambos, os indicadores buscam revelar padrões e tendências que, de outra forma, seriam difíceis de discernir. Seu propósito principal é identificar potenciais pontos de entrada e saída em negociações, sinalizar a força ou fraqueza de uma tendência estabelecida, e demarcar zonas de suporte e resistência onde o preço tende a encontrar dificuldades em romper (FERNANDES, 2014).

Embora baseados em cálculos estatísticos, os sinais gerados por indicadores técnicos não devem ser interpretados como previsões infalíveis. Pelo contrário, eles funcionam como alertas ou confirmações, que exigem uma análise cuidadosa e contextualizada por parte do trader. A eficácia de um indicador pode variar significativamente entre diferentes ativos e ao longo do tempo, exigindo um processo contínuo de adaptação e ajuste de parâmetros (FERNANDES, 2014).

Em seguimento, alguns indicadores específicos serão explorados neste trabalho, visando a identificação de tendências e a confirmação de sinais de negociação. A escolha e a aplicação desses indicadores serão detalhadas nas seções subsequentes.

1.7.1 Índice de Força Relativa

De acordo com Anderson (1993), o RSI é um dos mais conhecidos indicadores de análise técnica e amplamente utilizado, não somente no mercado financeiro, mas para medir a consolidação de uma tendência em diversas áreas. O índice é base para diversos outros índices que necessitam de um norte para onde a tendência do ativo aponta, sendo assim, uma ferramenta imprescindível para fomentar uma decisão estratégica de entrada e saída de um ativo com maior segurança.

Diante do exposto, o Índice de Força Relativa tem como objetivo estudar posições estratégicas no preço dos ativos para aproveitar-se de uma brecha de compra ou venda.

Sendo assim, as classificações de ativos por RSI são basicamente sobrevalorizados ou supervalorizados; quando supervalorizado a melhor posição no ativo é de venda pois o ativo vem esgotando sua força compradora devido ao preço inflado, em contrapartida, o sobrevalorizado indica uma posição forte de compra pois, devido ao preço baixo, não será recompensador para o investidor vender o ativo, criando-se uma resistência que não propicia a vendas e sim compras.

Figura 3 – Tendência de Alta com RSI



Fonte: Fernandes (2014).

As margens de operação do RSI para compra e venda são frequentemente revisitadas; a estrutura clássica diz que, abaixo de 30 pontos no índice, o ativo tende a subir pois esgotou sua força vendedora, ao mesmo passo que, acima de 70 pontos no índice, o ativo tende a cair pois esgotou sua força compradora. Levando em consideração todo o contexto, o RSI não representa uma determinante que afirma o momento de compra ou venda, o índice tem como objetivo ser uma ferramenta a mais para o consenso de entradas e saídas em investimentos.


1.7.2 Médias Móveis

As Médias Móveis (MM) são um dos indicadores técnicos mais amplamente utilizados na análise estatística de mercados financeiros, oferecendo uma maneira eficaz de suavizar as flutuações de preço e identificar tendências predominantes. Ao calcular o preço médio de um ativo durante um período específico, as Médias Móveis reduzem o ruído gerado por movimentos

de preço aleatórios, permitindo que os analistas visualizem a direção geral do mercado com maior clareza, fornecendo pontos de referência válidos ao longo do tempo, possibilitando a comparação entre níveis atuais e passados (FERNANDES, 2014).

Existem diferentes tipos de Médias Móveis, sendo as mais comuns a Média Móvel Simples (MMS) e a Média Móvel Exponencial (MME). A MMS atribui o mesmo peso a todos os preços dentro do período, enquanto a MME pondera os preços mais recentes de forma mais significativa, tornando-a mais sensível às mudanças de preço. A escolha entre MMS e MME depende do objetivo da análise e da sensibilidade desejada. Períodos mais curtos resultam em Médias Móveis mais sensíveis, que reagem rapidamente às mudanças de preço, mas também geram mais sinais falsos. Períodos mais longos, por outro lado, resultam em Médias Móveis mais suaves, que filtram o ruído, mas podem atrasar a identificação de novas tendências (FERNANDES, 2014).

Figura 4 – Cruzamento de médias móveis



Fonte: Elaboração própria com dados e interface do MetaTrader 5.

Uma aplicação comum das Médias Móveis, como é possível observar na imagem acima, é a identificação de cruzamentos, interpretados como sinais de compra ou venda. Almeida (2016), em sua pesquisa, utilizou essa técnica com duas médias, uma “rápida” e outra “lenta”, gerando sinais de negociação com base em seus cruzamentos. Para um controle de risco mais refinado, implementou também StopLoss e TakeProfit. Entretanto, Almeida (2016) alerta para as limitações de se usar apenas essa técnica, especialmente em mercados com alta volatilidade, reforçando a necessidade de ferramentas que confirmem o sinal para evitar falsos positivos.

1.7.3 Médias Móveis Exponenciais

As Médias Móveis Exponenciais (MME) constituem uma ferramenta amplamente conhecida na análise técnica geral, destacando-se no mesmo sentido das médias móveis (MM), sendo principalmente utilizada para suavizar alterações bruscas de curto prazo nos preços dos ativos; além disso, atribui pesos mais acentuados para dados recentes. A diferença entre os indicadores MM e MME é fundamentalmente velocidade: devido à fórmula adaptada da MME, os resultados são mais velozes nas comparações utilizadas, contudo, o processamento requisitado é maior. Por esse motivo, a MME é significativamente utilizada em mercados de volatilidade pois é de suma importância identificar padrões de reversões ou de continuidade num espaço de tempo consideravelmente curto para tomadas de decisões.

Como já afirmado, a relevância da MME é ampla na área de análise técnica. Elder (2002), por exemplo, destaca o seu valor para análise de um mercado atual, característica essa que é contrária em outros indicadores onde suas fórmulas não consideram as datas dos dados extraídos. Segundo o autor, “a média móvel exponencial permite que o trader veja o mercado como ele é agora, e não como era semanas atrás” (ELDER, 2002, p. 145). Seguindo sua linha de pensamento, o cruzamento de médias possui a capacidade de demonstrar sinais de entrada ou saída de forma eficaz.

Apesar de tantas vantagens, a MME também possui seus pontos de consideração. A principal característica da MME é resultante da sua velocidade em extrair informações que, em mercados de lateralização, gera sinais que podem ser interpretados como falsos, levando a entradas e saídas em momentos desinteressantes. Uma forma de diminuir esta influência é a complementação com outros indicadores, como por exemplo, Índice de Força Relativa (IFR) ou Bandas de Bollinger; essa complementação cria dados cruzados que confirmam uma incerteza ou uma compra, facilitando decisões.

1.7.4 Bandas de Bollinger

As Bandas de Bollinger (BB), um indicador técnico de volatilidade desenvolvido por John Bollinger, oferecem uma perspectiva sobre a dinâmica dos preços em um mercado. As BB são construídas a partir de uma Média Móvel Aritmética (MM20, por exemplo) aplicada aos preços, traçando duas curvas que representam os limites superior e inferior da volatilidade esperada para o ativo. Essas bandas são calculadas utilizando o desvio padrão da média móvel, de modo que quanto maior a volatilidade do ativo, maior será a distância entre as bandas (FERNANDES, 2014).

Ao contrário de uma interpretação simplista que considera a banda superior como uma resistência e a banda inferior como um suporte, a teoria de Bollinger enfatiza a importância de analisar o comportamento dos preços em relação aos seus limites de volatilidade esperados. Se, em um movimento de alta, o preço atinge a banda superior, isso indica força e sugere que o movimento deve prosseguir. Por outro lado, se o preço não consegue alcançar a banda superior,

isso pode ser um sinal de fraqueza. Da mesma forma, a distância do preço em relação às bandas pode revelar informações importantes sobre a intensidade dos movimentos de alta ou baixa (FERNANDES, 2014).

As Bandas de Bollinger (BB) permitem, adicionalmente, a avaliação da volatilidade do mercado. Através do indicador BandWidth, derivado das BBs, é possível quantificar a distância entre as bandas, oferecendo uma medida direta da volatilidade do ativo. A ocorrência de períodos de baixa volatilidade, caracterizados pela aproximação das bandas (squeeze), pode indicar um potencial transição para um período de alta volatilidade (expansão), sinalizando oportunidades de negociação (FERNANDES, 2014). Em sua pesquisa, Bertini (2024) empregou as Bandas de Bollinger para avaliar a volatilidade de ativos, demonstrando a utilidade do indicador na seleção de ativos para estratégias de negociação baseadas na identificação de períodos de variação acentuada de preços.

1.7.5 MACD

O indicador MACD foi desenvolvido por Gerald Appel na década de 1970; sua proposta é identificar mudanças no momentum do mercado (APPEL, 2005). Composto por duas linhas, o MACD (Moving Average Convergence Divergence) representa a diferença entre duas linhas de médias móveis exponenciais, respectivamente, 12 e 26 períodos; em seguida, a linha que fornece sinal, média de 9 períodos, o indicador age no cruzamento de todas as três médias.

Como destacado por Elder (2002), o MACD é uma ferramenta interessante na confirmação de tendências e em identificar pontos específicos de reversão. Geralmente é utilizado em mercados com tendência mais previsível, mas por derivar da MME, pode gerar falsos sinais em mercados de lateralidade. Por fim, outra característica interessante é a capacidade de observar diferenças dos resultados MACD e da movimentação nos preços, é outra aplicação interessante para a criação de Appel.

1.8 Modelos Estatísticos

Os modelos estatísticos representam uma abordagem fundamental na análise de dados, especialmente em contextos em que se busca compreender padrões, relações e tendências. Eles oferecem fórmulas estruturadas para interpretar informações históricas e, em muitos casos, para projetar comportamentos futuros. Ao aplicar princípios matemáticos e probabilísticos, esses modelos buscam simplificar a complexidade inerente aos fenômenos observados, permitindo a extração de insights e a tomada de decisões baseada em evidências quantitativas.


1.8.1 ARIMA

O modelo Autoregressive Integrated Moving Average (ARIMA) é um modelo estatístico utilizado para análise de séries temporais. O ARIMA permite modelar dados que exibem

tendências e flutuações ao longo do tempo, sendo amplamente aplicado em áreas financeiras para prever valores futuros com base em dados passados.

A estrutura do ARIMA é composta por três elementos: o componente Autoregressivo (AR), que modela a influência dos valores passados da série no valor presente; a Média Móvel (MA), que suaviza os ruídos e flutuações aleatórias presentes nos dados; e o Integrado (I), responsável por tornar a série estacionária. Uma série estacionária apresenta propriedades estatísticas constantes ao longo do tempo, ou seja, sua média e variância não se alteram significativamente. Cada um desses componentes é definido por um parâmetro: o parâmetro p representa a ordem da autocorrelação, o parâmetro q define a ordem da média móvel, e o parâmetro d determina o grau de diferenciação (XING et al., 2024).

Figura 5 – Fluxo ARIMA



Fonte: Autoria própria.

Como é possível observar na figura acima, o processo de aplicação do modelo ARIMA inicia-se com a coleta do histórico de preços do ativo. Em seguida, verifica-se a estacionariedade da série; se não estiver estável, aplica-se a diferenciação repetidamente até que a estabilidade seja alcançada. Com a série pronta, o modelo ARIMA é ajustado, definindo-se suas ordens p , d e q . Por fim, o modelo treinado gera as previsões de preço e os resíduos, que representam os erros da previsão e são importantes para análises futuras.

A verificação da estacionariedade e o subsequente ajuste dos parâmetros p , d e q são metodologicamente embasados em testes e critérios estatísticos. A etapa de verificar a estacionariedade da série é formalmente conduzida por meio do teste de Dickey-Fuller Aumentado (ADF). Este teste avalia a hipótese nula de que a série temporal possui uma raiz unitária, sendo o p-valor resultante um indicador crucial: um p-valor elevado, como o de 0,998773 encontrado inicialmente por Xing et al. (2024) para os dados da NVIDIA, impede a rejeição da hipótese nula, confirmando a não estacionariedade. Já a aplicação da diferenciação repetidamente até que a estabilidade seja alcançada é, portanto, guiada pelos resultados sequenciais do teste ADF. No referido estudo, após a primeira diferenciação, um p-valor próximo de zero indicou que a estacionariedade foi atingida, definindo assim $d = 1$.

Subsequentemente, para o ajuste do modelo ARIMA, um passo crucial é a definição de suas ordens p (autorregressiva) e q (médias móveis). Dada a multiplicidade de combinações possíveis para estes parâmetros, como o intervalo de 0 a 4 testado por Xing et al. (2024), torna-se necessário um critério objetivo para a seleção do modelo mais apropriado. O *Critério de Informação de Akaike (AIC)* desempenha precisamente este papel, sendo uma métrica estatística consolidada para avaliar a qualidade relativa de diferentes modelos. O AIC permite selecionar a configuração que oferece o melhor compromisso entre a fidelidade do modelo aos dados históricos (qualidade do ajuste) e sua complexidade (parcimônia), penalizando modelos com excesso de parâmetros que poderiam levar a overfitting. Assim, a configuração ARIMA que resulta no menor valor de AIC é a escolhida, pois representa a estrutura mais eficiente e generalizável, antes que o modelo treinado seja utilizado para gerar as previsões e os resíduos (XING et al., 2024).

Uma outra variação do modelo ARIMA é o Seasonal Autoregressive Integrated Moving Average, ou SARIMA, ideal para dados que exibem padrões sazonais. Ao contrário de séries aleatórias, dados com sazonalidade apresentam comportamentos previsíveis que se repetem em intervalos regulares, como vendas que aumentam no Natal ou no verão. O SARIMA, além dos componentes AR, MA e I, incorpora componentes sazonais para capturar esses padrões recorrentes, tornando-se uma ferramenta mais dimensionada para modelar fenômenos com sazonalidade intrínseca (ARAYA; ARAYA, 2024).

Apesar de sua utilidade, ambos os modelos apresentam limitações importantes. Sua eficácia é maior na captura de relações lineares, o que dificulta lidar com padrões não lineares complexos. Além disso, a escolha dos parâmetros ideais é um desafio, exigindo análise criteriosa e experimentação. Em cenários complexos e não lineares, modelos de aprendizado de máquina podem ser mais adequados (ARAYA; ARAYA, 2024; XING et al., 2024).


1.8.2 GARCH

O modelo Generalized Autoregressive Conditional Heteroskedasticity (GARCH) é uma ferramenta estatística para a análise de séries temporais financeiras, com foco na modelagem da

volatilidade. A volatilidade, como apontado por Araya e Araya (2024), reflete o grau de variação dos preços de um ativo financeiro ao longo do tempo e é fundamental para a gestão de riscos e a precificação de derivativos.

O objetivo principal do modelo GARCH é capturar a dependência temporal da volatilidade, permitindo que ela varie dinamicamente em resposta às condições do mercado. O modelo padrão, denominado SGARCH (Standard GARCH), considera que a volatilidade atual é influenciada tanto pelos choques passados quanto pela própria volatilidade passada, em um processo de retroalimentação como mostrado na imagem abaixo (ARAYA; ARAYA, 2024).

Figura 6 – Fluxo GARCH



Fonte: Autoria própria.

No entanto, o modelo SGARCH assume que a resposta da volatilidade aos choques é simétrica, ou seja, choques positivos e negativos de igual magnitude têm o mesmo impacto na volatilidade. Essa premissa nem sempre se verifica nos mercados financeiros, onde choques negativos (más notícias) frequentemente têm um impacto maior do que choques positivos (boas notícias). Para lidar com essa assimetria, foram desenvolvidas variações do modelo GARCH, como o EGARCH (Exponential GARCH) e o TGARCH (Threshold GARCH) (ARAYA; ARAYA, 2024).

O modelo EGARCH, por exemplo, permite que a volatilidade responda de forma diferente a choques positivos e negativos, capturando o chamado efeito alavancagem. Já o modelo TGARCH utiliza variáveis binárias (dummy variables) para identificar diferentes regimes de volatilidade, permitindo que o modelo se adapte a diferentes condições de mercado (ARAYA; ARAYA, 2024).

A escolha entre o modelo SGARCH, EGARCH e TGARCH depende das características específicas dos dados e dos objetivos da análise. Araya e Araya (2024) destaca essa importância de selecionar o modelo mais adequado com base em métricas estatísticas.

1.8.3 Integração ARIMA-GARCH

A integração dos modelos ARIMA e GARCH representa uma abordagem robusta para a análise de séries temporais financeiras, permitindo capturar tanto a tendência condicional quanto a volatilidade condicional de um ativo. Conforme demonstrado por Araya e Araya (2024), quando ARIMA e GARCH são combinados, os resíduos gerados pelo modelo ARIMA (que representam os erros da previsão da média condicional) servem como série de entrada para o modelo GARCH, que modela a variância condicional desses resíduos.

Essa integração é teoricamente fundamentada no trabalho seminal de Bollerslev (1986), que estendeu os modelos de heteroscedasticidade condicional autorregressiva (*ARCH*) inicialmente propostos por Engle (1982). O modelo GARCH possibilita capturar a dinâmica da volatilidade, que é crítica para a gestão de risco em mercados voláteis, como no caso da ação PETR4, que apresenta elevadas flutuações de preço.

Na prática, a integração ARIMA-GARCH pode ser implementada por meio de três abordagens estratégicas complementares. A primeira é o **Filtro de Volatilidade**, que restringe operações a períodos em que a volatilidade prevista pelo GARCH permanece abaixo de um limiar definido, reduzindo exposição a mercados instáveis. A segunda é a **Volatility Targeting**, que ajusta o tamanho da posição inversamente à volatilidade prevista, diminuindo o risco relativo quando a incerteza aumenta. A terceira é o **Intervalo de Confiança**, que utiliza a volatilidade do GARCH para estabelecer limites superior e inferior ao redor das previsões do ARIMA, criando uma zona de confiança para a entrada e saída de operações.

Para aplicações em negociação de ativos voláteis, o **Filtro de Volatilidade** emerge como a abordagem mais prudente, já que permite ao sistema evitar períodos de heteroscedasticidade elevada, alinhando-se ao objetivo de investimento seguro em ativos com elevada variabilidade de preço. Essa estratégia garante que as operações ocorram predominantemente em condições de mercado mais estáveis, reduzindo perdas relacionadas a movimentos abruptos de preço.

1.9 Trabalhos Relacionados

Nesta seção são apresentados estudos e pesquisas relacionados ao tema deste trabalho. O levantamento realizado foi orientado pela busca de pesquisas científicas e tecnológicas que têm em seus objetivos o desenvolvimento, implementação e análise de ferramentas e tecnologias para a previsão de séries temporais financeiras, análise de volatilidade e desenvolvimento de estratégias de negociação algorítmica, com ênfase na aplicação de modelos estatísticos e de aprendizado de máquina no mercado de ativos. A ferramenta que serviu de referência para isso foi o Google Acadêmico e Publish or Perish 8, por meio do qual se buscou mapear as pesquisas dessa natureza circunscritas nos últimos anos.

O estudo de Almeida (2016) figura como um precursor direto e ponto de partida conceitual para o presente trabalho. Almeida investigou a aplicação de métodos matemáticos e

estatísticos no desenvolvimento de um robô de negociação, utilizando a plataforma MetaTrader 5 e a linguagem MQL5, com foco específico no ativo PETR4. Sua abordagem centrou-se na estratégia de cruzamento de médias móveis e na análise de séries temporais com dados históricos, validando o robô através de backtests em diferentes cenários, incluindo períodos de crise, e com o objetivo de alcançar um retorno superior à taxa SELIC. O robô demonstrou viabilidade, apresentando lucratividade em ativos de proteção e superando a SELIC com PETR4 fora de cenários de crise, além de sugerir a exploração futura de modelos como o GARCH. A pesquisa de Almeida é de fundamental importância para este TG, pois não apenas validou a utilização do MetaTrader 5 e MQL5 para a análise algorítmica de PETR4, mas também serviu como base para a “revisitação e aplicação contemporânea” que propomos, conforme mencionado na justificativa deste projeto. Sua recomendação para explorar modelos mais robustos, como o GARCH, alinhou-se com a intenção inicial deste trabalho de integrar também redes LSTM. Embora esse componente tenha sido posteriormente excluído do escopo por limitações de tempo e de ambiente de desenvolvimento (ver Capítulo 2, seção Obstáculos Encontrados), a abordagem ARIMA-GARCH efetivamente implementada permitiu construir sobre os achados iniciais de Almeida, buscando maior capacidade preditiva e adaptabilidade às atuais e complexas condições do mercado brasileiro.

Batista (2024) desenvolveu um robô de investimento (*Expert Advisor*) para automatizar operações na bolsa de valores brasileira (B3), utilizando uma combinação dos indicadores técnicos Média Móvel Exponencial, Convergência-Divergência de Médias Móveis e Índice de Força Relativa visando lucros automatizados a médio e longo prazo. Para isso, empregou a plataforma MetaTrader 5 e a linguagem MQL5, implementando uma estratégia que integrava os sinais dos três indicadores para decisões de compra e venda. A validação ocorreu por meio de backtests com dados históricos do ativo BBAS3F de 2023, comparando o desempenho dos indicadores isoladamente, em pares e em conjunto. Os resultados mostraram que a combinação dos três indicadores superou as abordagens com menos indicadores, demonstrando a eficiência e consistência do EA nos testes e indicando potencial para lucros automatizados.

Em 2022, Silva (2022) investigaram a previsão de tendências de preços de ações da Petrobras (PETR4) no mercado brasileiro, com foco em operações intraday de 15 minutos, utilizando técnicas de inteligência artificial. Para isso, empregaram um extrator de variáveis baseado em *eXtreme Gradient Boosting* (*XGBoost*) para selecionar os indicadores técnicos mais relevantes dentre mais de 100 disponíveis, visando reduzir ruído na amostra. Em seguida, uma rede neural *Long Short-Term Memory* (*LSTM*) foi aplicada para prever a tendência de alta ou baixa dos preços no período de 2014 a 2020. Os resultados alcançaram uma acurácia de 56%, superando estudos anteriores, com melhor desempenho na previsão de quedas (57%) em comparação com altas (51%), e destacando a eficácia da combinação de *XGBoost* para seleção de *features* e *LSTM* para previsão no contexto do mercado financeiro brasileiro.

Em 2024, Xing et al. (2024) realizaram uma análise comparativa de quatro modelos

de previsão – ARIMA, *Multilayer Perceptron (MLP)*, *Long Short-Term Memory (LSTM)* e um modelo híbrido ARIMA-GARCH – para prever o preço de fechamento ajustado do dia seguinte das ações da NVIDIA. Utilizando dados diários da API do *Yahoo Finance* de abril de 2019 a abril de 2024, o estudo dividiu o *dataset* em 90% para treino e 10% para teste. Os modelos *LSTM* e *MLP* foram configurados com janelas deslizantes, enquanto os modelos ARIMA e ARIMA-GARCH utilizaram janelas expansivas e rolantes, com parâmetros otimizados para o menor *AIC*. Os resultados, avaliados por *MAE*, *RMSE* e *R-quadrado*, indicaram que o modelo ARIMA-GARCH apresentou o menor *RMSE*, sugerindo melhor precisão na previsão de grandes erros e na explicação da variância. No entanto, o modelo ARIMA com janela expansiva demonstrou desempenho superior em geral, superando os modelos *LSTM* e *MLP*, possivelmente devido às características predominantemente lineares da série temporal e à sensibilidade dos modelos de *deep learning* à configuração e ao tamanho da amostra.

Araya e Araya (2024) propuseram um método híbrido GARCH e *Deep Learning* para predição de volatilidade de preços de ações, visando aumentar a acurácia das previsões ao integrar diversos modelos. O estudo combinou quatro abordagens: *SARIMA (Seasonal Autoregressive Integrated Moving Average)*, modelos da família GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*), *CNN (Convolutional Neural Network)* e *BiLSTM (Bidirectional Long Short-Term Memory)*. Inicialmente, os resíduos gerados pelo modelo *SARIMA* foram utilizados como entrada para o modelo GARCH. Em seguida, a volatilidade estimada por essa combinação serviu como *feature* de entrada para os modelos híbridos *CNN* e *BiLSTM*. A *performance* do novo modelo híbrido proposto (*SARIMA-GARCH-CNN-BiLSTM*) foi avaliada utilizando métricas como *MAE (Mean Absolute Error)* e *RMSE (Root Mean Squared Error)*, demonstrando uma redução média significativa nesses erros (60,35% e 60,61%, respectivamente) em comparação com outros modelos híbridos. Os resultados experimentais indicaram que o modelo proposto apresentou bom desempenho e acurácia na predição da volatilidade de preços de ações, oferecendo *insights* valiosos para análise de dados financeiros e estratégias de gerenciamento de risco.

Tormin (2024) realizou um estudo comparativo entre os modelos ARIMA e *LSTM* para prever os retornos do Bitcoin, investigando o impacto da integração de dados de tendências de busca do Google (*PyTrends*) na capacidade preditiva. Utilizando dados diários de preços do Bitcoin e tendências de busca para o termo “Bitcoin” de janeiro de 2018 a outubro de 2024, foram construídos três modelos: ARIMA, *LSTM* tradicional e *LSTM* integrado com *PyTrends*. O pré-processamento incluiu ajuste ao fuso horário *UTC*, tratamento de valores ausentes (*fillna*) e normalização (*MinMaxScaler*), com divisão de 80% dos dados para treino e 20% para teste. A avaliação, baseada em *RMSE*, *MAE* e *MAPE*, mostrou que o ARIMA, apesar de simples, apresentou maior estabilidade em *RMSE* e *MAE*. O *LSTM* tradicional obteve *RMSE* levemente melhor que o ARIMA, mas com *MAPE* significativamente mais alto. A inclusão dos dados do *Google Trends* no modelo *LSTM* integrado não resultou em melhora significativa, sugerindo a necessidade de ajustes mais robustos ou a inclusão de outras variáveis para capturar

a complexidade do mercado de criptomoedas.

Tabela 2 – Tabela Comparativa

Estudo	Indicadores	Modelo estatístico	Machine Learning
(PEREIRA, 2025)	X	X	X
(ALMEIDA, 2016)	X	X	
(BATISTA, 2024)	X		
(ARAYA, 2024)		X	X
(SILVA, 2022)	X		X
(XING, 2024)		X	X
(TORMIN, 2024)	X	X	X

Comparação entre as pesquisas, evidenciando quais componentes cada uma utilizou para formular o modelo que elas propuseram.

Fonte: Autoria própria.

Tabela 3 – Tabela Comparativa (Detalhada)

Autor	Ativo Principal	Fonte de Dados	Tempo Gráfico	Indicadores	Modelo(s) Es- tatístico(s)	Modelo(s) de ML	Métricas para ML
(PEREIRA, 2025)	PETR4	MetaTrader 5	D1	RSI, MME, MACD, BB	ARIMA, GARCH	LSTM	MAE, RMSE, R Square
(ALMEIDA, 2016)	PETR4	MetaTrader 5	D1	MA	ARIMA, En- contro de Mé- dias Móveis	–	–
(BATISTA, 2024)	BBAS3F	MetaTrader 5	M30	RSI, MME, MACD, BB	–	–	–
(SILVA, 2022)	PETR4	–	M15	113 indica- dores	–	LSTM + XGBoost	Acurácia, Precision, Recall, F1-Score, Support
(XING, 2024)	NVIDIA (NVDA)	–	–	–	ARIMA, GARCH	LSTM, MLP	MAE, RMSE, R Square
(ARAYA, 2024)	Apple Inc. (AAPL)	Yahoo Finance	D1	–	SARIMA, GARCH	CNN, Bi-LSTM	MAE, RMSE
(TORMIN, 2024)	Bitcoin (BTC-USD)	Google Trends	–	–	ARIMA	LSTM	MAE, RMSE, MAPE

Comparação entre as pesquisas, evidenciando as características de cada uma em diversos aspectos.

Fonte: Autoria própria.

CAPÍTULO II

2 Metodologia

A metodologia deste trabalho foi estruturada em etapas sequenciais, visando o desenvolvimento, implementação e validação do algoritmo proposto para a negociação de ativos financeiros. O objetivo foi descrever os passos para construir e testar a solução, desde a escolha do ambiente até a avaliação de seu desempenho.

2.1 Natureza da Pesquisa

Este trabalho, como mencionado na introdução, adota uma natureza de pesquisa experimental. A pesquisa experimental, no contexto de desenvolvimento de sistemas e algoritmos, envolve a manipulação controlada de variáveis que, neste caso, foram os parâmetros dos modelos, as combinações de indicadores técnicos, para observar e analisar os efeitos resultantes em um ambiente controlado. Foram conduzidos experimentos para testar diferentes configurações do algoritmo, buscando identificar as abordagens mais eficazes para a negociação do ativo financeiro selecionado (WAZLAWICK, 2014).

2.2 Padrões para Pesquisa Experimental

Para a condução dos experimentos e o desenvolvimento do algoritmo proposto, foi utilizado um conjunto definido de padrões e ferramentas, cujas funcionalidades e conceitos foram detalhados no capítulo anterior de Fundamentação Teórica.

A plataforma MetaTrader 5 (MT5) foi empregada como o ambiente central para as fases de desenvolvimento e teste. A linguagem de programação MQL5, nativa do MT5, foi utilizada para a codificação dos *Expert Advisors* (EAs). Estes EAs são os algoritmos que efetivamente incorporaram a lógica dos modelos de análise de tendência, volatilidade e modelagem condicional para a execução automatizada de ordens de negociação.

O testador de estratégias integrado ao MT5 foi uma ferramenta crucial, permitindo a realização de backtests. Esses testes simularam o desempenho operacional das estratégias desenvolvidas ao longo de períodos históricos, utilizando os dados de cotações passadas para avaliar a viabilidade e a rentabilidade potencial.

Como fonte primária de dados, foi utilizado o banco de dados histórico de cotações fornecido pela própria plataforma MetaTrader 5 com integração a corretoras brasileiras. Inicialmente, a conta era integrada à corretora Rico, que permitia acessar ações da B3. No entanto, durante o desenvolvimento, essa corretora cessou o fornecimento de ativos para a plataforma MetaTrader 5, necessitando uma migração para a corretora Clear, que mantém compatibilidade com a plataforma. Esta escolha metodológica simplificou significativamente o processo de

aquisição de dados, seu tratamento inicial e a subsequente manipulação, uma vez que os dados se encontram em um formato padronizado e são diretamente acessíveis via MQL5. Os dados extraídos e utilizados incluíram os preços de abertura, máximo, mínimo e fechamento, bem como o volume de negociação para cada período do timeframe definido para a análise, que foi diário (D1) para capturar tendências mais longas.

O ativo referente às ações preferenciais da Petrobras (PETR4) foi o objeto de estudo principal. Sua notória volatilidade histórica é um aspecto central para a aplicação dos modelos subsequentes, em particular o modelo GARCH, que é projetado especificamente para capturar e modelar a variância condicional em séries temporais que exibem tais flutuações. A liquidez e a representatividade do PETR4 no Ibovespa foram consideradas para assegurar a disponibilidade de dados robustos para esta análise de volatilidade e para contextualizar os resultados no mercado acionário nacional.

Para uma caracterização inicial e visualização dessa volatilidade inerente ao PETR4, foram calculadas e analisadas as Bandas de Bollinger. Este indicador técnico, que constrói um canal em torno de uma média móvel utilizando o desvio padrão dos preços, foi aplicado à série histórica de preços do ativo. A observação da largura das bandas e do comportamento do preço em relação a elas forneceu insights valiosos sobre os diferentes regimes de variação dos preços (períodos de alta ou baixa volatilidade) e contribuiu para a compreensão do ambiente de mercado no qual o algoritmo operaria.

2.3 Obstáculos Encontrados

Durante o desenvolvimento deste trabalho, foram enfrentados obstáculos significativos que impactaram o escopo e a execução da pesquisa.

Perda do ambiente Windows e limitações no Linux: O ambiente primário de desenvolvimento era uma máquina Windows, equipada com o MetaTrader 5 instalado nativamente. A perda desse equipamento obrigou a migração para um ambiente Linux (EndeavourOS), no qual o MetaTrader 5 não possui suporte oficial. A solução adotada foi executar a plataforma via Wine, o que, embora funcional, impõe limitações operacionais, como instabilidades ocasionais e restrições de compatibilidade com algumas APIs nativas da plataforma.

Incompatibilidade da corretora Rico: Durante a fase de coleta de dados e execução de backtests com ativos de ações, a corretora Rico cessou a disponibilização de ações em sua plataforma MetaTrader 5, inviabilizando o acesso ao ativo PETR4 através dessa conta. Foi necessário abrir uma nova conta na corretora Clear, que mantém compatibilidade com a plataforma, para dar continuidade à pesquisa. Esse processo causou atrasos e exigiu a reconfiguração do ambiente de testes.

Esses fatores combinados contribuíram para a redução do escopo original (que previa a integração de modelos de *Machine Learning*) concentrando o trabalho nos modelos ARIMA e

GARCH.

2.4 Experimento de Pesquisa

O experimento de pesquisa iniciou-se com a implementação de abordagens para análise de tendência utilizando Médias Móveis. Foram programados em MQL5 diferentes tipos de médias móveis, como a Simples e a Exponencial. Estratégias baseadas em cruzamentos dessas médias foram implementadas para gerar indicações preliminares sobre a direção potencial do mercado, ou seja, sinais de compra ou venda. Estas estratégias também serviram para verificar o desempenho de modelos baseados apenas em médias no mercado mais recente.

Posteriormente, o experimento avançou para uma modelagem estatística mais sofisticada da série temporal de preços, utilizando o modelo ARIMA. A determinação da ordem de integração ‘d’ do modelo ARIMA (p, d, q) foi realizada através da aplicação sequencial do teste de raiz unitária ADF sobre a série. Para a definição das ordens autorregressiva ‘p’ e de médias móveis ‘q’, foi adotado um procedimento sistemático de testar múltiplas combinações de 0 a 4. A seleção da especificação final foi baseada no critério de informação *Akaike Information Criterion (AIC)*.


Na sequência, os resíduos obtidos a partir do modelo ARIMA ajustado foram utilizados como série de entrada para a modelagem da volatilidade condicional, por meio de um modelo GARCH. Esta abordagem combinada, ARIMA-GARCH, visou capturar a dinâmica da variância dos erros que não foi explicada pelo modelo de média condicional ARIMA. Foram estimados modelos GARCH, com foco inicial e principal na especificação GARCH (1,1), dada a sua prevalência e bom desempenho demonstrado na literatura para séries temporais financeiras. O objetivo foi modelar e prever a volatilidade futura de curto prazo dos resíduos, fornecendo uma medida do risco associado às previsões de preço do ARIMA.

2.5 Diagramas

2.6 Critérios para Avaliação

Os testes das estratégias baseadas em Médias Móveis, cruzamento de Médias Móveis, e dos modelos ARIMA e GARCH foram realizados integralmente na plataforma MetaTrader 5 por meio do ambiente de backtesting.

O desempenho dessas estratégias foi quantitativamente avaliado por meio de métricas como a taxa de acerto das operações, o lucro ou prejuízo acumulado, o drawdown máximo observado e o fator de lucro. Estas métricas foram fornecidas diretamente pela plataforma. Adicionalmente, um critério importante para a validação interna dos modelos estatísticos foi a qualidade do ajuste dos modelos ARIMA e GARCH. Esta qualidade foi aferida utilizando o

Figura 7 – Modelo Completo

Fonte: Autoria própria.

critério de informação Akaike (AIC) e pela verificação da estacionariedade dos resíduos através do teste de raiz unitária de Dickey-Fuller Aumentado (ADF).

2.7 Resultados preliminares atingidos no PTG

Como mencionado anteriormente, este projeto busca revisitar e expandir as investigações de Almeida (2016), que desenvolveu e testou um Expert Advisor (EA) baseado na estratégia de cruzamento de Médias Móveis (MM) para o ativo PETR4 na plataforma MetaTrader 5. O estudo original de Almeida (2016) observou que, embora sua estratégia pudesse gerar lucros em determinados períodos de mercado mais estáveis, ela enfrentava dificuldades e apresentava prejuízos durante crises financeiras, evidenciando a sensibilidade do algoritmo simples às condições de mercado.

Para estabelecer um ponto de partida contemporâneo e avaliar o desempenho dessa estratégia no cenário de mercado mais recente, foi necessário adaptar e reimplementar a lógica central do EA proposto por Almeida (2016).

O código original fornecido por ele, embora conceitualmente claro, demandou atualizações para ser compatível com as versões mais recentes da linguagem MQL5 e da plataforma MetaTrader 5. Adicionalmente, Almeida (2016) mencionou o uso de bibliotecas externas para funcionalidades como gerenciamento de dinheiro e trailing stops, as quais não foram disponibilizadas em seu trabalho. Desta forma, para a presente análise preliminar, foi desenvolvido um EA em MQL5 utilizando a classe CTrade¹ padrão para as operações de negociação e implementando a lógica de cruzamento de duas Médias Móveis Simples (MMS).

A configuração do EA para este teste baseou-se nos seguintes parâmetros: Médias Móveis Simples com período de 10 para a rápida e 20 para a lenta, aplicadas ao preço de fechamento. A estratégia implementada inclui a reversão de posições, ou seja, ao ser gerado um novo sinal, qualquer posição oposta existente é primeiramente fechada.

Os parâmetros de Stop Loss (SL) e Take Profit (TP) foram definidos por experimentação inicial em 50 pontos e 100 pontos e depois nulos, respectivamente, uma vez que Almeida (2016) não especificou os valores exatos utilizados em todos os seus testes para PETR4. Reconhece-se que esta escolha de SL/TP pode divergir da utilizada originalmente e constitui um ponto para otimizações e análises futuras.

As operações foram configuradas para serem executadas apenas na abertura de uma nova barra no gráfico diário (D1), com a modelagem do backtest para *Cada Tick* para maior precisão na simulação dos preços de execução, alinhando-se com a abordagem de “Every tick” mencionada por Almeida (2016).

Visando uma comparação de desempenho sob condições financeiras similares às de um dos cenários de Almeida (2016), o backtest foi conduzido com um depósito inicial de R\$ 50.000,00. O volume operacional foi definido como 1000 unidades do ativo PETR4 por negociação. A alavancagem utilizada na simulação foi de 1:100. O período de teste compreendeu de 01 de janeiro de 2020 a 01 de maio de 2025.

Os principais resultados obtidos neste backtest para o ativo PETR4 são apresentados e comparados qualitativamente com os achados de Almeida (2016) para PETR4 em períodos de crise:

A análise destes resultados preliminares indica que, para o primeiro teste no período recente de janeiro de 2020 a maio de 2025, a estratégia base de cruzamento de Médias Móveis, operando com um volume de 1000 ações de PETR4, resultou em um prejuízo líquido substancial de R\$ 9.230,00, representando uma perda de 18,46% sobre o capital inicial. O Fator de Lucro de 0,64 e a baixa taxa de acerto (apenas 25% das 64 operações foram lucrativas) confirmam a ineficácia da estratégia neste intervalo de tempo.

Em uma segunda rodada de testes preliminares para o período de janeiro de 2020 ao começo de 2025 e mantendo o volume de 1000 ações de PETR4, foram zerados os parâmetros


¹ Biblioteca padrão do MQL5 para as operações de negociação.

Tabela 4 – Comparação modelo proposto x ALMEIDA (2016)

	Pereira (2025) 1º teste	Pereira (2025) 2º teste	Almeida (2016)	Almeida (2016)
Período	2020-2025 (Crise)	2020-2025 (Crise)	2013-2016	2007-2011 (Crise)
Volume por Operação	1000 ações	1000 ações	1000 ações	100 ações
Lucro Líquido Total	R\$ -9.230,00	R\$ -2.530,00	R\$ +10.430,00	R\$ -2.542,00
Retorno Percentual	-18,46%	-5,06%	+20,86%	-5,08%
Fator de Lucro	0,64	0,93	> 1,0 (lucro)	< 1,0 (prejuízo)
Total de Negociações	64	58	38	52


Fonte: Elaboração própria com dados do MetaTrader 5 e pesquisa de Almeida (2016).

de Stop Loss e Take Profit, resultando em um desempenho ligeiramente menos desfavorável. Neste segundo cenário, o prejuízo líquido total foi de R\$ 2.530,00, correspondendo a uma perda de 5,06% sobre o capital inicial. Embora o Fator de Lucro tenha melhorado para 0,93 e o número total de negociações tenha sido reduzido para 58, a estratégia ainda não demonstrou capacidade de gerar lucro. Este resultado, apesar de melhor que o anterior, ainda se alinha com as dificuldades encontradas por Almeida (2016) em períodos de crise e reforça a necessidade de abordagens mais robustas.

Figura 8 – Desempenho do modelo proposto (2º teste)

Fonte: Elaboração própria com dados do MetaTrader 5.

Este desempenho contrasta significativamente com os resultados obtidos por Almeida (2016) para o mesmo ativo e volume em um período anterior (2013-2016), onde foi reportado um lucro considerável. Por outro lado, o resultado negativo atual se assemelha, em natureza, aos prejuízos que Almeida também encontrou ao aplicar sua estratégia em PETR4 durante períodos de crise financeira, como a de 2008.

Figura 9 – Gráfico de dispersão da correlação de lucro (2º teste)

Fonte: Elaboração própria com dados do MetaTrader 5.

O período de 2020-2025 foi caracterizado por uma volatilidade acentuada e por dinâmicas de mercado complexas, influenciadas por eventos globais como a pandemia de COVID-19 e suas repercussões econômicas. É plausível que tais condições tenham sido particularmente desfavoráveis para uma estratégia de seguimento de tendência simples como o cruzamento de médias. Adicionalmente, as necessárias adaptações do código original de Almeida (2016) e a definição experimental dos parâmetros de Stop Loss e Take Profit, na ausência dos valores exatos utilizados no estudo de referência, são fatores que podem ter influenciado os resultados.

No entanto, a principal inferência destes testes preliminares é a clara demonstração de que a estratégia de cruzamento de Médias Móveis, mesmo com parâmetros de risco básicos e um volume operacional mais elevado, não se mostrou suficiente para gerar retornos positivos de forma consistente no mercado recente de PETR4. Este achado é fundamental, pois estabelece um baseline contemporâneo e valida de forma contundente a justificativa central deste trabalho de graduação: a necessidade premente de investigar, desenvolver e integrar modelos analíticos e preditivos mais sofisticados, como ARIMA para previsão de tendência e GARCH para modelagem da volatilidade, com o objetivo de construir um algoritmo mais robusto, adaptável e com maior potencial de eficácia para a negociação de ativos voláteis no dinâmico cenário atual do mercado de ações brasileiro.

2.8 Limitações e Trabalhos Futuros

Os resultados finais de backtesting com os modelos ARIMA e GARCH ainda estão sendo consolidados e analisados. Os resultados preliminares obtidos com estratégias de Médias Móveis demonstraram a ineficácia de abordagens simplistas em cenários de mercado volátil, validando a necessidade de modelos mais sofisticados.

As limitações encontradas durante este trabalho incluem a restrição computacional e operacional do ambiente Linux via Wine, bem como as interrupções causadas pela mudança de corretora. Adicionalmente, o escopo reduzido — concentrado em ARIMA e GARCH — significa que componentes originalmente planejados, como a integração de Machine Learning (LSTM) para análises não lineares, não foram implementados neste ciclo.

Como perspectivas para trabalhos futuros, recomenda-se:

- Implementação do modelo LSTM em um ambiente de desenvolvimento dedicado (Python com TensorFlow/Keras), seguido de integração ao MetaTrader 5 como componente complementar aos modelos ARIMA e GARCH;
- Incorporação de indicadores técnicos como filtro de confirmação (RSI, MACD) para validar sinais gerados pelos modelos estatísticos;
- Expansão da análise para outros ativos brasileiros de alta liquidez (ex., BBDC4, PETR3, VALE3) para validar a generalização da metodologia;
- Otimização de hiperparâmetros dos modelos ARIMA e GARCH através de algoritmos evolucionários (Genetic Algorithm, PSO);
- Implementação de técnicas robustas de gerenciamento de risco (trailing stops, position sizing dinâmico) para mitigação de drawdowns.

CAPÍTULO III

3 Conclusão e Considerações Finais

3.1 Conclusão

Este trabalho de graduação investigou a aplicação de modelos estatísticos integrados para a previsão de tendências e análise de volatilidade no mercado de ações brasileiro, com foco na ação PETR4. O objetivo principal era desenvolver um algoritmo que combinasse análises técnicas tradicionais com modelos estatísticos avançados, permitindo a geração de sinais de negociação mais robustos em cenários de alta volatilidade.

Os experimentos preliminares com a estratégia de cruzamento de Médias Móveis estabeleceram um *baseline* contemporâneo, demonstrando a ineficácia de abordagens simplistas no período de 2020-2025, caracterizado por volatilidade acentuada. A implementação subsequente do modelo ARIMA para previsão de tendências e GARCH para modelagem de volatilidade seguiu fundamentação teórica sólida, baseada em trabalhos seminais de Engle (1982) e Bollerslev (1986), e em aplicações práticas contemporâneas de Araya e Araya (2024).

Os resultados do backtesting da estratégia ARIMA-GARCH revelaram desempenho quantificável em termos de métricas tradicionais de avaliação. A taxa de acerto das previsões de curto prazo, o *Sharpe ratio*, o drawdown máximo observado e o retorno anualizado constituem indicadores fundamentais para validação da abordagem. A estratégia demonstrou capacidade de reduzir a exposição a períodos de alta heterocedasticidade, evitando parcela substancial das operações desfavoráveis durante picos de volatilidade. A aplicação de Volatility Targeting apresentou impacto mensurável na redução do risco relativo, conforme evidenciado pelo drawdown máximo em relação aos cenários sem ajuste dinâmico.

A implementação em MQL5 nativo se mostrou viável apesar das limitações operacionais do ambiente de desenvolvimento, permitindo o backtesting e a validação da estratégia no *Strategy Tester* do MetaTrader 5. O código foi estruturado de forma modular, com a classe GARCH isolada e o modelo ARIMA incorporado ao *Expert Advisor*, facilitando futuras extensões e ajustes de parâmetros conforme novos dados históricos se tornem disponíveis.

Durante a implementação, observações importantes emergiram quanto às limitações inerentes à abordagem. O teste de Dickey-Fuller Aumentado para verificação de estacionariedade foi parametrizado através da entrada configurável do parâmetro d , permitindo que o backtesting revelasse empiricamente a ordem ótima de diferenciação. A otimização de hiperparâmetros (p , q para ARIMA; p , q para GARCH) foi realizada dentro de um espaço paramétrico discreto, deixando abertura para trabalhos futuros com algoritmos evolucionários ou de busca mais sofisticados. O período de teste, caracterizado por volatilidade acentuada e dinâmicas de mercado complexas, estabeleceu condições de validação rigorosas, porém com implicações

quanto à generalização para períodos de regime de mercado distinto.

Conclui-se que a abordagem ARIMA-GARCH com Filter de Volatilidade representa contribuição significativa ao estado da arte em negociação algorítmica baseada em análise estatística. O mecanismo de filtragem de volatilidade oferece gestão de risco robusta através da modelagem dinâmica da heteroscedasticidade condicional. A integração teórica entre modelos de média condicional (ARIMA) e variância condicional (GARCH) demonstrou-se fundamentalmente sólida, alinhando-se tanto à literatura acadêmica quanto às práticas profissionais contemporâneas de negociação automatizada no mercado de capitais brasileiro.

3.2 Considerações Finais

Além dos modelos estatísticos implementados neste trabalho, perspectivas promissoras emergem da integração de técnicas de aprendizado de máquina, particularmente redes neurais recorrentes, para a captura de padrões não-lineares que modelos como ARIMA podem não conseguir identificar.

O modelo *Long Short-Term Memory (LSTM)* é particularmente relevante para este contexto. As redes *LSTM* são especialmente adequadas para séries temporais financeiras devido à sua capacidade de capturar dependências de longo prazo e padrões complexos não-lineares. Diferentemente do ARIMA, que assume relações lineares entre observações, *LSTM* pode aprender representações latentes sofisticadas dos dados de preço, potencialmente identificando sinais de reversão e mudanças de regime de mercado que modelos estatísticos tradicionais não detectam.

Conforme destacado por Silva (2022), redes neurais *LSTM* combinadas com técnicas de seleção de *features* (como *XGBoost* ou *feature importance*) alcançam níveis de acurácia comparáveis ou superiores a modelos estatísticos isolados em cenários de negociação algorítmica. A pesquisa de Xing et al. (2024) demonstrou que modelos híbridos ARIMA-GARCH podem servir como componente complementar a *LSTM*, onde o ARIMA fornece sinais de tendência linear de curto prazo e o GARCH fornece estimativas de risco, enquanto a *LSTM* captura a dinâmica não-linear subjacente.

Uma extensão natural deste trabalho seria a implementação de uma arquitetura híbrida *ARIMA-GARCH-LSTM*, em que:

- O modelo ARIMA continuaria a capturar a tendência condicional de curto prazo;
- O modelo GARCH continuaria a modelar a volatilidade condicional para filtragem de operações de alto risco;
- Uma rede *LSTM* seria treinada para aprender padrões não-lineares residuais, gerando sinais complementares de confirmação ou rejeição das operações sinalizadas pelos modelos anteriores.

Tal abordagem poderia ser implementada em Python utilizando bibliotecas como *TensorFlow/Keras* ou *PyTorch*, com posterior integração ao MetaTrader 5 via *API* Python nativa ou através de componentes de suporte a *machine learning* em MQL5.

Adicionalmente, técnicas de *ensemble learning* poderiam ser aplicadas, combinando as previsões de múltiplos modelos (ARIMA, GARCH, *LSTM*, *Random Forest*, *Gradient Boosting*) através de algoritmos de votação ponderada ou *stacking*, potencialmente aumentando a robustez e a acurácia geral do sistema.

Por fim, recomenda-se a validação de qualquer extensão futura não apenas em dados históricos (*backtesting*), mas também em cenários de *forward testing* com dados de out-of-sample, garantindo a generalização genuína do modelo e evitando o sobreajuste que frequentemente afeta modelos de *machine learning* em contextos financeiros.

REFERÊNCIAS

- ALMEIDA, F. L. *Análise da ação PETR4 na Bolsa de Valores de São Paulo com MetaTrader 5*. Monografia (Graduação em Banco de Dados) — Faculdade de Tecnologia Dr. Archimedes Lammoglia, Indaiatuba, 2016. Disponível em: <<https://ric.cps.sp.gov.br/handle/123456789/24287>>. Acesso em: 20 fev. 2025.
- ANDERSON, G. *The RSI: The Complete Guide*. 1. ed. New York: Traders Press, 1993. 245 p.
- APPEL, G. *Technical Analysis: Power Tools for Active Investors*. Nova Iorque: Financial Times Press, 2005.
- ARAYA, T. H.; ARAYA, J. A. A hybrid garch and deep learning method for volatility prediction. *Journal of Mathematics*, Londres, Reino Unido, v. 2024, 2024. Article ID 6305525.
- AYRES, M. *Brazil's government sees inflation within target band, unlike markets*. Londres, Reino Unido: [s.n.], 2024. Reuters. 18 nov. 2024. Disponível em: <<https://www.reuters.com/world/americas/brazil-sees-33-gdp-growth-this-year-25-next-year-2024-11-18/>>. Acesso em: 30 mar. 2025.
- AYRES, M. *Economists ramp up projections for Brazil's interest rates to above 15%*. Londres, Reino Unido: [s.n.], 2025. Reuters. 21 jan. 2025. Disponível em: <<https://www.reuters.com/world/americas/economists-ramp-up-projections-brazils-interest-rates-above-15-2025-01-21/>>. Acesso em: 30 mar. 2025.
- BATISTA, C. B. *Desenvolvimento de robô para automação de investimentos na bolsa de valores utilizando indicadores técnicos*. Monografia (Graduação em Engenharia de Computação) — Pontifícia Universidade Católica de Goiás, Goiânia, 2024. Disponível em: <<https://repositorio.pucgoias.edu.br/jspui/handle/123456789/8073>>. Acesso em: 30 mar. 2025.
- BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, Elsevier, Amsterdam, v. 31, n. 3, p. 307–327, 1986.
- BRASIL. Banco Central do Brasil. *Bolsas de Valores*. Brasília, DF: [s.n.], 2025. Disponível em: <<https://www.bcb.gov.br/pre/composicao/bv.asp?frame=1>>. Acesso em: 22 abr. 2025.
- BRASIL. Banco Central do Brasil. *Corretoras e Distribuidoras*. Brasília, DF: [s.n.], 2025. Disponível em: <https://www.bcb.gov.br/acessoinformacao/legado?url=https:%2F%2Fwww.bcb.gov.br%2Fpre%2Fcomposicao%2Fcorretoras_distribuidoras.asp>. Acesso em: 22 abr. 2025.
- BRASIL. Banco Central do Brasil. *Histórico de Taxas de Juros*. Brasília, DF: [s.n.], 2025. Disponível em: <<https://www.bcb.gov.br/controleinflacao/historicotaxasjuros>>. Acesso em: 30 mar. 2025.
- BRASIL. Banco Central do Brasil. *Taxa Selic*. Brasília, DF: [s.n.], 2025. Disponível em: <<https://www.bcb.gov.br/estatisticas/detalhamentoGrafico/graficoshome/selic>>. Acesso em: 22 abr. 2025.
- COJOCARU, R. *The Future Of Retail Trading: Bots And Automated Tools*. Nova Jersey, EUA: [s.n.], 2024. Forbes. Forbes Technology Council. 31 jul. 2024. Disponível em: <<https://www.forbes.com/councils/forbestechcouncil/2024/07/31/the-future-of-retail-trading-bots-and-automated-tools/>>. Acesso em: 02 abr. 2025.

ELDER, A. *Come Into My Trading Room: a complete guide to trading*. Nova Iorque, EUA: Wiley, 2002.

ENGLE, R. F. Autoregressive conditional heteroskedasticity with estimates of the variance of the United Kingdom inflation. *Econometrica*, The Econometric Society, New Jersey, EUA, v. 50, n. 4, p. 987–1008, 1982.

FERNANDES, A. *Fundamentos de Análise Técnica de Ações*. 1. ed. Rio de Janeiro: Campus, 2014.

FUNDO MONETÁRIO INTERNACIONAL (FMI). *World Economic Outlook: Navigating Global Divergences*. Washington, D.C.: FMI, 2024. Out. 2024. Disponível em: <<https://www.imf.org/en/Publications/WEO>>. Acesso em: 22 abr. 2025.

METAQUOTES LTD. *MetaTrader 5: Plataforma de Negociação para Forex, Ações e Futuros*. Limassol: MetaQuotes Ltd., 2024. Disponível em: <<https://www.metatrader5.com/pt>>. Acesso em: 01 mar. 2025.

SILVA, M. F. *Previsão de preços no mercado de ações brasileiro por meio de técnicas de inteligência artificial*. Dissertação (Mestrado em Ciências Contábeis) — Universidade Federal de Uberlândia, Uberlândia, 2022. Disponível em: <<https://repositorio.ufu.br/handle/123456789/35138>>. Acesso em: 30 mar. 2025.

TORMIN, W. P. *Previsão de Retornos do Bitcoin: Uma Abordagem Comparativa Entre Modelos ARIMA e LSTM Integrados com Dados de Tendências do Google*. Monografia (Graduação em Economia) — Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa (IDP), Brasília, 2024. Acesso em: 26 mar. 2025.

WARREN MAGAZINE. *Conheça as fraquezas e vantagens dos investimentos ativos e passivos*. 2025. Warren Magazine. 14 fev. 2025. Disponível em: <<https://warren.com.br/magazine/investimento-ativo-ou-passivo/>>. Acesso em: 22 abr. 2025.

WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 2. ed. Rio de Janeiro: Elsevier, 2014.

XING, Y. et al. *Predicting NVIDIA's Next-Day Stock Price: A Comparative Analysis of LSTM, MLP, ARIMA, and ARIMA-GARCH Models*. 2024. ArXiv. Preprint. Disponível em: <<https://arxiv.org/abs/2405.08284>>. Acesso em: 09 abr. 2025.

APÊNDICES

APÊNDICE A – Algoritmo do Expert Advisor no MetaTrader 5

Este apêndice apresenta o código fonte do *Expert Advisor* baseado na estratégia de cruzamento de Médias Móveis, implementado conforme o trabalho de graduação de Almeida (2016) e as documentações oficiais do MetaTrader 5.

```

1  //+-----+
2  /// EA_MM_Crossover_SLTP_v1.06.mq5 |
3  //+-----+
4  #property copyright "Adaptado por [Seu Nome/Assistente Virtual]"
5  #property link      "https://www.mql5.com"
6  #property version   "1.06"
7  #property description "Cruzamento de MM com SL/TP e reversão"
8
9  #include <Trade\Trade.mqh>
10 CTrade Trade;
11
12 input group "Parâmetros das Médias Móveis"
13 input int   RapidaMM_Periodo    = 10;
14 input ENUM_MA_METHOD RapidaMM_Metodo = MODE_SMA;
15 input ENUM_APPLIED_PRICE RapidaMM_Precos = PRICE_CLOSE;
16 input int   RapidaMM_Shift      = 0;
17
18 input int   DevagarMM_Periodo    = 20;
19 input ENUM_MA_METHOD DevagarMM_Metodo = MODE_SMA;
20 input ENUM_APPLIED_PRICE DevagarMM_Precos = PRICE_CLOSE;
21 input int   DevagarMM_Shift      = 0;
22
23 input group "Parâmetros de Negociação"
24 input double Volume_Fixo_Input   = 1.0;
25 input int    StopLoss_Points     = 50;
26 input int    TakeProfit_Points   = 100;
27 input ulong  MagicNumber         = 12349;
28 input int    Slippage_Points     = 10;
29 input bool   TradeOnNewBarOnly   = true;
30
31 int     h_RapidaMM;
32 int     h_DevagarMM;
33 datetime gl_TimeUltimaBarraProcessada = 0;
34 int      gl_DigitsPrice;
35 double   g_VolumeOperacional;
36
37 //+-----+
38 int OnInit()
39 {
40     g_VolumeOperacional = Volume_Fixo_Input;
41
42     h_RapidaMM = iMA(_Symbol, _Period, RapidaMM_Periodo, RapidaMM_Shift, RapidaMM_Metodo,
43                     RapidaMM_Precos);
44     if(h_RapidaMM == INVALID_HANDLE) return(INIT_FAILED);
45
46     h_DevagarMM = iMA(_Symbol, _Period, DevagarMM_Periodo, DevagarMM_Shift,
47                     DevagarMM_Metodo, DevagarMM_Precos);
48     if(h_DevagarMM == INVALID_HANDLE) return(INIT_FAILED);
49
50     Trade.SetExpertMagicNumber(MagicNumber);
51     Trade.SetDeviationInPoints(Slippage_Points);
52     Trade.SetTypeFillingBySymbol(_Symbol);
53
54     gl_DigitsPrice = (int)SymbolInfoInteger(_Symbol, SYMBOL_DIGITS);
55 }

```

```

54     double min_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MIN);
55     double max_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MAX);
56     double step_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_STEP);
57
58     if(g_VolumeOperacional < min_volume) g_VolumeOperacional = min_volume;
59     if(g_VolumeOperacional > max_volume) g_VolumeOperacional = max_volume;
60
61     if(step_volume > 0) {
62         double remainder = MathMod(g_VolumeOperacional, step_volume);
63         if(MathAbs(remainder) > 1e-10) {
64             g_VolumeOperacional = MathRound(g_VolumeOperacional / step_volume) *
                step_volume;
65             int volume_digits = 0;
66             if(step_volume < 1.0 && step_volume > 0) {
67                 string step_str = DoubleToString(step_volume, 8);
68                 int dot_pos = StringFind(step_str, ".");
69                 if(dot_pos != -1) volume_digits = StringLen(step_str) - dot_pos - 1;
70             }
71             g_VolumeOperacional = NormalizeDouble(g_VolumeOperacional, volume_digits);
72         }
73     }
74     if(g_VolumeOperacional < min_volume) g_VolumeOperacional = min_volume;
75
76     return(INIT_SUCCEEDED);
77 }
78 //+-----+
79 void OnDeinit(const int reason)
80 {
81     if(h_RapidaMM != INVALID_HANDLE) IndicatorRelease(h_RapidaMM);
82     if(h_DevagarMM != INVALID_HANDLE) IndicatorRelease(h_DevagarMM);
83 }
84 //+-----+
85 ENUM_POSITION_TYPE ObterTipoPosicaoAtual() {
86     for(int i = PositionsTotal() - 1; i >= 0; i--) {
87         ulong ticket = PositionGetTicket(i);
88         if(ticket > 0 && PositionSelectByTicket(ticket)) {
89             if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
                PositionGetInteger(POSITION_MAGIC) == MagicNumber) {
90                 return (ENUM_POSITION_TYPE)PositionGetInteger(POSITION_TYPE);
91             }
92         }
93     }
94 }
95 return (ENUM_POSITION_TYPE)-1;
96 }
97 //+-----+
98 bool FecharPosicaoAtual(ENUM_POSITION_TYPE tipoPosicaoParaFechar) {
99     if (tipoPosicaoParaFechar == POSITION_TYPE_BUY || tipoPosicaoParaFechar ==
        POSITION_TYPE_SELL) {
100         for(int i = PositionsTotal() - 1; i >= 0; i--) {
101             ulong ticket = PositionGetTicket(i);
102             if(ticket > 0 && PositionSelectByTicket(ticket)) {
103                 if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
                    PositionGetInteger(POSITION_MAGIC) == MagicNumber &&
                    PositionGetInteger(POSITION_TYPE) == tipoPosicaoParaFechar) {
104
105                     if(Trade.PositionClose(ticket, Slippage_Points)) {
106                         return true;
107                     } else {
108                         return false;
109                     }
110                 }
111             }
112         }
113     }
114 }

```

```

115     }
116     return true;
117 }
118 //+-----+
119 void OnTick()
120 {
121
122     if(TradeOnNewBarOnly)
123     {
124         static datetime prevTime = 0;
125         datetime currentTime = (datetime)SeriesInfoInteger(_Symbol, _Period,
            SERIES_LASTBAR_DATE);
126         if(currentTime == prevTime) return;
127         prevTime = currentTime;
128     }
129
130     double arr_temp[1];
131     double maRapidaAnterior, maLentaAnterior, maRapidaAntesDoCruzamento,
        maLentaAntesDoCruzamento;
132
133     if(CopyBuffer(h_RapidaMM, 0, 1, 1, arr_temp) != 1) return; maRapidaAnterior = arr_temp
        [0];
134     if(CopyBuffer(h_DevagarMM, 0, 1, 1, arr_temp) != 1) return; maLentaAnterior =
        arr_temp[0];
135     if(CopyBuffer(h_RapidaMM, 0, 2, 1, arr_temp) != 1) return; maRapidaAntesDoCruzamento =
        arr_temp[0];
136     if(CopyBuffer(h_DevagarMM, 0, 2, 1, arr_temp) != 1) return; maLentaAntesDoCruzamento
        = arr_temp[0];
137
138     MqlTick tick;
139     if(!SymbolInfoTick(_Symbol, tick) || tick.ask == 0 || tick.bid == 0) return;
140     double askPrice = tick.ask;
141     double bidPrice = tick.bid;
142
143     ENUM_POSITION_TYPE tipoPosicaoAtual = ObterTipoPosicaoAtual();
144
145     bool condicaoCompra = maRapidaAnterior > maLentaAnterior && maRapidaAntesDoCruzamento
        <= maLentaAntesDoCruzamento;
146     if(condicaoCompra)
147     {
148         if(tipoPosicaoAtual == POSITION_TYPE_SELL) {
149             if(!FecharPosicaoAtual(POSITION_TYPE_SELL)) return;
150             Sleep(1);
151             tipoPosicaoAtual = ObterTipoPosicaoAtual();
152         }
153
154         if(tipoPosicaoAtual != POSITION_TYPE_BUY) {
155             double sl = 0, tp = 0;
156             double stop_level_points = (double)SymbolInfoInteger(_Symbol,
                SYMBOL_TRADE_STOPS_LEVEL);
157             double min_distance_sl_tp = stop_level_points * _Point;
158
159             if(StopLoss_Points > 0) {
160                 sl = NormalizeDouble(askPrice - StopLoss_Points * _Point, gl_DigitsPrice);
161                 if (min_distance_sl_tp > 0 && askPrice - sl < min_distance_sl_tp) {
162                     sl = NormalizeDouble(askPrice - min_distance_sl_tp, gl_DigitsPrice);
163                 }
164                 if (sl >= askPrice) sl = 0;
165             }
166             if(TakeProfit_Points > 0) {
167                 tp = NormalizeDouble(askPrice + TakeProfit_Points * _Point, gl_DigitsPrice)
                    ;
168                 if (min_distance_sl_tp > 0 && tp - askPrice < min_distance_sl_tp) {

```

```

169         tp = NormalizeDouble(askPrice + min_distance_sl_tp, gl_DigitsPrice);
170     }
171     if (tp <= askPrice && TakeProfit_Points > 0) tp = 0;
172 }
173
174 Trade.Buy(g_VolumeOperacional, _Symbol, askPrice, sl, tp, "Compra MM Rev");
175 }
176 return;
177 }
178
179 bool condicaoVenda = maRapidaAnterior < maLentaAnterior && maRapidaAntesDoCruzamento
180     >= maLentaAntesDoCruzamento;
181 if(condicaoVenda)
182 {
183     if(tipoPosicaoAtual == POSITION_TYPE_BUY) {
184         if(!FecharPosicaoAtual(POSITION_TYPE_BUY)) return;
185         Sleep(1);
186         tipoPosicaoAtual = ObterTipoPosicaoAtual();
187     }
188     if(tipoPosicaoAtual != POSITION_TYPE_SELL) {
189         double sl = 0, tp = 0;
190         double stop_level_points = (double)SymbolInfoInteger(_Symbol,
191             SYMBOL_TRADE_STOPS_LEVEL);
192         double min_distance_sl_tp = stop_level_points * _Point;
193
194         if(StopLoss_Points > 0) {
195             sl = NormalizeDouble(bidPrice + StopLoss_Points * _Point, gl_DigitsPrice);
196             if (min_distance_sl_tp > 0 && sl - bidPrice < min_distance_sl_tp) {
197                 sl = NormalizeDouble(bidPrice + min_distance_sl_tp, gl_DigitsPrice);
198             }
199             if (sl <= bidPrice) sl = 0;
200         }
201         if(TakeProfit_Points > 0) {
202             tp = NormalizeDouble(bidPrice - TakeProfit_Points * _Point, gl_DigitsPrice)
203             ;
204             if (min_distance_sl_tp > 0 && bidPrice - tp < min_distance_sl_tp) {
205                 tp = NormalizeDouble(bidPrice - min_distance_sl_tp, gl_DigitsPrice);
206             }
207             if (tp >= bidPrice && TakeProfit_Points > 0) tp = 0;
208         }
209         Trade.Sell(g_VolumeOperacional, _Symbol, bidPrice, sl, tp, "Venda MM Rev");
210     }
211     return;
212 }
213 //+-----+

```