

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

**Previsão e Análise de Tendências no Mercado de Ativos:
Desenvolvimento de Ferramenta Algorítmica com Modelos
Estatísticos no MetaTrader 5**

Indaiatuba

2025

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

**Previsão e Análise de Tendências no Mercado de Ativos:
Desenvolvimento de Ferramenta Algorítmica com Modelos
Estatísticos no MetaTrader 5**

Projeto de trabalho de graduação apresentado por Bruno Rocha Pereira e Giovanni Silva Loose como pré-requisito para a conclusão do Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Faculdade de Tecnologia de Indaiatuba, elaborado sob a orientação do Prof. MsC. Michel Moron Munhoz.

Indaiatuba

2025

RESUMO

O cenário econômico brasileiro recente, caracterizado por instabilidade macroeconômica, inflação elevada e consequente aumento da taxa Selic, impõe desafios significativos aos investidores. A volatilidade do mercado financeiro, intensificada por fatores internos e externos, dificulta a tomada de decisões de investimento, especialmente em ativos como ações. Diante desse contexto e da crescente digitalização do setor financeiro, o trading algorítmico surge como uma alternativa promissora. Este projeto propõe o desenvolvimento de uma ferramenta computacional, utilizando a linguagem MQL5 na plataforma MetaTrader 5, para análise de padrões de tendência e volatilidade no mercado de ações brasileiro, tomando como base o ativo PETR4. A ferramenta integrará análises técnicas estatísticas, combinando o uso de Médias Móveis para identificação de tendências, o modelo ARIMA para previsão de séries temporais de preços, o modelo GARCH para modelagem da volatilidade condicional dos resíduos do ARIMA, indicadores como RSI como filtro de confirmação e Machine Learning para envolver análise não linear. A hipótese central é que essa abordagem integrada permitirá a geração de sinais de negociação com maior eficácia (potencial de acerto e adequação ao risco) em comparação com o uso isolado ou incompleto dessas técnicas. O estudo visa explorar modelos com dados atualizados, fornecer análises que possam embasar estratégias de investimento adaptadas ao cenário de juros altos e investigar a robustez da combinação de modelos frente às flutuações do mercado, contribuindo para o conhecimento na área e oferecendo uma alternativa prática para investidores.

Palavras-chave: Trading Algorítmico. Modelos Estatísticos. ARIMA. GARCH. Mercado de Ações. Bolsa de Valores. Volatilidade. MQL5.

ABSTRACT

The recent Brazilian economic scenario, characterized by macroeconomic instability, high inflation, and a consequent increase in the Selic interest rate, poses significant challenges for investors. Financial market volatility, intensified by internal and external factors, hinders investment decision-making, especially in assets such as stocks. Given this context and the increasing digitalization of the financial sector, algorithmic trading emerges as a promising alternative. This project proposes the development of a computational tool, using the MQL5 language on the MetaTrader 5 platform, for analyzing trend and volatility patterns in the Brazilian stock market, focusing on the PETR4 asset. The tool will integrate statistical technical analyses, combining the use of Moving Averages for trend identification, the ARIMA model for forecasting price time series, the GARCH model for modeling the conditional volatility of ARIMA residuals, the RSI indicator as a confirmation filter and Machine Learning for non-linear analysis. The central hypothesis is that this integrated approach will allow the generation of trading signals with greater effectiveness (potential accuracy and risk suitability) compared to the isolated or incomplete use of these techniques. The study aims to explore models with updated data, provide analyses that can support investment strategies adapted to the high-interest-rate scenario, and investigate the robustness of the combined models against market fluctuations, contributing to knowledge in the field and offering a practical alternative for investors.

Keywords: *Algorithmic Trading. Statistical Models. ARIMA. GARCH. Stock Market. Volatility. MQL5.*

LISTA DE FIGURAS

Figura 1 – Interface MetaTrader	19
Figura 2 – Fluxograma do Funcionamento do EA	20
Figura 3 – Tendência de Alta com RSI	22
Figura 4 – Cruzamento de médias móveis	23
Figura 5 – Fluxo ARIMA	26
Figura 6 – Fluxo GARCH	28
Figura 7 – Célula de Memória do LSTM	29
Figura 8 – Modelo Completo	41
Figura 9 – Desempenho do modelo proposto (2º teste)	44
Figura 10 – Gráfico de dispersão da correlação de lucro (2º teste)	44

LISTA DE TABELAS

Tabela 1 – Variações da SELIC anual, Meta e Real (2020-2025*).....	9
Tabela 2 – Tabela Comparativa	35
Tabela 3 – Tabela Comparativa (Detalhada)	36
Tabela 4 – Comparação modelo proposto x ALMEIDA (2016)	43
Tabela 5 – Cronograma de Atividades	46

LISTA DE SIGLAS

ADF	Augmented Dickey-Fuller
AIC	Akaike Information Criterion
API	Application Programming Interface
ARIMA	AutoRegressive Integrated Moving Average
BiLSTM	Bidirectional Long Short-Term Memory
CNN	Convolutional Neural Network
Copom	Comitê de Política Monetária
EA	Expert Advisor
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
IFR	Índice de Força Relativa
LSTM	Long Short-Term Memory
MACD	Moving Average Convergence Divergence
MLP	Multilayer Perceptron
MM	Média Móvel
MME	Média Móvel Exponencial
MMS	Média Móvel Simples
MQL5	MetaQuotes Language 5
MT5	MetaTrader 5
PETR4	Código de negociação das ações preferenciais da Petrobras
PIB	Produto Interno Bruto
PTG	Projeto de Trabalho de Graduação
RNN	Redes Neurais Recorrentes
RSI	Relative Strength Index
SELIC	Sistema Especial de Liquidação e de Custódia
SL	Stop Loss
TP	Take Profit

SUMÁRIO

INTRODUÇÃO	9
1 Contextualização	9
1.1 Problema	10
1.2 Hipóteses.....	11
1.3 Objetivo	12
1.4 Justificativa	12
1.5 Natureza e Tipo da pesquisa a ser desenvolvido	13
1.6 Organização dos capítulos	14
CAPÍTULO I	16
2 Fundamentação Teórica.....	16
2.1 Macro, Microeconomia e Inflação	16
2.2 Corretora	16
2.3 Bolsa de Valores	17
2.4 Ativos	17
2.5 Tipos de Análise Técnica	17
2.6 MetaTrader 5	19
2.7 Indicadores.....	21
2.8 Modelos Estatísticos	25
2.9 Aprendizagem de Máquina	28
2.10 Trabalhos Relacionados	33
CAPÍTULO II	37
3 Metodologia	37
3.1 Natureza da Pesquisa	37
3.2 Padrões para Pesquisa Experimental	37
3.3 Experimento de Pesquisa	38
3.4 Diagramas	40
3.5 Critérios para Avaliação.....	40
3.6 Resultados preliminares atingidos no PTG.....	42
3.7 Resultados Esperados no TG	45
3.8 Cronograma.....	45

REFERÊNCIAS.....	47
-------------------------	-----------

INTRODUÇÃO

1 Contextualização

Nos últimos anos, a economia brasileira tem enfrentado um cenário desafiador, marcado por instabilidade macroeconômica e oscilações no mercado financeiro. Para tentar controlar a inflação pressionada pela alta do dólar e pelos desafios nas contas públicas, o Banco Central tem buscado contê-la por meio do aumento da taxa Selic, que alcançou 14,25% ao ano e pode ultrapassar 15%.

Definida periodicamente pelo Comitê de Política Monetária (Copom), essa taxa reflete as condições macroeconômicas do país e as expectativas para a inflação em 2025, segundo previsões de instituições financeiras como Citi, Itaú e XP (AYRES, 2025).

Esse aumento da Selic reflete preocupações com a inflação, que vem subindo não só pelo custo maior de produtos importados, consequência direta da desvalorização do Real, mas também por fatores internos, como o consumo elevado e a falta de confiança na estabilidade fiscal do país. Essa instabilidade do mercado financeiro está diretamente relacionada à política monetária adotada pelo Banco Central, com destaque para a taxa Selic. Como principal instrumento para o controle da inflação e a regulação da atividade econômica, a Selic influencia diretamente outras taxas de juros, como as de empréstimos, financiamentos e aplicações financeiras (BRASIL. Banco Central do Brasil, d). Mudanças significativas na Selic podem alterar a dinâmica do mercado financeiro, impactando tanto o custo do crédito quanto o retorno dos investimentos.

Tabela 1 – Variações da SELIC anual, Meta e Real (2020-2025*)

Ano	SELIC Meta (%)	SELIC Real (%)
2025	14,25*	–
2024	12,25	12,15
2023	11,75	11,65
2022	13,75	13,65
2021	9,25	9,15
2020	2,00	1,90

Fonte: Banco Central do Brasil (2025).

Apesar do cenário desafiador, a economia brasileira continua crescendo, com um avanço de 3,3% em 2024 e previsão de 2,5% para 2025 no PIB (AYRES, 2024). No entanto, esse crescimento acontece em meio a desafios. A alta dos juros torna o crédito mais caro e dificulta novos investimentos, enquanto a queda do Real, apesar de favorecer exportadores, encarece produtos e reduz o poder de compra da população.

Por outro lado, a crescente digitalização e modernização do mercado financeiro impulsiona o desenvolvimento de soluções tecnológicas que visam otimizar o processo de tomada de decisão e mitigar os riscos inerentes ao mercado, como o surgimento do trading algorítmico¹ (ALMEIDA, 2016; SILVA, 2022). Nesse contexto, essa ferramenta, que se configura como

¹ Negociação de ativos automatizada por algoritmos.

uma forma automatizada de investir por meio de algoritmos, ganha relevância na execução de operações com modelos matemáticos e estatísticos. Essa abordagem busca proporcionar maior eficiência operacional ao identificar padrões de tendência nos ativos financeiros. Embora o estudo de Almeida (2016) aponte desafios em relação à lucratividade em períodos de crise, os resultados de ambos os trabalhos demonstram o potencial do trading algorítmico para otimizar a tomada de decisões e buscar resultados consistentes, sobretudo em cenários de mercado mais estáveis.

Conforme apontado em artigo da Forbes (COJOCARU, 2024), essa tendência digital, que já automatiza entre 60% e 73% das negociações de ações nos EUA, está se expandindo globalmente. Empresas como Trade Ideas, TrendSpider e Imperative Execution utilizam inteligência artificial para analisar grandes volumes de dados, prevendo tendências de mercado e padrões, e plataformas como TD Ameritrade, Interactive Brokers e TradeStation oferecem ferramentas e APIs para que investidores, inclusive de varejo, desenvolvam e implementem estratégias algorítmicas.

Diante desse cenário, o objetivo deste projeto é propor a criação de uma ferramenta baseada em trading algorítmico e modelos estatísticos para analisar padrões de tendência no mercado de ativos, explorando as oportunidades geradas pela volatilidade.

1.1 Problema

A alta inflação é constante no mercado brasileiro da atualidade, amplamente estudada e divulgada pelo BCB, mais especificamente pelo órgão COPOM, que regula e configura a taxa mais adequada para os níveis inflacionários no país. Os sucessivos aumentos da taxa básica de juros tornam investimentos menos favoráveis e comprometem o poder de compra, representando um desafio central para a manutenção de patrimônio.

A instabilidade inerente aos ativos financeiros dificulta a realização de previsões confiáveis, enquanto a persistente inflação desvaloriza a moeda nacional, exigindo dos investidores a adoção de estratégias que visem primordialmente a proteção do capital e, secundariamente, a obtenção de retornos reais positivos.

Diante desse cenário macroeconômico adverso, torna-se essencial a busca e adoção de modalidades de investimento que sejam não apenas adaptadas à inflação vigente, mas também resilientes às frequentes e, por vezes, abruptas oscilações do mercado. A complexidade observada nos modelos tradicionais de análise de investimento, quando confrontados com a dinâmica atual do mercado, amplia o desafio. Emerge, portanto, a necessidade premente do desenvolvimento de ferramentas analíticas avançadas que possam auxiliar na identificação de padrões de tendência e na tomada de decisões de investimento mais informadas e potencialmente mais seguras neste contexto econômico particular.

1.2 Hipóteses

1.2.1 Hipótese Central

Propõe-se que a integração metodológica de previsão de séries temporais com modelo ARIMA, modelagem de volatilidade condicional com modelo GARCH e indicadores como RSI em uma ferramenta algorítmica unificada, desenvolvida em MQL5, permite a geração de sinais de negociação para ativos com maior eficácia, aferida em termos de potencial de acerto e adequação ao risco, do que abordagens que empregam estas técnicas de forma isolada ou incompleta. A viabilidade de combinar diferentes ferramentas de análise para obter resultados superiores encontra respaldo em trabalhos como o de Batista (2024), que demonstrou resultados positivos ao integrar indicadores como RSI, Médias Móveis Exponenciais e MACD em um modelo de negociação.

1.2.2 Hipótese da Complementaridade Preditiva e de Risco

Postula-se que a combinação sequencial dos modelos ARIMA e GARCH constitui um avanço significativo em relação a análises baseadas em Médias Móveis, como as exploradas por Almeida (2016). Especificamente, espera-se que: o modelo ARIMA capture a dinâmica temporal e forneça previsões de curto prazo da direção dos preços com maior refinamento do que as Médias Móveis. A subsequente aplicação do modelo GARCH aos resíduos gerados pelo ARIMA incorpore com maior detalhe a modelagem da volatilidade e do risco associado às previsões, permitindo uma avaliação mais ampla do cenário de mercado.

1.2.3 Hipótese da Necessidade de Confirmação por Indicadores

Assume-se que a incorporação de indicadores técnicos como o RSI pode assegurar melhores decisões prevenindo falsos positivos. A análise de condições de mercado adicionais (e.g., níveis de sobrecompra/sobre venda indicados pelo RSI) atua como um mecanismo de filtro essencial para validar ou invalidar os sinais primários gerados pela combinação ARIMA-GARCH, mitigando o risco de entradas em momentos potencialmente inoportunos e aumentando a seletividade das operações identificadas pela ferramenta.

1.2.4 Hipótese da Potencialização Preditiva com uso de Machine Learning

Propõe-se que, motivada pelos desafios que modelos estatísticos tradicionais como ARIMA e GARCH enfrentam ao lidar com a complexidade dos mercados financeiros, conforme demonstrado por Araya e Araya (2024) em sua pesquisa com modelos híbridos, a integração do modelo LSTM pode aprimorar a precisão das previsões geradas por esses modelos. Os mercados financeiros são influenciados por diversos fatores, muitos dos quais não seguem padrões lineares simples. O LSTM, por sua capacidade de identificar padrões complexos e pequenas dependências temporais nos dados, pode capturar nuances que escapam a modelos mais tradicionais.

Embora o estudo de Xing et al. (2024) mostre que, em algumas situações, modelos lineares podem ser mais eficazes, assume-se que as características específicas do mercado de ações brasileiro e a volatilidade histórica de PETR4 introduzem um nível significativo de não linearidade. Portanto, espera-se que o LSTM, após um treinamento cuidadoso, seja capaz de refinar e complementar as previsões de ARIMA, GARCH e indicadores técnicos, resultando em uma ferramenta de negociação mais adaptável, precisa e eficaz na gestão de riscos.

1.3 Objetivo

1.3.1 Objetivo Geral

Propor uma ferramenta algorítmica integrada, utilizando a linguagem de programação MQL5 e a plataforma MetaTrader 5, para análise e previsão de tendências no mercado de ativos, com foco na economia brasileira.

1.3.2 Objetivos Específicos

- Aprofundar conceitos teóricos do mercado financeiro, com ampla ênfase em volatilidade e tendências;
- Compreender e aplicar os conhecimentos na plataforma MetaTrader em junção com MQL5 na automação de estratégias;
- Implementar modelos estatísticos (ARIMA e GARCH) para previsão de séries temporais e modelagem de volatilidade;
- Integrar indicadores técnicos (RSI e MACD) para obter sinais congruentes em pontos de entrada e saída;
- Comparar resultados obtidos com a atual Taxa SELIC (16, mai. 2025);
- Usar Machine Learning com modelo LSTM para realizar análises não lineares com os resultados do modelo que será criado.

1.4 Justificativa

Esta pesquisa se justifica inicialmente pela revisitação e aplicação contemporânea do conceito explorado por Almeida (2016). Seu estudo demonstrou a viabilidade do uso de robôs de investimento via MetaTrader em diferentes períodos sobre o ativo PETR4. Contudo, houve uma evolução significativa nos cenários econômicos e nas tecnologias disponíveis desde então, o que motiva esta nova abordagem, alinhada às suas próprias recomendações futuras para aplicação em mercados de alta volatilidade.

Ademais, por consequência direta do presente cenário econômico de inflação persistente e juros elevados no Brasil, outro ponto central que justifica este trabalho é a necessidade de identificar e avaliar alternativas de investimento que possam se mostrar viáveis e potencialmente lucrativas. Este estudo visa contribuir para mitigar os efeitos do congelamento financeiro que pode afetar investidores nesse contexto, oferecendo análises que possam embasar decisões para aqueles interessados em diversificar seus portfólios.

Além disso, a pesquisa busca agregar valor ao conhecimento acadêmico na área de finanças quantitativas e trading algorítmico no contexto brasileiro, podendo servir de base ou inspiração para futuros projetos relacionados.

1.5 Natureza e Tipo da pesquisa a ser desenvolvido

A presente pesquisa se enquadra, inicialmente, na classificação de ciência empírica, uma vez que se dedica à investigação de fenômenos observáveis do mundo real. Conforme Wazlawick (2014), a ciência empírica se caracteriza pela busca de conhecimento através da experiência e da observação, o que se manifesta neste estudo na análise de dados históricos de preços de ações para a identificação de padrões e tendências. A coleta e o tratamento desses dados são fundamentais para a construção e validação da ferramenta algorítmica.

Adicionalmente, a pesquisa possui um caráter aplicado. Wazlawick (2014) destaca que a ciência aplicada se preocupa com a utilização prática do conhecimento científico para a solução de problemas específicos. Neste contexto, o desenvolvimento de uma ferramenta para auxiliar investidores no mercado de ativos demonstra claramente a intenção de aplicar os conhecimentos gerados para atender a uma demanda concreta, buscando otimizar o processo de tomada de decisão e a gestão de riscos.

No que tange à sua natureza, a pesquisa se aproxima de uma ciência exata, embora com ressalvas. A utilização de modelos estatísticos como ARIMA e GARCH, bem como a adoção de métricas quantitativas para avaliar o desempenho da ferramenta, refletem a busca por precisão e objetividade, características marcantes das ciências exatas. No entanto, é fundamental reconhecer que o mercado financeiro, objeto de estudo desta pesquisa, é intrinsecamente marcado pela incerteza e pela volatilidade. Essa característica introduz um elemento de inexatidão que diferencia este campo de investigação de sistemas puramente determinísticos, nos quais as ciências exatas tradicionalmente se concentram.

Sob a perspectiva do rigor metodológico, a pesquisa busca alinhamento com uma ciência hard. Segundo Wazlawick (2014), as ciências hard se caracterizam pela utilização de métodos formais e quantitativos, pela busca de leis gerais e pela ênfase na objetividade e na replicabilidade. A aplicação de métodos estatísticos, a definição de métricas de avaliação e a validação empírica por meio de backtesting demonstram a preocupação em conferir solidez e validade aos resultados obtidos.

Por fim, a pesquisa possui um componente nomotético. Wazlawick (2014) explica que

as ciências nomotéticas buscam estabelecer leis gerais ou princípios que expliquem classes de fenômenos. Neste estudo, a análise de tendências e volatilidade no mercado de ações tem como objetivo identificar padrões que possam, dentro de certas limitações, auxiliar na previsão do comportamento futuro dos ativos. Embora a previsão no mercado financeiro seja inerentemente complexa, a busca por regularidades e a tentativa de formular generalizações demonstram o caráter nomotético da investigação.

Em relação aos objetivos, a pesquisa se classifica como explicativa. Conforme Wazlawick (2014), a pesquisa explicativa busca identificar as causas ou razões de determinados fenômenos, aprofundando o conhecimento sobre as relações entre variáveis. Neste caso, o estudo busca explicar como a combinação de diferentes modelos estatísticos e de aprendizado de máquina pode influenciar a capacidade preditiva e a gestão de riscos no mercado de ações, investigando os mecanismos pelos quais essa integração pode otimizar o desempenho da ferramenta algorítmica.

No que concerne aos procedimentos técnicos, a pesquisa se desenvolve por meio de pesquisa bibliográfica e pesquisa experimental. A pesquisa bibliográfica é fundamental para a revisão da literatura existente sobre modelos estatísticos, aprendizado de máquina e trading algorítmico, fornecendo a base teórica e conceitual para o estudo. A pesquisa experimental, por sua vez, é realizada por meio de backtesting na plataforma MetaTrader 5, envolvendo a manipulação de variáveis (parâmetros dos modelos, indicadores técnicos) e a observação dos resultados (taxa de acerto, lucro/prejuízo) para validar a eficácia da ferramenta desenvolvida.

1.6 Organização dos capítulos

O Capítulo 1 apresenta a Fundamentação Teórica, oferecendo a base de conhecimento necessária para a compreensão do projeto.

Inicialmente, serão abordados conceitos introdutórios que contextualizam a pesquisa. Isso inclui algumas partes sobre economia e princípios básicos do mercado financeiro, como o funcionamento de corretoras, bolsas de valores e as características dos ativos negociados.

Mais adiante, o capítulo se aprofunda em conceitos mais técnicos, importantes para a análise e modelagem. Serão discutidas as diferentes abordagens da análise técnica de ativos, com foco nos métodos estatísticos. A plataforma MetaTrader 5 e sua linguagem MQL5, utilizadas no desenvolvimento, serão apresentadas, assim como os tipos de indicadores de mercado e os modelos estatísticos para análise de séries temporais e volatilidade. Também serão introduzidos os conceitos de Aprendizagem de Máquina aplicados à previsão financeira.

Por fim, o capítulo apresentará uma revisão de pesquisas anteriores. Esta seção buscará relacionar o presente estudo com trabalhos já existentes na área, identificando como esta pesquisa se posiciona e contribui para o campo.

O Capítulo 2 detalha a Metodologia utilizada, explicando o processo de construção e validação da ferramenta algorítmica.

Este capítulo começa descrevendo a natureza da pesquisa e como o ambiente para os

experimentos será preparado. Serão especificadas as ferramentas de software, linguagens de programação e as fontes de dados para o ativo financeiro em estudo, incluindo como os dados do mercado brasileiro serão acessados.

Em seguida, explora-se como o experimento de pesquisa será conduzido, com a descrição das etapas para a implementação dos diferentes componentes da ferramenta. O processo inicia com as análises baseadas em indicadores de tendência, avança para a modelagem estatística dos preços e a análise da volatilidade dos resíduos, e culmina na integração de técnicas de Aprendizagem de Máquina visando aprimorar as previsões.

O capítulo conclui estabelecendo os critérios para a avaliação dos modelos desenvolvidos e da ferramenta como um todo, detalhando as métricas de desempenho que serão utilizadas nos testes. Adicionalmente, são apresentados os resultados preliminares obtidos e os esperados ao final do projeto e o cronograma planejado para a sua execução.

CAPÍTULO I

2 Fundamentação Teórica

2.1 Macro, Microeconomia e Inflação

O cenário econômico global recente tem sido impactado por choques simultâneos: conflitos geopolíticos, problemas gerais nas cadeias produtivas e pressões inflacionárias de alto risco. Conforme o FUNDO MONETÁRIO INTERNACIONAL (FMI) (2024), esse cenário evidencia um problema estrutural do sistema internacional: a liquidez global supera, em alguns níveis, a produção real, criando distorções gerais nos preços e no crescimento econômico.

No Brasil, a microeconomia sofre os efeitos desse ambiente. A taxa Selic em 14,25% (COPOM, 2025) desestimula investimentos em produção real, como comprovam os estudos do BRASIL. Banco Central do Brasil (c), que relacionam juros altos à migração do capital para aplicações financeiras, reduzindo posições no setor industrial.

A inflação, por fim, é um desafio em especial. O FUNDO MONETÁRIO INTERNACIONAL (FMI) (2024) alertou que as economias emergentes, assim como a brasileira, enfrentam o “trade-off” perverso: políticas monetárias com grande enfoque restritivo controlam os preços, mas sacrificam, no curto prazo, o crescimento do PIB.

Diante desse cenário geral, alternativas economicamente viáveis tornam-se uma prioridade, especialmente as menos atreladas às variáveis macroeconômicas. Essa contextualização servirá de pano de fundo para o estudo de estratégias de análise econômica, que serão detalhadas no decorrer do projeto.

2.2 Corretora

De acordo com o BCB (Banco Central do Brasil), as corretoras e distribuidoras, na atividade de intermediação, oferecem serviços como plataformas de investimento pela internet (home broker), consultoria financeira, clubes de investimentos, financiamento para compra de ações (conta margem) e administração e custódia de títulos e valores mobiliários dos clientes. Na remuneração pelos serviços, essas instituições podem cobrar comissões e taxas (BRASIL. Banco Central do Brasil, b).

Portanto, a substancial necessidade de um serviço mediador para representação em ativos de capital aberto, ou seja, ativos que possuem participação em mercado anunciadas para o acesso do grande público. Além disso, existem séries de medidas formais que se demonstram necessárias para o processo burocrático da parte fiscal e jurídica na transação de participações em empresas, medidas essas que são assumidas por serviços de corretagem.

2.3 Bolsa de Valores

De acordo com o BCB (Banco Central do Brasil), as bolsas de valores são sociedades anônimas ou associações civis, com o objetivo de manter local ou sistema adequado ao encontro de seus membros e à realização entre eles de transações de compra e venda de títulos e valores mobiliários, em mercado livre e aberto, especialmente organizado e fiscalizado por seus membros e pela Comissão de Valores Mobiliários. Possuem autonomia financeira, patrimonial e administrativa (Resolução CMN 2.690, de 2000) (BRASIL. Banco Central do Brasil, a).

Diante da necessidade de capital exógeno, as empresas possuem o mecanismo de capital aberto que possibilita a entrada de capital de fora da empresa por parte de investidores; em contrapartida, a empresa cede porcentagens do negócio proporcionais aos montantes investidos por parte dos acionistas. Concluindo, a prática é extremamente relevante para fomentar e financiar o escalonamento da empresa, mesmo que sejam cedidos percentuais do empreendimento, o montante geral escalonado é, geralmente, maior que o montante de capital fechado.

2.4 Ativos

De acordo com a Warren Magazine, os ativos são todos aqueles que possuem expectativa de superar o desempenho do mercado ou de um índice de referência. Utilizando-se de análises detalhadas, pesquisas de mercado e previsões econômicas, os gestores se alinham para decisões por posições em investimentos (WARREN MAGAZINE, 2025).

Por fim, os gestores buscam por oportunidades de investimento que possam gerar retornos acima da média do ativo e do mercado, alinhando-se ao princípio de alocação eficiente de capital. Assim como destacado por Elder (2002), cada decisão de investimento requer uma análise minuciosa do trade-off, escolha com custo de oportunidade, entre risco e retorno, uma vez que os recursos são limitados e devem ser distribuídos de forma otimizada. Todavia, em cenários adversos, pode-se demonstrar necessário o rebalanceamento da carteira, estrategicamente mitigando perdas de capital, prática comum em mercados voláteis, assim como foi apontado por Ayres (2025).

2.5 Tipos de Análise Técnica

Uma forma de tentar prever o que vai acontecer com os preços dos ativos no mercado financeiro é usar a análise técnica. Essa análise estuda o histórico dos preços para encontrar padrões e tendências que possam indicar o que pode acontecer no futuro. Essa ideia surgiu há muito tempo, com o comércio de arroz, e hoje é usada para analisar ações, moedas e outros ativos. O importante é olhar para os preços, sem se preocupar com notícias ou outras coisas que possam influenciar o mercado (FERNANDES, 2014).

A análise técnica pode ser usada em quase todos os mercados e mistura ciência com a forma como as pessoas pensam e agem nesses mercados. Para ter mais chances de sucesso, é

bom se especializar em um mercado e escolher as ferramentas certas para analisar os dados. Existem dois jeitos principais de fazer análise técnica: a mais antiga, chamada empírica ou clássica, e a mais moderna, chamada estatística (FERNANDES, 2014).

2.5.1 Análise Técnica Empírica ou Clássica

A análise técnica empírica, ou clássica, é o método mais tradicional de analisar o mercado financeiro. Nessa abordagem, os analistas usavam seus gráficos impressos, observando cuidadosamente o movimento dos preços manualmente, com ferramentas mais simples e rudimentares como réguas e lápis (FERNANDES, 2014).

O objetivo dela é identificar tendências de alta ou de baixa nos preços, assim como encontrar áreas onde os preços geralmente encontram dificuldades para ultrapassar (resistências) ou onde encontram apoio e param de cair (suportes). Além disso, esse analista busca por padrões gráficos, que se repetem ao longo do tempo e que, segundo essa abordagem, podem sinalizar movimentos futuros dos preços (FERNANDES, 2014).

Apesar de sua tradição, essa análise pode ser um tanto subjetiva. A interpretação dos gráficos, a identificação dos padrões e a definição das áreas de suporte e resistência dependem muito da experiência e da percepção de cada analista, o que pode levar a conclusões diferentes sobre o mesmo ativo (FERNANDES, 2014).

2.5.2 Análise Técnica Estatística ou Moderna

A análise técnica estatística, ou moderna, representa uma abordagem mais científica para analisar o mercado financeiro. Em vez de depender da interpretação visual e subjetiva dos gráficos, os analistas utilizam modelos matemáticos e estatísticos para analisar os preços dos ativos (FERNANDES, 2014).

Para isso, utilizam programas de computador que calculam uma variedade de indicadores técnicos, como médias móveis (que suavizam os movimentos dos preços e ajudam a identificar tendências), osciladores (como o Índice de Força Relativa – RSI, que indica se um ativo está “sobrecomprado” ou “sobrevendido”) e muitos outros. Esses indicadores fornecem informações objetivas sobre o comportamento do mercado, auxiliando na tomada de decisões (FERNANDES, 2014).

Essa abordagem é considerada mais objetiva, pois minimiza a influência da subjetividade na interpretação dos dados, utilizando métodos quantitativos e modelos matemáticos para auxiliar na tomada de decisões (FERNANDES, 2014).

Neste trabalho, adotaremos a análise técnica estatística para criar uma ferramenta que utilize modelos avançados para identificar oportunidades de negociação no mercado. Essa abordagem se adequa à utilização de modelos complexos e algoritmos que buscam aumentar a precisão e a eficiência na identificação de padrões e na avaliação de riscos, permitindo a criação de estratégias de negociação mais sofisticadas e adaptáveis às diferentes condições do mercado.

2.6 MetaTrader 5

O MetaTrader 5 (MT5) é plataforma de negociação multimercado avançada, projetada para atender às crescentes demandas dos mercados financeiros globais. Oferecendo um ambiente integrado para a negociação de Forex, ações, futuros e commodities, o MT5 proporciona uma experiência completa, que abrange desde a execução de ordens até a análise técnica avançada e o desenvolvimento de sistemas automatizados (METAQUOTES LTD., 2024).


Figura 1 – Interface MetaTrader



Fonte: METAQUOTES LTD. (2024).

A plataforma MetaTrader 5 (MT5), como se observa na imagem acima, oferece uma interface personalizável que permite aos usuários organizarem múltiplas janelas de acordo com suas preferências. A janela de Cotações exibe os preços em tempo real dos instrumentos financeiros selecionados, e os Gráficos de Preços permitem visualizar a evolução dos preços ao longo do tempo. O Navegador oferece acesso rápido a contas, indicadores técnicos e scripts, facilitando a análise e o acompanhamento do mercado (METAQUOTES LTD., 2024).

Um dos recursos mais poderosos do MT5 são os Expert Advisors (EAs), também conhecidos como robôs de negociação (FLÁVIO, 2023). EAs são programas que automatizam o processo de negociação, permitindo que os usuários executem estratégias complexas sem a necessidade de intervenção manual (FLÁVIO, 2023). Esses robôs abrem, modificam e fecham ordens automaticamente, com base em algoritmos predefinidos, e podem ser criados tanto manualmente, para maior customização, quanto automaticamente, por meio do MQL5 (ALMEIDA, 2016).

Figura 2 – Fluxograma do Funcionamento do EA

Fonte: Almeida (2016).

A análise técnica é um componente fundamental do MT5, com um conjunto abrangente de ferramentas para a identificação de padrões e sinais de mercado. A plataforma oferece uma variedade de indicadores técnicos integrados, abrangendo todas as principais categorias, bem como objetos gráficos e ferramentas de desenho para uma análise visual detalhada dos gráficos. A capacidade de analisar dados em múltiplos períodos, desde M1 (1 minuto) até MN1 (1 mês), permite capturar padrões que podem não ser evidentes em uma única escala temporal, resultando em algoritmos de previsão mais robustos (METAQUOTES LTD., 2024).

A negociação algorítmica é um dos pilares do MT5, devido à linguagem MQL5, que permite criar EAs para a análise automatizada de dados de mercado, a geração de sinais de negociação e a execução de ordens. O MetaEditor oferece um ambiente de desenvolvimento completo, com recursos como destaque de sintaxe, compilador integrado e depurador. O Testador de Estratégias possibilita a validação e otimização de algoritmos utilizando dados históricos, com opções para testar em diferentes períodos para simulação precisa e analisar estatísticas de desempenho detalhadas (METAQUOTES LTD., 2024).

A integração com Python, através de uma API dedicada, amplia as capacidades do MT5, permitindo a utilização de bibliotecas de aprendizado de máquina e a criação de modelos preditivos sofisticados. Essa integração possibilita a combinação das funcionalidades nativas da plataforma com o poder analítico do ecossistema Python, resultando em algoritmos de previsão mais precisos e adaptáveis. Adicionalmente, o MT5 oferece suporte nativo para redes neurais em MQL5 e computação paralela com OpenCL, fornecendo recursos avançados para o desenvolvimento de algoritmos computacionalmente intensivos (METAQUOTES LTD., 2024).

Em suma, o MetaTrader 5 se consolida como uma plataforma versátil e poderosa para o desenvolvimento e a implementação de algoritmos de previsão de mercado. Sua combinação de recursos nativos, integração com tecnologias externas e ecossistema maduro o tornam uma escolha estratégica para pesquisadores, desenvolvedores e traders que buscam criar sistemas preditivos sofisticados e eficientes para os mercados financeiros.

2.7 Indicadores

Indicadores Técnicos são ferramentas fundamentais na análise estatística de mercados financeiros, pois traduzem fórmulas matemáticas e gráficos de forma que auxiliam os traders na tomada de decisões. Utilizando dados históricos de preço, volume, ou a combinação de ambos, os indicadores buscam revelar padrões e tendências que, de outra forma, seriam difíceis de discernir. Seu propósito principal é identificar potenciais pontos de entrada e saída em negociações, sinalizar a força ou fraqueza de uma tendência estabelecida, e demarcar zonas de suporte e resistência onde o preço tende a encontrar dificuldades em romper (FERNANDES, 2014).

Embora baseados em cálculos estatísticos, os sinais gerados por indicadores técnicos não devem ser interpretados como previsões infalíveis. Pelo contrário, eles funcionam como alertas ou confirmações, que exigem uma análise cuidadosa e contextualizada por parte do trader. A eficácia de um indicador pode variar significativamente entre diferentes ativos e ao longo do tempo, exigindo um processo contínuo de adaptação e ajuste de parâmetros (FERNANDES, 2014).

Em seguimento, alguns indicadores específicos serão explorados neste trabalho, visando a identificação de tendências e a confirmação de sinais de negociação. A escolha e a aplicação desses indicadores serão detalhadas nas seções subsequentes.

2.7.1 Índice de Força Relativa

De acordo com Anderson (1993), o RSI é um dos mais conhecidos indicadores de análise técnica e amplamente utilizado, não somente no mercado financeiro, mas para medir a consolidação de uma tendência em diversas áreas. O índice é base para diversos outros índices que necessitam de um norte para onde a tendência do ativo aponta, sendo assim, uma ferramenta imprescindível para fomentar uma decisão estratégica de entrada e saída de um ativo com maior segurança.

Diante do exposto, o Índice de Força Relativa tem como objetivo estudar posições estratégicas no preço dos ativos para aproveitar-se de uma brecha de compra ou venda.

Sendo assim, as classificações de ativos por RSI são basicamente sobrevalorizados ou supervalorizados; quando supervalorizado a melhor posição no ativo é de venda pois o ativo vem esgotando sua força compradora devido ao preço inflado, em contrapartida, o sobrevalorizado indica uma posição forte de compra pois, devido ao preço baixo, não será recompensador para o investidor vender o ativo, criando-se uma resistência que não propicia a vendas e sim compras.

Figura 3 – Tendência de Alta com RSI



Fonte: Fernandes (2014).

As margens de operação do RSI para compra e venda são frequentemente revisitadas; a estrutura clássica diz que, abaixo de 30 pontos no índice, o ativo tende a subir pois esgotou sua força vendedora, ao mesmo passo que, acima de 70 pontos no índice, o ativo tende a cair pois esgotou sua força compradora. Levando em consideração todo o contexto, o RSI não representa uma determinante que afirma o momento de compra ou venda, o índice tem como objetivo ser uma ferramenta a mais para o consenso de entradas e saídas em investimentos.


2.7.2 Médias Móveis

As Médias Móveis (MM) são um dos indicadores técnicos mais amplamente utilizados na análise estatística de mercados financeiros, oferecendo uma maneira eficaz de suavizar as flutuações de preço e identificar tendências predominantes. Ao calcular o preço médio de um ativo durante um período específico, as Médias Móveis reduzem o ruído gerado por movimentos de preço aleatórios, permitindo que os analistas visualizem a direção geral do mercado com maior clareza, fornecendo pontos de referência válidos ao longo do tempo, possibilitando a comparação entre níveis atuais e passados (FERNANDES, 2014).

Existem diferentes tipos de Médias Móveis, sendo as mais comuns a Média Móvel Simples (MMS) e a Média Móvel Exponencial (MME). A MMS atribui o mesmo peso a todos os preços dentro do período, enquanto a MME pondera os preços mais recentes de forma mais significativa, tornando-a mais sensível às mudanças de preço. A escolha entre MMS

e MME depende do objetivo da análise e da sensibilidade desejada. Períodos mais curtos resultam em Médias Móveis mais sensíveis, que reagem rapidamente às mudanças de preço, mas também geram mais sinais falsos. Períodos mais longos, por outro lado, resultam em Médias Móveis mais suaves, que filtram o ruído, mas podem atrasar a identificação de novas tendências (FERNANDES, 2014).

Figura 4 – Cruzamento de médias móveis



Fonte: Elaboração própria com dados e interface do MetaTrader 5.

Uma aplicação comum das Médias Móveis, como é possível observar na imagem acima, é a identificação de cruzamentos, interpretados como sinais de compra ou venda. Almeida (2016), em sua pesquisa, utilizou essa técnica com duas médias, uma “rápida” e outra “lenta”, gerando sinais de negociação com base em seus cruzamentos. Para um controle de risco mais refinado, implementou também StopLoss e TakeProfit. Entretanto, Almeida (2016) alerta para as limitações de se usar apenas essa técnica, especialmente em mercados com alta volatilidade, reforçando a necessidade de ferramentas que confirmem o sinal para evitar falsos positivos.

2.7.3 Médias Móveis Exponenciais

As Médias Móveis Exponenciais (MME) constituem uma ferramenta amplamente conhecida na análise técnica geral, destacando-se no mesmo sentido das médias móveis (MM), sendo principalmente utilizada para suavizar alterações bruscas de curto prazo nos preços dos ativos; além disso, atribui pesos mais acentuados para dados recentes. A diferença entre os indicadores MM e MME é fundamentalmente velocidade: devido à fórmula adaptada da MME, os resultados são mais velozes nas comparações utilizadas, contudo, o processamento requisitado é maior. Por esse motivo, a MME é significativamente utilizada em mercados de volatilidade pois é de suma importância identificar padrões de reversões ou de continuidade num espaço de tempo consideravelmente curto para tomadas de decisões.

Como já afirmado, a relevância da MME é ampla na área de análise técnica. Elder (2002), por exemplo, destaca o seu valor para análise de um mercado atual, característica essa que é contrária em outros indicadores onde suas fórmulas não consideram as datas dos dados extraídos. Segundo o autor, “a média móvel exponencial permite que o trader veja o mercado como ele é agora, e não como era semanas atrás” (ELDER, 2002, p. 145). Seguindo sua linha de pensamento, o cruzamento de médias possui a capacidade de demonstrar sinais de entrada ou saída de forma eficaz.

Apesar de tantas vantagens, a MME também possui seus pontos de consideração. A principal característica da MME é resultante da sua velocidade em extrair informações que, em mercados de lateralização, gera sinais que podem ser interpretados como falsos, levando a entradas e saídas em momentos desinteressantes. Uma forma de diminuir esta influência é a complementação com outros indicadores, como por exemplo, Índice de Força Relativa (IFR) ou Bandas de Bollinger; essa complementação cria dados cruzados que confirmam uma incerteza ou uma compra, facilitando decisões.

2.7.4 Bandas de Bollinger

As Bandas de Bollinger (BB), um indicador técnico de volatilidade desenvolvido por John Bollinger, oferecem uma perspectiva sobre a dinâmica dos preços em um mercado. As BB são construídas a partir de uma Média Móvel Aritmética (MM20, por exemplo) aplicada aos preços, traçando duas curvas que representam os limites superior e inferior da volatilidade esperada para o ativo. Essas bandas são calculadas utilizando o desvio padrão da média móvel, de modo que quanto maior a volatilidade do ativo, maior será a distância entre as bandas (FERNANDES, 2014).

Ao contrário de uma interpretação simplista que considera a banda superior como uma resistência e a banda inferior como um suporte, a teoria de Bollinger enfatiza a importância de analisar o comportamento dos preços em relação aos seus limites de volatilidade esperados. Se, em um movimento de alta, o preço atinge a banda superior, isso indica força e sugere que o movimento deve prosseguir. Por outro lado, se o preço não consegue alcançar a banda superior, isso pode ser um sinal de fraqueza. Da mesma forma, a distância do preço em relação às bandas pode revelar informações importantes sobre a intensidade dos movimentos de alta ou baixa (FERNANDES, 2014).

As Bandas de Bollinger (BB) permitem, adicionalmente, a avaliação da volatilidade do mercado. Através do indicador BandWidth, derivado das BBs, é possível quantificar a distância entre as bandas, oferecendo uma medida direta da volatilidade do ativo. A ocorrência de períodos de baixa volatilidade, caracterizados pela aproximação das bandas (squeeze), pode indicar um potencial transição para um período de alta volatilidade (expansão), sinalizando oportunidades de negociação (FERNANDES, 2014). Em sua pesquisa, Bertini (2024) empregou as Bandas de Bollinger para avaliar a volatilidade de ativos, demonstrando a utilidade do indicador na seleção de ativos para estratégias de negociação baseadas na identificação de períodos de variação

acentuada de preços.

2.7.5 MACD

O indicador MACD foi desenvolvido por Gerald Appel na década de 1970; sua proposta é identificar mudanças no momentum do mercado (APPEL, 2005). Composto por duas linhas, o MACD (Moving Average Convergence Divergence) representa a diferença entre duas linhas de médias móveis exponenciais, respectivamente, 12 e 26 períodos; em seguida, a linha que fornece sinal, média de 9 períodos, o indicador age no cruzamento de todas as três médias.

Como destacado por Elder (2002), o MACD é uma ferramenta interessante na confirmação de tendências e em identificar pontos específicos de reversão. Geralmente é utilizado em mercados com tendência mais previsível, mas por derivar da MME, pode gerar falsos sinais em mercados de lateralidade. Por fim, outra característica interessante é a capacidade de observar diferenças dos resultados MACD e da movimentação nos preços, é outra aplicação interessante para a criação de Appel.

2.8 Modelos Estatísticos

Os modelos estatísticos representam uma abordagem fundamental na análise de dados, especialmente em contextos em que se busca compreender padrões, relações e tendências. Eles oferecem fórmulas estruturadas para interpretar informações históricas e, em muitos casos, para projetar comportamentos futuros. Ao aplicar princípios matemáticos e probabilísticos, esses modelos buscam simplificar a complexidade inerente aos fenômenos observados, permitindo a extração de insights e a tomada de decisões baseada em evidências quantitativas.


2.8.1 ARIMA

O modelo Autoregressive Integrated Moving Average (ARIMA) é um modelo estatístico utilizado para análise de séries temporais. O ARIMA permite modelar dados que exibem tendências e flutuações ao longo do tempo, sendo amplamente aplicado em áreas financeiras para prever valores futuros com base em dados passados.

A estrutura do ARIMA é composta por três elementos: o componente Autoregressivo (AR), que modela a influência dos valores passados da série no valor presente; a Média Móvel (MA), que suaviza os ruídos e flutuações aleatórias presentes nos dados; e o Integrado (I), responsável por tornar a série estacionária. Uma série estacionária apresenta propriedades estatísticas constantes ao longo do tempo, ou seja, sua média e variância não se alteram significativamente. Cada um desses componentes é definido por um parâmetro: o parâmetro p representa a ordem da autocorrelação, o parâmetro q define a ordem da média móvel, e o parâmetro d determina o grau de diferenciação (XING et al., 2024).

Como é possível observar na figura acima, o processo de aplicação do modelo ARIMA inicia-se com a coleta do histórico de preços do ativo. Em seguida, verifica-se a estacionariedade

Figura 5 – Fluxo ARIMA



Fonte: Autoria própria.

da série; se não estiver estável, aplica-se a diferenciação repetidamente até que a estabilidade seja alcançada. Com a série pronta, o modelo ARIMA é ajustado, definindo-se suas ordens p , d e q . Por fim, o modelo treinado gera as previsões de preço e os resíduos, que representam os erros da previsão e são importantes para análises futuras.

A verificação da estacionariedade e o subsequente ajuste dos parâmetros p , d e q são metodologicamente embasados em testes e critérios estatísticos. A etapa de verificar a estacionariedade da série é formalmente conduzida por meio do teste de Dickey-Fuller Aumentado (ADF). Este teste avalia a hipótese nula de que a série temporal possui uma raiz unitária, sendo o p-valor resultante um indicador crucial: um p-valor elevado, como o de 0,998773 encontrado inicialmente por Xing et al. (2024) para os dados da NVIDIA, impede a rejeição da hipótese nula, confirmando a não estacionariedade. Já a aplicação da diferenciação repetidamente até que a estabilidade seja alcançada é, portanto, guiada pelos resultados sequenciais do teste ADF. No referido estudo, após a primeira diferenciação, um p-valor próximo de zero indicou que a estacionariedade foi atingida, definindo assim $d = 1$.

Subsequentemente, para o ajuste do modelo ARIMA, um passo crucial é a definição de suas ordens p (autorregressiva) e q (médias móveis). Dada a multiplicidade de combinações

possíveis para estes parâmetros, como o intervalo de 0 a 4 testado por Xing et al. (2024), torna-se necessário um critério objetivo para a seleção do modelo mais apropriado. O Critério de Informação de Akaike (AIC) desempenha precisamente este papel, sendo uma métrica estatística consolidada para avaliar a qualidade relativa de diferentes modelos. O AIC permite selecionar a configuração que oferece o melhor compromisso entre a fidelidade do modelo aos dados históricos (qualidade do ajuste) e sua complexidade (parcimônia), penalizando modelos com excesso de parâmetros que poderiam levar a overfitting. Assim, a configuração ARIMA que resulta no menor valor de AIC é a escolhida, pois representa a estrutura mais eficiente e generalizável, antes que o modelo treinado seja utilizado para gerar as previsões e os resíduos (XING et al., 2024).

Uma outra variação do modelo ARIMA é o Seasonal Autoregressive Integrated Moving Average, ou SARIMA, ideal para dados que exibem padrões sazonais. Ao contrário de séries aleatórias, dados com sazonalidade apresentam comportamentos previsíveis que se repetem em intervalos regulares, como vendas que aumentam no Natal ou no verão. O SARIMA, além dos componentes AR, MA e I, incorpora componentes sazonais para capturar esses padrões recorrentes, tornando-se uma ferramenta mais dimensionada para modelar fenômenos com sazonalidade intrínseca (ARAYA; ARAYA, 2024).


Apesar de sua utilidade, ambos os modelos apresentam limitações importantes. Sua eficácia é maior na captura de relações lineares, o que dificulta lidar com padrões não lineares complexos. Além disso, a escolha dos parâmetros ideais é um desafio, exigindo análise criteriosa e experimentação. Em cenários complexos e não lineares, modelos de aprendizado de máquina podem ser mais adequados (ARAYA; ARAYA, 2024; XING et al., 2024).

2.8.2 GARCH

O modelo Generalized Autoregressive Conditional Heteroskedasticity (GARCH) é uma ferramenta estatística para a análise de séries temporais financeiras, com foco na modelagem da volatilidade. A volatilidade, como apontado por Araya e Araya (2024), reflete o grau de variação dos preços de um ativo financeiro ao longo do tempo e é fundamental para a gestão de riscos e a precificação de derivativos.

O objetivo principal do modelo GARCH é capturar a dependência temporal da volatilidade, permitindo que ela varie dinamicamente em resposta às condições do mercado. O modelo padrão, denominado SGARCH (Standard GARCH), considera que a volatilidade atual é influenciada tanto pelos choques passados quanto pela própria volatilidade passada, em um processo de retroalimentação como mostrado na imagem abaixo (ARAYA; ARAYA, 2024).

No entanto, o modelo SGARCH assume que a resposta da volatilidade aos choques é simétrica, ou seja, choques positivos e negativos de igual magnitude têm o mesmo impacto na volatilidade. Essa premissa nem sempre se verifica nos mercados financeiros, onde choques negativos (más notícias) frequentemente têm um impacto maior do que choques positivos (boas notícias). Para lidar com essa assimetria, foram desenvolvidas variações do modelo GARCH,

Figura 6 – Fluxo GARCH

Fonte: Autoria própria.

como o EGARCH (Exponential GARCH) e o TGARCH (Threshold GARCH) (ARAYA; ARAYA, 2024).

O modelo EGARCH, por exemplo, permite que a volatilidade responda de forma diferente a choques positivos e negativos, capturando o chamado efeito alavancagem. Já o modelo TGARCH utiliza variáveis binárias (dummy variables) para identificar diferentes regimes de volatilidade, permitindo que o modelo se adapte a diferentes condições de mercado (ARAYA; ARAYA, 2024).

A escolha entre o modelo SGARCH, EGARCH e TGARCH depende das características específicas dos dados e dos objetivos da análise. Araya e Araya (2024) destaca essa importância de selecionar o modelo mais adequado com base em métricas estatísticas.

2.9 Aprendizagem de Máquina

A Aprendizagem de Máquina oferece um conjunto de algoritmos capazes de identificar padrões em dados, tornando-se uma área de estudo relevante para a análise de séries temporais financeiras. A seguir, serão explorados alguns dos modelos de ML que têm sido investigados e aplicados em pesquisas recentes na área financeira, servindo como base para a compreensão das metodologias disponíveis e para a posterior seleção do modelo a ser implementado neste trabalho.


2.9.1 LSTM

As redes Long Short-Term Memory (LSTM) representam uma forma de Rede Neural Recorrente (RNN), projetadas para superar as limitações das tradicionais no processamento de longas sequências de dados (XING et al., 2024). As RNNs são particularmente adequadas para dados sequenciais, aproveitando sua capacidade de integrar o estado atual, influenciado por entradas anteriores, com novas entradas para gerar saídas. Essa característica é recomendada para tarefas

que necessitam de compreensão de padrões temporais e dependências de longo prazo, pois as RNNs preservam um estado interno que registra entradas anteriores (XING et al., 2024).

Diferentemente das Redes Neurais Artificiais (ANNs) regulares, que processam entradas de maneira linear e feedforward, sem memória de entradas passadas, as RNNs são essenciais para aplicações onde a sequência e o contexto dos dados são cruciais. As LSTMs refinam a arquitetura RNN com três “portões” (gates) especializados: o portão de esquecimento (forget gate – f_t), que controla a retenção ou remoção de informações do estado da célula; o portão de entrada (input gate – i_t), que regula a adição de novas informações ao estado da célula; e o portão de saída (output gate – O_t), que determina o que passar para a próxima camada de saída (XING et al., 2024).

Figura 7 – Célula de Memória do LSTM



Fonte: Xing et al. (2024).

Na imagem que representa uma célula LSTM, vemos alguns elementos importantes: h_{t-1} (saída da célula no passo anterior), x_t (entrada atual), f_t (portão de esquecimento), i_t (portão de entrada), $\tilde{C}_t$ (candidato ao estado da célula), C_t (estado atualizado da célula), O_t (portão de saída) e h_t (saída final da célula). Esses portões permitem que as LSTMs aprendam dependências de longo prazo nos dados, tornando-as ideais para tarefas como previsão de séries temporais financeiras (XING et al., 2024).

2.9.2 Bi-LSTM

As Redes Neurais de Memória de Longo e Curto Prazo Bidirecionais (Bi-LSTMs) são uma extensão poderosa das LSTMs tradicionais, projetadas para capturar dependências temporais em sequências de dados de forma mais completa. Enquanto uma LSTM padrão processa a informação em uma única direção (geralmente do passado para o futuro), uma Bi-LSTM, como empregada por Araya e Araya (2024) em seu modelo híbrido para previsão de volatilidade, utiliza duas camadas LSTM distintas: uma que processa a sequência de entrada na direção progressiva (do início para o fim) e outra que a processa na direção regressiva (do fim para o início).

Essa arquitetura bidirecional permite que o modelo, em cada ponto da sequência, tenha acesso tanto ao contexto passado quanto ao contexto futuro. Para tarefas de previsão de séries temporais, isso significa que a previsão para um determinado instante t pode ser informada não apenas pelos dados que o precederam, mas também por informações implícitas nos dados que o sucedem (no conjunto de treinamento). As saídas dessas duas camadas LSTM (progressiva e regressiva) são então tipicamente concatenadas ou combinadas de alguma forma (por exemplo, somadas ou multiplicadas) antes de serem passadas para as camadas subsequentes da rede. Araya e Araya (2024) destacam que essa capacidade de utilizar padrões de informação tanto do passado quanto do futuro melhora a precisão na previsão de séries temporais, pois o Bi-LSTM consegue tomar decisões mais completas e precisas ao considerar a dinâmica dos dados em ambas as direções. Suas células de memória, herdadas das LSTMs, também são eficazes para lidar com dados propensos a padrões irregulares e sazonais.

2.9.3 CNN

As Redes Neurais Convolucionais (CNNs) são uma classe de modelos de aprendizado profundo especialmente eficazes no processamento de dados com estrutura de grade, como imagens, mas também têm sido adaptadas com sucesso para dados sequenciais, como séries temporais financeiras. Conforme descrito por Araya e Araya (2024), que integraram CNNs em seu modelo híbrido, a principal força das CNNs reside na sua capacidade de aprender e extrair características (features) hierárquicas dos dados de entrada automaticamente. Isso é feito através de camadas convolucionais, que aplicam filtros (kernels) aos dados para detectar padrões locais, como tendências de curto prazo ou formações específicas nos preços.

No contexto de previsão de volatilidade, Araya e Araya (2024) utilizaram camadas convolucionais unidimensionais (1D-CNN) seguidas por camadas de pooling (como max-pooling) para processar a volatilidade estimada pelos modelos GARCH. As camadas convolucionais identificam padrões temporais e relações nos dados de volatilidade, enquanto as camadas de pooling reduzem a dimensionalidade dos dados, mantendo as informações mais relevantes e ajudando a criar representações mais robustas e menos sensíveis a pequenas variações. A saída dessas camadas é então geralmente achatada (flattened) e passada para camadas densas (fully connected) ou para outros tipos de redes neurais, como LSTMs, para a previsão final. A utilização de funções de ativação como ReLU e técnicas de regularização como dropout são comuns para melhorar o desempenho e evitar overfitting.

2.9.4 XGBoost

Outra técnica de aprendizado de máquina empregada em algumas análises de dados financeiros, especialmente para a seleção de características (feature selection) e tarefas de classificação, é o eXtreme Gradient Boosting (XGBoost). Conforme utilizado por Silva (2022) em seu estudo sobre a previsão de tendências de preços da PETR4, o XGBoost se destaca por sua eficiência e

capacidade de lidar com grandes volumes de dados e um número elevado de variáveis.

O XGBoost é um algoritmo de boosting de gradiente otimizado e escalável, baseado em árvores de decisão. Ele constrói modelos de forma sequencial, onde cada nova árvore tenta corrigir os erros das árvores anteriores (DEY, 2016 apud SILVA, 2022). Uma de suas principais vantagens é a capacidade de fornecer um ranking de importância das variáveis (features) de entrada, o que é particularmente útil em cenários com muitos indicadores técnicos, como no mercado financeiro. Silva (2022) aplicou o XGBoost precisamente com este objetivo: dentre mais de 100 indicadores técnicos, o XGBoost foi utilizado para identificar e selecionar os mais relevantes para a previsão da tendência do preço da ação, reduzindo o ruído na amostra e melhorando a eficiência do modelo de previsão subsequente (neste caso, uma LSTM). Essa etapa de seleção de variáveis é crucial, pois indicadores irrelevantes ou redundantes podem prejudicar o desempenho dos modelos de aprendizado de máquina.

2.9.5 Escolha do Modelo

Após a análise de diversas arquiteturas de Aprendizagem de Máquina referenciadas na literatura para a previsão de séries temporais financeiras, a escolha do modelo LSTM para este projeto foi fundamentada em suas características intrínsecas e no alinhamento com os objetivos específicos desta pesquisa.

A decisão de não utilizar CNNs, por exemplo, decorre do foco principal das CNNs no processamento de dados com estrutura de grade e extração de características espaciais, como em imagens (ARAYA; ARAYA, 2024). Embora adaptáveis para séries temporais, o objetivo central deste trabalho não é a análise visual de padrões gráficos de forma hierárquica, mas sim a modelagem de dependências sequenciais e temporais nos dados de preço e indicadores técnicos.

Similarmente, técnicas como o XGBoost, embora altamente eficazes para tarefas de classificação e, crucialmente, para a seleção de características (features) a partir de um grande conjunto de indicadores, como demonstrado por Silva (2022), não foram o foco principal para a modelagem preditiva direta neste estudo. O objetivo primário não é filtrar ou ranquear um vasto conjunto de indicadores, mas sim desenvolver um modelo capaz de aprender as dinâmicas temporais de um conjunto já pré-selecionado de entradas para previsão de preços.

Quanto às variações mais complexas de redes recorrentes, como as Bi-LSTMs, que processam informações em ambas as direções temporais (ARAYA; ARAYA, 2024), optou-se por iniciar com a arquitetura LSTM unidirecional padrão. Embora as Bi-LSTMs possam oferecer um contexto mais rico ao considerar informações “futuras” (no conjunto de treinamento), elas introduzem uma maior complexidade computacional e de modelo. Para os propósitos deste projeto, que visa integrar o modelo de ML com modelos estatísticos clássicos (ARIMA, GARCH) e indicadores técnicos em uma ferramenta algorítmica, a LSTM padrão oferece um equilíbrio adequado entre capacidade de modelagem de dependências de longo prazo e tratabilidade computacional, alinhando-se com a abordagem de Xing et al. (2024) que também explorou LSTMs para previsão de preços de ações.

Adicionalmente, é importante ressaltar que modelos focados em Processamento de Linguagem Natural (NLP), que analisam dados textuais como notícias ou sentimentos de mídias sociais, não foram considerados, pois o escopo deste trabalho se concentra na análise técnica e estatística baseada em dados quantitativos de preço e indicadores, e não na análise fundamentalista ou de sentimento derivada de fontes textuais.

Dessa forma, a Rede Neural de Memória de Longo e Curto Prazo (LSTM) foi selecionada devido à sua comprovada capacidade de capturar dependências temporais e, crucialmente, modelar os padrões não lineares frequentemente presentes em séries financeiras, uma tarefa onde modelos estatísticos mais simples demonstram limitações. Sua ampla utilização e reconhecimento na literatura (XING et al., 2024; ARAYA; ARAYA, 2024) atestam sua robustez como ponto de partida. Adicionalmente, a LSTM oferece versatilidade na configuração e notável facilidade de acoplamento com outras ferramentas e modelos, como os componentes estatísticos (ARIMA, GARCH) e indicadores técnicos propostos neste estudo, tornando-a uma escolha estratégica para desenvolver uma ferramenta algorítmica integrada e adaptável.

2.9.6 Métricas de Validação

Para avaliar a eficácia e desempenho dos modelos de aprendizado de máquina, incluindo as LSTMs, diversas métricas de validação são empregadas. A escolha da métrica ideal depende do contexto da análise, e dentre as pesquisas observadas, algumas foram recolhidas para utilizar nessa.

O Erro Médio Absoluto (MAE) oferece uma visão geral da precisão do modelo, medindo a magnitude média dos erros de previsão (XING et al., 2024). Em outras palavras, o MAE calcula a média das diferenças absolutas entre os valores previstos pelo modelo e os valores reais observados nos dados. Essa métrica é amplamente utilizada devido à sua facilidade de interpretação e à sua robustez em relação a outliers, ou seja, valores extremos que podem distorcer outras medidas de erro. Ao calcular a média das diferenças absolutas, o MAE atribui o mesmo peso a todos os erros, independentemente de sua magnitude, tornando-o uma medida de precisão mais estável e representativa do desempenho geral do modelo (XING et al., 2024).

A Raiz do Erro Quadrático Médio (RMSE) é uma métrica que avalia a precisão de um modelo de previsão, com ênfase na magnitude dos erros. O RMSE é particularmente sensível a erros maiores, o que significa que ele atribui um peso maior a previsões que se desviam significativamente dos valores reais (ARAYA; ARAYA, 2024; XING et al., 2024). Essa característica torna o RMSE útil quando é importante minimizar a ocorrência de grandes erros, pois ele reflete o impacto desses erros de forma mais acentuada do que outras métricas. Em termos práticos, o RMSE indica o quão distante, em média, as previsões do modelo estão dos valores reais, com uma ênfase maior em erros que se destacam por sua magnitude.

Por fim, o Coeficiente de Determinação (R^2) indica o quão bem o modelo explica a variância dos dados, revelando sua capacidade de capturar os padrões subjacentes. O R^2 varia de 0 a 1, com valores mais próximos de 1 indicando que o modelo explica uma grande parte

da variância nos dados, e valores mais próximos de 0 indicando que o modelo explica pouco da variância (XING et al., 2024). O R^2 é uma métrica útil para comparar diferentes modelos e avaliar sua capacidade de generalização para novos dados.

2.10 Trabalhos Relacionados

Nesta seção são apresentados estudos e pesquisas relacionados ao tema deste trabalho. O levantamento realizado foi orientado pela busca de pesquisas científicas e tecnológicas que têm em seus objetivos o desenvolvimento, implementação e análise de ferramentas e tecnologias para a previsão de séries temporais financeiras, análise de volatilidade e desenvolvimento de estratégias de negociação algorítmica, com ênfase na aplicação de modelos estatísticos e de aprendizado de máquina no mercado de ativos. A ferramenta que serviu de referência para isso foi o Google Acadêmico e Publish or Perish 8, por meio do qual se buscou mapear as pesquisas dessa natureza circunscritas nos últimos anos.

O estudo de Almeida (2016) figura como um precursor direto e ponto de partida conceitual para o presente trabalho. Almeida investigou a aplicação de métodos matemáticos e estatísticos no desenvolvimento de um robô de negociação, utilizando a plataforma MetaTrader 5 e a linguagem MQL5, com foco específico no ativo PETR4. Sua abordagem centrou-se na estratégia de cruzamento de médias móveis e na análise de séries temporais com dados históricos, validando o robô através de backtests em diferentes cenários, incluindo períodos de crise, e com o objetivo de alcançar um retorno superior à taxa SELIC. O robô demonstrou viabilidade, apresentando lucratividade em ativos de proteção e superando a SELIC com PETR4 fora de cenários de crise, além de sugerir a exploração futura de modelos como o GARCH. A pesquisa de Almeida é de fundamental importância para este TG, pois não apenas validou a utilização do MetaTrader 5 e MQL5 para a análise algorítmica de PETR4, mas também serviu como base para a “revisitação e aplicação contemporânea” que propomos, conforme mencionado na justificativa deste projeto. Sua recomendação para explorar modelos mais robustos, como o GARCH, alinhou-se diretamente com a nossa intenção de integrar ARIMA, GARCH e, adicionalmente, LSTM, permitindo-nos construir sobre seus achados iniciais e buscar uma ferramenta com maior capacidade preditiva e adaptabilidade às atuais e complexas condições do mercado brasileiro.

Batista (2024) desenvolveu um robô de investimento (Expert Advisor) para automatizar operações na bolsa de valores brasileira (B3), utilizando uma combinação dos indicadores técnicos Média Móvel Exponencial, Convergência-Divergência de Médias Móveis e Índice de Força Relativa visando lucros automatizados a médio e longo prazo. Para isso, empregou a plataforma MetaTrader 5 e a linguagem MQL5, implementando uma estratégia que integrava os sinais dos três indicadores para decisões de compra e venda. A validação ocorreu por meio de backtests com dados históricos do ativo BBAS3F de 2023, comparando o desempenho dos indicadores isoladamente, em pares e em conjunto. Os resultados mostraram que a combinação dos três indicadores superou as abordagens com menos indicadores, demonstrando a eficiência e

consistência do EA nos testes e indicando potencial para lucros automatizados.

Em 2022, Silva (2022) investigaram a previsão de tendências de preços de ações da Petrobras (PETR4) no mercado brasileiro, com foco em operações intraday de 15 minutos, utilizando técnicas de inteligência artificial. Para isso, empregaram um extrator de variáveis baseado em eXtreme Gradient Boosting (XGBoost) para selecionar os indicadores técnicos mais relevantes dentre mais de 100 disponíveis, visando reduzir ruído na amostra. Em seguida, uma rede neural Long Short-Term Memory (LSTM) foi aplicada para prever a tendência de alta ou baixa dos preços no período de 2014 a 2020. Os resultados alcançaram uma acurácia de 56%, superando estudos anteriores, com melhor desempenho na previsão de quedas (57%) em comparação com altas (51%), e destacando a eficácia da combinação de XGBoost para seleção de features e LSTM para previsão no contexto do mercado financeiro brasileiro.

Em 2024, Xing et al. (2024) realizaram uma análise comparativa de quatro modelos de previsão – ARIMA, Multilayer Perceptron (MLP), Long Short-Term Memory (LSTM) e um modelo híbrido ARIMA-GARCH – para prever o preço de fechamento ajustado do dia seguinte das ações da NVIDIA. Utilizando dados diários da API do Yahoo Finance de abril de 2019 a abril de 2024, o estudo dividiu o dataset em 90% para treino e 10% para teste. Os modelos LSTM e MLP foram configurados com janelas deslizantes, enquanto os modelos ARIMA e ARIMA-GARCH utilizaram janelas expansivas e rolantes, com parâmetros otimizados para o menor AIC. Os resultados, avaliados por MAE, RMSE e R-quadrado, indicaram que o modelo ARIMA-GARCH apresentou o menor RMSE, sugerindo melhor precisão na previsão de grandes erros e na explicação da variância. No entanto, o modelo ARIMA com janela expansiva demonstrou desempenho superior em geral, superando os modelos LSTM e MLP, possivelmente devido às características predominantemente lineares da série temporal e à sensibilidade dos modelos de deep learning à configuração e ao tamanho da amostra.

Araya e Araya (2024) propuseram um método híbrido GARCH e Deep Learning para predição de volatilidade de preços de ações, visando aumentar a acurácia das previsões ao integrar diversos modelos. O estudo combinou quatro abordagens: SARIMA (Seasonal Autoregressive Integrated Moving Average), modelos da família GARCH (Generalized Autoregressive Conditional Heteroskedasticity), CNN (Convolutional Neural Network) e BiLSTM (Bidirectional Long Short-Term Memory). Inicialmente, os resíduos gerados pelo modelo SARIMA foram utilizados como entrada para o modelo GARCH. Em seguida, a volatilidade estimada por essa combinação serviu como feature de entrada para os modelos híbridos CNN e BiLSTM. A performance do novo modelo híbrido proposto (SARIMA-GARCH-CNN-BiLSTM) foi avaliada utilizando métricas como MAE (Mean Absolute Error) e RMSE (Root Mean Squared Error), demonstrando uma redução média significativa nesses erros (60,35% e 60,61%, respectivamente) em comparação com outros modelos híbridos. Os resultados experimentais indicaram que o modelo proposto apresentou bom desempenho e acurácia na predição da volatilidade de preços de ações, oferecendo insights valiosos para análise de dados financeiros e estratégias de gerenciamento de risco.

Tormin (2024) realizou um estudo comparativo entre os modelos ARIMA e LSTM para prever os retornos do Bitcoin, investigando o impacto da integração de dados de tendências de busca do Google (PyTrends) na capacidade preditiva. Utilizando dados diários de preços do Bitcoin e tendências de busca para o termo “Bitcoin” de janeiro de 2018 a outubro de 2024, foram construídos três modelos: ARIMA, LSTM tradicional e LSTM integrado com PyTrends. O pré-processamento incluiu ajuste ao fuso horário UTC, tratamento de valores ausentes (fillna) e normalização (MinMaxScaler), com divisão de 80% dos dados para treino e 20% para teste. A avaliação, baseada em RMSE, MAE e MAPE, mostrou que o ARIMA, apesar de simples, apresentou maior estabilidade em RMSE e MAE. O LSTM tradicional obteve RMSE levemente melhor que o ARIMA, mas com MAPE significativamente mais alto. A inclusão dos dados do Google Trends no modelo LSTM integrado não resultou em melhora significativa, sugerindo a necessidade de ajustes mais robustos ou a inclusão de outras variáveis para capturar a complexidade do mercado de criptomoedas.

Tabela 2 – Tabela Comparativa

Estudo	Indicadores	Modelo estatístico	Machine Learning
(PEREIRA, 2025)	X	X	X
(ALMEIDA, 2016)	X	X	
(BATISTA, 2024)	X		
(HAILABE T. ARAYA, 2024)		X	X
(SILVA, 2022)	X		X
(YILUAN XING, 2024)		X	X
(WILLIAN PINHEIRO TORMIN, 2024)	X	X	X

Comparação entre as pesquisas, evidenciando quais componentes cada uma utilizou para formular o modelo que elas propuseram.

Fonte: Autoria própria.

Tabela 3 – Tabela Comparativa (Detalhada)

Autor	Ativo Principal	Fonte de Dados	Tempo Gráfico	Indicadores	Modelo(s) Es- tatístico(s)	Modelo(s) de ML	Métricas para ML
(PEREIRA, 2025)	PETR4	MetaTrader 5	D1	RSI, MME, MACD, BB	ARIMA, GARCH	LSTM	MAE, RMSE, R Square
(ALMEIDA, 2016)	PETR4	MetaTrader 5	D1	MA	ARIMA, En- contro de Mé- dias Móveis	–	–
(BATISTA, 2024)	BBAS3F	MetaTrader 5	M30	RSI, MME, MACD, BB	–	–	–
(SILVA, 2022)	PETR4	–	M15	113 indica- dores	–	LSTM + XGBoost	Acurácia, Precision, Recall, F1-Score, Support
(YILUAN XING, 2024)	NVIDIA (NVDA)	–	–	–	ARIMA, GARCH	LSTM, MLP	MAE, RMSE, R Square
(HAILABE T. ARAYA, 2024)	Apple Inc. (AAPL)	Yahoo Finance	D1	–	SARIMA, GARCH	CNN, Bi-LSTM	MAE, RMSE
(WILLIAN PINHEIRO TOR- MIN, 2024)	Bitcoin (BTC-USD)	Google Trends	–	–	ARIMA	LSTM	MAE, RMSE, MAPE

Comparação entre as pesquisas, evidenciando as características de cada uma em diversos aspectos.

Fonte: Autoria própria.

CAPÍTULO II

3 Metodologia

A metodologia deste projeto será estruturada em etapas sequenciais, visando o desenvolvimento, implementação e validação da ferramenta algorítmica proposta para a negociação de ativos financeiros. O objetivo é descrever os passos para construir e testar a solução, desde a escolha do ambiente até a avaliação de seu desempenho.

3.1 Natureza da Pesquisa

Este projeto, como mencionado na introdução, adota uma natureza de pesquisa experimental. A pesquisa experimental, no contexto de desenvolvimento de sistemas e algoritmos, envolve a manipulação controlada de variáveis que, neste caso, seriam os parâmetros dos modelos, as combinações de indicadores e as arquiteturas de rede neural, para observar e analisar os efeitos resultantes em um ambiente controlado. Serão conduzidos experimentos para testar diferentes configurações da ferramenta algorítmica, buscando identificar as abordagens mais eficazes para a negociação do ativo financeiro selecionado (WAZLAWICK, 2014).

3.2 Padrões para Pesquisa Experimental

Para a condução dos experimentos e o desenvolvimento da ferramenta algorítmica proposta, será utilizado um conjunto definido de padrões e ferramentas, cujas funcionalidades e conceitos foram detalhados no capítulo anterior de Fundamentação Teórica.

A plataforma MetaTrader 5 (MT5) será empregada como o ambiente central para as fases de desenvolvimento e teste. A linguagem de programação MQL5, nativa do MT5, será utilizada para a codificação dos Expert Advisors (EAs). Estes EAs são os algoritmos que efetivamente incorporarão a lógica dos modelos de análise de tendência, volatilidade, os indicadores técnicos e, em uma fase posterior, as previsões geradas pelo modelo de Aprendizagem de Máquina (LSTM) para a execução automatizada de ordens de negociação.

O testador de estratégias integrado ao MT5 será uma ferramenta crucial, permitindo a realização de backtests. Esses testes simularão o desempenho operacional das estratégias desenvolvidas ao longo de períodos históricos, utilizando os dados de cotações passadas para avaliar a viabilidade e a rentabilidade potencial.

Como fonte primária de dados, será utilizado o banco de dados histórico de cotações fornecido pela própria plataforma MetaTrader 5 com integração a corretoras brasileiras, como a Rico, que permite acessar ações da B3, como o ativo selecionado. Esta escolha metodológica simplifica significativamente o processo de aquisição de dados, seu tratamento inicial e a subsequente manipulação, uma vez que os dados já se encontram em um formato padronizado e são diretamente acessíveis via MQL5. Os dados a serem extraídos e utilizados incluirão,

no mínimo, os preços de abertura, máximo, mínimo e fechamento, bem como o volume de negociação para cada período do timeframe definido para a análise, que será diário – D1 para capturar tendências mais longas, mas podendo ser adaptado.

O ativo referente às ações preferenciais da Petrobras (PETR4) será o objeto de estudo principal. Sua notória volatilidade histórica é um aspecto central para a aplicação dos modelos subsequentes, em particular o modelo GARCH, que é projetado especificamente para capturar e modelar a variância condicional em séries temporais que exibem tais flutuações. A liquidez e a representatividade do PETR4 no Ibovespa serão consideradas para assegurar a disponibilidade de dados robustos para esta análise de volatilidade e para contextualizar os resultados no mercado acionário nacional.

Para uma caracterização inicial e visualização dessa volatilidade inerente ao PETR4 e, se relevante para contextualização, de outros ativos comparáveis, serão calculadas e analisadas as Bandas de Bollinger. Este indicador técnico, que constrói um canal em torno de uma média móvel utilizando o desvio padrão dos preços, será aplicado à série histórica de preços do ativo. A observação da largura das bandas e do comportamento do preço em relação a elas poderá fornecer insights valiosos sobre os diferentes regimes de variação dos preços (períodos de alta ou baixa volatilidade) e auxiliar na compreensão do ambiente de mercado no qual a ferramenta algorítmica operará.

No que tange ao desenvolvimento específico dos componentes de Aprendizagem de Máquina, notadamente o modelo LSTM, serão empregadas bibliotecas e ferramentas do ecossistema Python. Para as etapas cruciais de pré-processamento avançado de dados, que podem incluir a normalização/escalamento das séries temporais, a criação de sequências de entrada para o LSTM e outras manipulações de arrays multidimensionais, serão utilizadas bibliotecas consolidadas como NumPy e Pandas.

A implementação da arquitetura da rede neural LSTM, seu treinamento com os dados históricos e a subsequente avaliação de seu desempenho preditivo serão conduzidos utilizando um framework de deep learning robusto e popular, como Keras com o backend TensorFlow, ou alternativamente, PyTorch. A escolha final entre estes frameworks será guiada pela flexibilidade oferecida para a modelagem de arquiteturas LSTM específicas para séries temporais, a disponibilidade de recursos de otimização de hiperparâmetros, a qualidade da documentação e o suporte da comunidade para as tarefas de previsão financeira.

3.3 Experimento de Pesquisa

O experimento de pesquisa se iniciará com a implementação de abordagens para análise de tendência utilizando Médias Móveis. Serão programados em MQL5 diferentes tipos de médias móveis, como a Simples e a Exponencial. Estratégias baseadas em cruzamentos dessas médias serão implementadas para gerar indicações preliminares sobre a direção potencial do mercado, ou seja, sinais de compra ou venda. Estas estratégias também servirão para verificar o desempenho

de modelos baseados apenas em médias no mercado mais recente.

Posteriormente, o experimento avançará para uma modelagem estatística mais sofisticada da série temporal de preços, utilizando o modelo ARIMA. A determinação da ordem de integração 'd' do modelo ARIMA (p, d, q) será realizada através da aplicação sequencial do teste de raiz unitária ADF sobre a série. Para a definição das ordens autorregressiva 'p' e de médias móveis 'q', será adotado um procedimento sistemático de testar múltiplas combinações de 0 a 4. A seleção da especificação final será baseada no critério de informação Akaike Information Criterion (AIC).

Na sequência, os resíduos obtidos a partir do modelo ARIMA ajustado serão utilizados como série de entrada para a modelagem da volatilidade condicional, por meio de um modelo GARCH. Esta abordagem combinada, ARIMA-GARCH, visará capturar a dinâmica da variância dos erros que não foi explicada pelo modelo de média condicional ARIMA. Serão estimados modelos GARCH, com foco inicial e principal na especificação GARCH (1,1), dada a sua prevalência e bom desempenho demonstrado na literatura para séries temporais financeiras e conforme a prática adotada em estudos de referência. O objetivo é modelar e, potencialmente, prever a volatilidade futura de curto prazo dos resíduos, fornecendo uma medida do risco associado às previsões de preço do ARIMA.

Para enriquecer a análise e fornecer uma espécie de filtro de confirmação, serão incorporados indicadores técnicos. Especificamente, o RSI será utilizado para avaliar potenciais níveis de sobrecompra ou sobrevenda do ativo antes de validar operações com base nos demais modelos. A metodologia também contempla a possibilidade de inclusão futura de outros indicadores técnicos relevantes, conforme a necessidade.

Em um esforço para refinar ainda mais a capacidade preditiva da ferramenta, a metodologia será expandida com a incorporação de um modelo de redes neurais recorrentes (RNN), especificamente o Long Short-Term Memory (LSTM). A escolha do LSTM se justifica por sua habilidade intrínseca de modelar relações não lineares, corrigindo uma limitação frequentemente observada em modelos puramente estatísticos como ARIMA e GARCH. A implementação buscará adaptações para o contexto do ativo PETR4 e as características operacionais do MetaTrader 5.

Inicialmente, será crucial avaliar a necessidade de pré-processamento dos dados para o LSTM. Caso seja identificado como necessário, etapas como o preenchimento de dados faltantes, utilizando, por exemplo, interpolação spline cúbica (KAYA, 2014), a detecção e o tratamento de outliers, e a normalização dos dados, possivelmente utilizando a escala Min-Max, serão implementadas.

A próxima etapa consistirá na divisão dos dados em conjuntos de treinamento, validação e teste, que será realizada de forma sequencial para preservar a estrutura temporal inerente à série. Os 80% iniciais dos dados serão utilizados para o treinamento do modelo LSTM. Os 10% seguintes serão destinados à validação, com o objetivo de ajustar os hiperparâmetros da rede. Os 10% finais serão reservados exclusivamente para o teste, permitindo uma avaliação do

desempenho do modelo em dados completamente novos para ele.

Após esta divisão, os dados serão reorganizados em um formato que é compatível com a estrutura de entrada esperada pela rede LSTM. O tamanho da janela (window size), um hiperparâmetro crucial que define quantas observações anteriores serão utilizadas para prever o próximo valor, será ajustado empiricamente com base nos resultados obtidos durante a fase de validação.

O treinamento da rede LSTM envolverá a escolha da arquitetura do modelo, da função de ativação, do otimizador e da função de perda. Estas decisões serão tomadas através de experimentação e análise de desempenho no conjunto de validação. O número de épocas de treinamento será determinado monitorando o desempenho no conjunto de validação, utilizando técnicas como early stopping, para evitar o overfitting do modelo aos dados de treinamento.

Em relação ao ambiente de treinamento para o modelo LSTM, a intenção inicial é utilizar a plataforma Google Colab, aproveitando seus recursos de GPU. No entanto, reconhece-se que, dependendo da complexidade final do modelo e do volume de dados processados, os recursos computacionais oferecidos nos planos gratuitos do Google Colab podem se mostrar insuficientes. Diante dessa possibilidade, o treinamento será realizado localmente em uma estação de trabalho equipada com uma GPU NVIDIA GeForce RTX 3050 (6GB VRAM), um processador Intel(R) 13th Gen i5-13450HX e 32GB de memória RAM.


Caso mesmo esta configuração local apresente limitações para o treinamento do modelo desejado em um tempo viável, serão consideradas alternativas. Uma delas consiste na simplificação da arquitetura do modelo LSTM, aceitando um possível trade-off entre complexidade e capacidade preditiva para garantir a viabilidade do projeto. Alternativamente, será avaliada a aquisição de planos pagos com maior capacidade computacional em plataformas como o Google Colab, se o orçamento permitir e o ganho de desempenho justificar tal investimento.

3.4 Diagramas

3.5 Critérios para Avaliação

Os testes das estratégias baseadas em Médias Móveis, cruzamento de Médias Móveis, e dos modelos ARIMA e GARCH, tanto de forma isolada, quanto em conjunto e combinados com o indicador RSI, serão realizados integralmente na plataforma MetaTrader 5 por meio do ambiente de backtesting.

O desempenho dessas estratégias será quantitativamente avaliado por meio de métricas como a taxa de acerto das operações, o lucro ou prejuízo acumulado, o drawdown máximo observado e o fator de lucro. Todas estas métricas são fornecidas diretamente pela plataforma. Adicionalmente, um critério importante para a validação interna dos modelos estatísticos será a qualidade do ajuste dos modelos ARIMA e GARCH. Esta qualidade será aferida utilizando o critério de informação Akaike (AIC) e pela verificação da estacionariedade dos resíduos através do teste de raiz unitária de Dickey-Fuller Aumentado (ADF).

Figura 8 – Modelo Completo

Fonte: Autoria própria.

O modelo LSTM, por sua vez, passará por uma fase inicial de treinamento e avaliação fora do ambiente MetaTrader 5. Para esta validação preliminar, será utilizado um conjunto de dados separado e obtido da plataforma. O desempenho do modelo LSTM durante esta fase de treinamento e teste externo será avaliado utilizando as métricas de Erro Absoluto Médio (MAE), Raiz do Erro Quadrático Médio (RMSE) e o coeficiente de determinação R^2 . As singularidades de cada uma permitem analisar diferentes perspectivas do desempenho do modelo, viabilizando assim a comparação dos resultados obtidos neste projeto com outros estudos e benchmarks da área.

Finalmente, após o treinamento e a validação iniciais, o modelo LSTM será integrado ao ambiente MetaTrader 5, materializado como um Expert Advisor. Nesta etapa crucial, o desempenho do modelo LSTM, agora operando como parte da ferramenta algorítmica, será avaliado através de backtesting extensivo em dados históricos do PETR4. Serão utilizadas exatamente as mesmas métricas de desempenho operacional fornecidas pela plataforma, que foram aplicadas às outras estratégias: taxa de acerto, lucro/prejuízo acumulado, drawdown máximo e fator de lucro.

O objetivo desta etapa final de avaliação é permitir uma comparação direta e objetiva do desempenho do modelo LSTM em um ambiente de negociação simulado com os resultados das outras estratégias implementadas (Médias Móveis, ARIMA-GARCH e RSI). Esta análise comparativa visará identificar a abordagem ou combinação de abordagens mais promissora para a negociação do PETR4. Fundamentalmente, buscará validar as hipóteses do projeto sobre a efetividade da junção desses modelos na previsão de preços de ativos voláteis, fornecendo um termômetro claro do sucesso alcançado.

3.6 Resultados preliminares atingidos no PTG

Como mencionado anteriormente, este projeto busca revisar e expandir as investigações de Almeida (2016), que desenvolveu e testou um Expert Advisor (EA) baseado na estratégia de cruzamento de Médias Móveis (MM) para o ativo PETR4 na plataforma MetaTrader 5. O estudo original de Almeida (2016) observou que, embora sua estratégia pudesse gerar lucros em determinados períodos de mercado mais estáveis, ela enfrentava dificuldades e apresentava prejuízos durante crises financeiras, evidenciando a sensibilidade do algoritmo simples às condições de mercado.

Para estabelecer um ponto de partida contemporâneo e avaliar o desempenho dessa estratégia no cenário de mercado mais recente, foi necessário adaptar e reimplementar a lógica central do EA proposto por Almeida (2016).

O código original fornecido por ele, embora conceitualmente claro, demandou atualizações para ser compatível com as versões mais recentes da linguagem MQL5 e da plataforma MetaTrader 5. Adicionalmente, Almeida (2016) mencionou o uso de bibliotecas externas para funcionalidades como gerenciamento de dinheiro e trailing stops, as quais não foram disponibilizadas em seu trabalho. Desta forma, para a presente análise preliminar, foi desenvolvido um EA em MQL5 utilizando a classe CTrade¹ padrão para as operações de negociação e implementando a lógica de cruzamento de duas Médias Móveis Simples (MMS).

A configuração do EA para este teste baseou-se nos seguintes parâmetros: Médias Móveis Simples com período de 10 para a rápida e 20 para a lenta, aplicadas ao preço de fechamento. A estratégia implementada inclui a reversão de posições, ou seja, ao ser gerado um novo sinal, qualquer posição oposta existente é primeiramente fechada.

Os parâmetros de Stop Loss (SL) e Take Profit (TP) foram definidos por experimentação inicial em 50 pontos e 100 pontos e depois nulos, respectivamente, uma vez que Almeida (2016) não especificou os valores exatos utilizados em todos os seus testes para PETR4. Reconhece-se que esta escolha de SL/TP pode divergir da utilizada originalmente e constitui um ponto para otimizações e análises futuras.

As operações foram configuradas para serem executadas apenas na abertura de uma nova barra no gráfico diário (D1), com a modelagem do backtest para “Cada Tick” para maior

¹ Biblioteca padrão do MQL5 para as operações de negociação.

precisão na simulação dos preços de execução, alinhando-se com a abordagem de “Every tick” mencionada por Almeida (2016).

Visando uma comparação de desempenho sob condições financeiras similares às de um dos cenários de Almeida (2016), o backtest foi conduzido com um depósito inicial de R\$ 50.000,00. O volume operacional foi definido como 1000 unidades do ativo PETR4 por negociação. A alavancagem utilizada na simulação foi de 1:100. O período de teste compreendeu de 01 de janeiro de 2020 a 01 de maio de 2025.

Os principais resultados obtidos neste backtest para o ativo PETR4 são apresentados e comparados qualitativamente com os achados de Almeida (2016) para PETR4 em períodos de crise:

Tabela 4 – Comparação modelo proposto x ALMEIDA (2016)


	Pereira (2025) 1º teste	Pereira (2025) 2º teste	Almeida (2016)	Almeida (2016)
Período	2020-2025 (Crise)	2020-2025 (Crise)	2013-2016	2007-2011 (Crise)
Volume por Operação	1000 ações	1000 ações	1000 ações	100 ações
Lucro Líquido Total	R\$ -9.230,00	R\$ -2.530,00	R\$ +10.430,00	R\$ -2.542,00
Retorno Percentual	-18,46%	-5,06%	+20,86%	-5,08%
Fator de Lucro	0,64	0,93	> 1,0 (lucro)	< 1,0 (prejuízo)
Total de Negociações	64	58	38	52

Fonte: Elaboração própria com dados do MetaTrader 5 e pesquisa de Almeida (2016).


A análise destes resultados preliminares indica que, para o primeiro teste no período recente de janeiro de 2020 a maio de 2025, a estratégia base de cruzamento de Médias Móveis, operando com um volume de 1000 ações de PETR4, resultou em um prejuízo líquido substancial de R\$ 9.230,00, representando uma perda de 18,46% sobre o capital inicial. O Fator de Lucro de 0,64 e a baixa taxa de acerto (apenas 25% das 64 operações foram lucrativas) confirmam a ineficácia da estratégia neste intervalo de tempo.

Em uma segunda rodada de testes preliminares para o período de janeiro de 2020 ao começo de 2025 e mantendo o volume de 1000 ações de PETR4, foram zerados os parâmetros de Stop Loss e Take Profit, resultando em um desempenho ligeiramente menos desfavorável. Neste segundo cenário, o prejuízo líquido total foi de R\$ 2.530,00, correspondendo a uma perda de 5,06% sobre o capital inicial. Embora o Fator de Lucro tenha melhorado para 0,93 e o número total de negociações tenha sido reduzido para 58, a estratégia ainda não demonstrou capacidade de gerar lucro. Este resultado, apesar de melhor que o anterior, ainda se alinha com as dificuldades encontradas por Almeida (2016) em períodos de crise e reforça a necessidade de abordagens mais robustas.

Este desempenho contrasta significativamente com os resultados obtidos por Almeida (2016) para o mesmo ativo e volume em um período anterior (2013-2016), onde foi reportado um lucro considerável. Por outro lado, o resultado negativo atual se assemelha, em natureza, aos prejuízos que Almeida também encontrou ao aplicar sua estratégia em PETR4 durante períodos de crise financeira, como a de 2008.

Figura 9 – Desempenho do modelo proposto (2º teste)

Fonte: Elaboração própria com dados do MetaTrader 5.

Figura 10 – Gráfico de dispersão da correlação de lucro (2º teste)

Fonte: Elaboração própria com dados do MetaTrader 5.

O período de 2020-2025 foi caracterizado por uma volatilidade acentuada e por dinâmicas de mercado complexas, influenciadas por eventos globais como a pandemia de COVID-19 e suas repercussões econômicas. É plausível que tais condições tenham sido particularmente desfavoráveis para uma estratégia de seguimento de tendência simples como o cruzamento de médias. Adicionalmente, as necessárias adaptações do código original de Almeida (2016) e a definição experimental dos parâmetros de Stop Loss e Take Profit, na ausência dos valores exatos utilizados no estudo de referência, são fatores que podem ter influenciado os resultados.

No entanto, a principal inferência destes testes preliminares é a clara demonstração de que a estratégia de cruzamento de Médias Móveis, mesmo com parâmetros de risco básicos e um volume operacional mais elevado, não se mostrou suficiente para gerar retornos positivos de forma consistente no mercado recente de PETR4. Este achado é fundamental, pois estabelece

um baseline contemporâneo e válida de forma contundente a justificativa central deste trabalho de graduação: a necessidade premente de investigar, desenvolver e integrar modelos analíticos e preditivos mais sofisticados, como ARIMA para previsão de tendência, GARCH para modelagem da volatilidade e redes LSTM para a captura de padrões não lineares, com o objetivo de construir uma ferramenta algorítmica mais robusta, adaptável e com maior potencial de eficácia para a negociação de ativos voláteis no dinâmico cenário atual do mercado de ações brasileiro.

3.7 Resultados Esperados no TG

Espera-se, primordialmente, o desenvolvimento e a validação de um Expert Advisor (EA) funcional em MQL5 para MetaTrader 5. Esta ferramenta algorítmica integrará modelos ARIMA para previsão, GARCH para volatilidade, RSI como filtro e um modelo LSTM para análises não lineares, com foco no ativo PETR4 e uma análise inicial com Médias Móveis como baseline comparativo.

O resultado central será a demonstração da superioridade da abordagem híbrida. Espera-se que a integração do modelo LSTM, cuja capacidade preditiva será rigorosamente aferida por métricas como MAE, RMSE e R^2 buscando valores que indiquem alta acurácia, contribua decisivamente para que o EA final apresente, nos backtests do MetaTrader 5, um desempenho otimizado. Este desempenho será refletido em indicadores como maior taxa de acerto, fator de lucro superior e drawdown máximo reduzido, superando os resultados obtidos por estratégias isoladas ou mais simples e, idealmente, a taxa Selic vigente.

Finalmente, almeja-se que a pesquisa valide as hipóteses de complementaridade dos modelos e a eficácia da filtragem de sinais, resultando em uma ferramenta algorítmica com comprovada capacidade de gerar resultados superiores no mercado de ativos. Esta contribuição visa oferecer uma metodologia robusta e avançada para o trading algorítmico, consolidando as competências técnicas dos autores.

3.8 Cronograma

A execução deste projeto seguirá o cronograma proposto abaixo, distribuído ao longo de 6 meses:

Tabela 5 – Cronograma de Atividades

Etapa/Atividade	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6
Revisão Bibliográfica Aprofundada	X	X				
Coleta e Preparação de Dados	X	X				
Implementação Médias Móveis	X	X				
Implementação ARIMA		X	X	X		
Implementação GARCH				X	X	
Implementação Indicador RSI				X	X	
Análise de Pré-Processamento		X	X	X		
Pré-Processamento de Dados			X	X	X	
Implementação Modelo LSTM				X	X	
Treinamento Modelo LSTM				X	X	X
Integração do Modelo LSTM					X	X
Backtesting e Validação					X	X
Análise dos Resultados						X

Fonte: Autoria própria.

REFERÊNCIAS

- ALMEIDA, F. L. *Análise da ação PETR4 na Bolsa de Valores de São Paulo com MetaTrader 5*. Dissertação (Monografia (Graduação em Banco de Dados)) — Faculdade de Tecnologia Dr. Archimedes Lammoglia, Indaiatuba, 2016. Disponível em: <<https://ric.cps.sp.gov.br/handle/123456789/24287>>. Acesso em: 20 fev. 2025.
- ANDERSON, G. *The RSI: The Complete Guide*. 1. ed. New York: Traders Press, 1993. 245 p.
- APPEL, G. *Technical Analysis: Power Tools for Active Investors*. Nova Iorque: Financial Times Press, 2005.
- ARAYA, T. H.; ARAYA, J. A. A hybrid garch and deep learning method for volatility prediction. *Journal of Mathematics*, Londres, Reino Unido, v. 2024, 2024. Article ID 6305525.
- AYRES, M. *Brazil's government sees inflation within target band, unlike markets*. Londres, Reino Unido: [s.n.], 2024. Reuters. 18 nov. 2024. Disponível em: <<https://www.reuters.com/world/americas/brazil-sees-33-gdp-growth-this-year-25-next-year-2024-11-18/>>. Acesso em: 30 mar. 2025.
- AYRES, M. *Economists ramp up projections for Brazil's interest rates to above 15%*. Londres, Reino Unido: [s.n.], 2025. Reuters. 21 jan. 2025. Disponível em: <<https://www.reuters.com/world/americas/economists-ramp-up-projections-brazils-interest-rates-above-15-2025-01-21/>>. Acesso em: 30 mar. 2025.
- BATISTA, C. B. *Desenvolvimento de robô para automação de investimentos na bolsa de valores utilizando indicadores técnicos*. Dissertação (Monografia (Graduação em Engenharia de Computação)) — Pontifícia Universidade Católica de Goiás, Goiânia, 2024. Disponível em: <<https://repositorio.pucgoias.edu.br/jspui/handle/123456789/8073>>. Acesso em: 30 mar. 2025.
- BRASIL. Banco Central do Brasil. *Bolsas de Valores*. Brasília, DF: [s.n.]. Disponível em: <<https://www.bcb.gov.br/pre/composicao/bv.asp?frame=1>>. Acesso em: 22 abr. 2025.
- BRASIL. Banco Central do Brasil. *Corretoras e Distribuidoras*. Brasília, DF: [s.n.]. Disponível em: <https://www.bcb.gov.br/acessoinformacao/legado?url=https:%2F%2Fwww.bcb.gov.br%2Fpre%2Fcomposicao%2Fcorretoras_distribuidoras.asp>. Acesso em: 22 abr. 2025.
- BRASIL. Banco Central do Brasil. *Histórico de Taxas de Juros*. Brasília, DF: [s.n.]. Disponível em: <<https://www.bcb.gov.br/controleinflacao/historicotaxasjuros>>. Acesso em: 30 mar. 2025.
- BRASIL. Banco Central do Brasil. *Taxa Selic*. Brasília, DF: [s.n.]. Disponível em: <<https://www.bcb.gov.br/estatisticas/detalhamentoGrafico/graficoshome/selic>>. Acesso em: 22 abr. 2025.
- COJOCARU, R. *The Future Of Retail Trading: Bots And Automated Tools*. Nova Jersey, EUA: [s.n.], 2024. Forbes. Forbes Technology Council. 31 jul. 2024. Disponível em: <<https://www.forbes.com/councils/forbestechcouncil/2024/07/31/the-future-of-retail-trading-bots-and-automated-tools/>>. Acesso em: 02 abr. 2025.
- ELDER, A. *Come Into My Trading Room: a complete guide to trading*. Nova Iorque, EUA: Wiley, 2002.
- FERNANDES, A. *Fundamentos de Análise Técnica de Ações*. 1. ed. Rio de Janeiro: Campus, 2014.

FUNDO MONETÁRIO INTERNACIONAL (FMI). *World Economic Outlook: Navigating Global Divergences*. Washington, D.C.: FMI, 2024. Out. 2024. Disponível em: <<https://www.imf.org/en/Publications/WEO>>. Acesso em: 22 abr. 2025.

KAYA, E. Spline interpolation techniques. *Journal of Science and Technology (JTST)*, International Black Sea University, Tbilisi, Geórgia, v. 2, n. 1, p. 56–62, 2014.

METAQUOTES LTD. *MetaTrader 5: Plataforma de Negociação para Forex, Ações e Futuros*. Limassol: MetaQuotes Ltd., 2024. Disponível em: <<https://www.metatrader5.com/pt>>. Acesso em: 01 mar. 2025.

SILVA, M. F. *Previsão de preços no mercado de ações brasileiro por meio de técnicas de inteligência artificial*. Dissertação (Dissertação (Mestrado em Ciências Contábeis)) — Universidade Federal de Uberlândia, Uberlândia, 2022. Disponível em: <<https://repositorio.ufu.br/handle/123456789/35138>>. Acesso em: 30 mar. 2025.

TORMIN, W. P. *Previsão de Retornos do Bitcoin: Uma Abordagem Comparativa Entre Modelos ARIMA e LSTM Integrados com Dados de Tendências do Google*. Dissertação (Trabalho de Conclusão de Curso (Graduação em Economia)) — Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa (IDP), Brasília, 2024. Acesso em: 26 mar. 2025.

WARREN MAGAZINE. *Conheça as fraquezas e vantagens dos investimentos ativos e passivos*. 2025. Warren Magazine. 14 fev. 2025. Disponível em: <<https://warren.com.br/magazine/investimento-ativo-ou-passivo/>>. Acesso em: 22 abr. 2025.

WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 2. ed. Rio de Janeiro: Elsevier, 2014.

XING, Y. et al. *Predicting NVIDIA's Next-Day Stock Price: A Comparative Analysis of LSTM, MLP, ARIMA, and ARIMA-GARCH Models*. 2024. ArXiv. Preprint. Disponível em: <<https://arxiv.org/abs/2405.08284>>. Acesso em: 09 abr. 2025.

APÊNDICES

APÊNDICE A – Algoritmo do Expert Advisor no MetaTrader 5, baseado no Trabalho de graduação de Almeida (2016) e nas documentações do MetaTrader 5

```

1 //+-----+
2 //| EA_MM_Crossover_SLTP_v1.06.mq5 |
3 //+-----+
4 #property copyright "Adaptado por [Seu Nome/Assistente Virtual]"
5 #property link      "https://www.mql5.com"
6 #property version   "1.06"
7 #property description "Cruzamento de MM com SL/TP e reversão"
8
9 #include <Trade\Trade.mqh>
10 CTrade Trade;
11
12 input group "Parâmetros das Médias Móveis"
13 input int      RapidaMM_Periodo    = 10;
14 input ENUM_MA_METHOD RapidaMM_Metodo = MODE_SMA;
15 input ENUM_APPLIED_PRICE RapidaMM_Preco = PRICE_CLOSE;
16 input int      RapidaMM_Shift      = 0;
17
18 input int      DevagarMM_Periodo    = 20;
19 input ENUM_MA_METHOD DevagarMM_Metodo = MODE_SMA;
20 input ENUM_APPLIED_PRICE DevagarMM_Preco = PRICE_CLOSE;
21 input int      DevagarMM_Shift      = 0;
22
23 input group "Parâmetros de Negociação"
24 input double   Volume_Fixo_Input    = 1.0;
25 input int      StopLoss_Points      = 50;
26 input int      TakeProfit_Points    = 100;
27 input ulong    MagicNumber          = 12349;
28 input int      Slippage_Points      = 10;
29 input bool     TradeOnNewBarOnly    = true;
30
31 int      h_RapidaMM;
32 int      h_DevagarMM;
33 datetime gl_TimeUltimaBarraProcessada = 0;
34 int      gl_DigitsPrice;
35 double   g_VolumeOperacional;
36
37 //+-----+
38 int OnInit()
39 {
40     g_VolumeOperacional = Volume_Fixo_Input;
41
42     h_RapidaMM = iMA(_Symbol, _Period, RapidaMM_Periodo, RapidaMM_Shift, RapidaMM_Metodo,
43                     RapidaMM_Preco);
44     if(h_RapidaMM == INVALID_HANDLE) return(INIT_FAILED);
45
46     h_DevagarMM = iMA(_Symbol, _Period, DevagarMM_Periodo, DevagarMM_Shift,
47                     DevagarMM_Metodo, DevagarMM_Preco);
48     if(h_DevagarMM == INVALID_HANDLE) return(INIT_FAILED);
49
50     Trade.SetExpertMagicNumber(MagicNumber);
51     Trade.SetDeviationInPoints(Slippage_Points);
52     Trade.SetTypeFillingBySymbol(_Symbol);
53
54     gl_DigitsPrice = (int)SymbolInfoInteger(_Symbol, SYMBOL_DIGITS);
55
56     double min_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MIN);

```

```

55     double max_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MAX);
56     double step_volume = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_STEP);
57
58     if(g_VolumeOperacional < min_volume) g_VolumeOperacional = min_volume;
59     if(g_VolumeOperacional > max_volume) g_VolumeOperacional = max_volume;
60
61     if(step_volume > 0) {
62         double remainder = MathMod(g_VolumeOperacional, step_volume);
63         if(MathAbs(remainder) > 1e-10) {
64             g_VolumeOperacional = MathRound(g_VolumeOperacional / step_volume) *
65                 step_volume;
66             int volume_digits = 0;
67             if(step_volume < 1.0 && step_volume > 0) {
68                 string step_str = DoubleToString(step_volume, 8);
69                 int dot_pos = StringFind(step_str, ".");
70                 if(dot_pos != -1) volume_digits = StringLen(step_str) - dot_pos - 1;
71             }
72             g_VolumeOperacional = NormalizeDouble(g_VolumeOperacional, volume_digits);
73         }
74     }
75     if(g_VolumeOperacional < min_volume) g_VolumeOperacional = min_volume;
76
77     return(INIT_SUCCEEDED);
78 }
79 //+-----+
80 void OnDeinit(const int reason)
81 {
82     if(h_RapidaMM != INVALID_HANDLE) IndicatorRelease(h_RapidaMM);
83     if(h_DevagarMM != INVALID_HANDLE) IndicatorRelease(h_DevagarMM);
84 }
85 //+-----+
86 ENUM_POSITION_TYPE ObterTipoPosicaoAtual() {
87     for(int i = PositionsTotal() - 1; i >= 0; i--) {
88         ulong ticket = PositionGetTicket(i);
89         if(ticket > 0 && PositionSelectByTicket(ticket)) {
90             if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
91                 PositionGetInteger(POSITION_MAGIC) == MagicNumber) {
92                 return (ENUM_POSITION_TYPE)PositionGetInteger(POSITION_TYPE);
93             }
94         }
95     }
96     return (ENUM_POSITION_TYPE)-1;
97 }
98 //+-----+
99 bool FecharPosicaoAtual(ENUM_POSITION_TYPE tipoPosicaoParaFechar) {
100     if (tipoPosicaoParaFechar == POSITION_TYPE_BUY || tipoPosicaoParaFechar ==
101         POSITION_TYPE_SELL) {
102         for(int i = PositionsTotal() - 1; i >= 0; i--) {
103             ulong ticket = PositionGetTicket(i);
104             if(ticket > 0 && PositionSelectByTicket(ticket)) {
105                 if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
106                     PositionGetInteger(POSITION_MAGIC) == MagicNumber &&
107                     PositionGetInteger(POSITION_TYPE) == tipoPosicaoParaFechar) {
108                     if(Trade.PositionClose(ticket, Slippage_Points)) {
109                         return true;
110                     } else {
111                         return false;
112                     }
113                 }
114             }
115         }
116     }
117 }

```

```

116     return true;
117 }
118 //+-----+
119 void OnTick()
120 {
121
122     if(TradeOnNewBarOnly)
123     {
124         static datetime prevTime = 0;
125         datetime currentTime = (datetime)SeriesInfoInteger(_Symbol, _Period,
            SERIES_LASTBAR_DATE);
126         if(currentTime == prevTime) return;
127         prevTime = currentTime;
128     }
129
130     double arr_temp[1];
131     double maRapidaAnterior, maLentaAnterior, maRapidaAntesDoCruzamento,
        maLentaAntesDoCruzamento;
132
133     if(CopyBuffer(h_RapidaMM, 0, 1, 1, arr_temp) != 1) return; maRapidaAnterior = arr_temp
        [0];
134     if(CopyBuffer(h_DevagarMM, 0, 1, 1, arr_temp) != 1) return; maLentaAnterior =
        arr_temp[0];
135     if(CopyBuffer(h_RapidaMM, 0, 2, 1, arr_temp) != 1) return; maRapidaAntesDoCruzamento =
        arr_temp[0];
136     if(CopyBuffer(h_DevagarMM, 0, 2, 1, arr_temp) != 1) return; maLentaAntesDoCruzamento
        = arr_temp[0];
137
138     MqlTick tick;
139     if(!SymbolInfoTick(_Symbol, tick) || tick.ask == 0 || tick.bid == 0) return;
140     double askPrice = tick.ask;
141     double bidPrice = tick.bid;
142
143     ENUM_POSITION_TYPE tipoPosicaoAtual = ObterTipoPosicaoAtual();
144
145     bool condicaoCompra = maRapidaAnterior > maLentaAnterior && maRapidaAntesDoCruzamento
        <= maLentaAntesDoCruzamento;
146     if(condicaoCompra)
147     {
148         if(tipoPosicaoAtual == POSITION_TYPE_SELL) {
149             if(!FecharPosicaoAtual(POSITION_TYPE_SELL)) return;
150             Sleep(1);
151             tipoPosicaoAtual = ObterTipoPosicaoAtual();
152         }
153
154         if(tipoPosicaoAtual != POSITION_TYPE_BUY) {
155             double sl = 0, tp = 0;
156             double stop_level_points = (double)SymbolInfoInteger(_Symbol,
                SYMBOL_TRADE_STOPS_LEVEL);
157             double min_distance_sl_tp = stop_level_points * _Point;
158
159             if(StopLoss_Points > 0) {
160                 sl = NormalizeDouble(askPrice - StopLoss_Points * _Point, gl_DigitsPrice);
161                 if (min_distance_sl_tp > 0 && askPrice - sl < min_distance_sl_tp) {
162                     sl = NormalizeDouble(askPrice - min_distance_sl_tp, gl_DigitsPrice);
163                 }
164                 if (sl >= askPrice) sl = 0;
165             }
166             if(TakeProfit_Points > 0) {
167                 tp = NormalizeDouble(askPrice + TakeProfit_Points * _Point, gl_DigitsPrice)
                    ;
168                 if (min_distance_sl_tp > 0 && tp - askPrice < min_distance_sl_tp) {
169                     tp = NormalizeDouble(askPrice + min_distance_sl_tp, gl_DigitsPrice);

```

```

170         }
171         if (tp <= askPrice && TakeProfit_Points > 0) tp = 0;
172     }
173
174     Trade.Buy(g_VolumeOperacional, _Symbol, askPrice, sl, tp, "Compra MM Rev");
175 }
176 return;
177 }
178
179 bool condicaoVenda = maRapidaAnterior < maLentaAnterior && maRapidaAntesDoCruzamento
    >= maLentaAntesDoCruzamento;
180 if(condicaoVenda)
181 {
182     if(tipoPosicaoAtual == POSITION_TYPE_BUY) {
183         if(!FecharPosicaoAtual(POSITION_TYPE_BUY)) return;
184         Sleep(1);
185         tipoPosicaoAtual = ObterTipoPosicaoAtual();
186     }
187
188     if(tipoPosicaoAtual != POSITION_TYPE_SELL) {
189         double sl = 0, tp = 0;
190         double stop_level_points = (double)SymbolInfoInteger(_Symbol,
            SYMBOL_TRADE_STOPS_LEVEL);
191         double min_distance_sl_tp = stop_level_points * _Point;
192
193         if(StopLoss_Points > 0) {
194             sl = NormalizeDouble(bidPrice + StopLoss_Points * _Point, gl_DigitsPrice);
195             if (min_distance_sl_tp > 0 && sl - bidPrice < min_distance_sl_tp) {
196                 sl = NormalizeDouble(bidPrice + min_distance_sl_tp, gl_DigitsPrice);
197             }
198             if (sl <= bidPrice) sl = 0;
199         }
200         if(TakeProfit_Points > 0) {
201             tp = NormalizeDouble(bidPrice - TakeProfit_Points * _Point, gl_DigitsPrice)
                ;
202             if (min_distance_sl_tp > 0 && bidPrice - tp < min_distance_sl_tp) {
203                 tp = NormalizeDouble(bidPrice - min_distance_sl_tp, gl_DigitsPrice);
204             }
205             if (tp >= bidPrice && TakeProfit_Points > 0) tp = 0;
206         }
207
208         Trade.Sell(g_VolumeOperacional, _Symbol, bidPrice, sl, tp, "Venda MM Rev");
209     }
210     return;
211 }
212 }
213 //+-----+

```