CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA
FACULDADE DE TECNOLOGIA DE INDAIATUBA
DR. ARCHIMEDES LAMOGLIA
CURSO DE TECNOLOGIA
EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Desenvolvimento e comparação de modelos de negociação algorítmica: ARIMA-GARCH e médias móveis

Indaiatuba
2026

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Desenvolvimento e comparação de modelos de negociação algorítmica: ARIMA-GARCH e médias móveis

Trabalho de graduação apresentado por Bruno Rocha Pereira e Giovanni Silva Loose como pré-requisito para a conclusão do Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Faculdade de Tecnologia de Indaiatuba, elaborado sob a orientação da Profa. Simone Mendes da Silva.

Indaiatuba

2026

RESUMO

Este trabalho retoma um estudo desenvolvido na Faculdade de Tecnologia de Indaiatuba em 2016, no qual um robô de negociação para a plataforma MetaTrader 5, guiado pelo cruzamento de médias móveis, obteve bons resultados em períodos de mercado estável, mas acumulou prejuízo no período que inclui a crise financeira de 2008. Ao final daquele estudo, o autor sugeriu que modelos capazes de medir a volatilidade poderiam ajudar a contornar essa limitação. Partindo dessa sugestão, desenvolveu-se um novo robô que reúne dois modelos estatísticos com papéis distintos. O primeiro, chamado ARIMA, procura antecipar a direção dos preços. O segundo, chamado GARCH, estima o quanto o mercado deve oscilar e decide se vale a pena operar. Os dois modelos foram programados na própria linguagem da plataforma e testados sobre o histórico oficial da bolsa brasileira, em períodos de crise e de calma, sempre em comparação com a estratégia original e com uma versão do robô sem o controle de volatilidade. Os resultados mostram que esse controle tornou o robô mais seguro. Em todos os períodos analisados, ele oscilou menos que a versão sem o controle e que a estratégia original, e as perdas nos piores momentos foram menores que as da versão sem o controle. Em boa parte dos períodos, o ganho final também foi maior. A capacidade de acertar a direção do mercado, porém, continuou próxima do acaso, e as diferenças de ganho em relação à estratégia original variaram conforme o período, ora a favor de um, ora de outro. Conclui-se que o modelo de volatilidade funciona como um instrumento de proteção, especialmente útil em quedas prolongadas como a crise de 2008, e não como uma forma de prever melhor o mercado.

Palavras-chave: ARIMA-GARCH; negociação algorítmica; MetaTrader 5.

ABSTRACT

This work revisits a study carried out at the Faculdade de Tecnologia de Indaiatuba in 2016, in which a trading robot for the MetaTrader 5 platform, guided by moving average crossovers, performed well in stable market periods but accumulated losses over the period that includes the 2008 financial crisis. At the end of that study, the author suggested that models able to measure volatility could help overcome this limitation. Building on that suggestion, a new robot was developed that brings together two statistical models with distinct roles. The first, called ARIMA, tries to anticipate the direction of prices. The second, called GARCH, estimates how much the market is likely to fluctuate and decides whether it is worth trading. Both models were programmed in the platform's own language and tested on the official history of the Brazilian stock exchange, in periods of crisis and of calm, always in comparison with the original strategy and with a version of the robot without the volatility control. The results show that this control made the robot safer. In every period analysed, it fluctuated less than both the version without the control and the original strategy, and its losses in the worst moments were smaller than those of the version without the control. In many periods the final gain was also larger. The ability to predict market direction, however, remained close to chance, and the differences in gain relative to the original strategy varied from period to period, sometimes favouring one and sometimes the other. The conclusion is that the volatility model works as a protective instrument, especially useful in prolonged downturns such as the 2008 crisis, and not as a way of predicting the market better.

Keywords: ARIMA-GARCH; algorithmic trading; MetaTrader 5.

LISTA DE ILUSTRAÇÕES

Figura 1 – Cruzamento de médias móveis 12
Figura 2 – Interface do MetaTrader 5 13
Figura 3 – Ciclo de funcionamento de um *Expert Advisor* 14
Figura 4 – Etapas de aplicação do modelo ARIMA 16
Figura 5 – Retroalimentação da variância no modelo GARCH 18
Quadro 1 – Métricas de avaliação usadas no trabalho 20
Quadro 2 – Características dos estudos relacionados 22
Quadro 3 – Configurações testadas na otimização 30
Quadro 4 – Períodos de otimização e de teste 30
Quadro 5 – Forma de uso do GARCH em cada robô escolhido 35
Gráfico 1 – Retorno por ano, 2007 a 2011 36
Gráfico 2 – Patrimônio e queda acumulada, 2007 a 2011 37
Gráfico 3 – Saldo registrado pelo MetaTrader 5, 2007 a 2011 38
Gráfico 4 – Retorno por ano, 2013 a 2016 39
Gráfico 5 – Patrimônio e queda acumulada, 2013 a 2016 40
Gráfico 6 – Saldo registrado pelo MetaTrader 5, 2013 a 2016 41
Gráfico 7 – Patrimônio e queda acumulada, 2017 a 2024 42
Gráfico 8 – Retorno por ano, 2017 a 2024 43
Gráfico 9 – Saldo registrado pelo MetaTrader 5, 2017 a 2024 44
Gráfico 10 – Patrimônio e queda acumulada, 2025 a 2026 46
Gráfico 11 – Saldo registrado pelo MetaTrader 5, 2025 a 2026 47
Gráfico 12 – Preço da PETR4 e patrimônio aplicado na ação, 2007 a 2011 50

LISTA DE TABELAS

Tabela 1 – Reprodução dos testes de Almeida (2016) 33
Tabela 2 – Risco nas condições originais, 2013 a 2016 34
Tabela 3 – Resultado de 2007 a 2011 35
Tabela 4 – Resultado de 2013 a 2016 38
Tabela 5 – Resultado de 2017 a 2024 41
Tabela 6 – Resultado em 2020, ano da pandemia 44
Tabela 7 – Resultado de 2025 a 2026 45
Tabela 8 – Cada versão com e sem o GARCH 48
Tabela 9 – Retorno por camada, 2007 a 2011 51
Tabela 10 – Retorno por camada, 2013 a 2016 51
Tabela 11 – Retorno por camada, 2017 a 2024 51
Tabela 12 – Retorno por camada, 2025 a 2026 51
Tabela 13 – Retorno e queda máxima em outras ações 52

LISTA DE SIGLAS

ADF	*Augmented Dickey-Fuller*
AIC	*Akaike Information Criterion*
AR	Autorregressivo
ARCH	*Autoregressive Conditional Heteroskedasticity*
ARIMA	*Autoregressive Integrated Moving Average*
ARMA	*Autoregressive Moving Average*
B3	Brasil, Bolsa, Balcão
COTAHIST	Arquivo de Cotações Históricas da B3
EA	*Expert Advisor*
EGARCH	*Exponential* GARCH
FATEC	Faculdade de Tecnologia
GARCH	*Generalized Autoregressive Conditional Heteroskedasticity*
LSTM	*Long Short-Term Memory*
MQL5	*MetaQuotes Language* 5
PETR4	Código de negociação das ações preferenciais da Petrobras
SARIMA	*Seasonal Autoregressive Integrated Moving Average*
Selic	Sistema Especial de Liquidação e de Custódia
TGARCH	*Threshold* GARCH

SUMÁRIO

INTRODUÇÃO 9
CAPÍTULO I 11
1 Fundamentação teórica 11
1.1 Mercado de ações 11
1.2 Análise técnica 11
1.2.1 Médias móveis 12
1.3 MetaTrader 5 13
1.4 Modelos estatísticos de séries temporais 14
1.4.1 ARIMA 14
1.4.2 GARCH 17
1.4.3 Integração entre ARIMA e GARCH 18
1.4.4 Uso da volatilidade prevista na operação 19
1.5 Métricas de avaliação 19
1.6 Trabalhos relacionados 21
CAPÍTULO II 23
2 Percurso metodológico 23
2.1 Caracterização da pesquisa 23
2.1.1 Quanto aos objetivos 23
2.1.2 Quanto ao delineamento 23
2.2 Caracterização do lugar e da amostra de pesquisa 23
2.3 Procedimentos para coleta e análise de dados 24
2.3.1 Técnicas para coleta de dados 24
2.3.2 Natureza da análise de dados 25
2.4 Implementação dos modelos 25
2.4.1 Preparação dos preços 25
2.4.2 Estimação do ARIMA 26
2.4.3 Estimação do GARCH 26
2.4.4 Janela de estimação 27
2.4.5 Funcionamento do robô 27
2.4.6 Uso do GARCH na decisão 27
2.4.7 Parâmetros do robô 28
2.5 Plano experimental 28
2.5.1 Condições das simulações 28
2.5.2 Medição dos resultados 28
2.5.3 Reprodução do estudo de referência 29
2.5.4 Configurações testadas 29
2.5.5 Escolha da configuração 30

2.5.6 Robôs comparados 31
2.5.7 Testes complementares 31
2.6 Obstáculos encontrados 31
CAPÍTULO III 33
3 Análise e discussão dos dados 33
3.1 Reprodução do estudo de referência 33
3.2 Como os resultados são apresentados 34
3.3 Crise financeira, 2007 a 2011 35
3.4 Queda prolongada e recuperação, 2013 a 2016 38
3.5 Teste principal, 2017 a 2024 41
3.6 A crise da pandemia, 2020 44
3.7 Período recente, 2025 a 2026 45
3.8 O efeito vem do GARCH? 47
3.9 Como o GARCH protege 48
3.10 Efeito dos custos, da Selic e dos proventos 50
3.11 Outras ações 52
CONSIDERAÇÕES FINAIS 54
REFERÊNCIAS 57
APÊNDICE A – Código do *Expert Advisor* 60

INTRODUÇÃO

Este trabalho dá continuidade ao estudo de Almeida (2016), desenvolvido nesta mesma instituição. O autor programou em MQL5, para a plataforma MetaTrader 5, um robô de negociação para a PETR4, chamado na plataforma de *Expert Advisor*, isto é, um programa que compra e vende o ativo automaticamente segundo regras definidas previamente. A regra escolhida foi o cruzamento de duas médias móveis do preço: quando a média de curto prazo cruza a de longo prazo, o robô interpreta o movimento como início de uma tendência e abre a posição. Avaliado sobre dados históricos, o robô obteve lucro entre 2013 e 2016, mas prejuízo entre 2007 e 2011, período que inclui a crise financeira de 2008. Ao discutir esse resultado, o próprio autor alertou para as limitações da técnica em mercados de alta volatilidade e indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa.

A dificuldade apontada por ele continua atual, porque as crises voltam a acontecer, e é nelas que as maiores perdas se concentram. Em março de 2020, no início da pandemia de covid-19, o Ibovespa, principal índice de ações da bolsa brasileira, caiu 29,9% em um único mês (Máximo, 2020). A própria PETR4 perdeu 48,6% do seu valor entre o fim de 2019 e o início de abril de 2020, segundo as cotações oficiais da bolsa (B3, 2026). Uma estratégia baseada apenas no cruzamento de médias responde a uma única pergunta, a de para que lado o preço parece estar indo, e nada diz sobre o quanto ele pode oscilar no caminho. Por isso, ela entra no mercado com a mesma convicção em um dia calmo e em um dia de forte turbulência.

Os modelos estatísticos de séries temporais permitem separar essas duas perguntas. O modelo ARIMA estima a direção esperada do preço a partir do comportamento passado da própria série, de forma parecida com uma média móvel, mas com pesos ajustados aos dados. O modelo GARCH estima a volatilidade esperada para o período seguinte. Reunidos em um mesmo algoritmo, o primeiro indicaria o lado da operação e o segundo poderia atuar como um filtro de risco, evitando operar quando a oscilação esperada fosse alta. É essa a proposta que este trabalho investiga, retomando a sugestão de Almeida (2016) dez anos depois, sobre o mesmo ativo e na mesma plataforma.

Resta saber, porém, o que efetivamente se ganha ao acrescentar essa camada de modelagem. Acrescentar um modelo de volatilidade torna o algoritmo mais complexo, exige a estimação de parâmetros adicionais a cada operação e reduz o número de negócios realizados, e nada garante, de antemão, que o resultado compense esse custo. Coloca-se, assim, a questão norteadora deste trabalho: em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis?

Duas hipóteses foram formuladas antes dos experimentos. A primeira é a de que a integração entre a previsão de séries temporais pelo ARIMA e a modelagem de volatilidade condicional pelo GARCH gera sinais de negociação mais eficazes, tanto em acerto direcional quanto em adequação ao risco, do que o emprego isolado do ARIMA. A ideia de combinar

técnicas com funções distintas para obter resultados superiores encontra respaldo em trabalhos como o de Batista (2024), que integrou indicadores técnicos em um mesmo robô de negociação. A segunda é a de que essa combinação representa um avanço em relação às análises baseadas em médias móveis. Ambas são confrontadas com os resultados nas considerações finais.

O objetivo geral foi desenvolver, em MQL5, um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar o efeito do GARCH sobre o desempenho e o risco das operações, em comparação com o ARIMA isolado e com a estratégia de Almeida (2016). Os objetivos específicos foram implementar os modelos ARIMA e GARCH na própria linguagem da plataforma, automatizar a escolha das ordens do ARIMA, reproduzir a estratégia de médias móveis de Almeida (2016) e comparar os três algoritmos quanto a retorno e risco em diferentes períodos do mercado, incluindo períodos de crise.

A pesquisa se justifica, em primeiro lugar, por retomar uma recomendação deixada em aberto em um estudo da própria instituição. Justifica-se, também, por ter sido conduzida no mercado brasileiro, com o histórico oficial da B3 e atravessando as crises que atingiram a bolsa do país. Há, ainda, uma contribuição técnica. Como a biblioteca padrão da linguagem MQL5 não traz modelos de séries temporais, os estimadores foram construídos para este trabalho, e o controle de risco feito pelo GARCH, separado da previsão de direção, pode ser reaproveitado em outras estratégias para torná-las mais protetivas.

Quanto à natureza, a pesquisa é primária, por produzir conhecimento novo a partir da realização de experimentos, e se apoia no método empírico, que fundamenta as conclusões em observações (Wazlawick, 2021). É também aplicada, por voltar esse conhecimento a um problema concreto de decisão. Quanto aos objetivos, é explicativa, quanto ao delineamento, é quase experimental, e a análise dos dados é quantitativa. Os algoritmos foram testados por simulação no MetaTrader 5, sobre o histórico oficial de preços da B3, conforme detalhado no Capítulo II.

O trabalho está organizado em três capítulos, seguidos das considerações finais. O Capítulo I apresenta a fundamentação teórica, que parte do mercado de ações e da plataforma MetaTrader 5, passa pela análise técnica e pelas médias móveis, chega aos modelos ARIMA e GARCH e às medidas de desempenho e risco, e encerra-se com os trabalhos relacionados. O Capítulo II descreve o percurso metodológico, isto é, a caracterização da pesquisa, a amostra, a coleta dos dados, a implementação dos modelos, o plano experimental e os obstáculos encontrados. O Capítulo III apresenta a análise e a discussão dos dados. As considerações finais respondem à questão norteadora, retomam as hipóteses e avaliam o cumprimento dos objetivos.

CAPÍTULO I

1 Fundamentação teórica

Este capítulo reúne os conceitos sobre os quais o trabalho se apoia. Parte do ambiente em que as operações acontecem, isto é, a bolsa de valores e a plataforma de negociação, passa pela análise técnica e pelas médias móveis empregadas por Almeida (2016) e chega aos modelos estatísticos ARIMA e GARCH e às medidas usadas para avaliar uma estratégia. Ao final, são apresentados os trabalhos relacionados.

1.1 Mercado de ações

De acordo com o Banco Central do Brasil (2025a), as bolsas de valores são sociedades anônimas ou associações civis que mantêm local ou sistema adequado à realização de operações de compra e venda de títulos e valores mobiliários, em mercado livre e aberto, organizado e fiscalizado por seus membros e pela Comissão de Valores Mobiliários. No Brasil, esse papel é exercido pela B3.

Para a empresa, a abertura de capital é uma forma de obter recursos de terceiros. Em troca do capital recebido, ela cede aos acionistas uma participação no negócio proporcional ao valor investido. Para o investidor, a ação passa a ser um ativo cujo preço varia a cada pregão, isto é, a cada sessão diária de negociação na bolsa, conforme a oferta e a procura, e é essa variação que as estratégias de negociação procuram aproveitar.

O investidor não negocia diretamente na bolsa. O acesso se dá por meio de corretoras, instituições que intermediam as operações e oferecem serviços como plataformas de negociação pela internet, custódia dos títulos e financiamento para a compra de ações, cobrando por isso comissões e taxas (Banco Central do Brasil, 2025b). É pela corretora que uma plataforma como o MetaTrader 5 se conecta ao mercado.

A taxa Selic é a taxa básica de juros da economia brasileira. Ela serve de base para as demais taxas praticadas no mercado e influencia tanto o custo do crédito quanto o retorno das aplicações financeiras (Banco Central do Brasil, 2025c). Por esse motivo, o capital que uma estratégia mantém fora do mercado costuma ser comparado ao que renderia se estivesse aplicado a essa taxa.

1.2 Análise técnica

A análise técnica busca antecipar o comportamento dos preços a partir do estudo do seu próprio histórico, procurando padrões e tendências que possam indicar o movimento seguinte. Sua origem remonta ao comércio de arroz, e hoje ela é aplicada a ações, moedas e outros ativos. Para essa abordagem, o que importa é o comportamento do preço, sem considerar notícias ou outros fatores que possam influenciar o mercado (Fernandes, 2014).

Fernandes (2014) distingue duas vertentes. A empírica, ou clássica, é a mais antiga: o analista observa o gráfico e identifica tendências, suportes, resistências e padrões que, segundo essa abordagem, tendem a se repetir. Por depender da interpretação de quem observa, ela é sujeita a conclusões diferentes sobre o mesmo ativo. A estatística, ou moderna, substitui a interpretação visual por cálculos aplicados à série de preços, o que torna a análise reproduzível e permite que ela seja executada por um programa de computador.

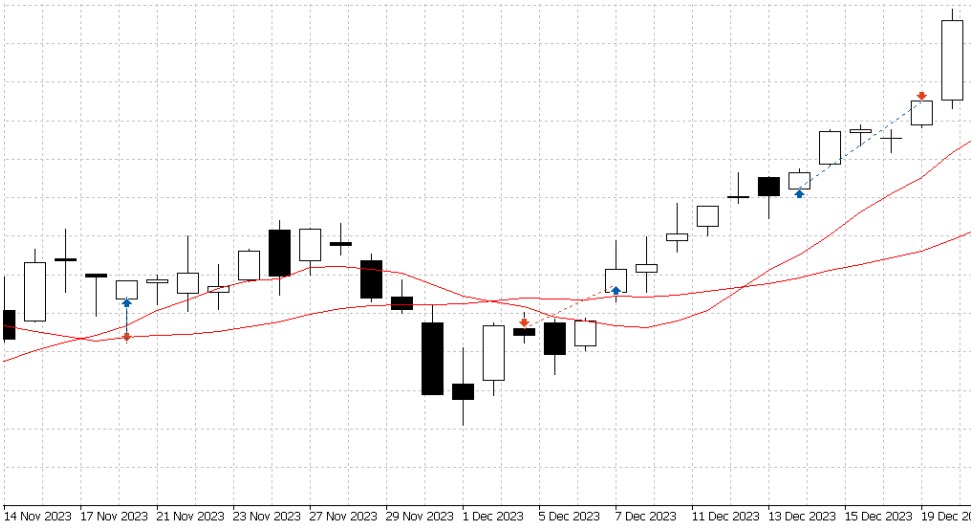
É na segunda vertente que este trabalho se insere. Tanto a estratégia de médias móveis de Almeida (2016) quanto os modelos ARIMA e GARCH são regras matemáticas aplicadas ao histórico de preços, e por isso podem ser programados, testados sobre dados passados e comparados entre si sob as mesmas condições.

1.2.1 Médias móveis

A média móvel é um dos instrumentos mais utilizados da análise técnica. Ela calcula o preço médio de um ativo nos últimos n períodos e é recalculada a cada novo período, descartando o valor mais antigo e incorporando o mais recente. Com isso, suaviza as oscilações de curto prazo e evidencia a direção predominante dos preços (Fernandes, 2014). Na média móvel simples, todos os preços da janela recebem o mesmo peso, de modo que a média de dez períodos atribui peso de um décimo a cada um dos dez últimos fechamentos.

O tamanho da janela determina o comportamento da média. Janelas curtas reagem rapidamente a mudanças de preço, mas produzem mais sinais falsos, enquanto janelas longas filtram melhor o ruído, à custa de reconhecer uma nova tendência com atraso (Fernandes, 2014). A estratégia de cruzamento combina as duas: utiliza uma média rápida, de janela curta, e uma lenta, de janela longa, e interpreta o cruzamento entre elas como sinal de compra ou de venda, como ilustra a Figura 1.

Figura 1 – Cruzamento de médias móveis



Fonte: Elaboração própria com dados e interface do MetaTrader 5.

Foi essa a estratégia adotada por Almeida (2016). O autor utilizou duas médias móveis simples, uma de dez e outra de vinte períodos, calculadas sobre o preço de fechamento, e operou nos dois sentidos, comprando quando a média rápida cruzava a lenta para cima e vendendo no cruzamento inverso. Seu algoritmo previa ainda parâmetros de limite de perda e de realização de lucro, embora os testes relatados tenham sido conduzidos com ambos nulos. O próprio autor alertou para as limitações de se usar apenas essa técnica em mercados de alta volatilidade (Almeida, 2016).

1.3 MetaTrader 5

O MetaTrader 5 é uma plataforma de negociação multimercado desenvolvida pela MetaQuotes, que reúne em um mesmo ambiente a execução de ordens, a análise gráfica e o desenvolvimento de sistemas automatizados para ações, futuros, moedas e outros instrumentos (MetaQuotes Ltd., 2024). Sua interface, mostrada na Figura 2, organiza em janelas as cotações em tempo real, os gráficos de preços e o navegador, que dá acesso às contas, aos indicadores e aos programas instalados.

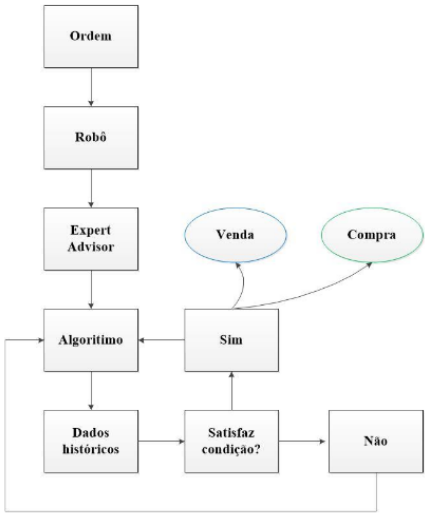
Figura 2 – Interface do MetaTrader 5



Fonte: MetaQuotes Ltd. (2024).

Os programas que negociam de forma automática na plataforma são chamados de *Expert Advisors* (EAs), também conhecidos como robôs de negociação. Um EA abre, modifica e encerra posições segundo regras programadas, sem intervenção manual (Almeida, 2016). A Figura 3 apresenta o ciclo de funcionamento de um EA.

Figura 3 – Ciclo de funcionamento de um *Expert Advisor*



Fonte: Almeida (2016).

Os EAs são escritos em MQL5, linguagem própria da plataforma, de sintaxe próxima à do C++. O ambiente de desenvolvimento, chamado MetaEditor, oferece editor, compilador e depurador integrados. Para avaliar uma estratégia antes de usá-la, a plataforma dispõe do testador de estratégias, o *Strategy Tester*, que executa o EA sobre dados históricos, simulando as ordens como se o mercado estivesse aberto, e produz relatórios de desempenho (MetaQuotes Ltd., 2024). Esse procedimento é conhecido como *backtesting*, e foi por meio dele que todos os experimentos deste trabalho foram conduzidos.

1.4 Modelos estatísticos de séries temporais

Uma série temporal é uma sequência de observações ordenadas no tempo, como os preços de fechamento diários de uma ação. Os modelos de séries temporais procuram descrever a estrutura dessa sequência, isto é, de que forma cada observação se relaciona com as anteriores, e utilizam essa descrição para projetar valores futuros. Neste trabalho são empregados dois desses modelos, com funções diferentes. O ARIMA descreve o valor esperado da série, e o GARCH descreve o tamanho esperado dos erros em torno desse valor.

1.4.1 ARIMA

O modelo autorregressivo integrado de médias móveis, conhecido pela sigla ARIMA, do inglês *Autoregressive Integrated Moving Average*, é um dos modelos mais empregados na previsão de séries temporais, inclusive em séries financeiras (Xing *et al.*, 2024). Ele é composto por três partes, cada uma associada a uma ordem.

A parte autorregressiva, de ordem p, expressa o valor atual da série como combinação dos seus p valores anteriores. A parte de médias móveis, de ordem q, acrescenta a influência dos q erros de previsão anteriores, isto é, das diferenças entre o que o modelo previu e o que de fato

ocorreu. A parte integrada, de ordem d, indica quantas vezes a série precisa ser diferenciada, ou seja, substituída pela variação entre uma observação e a anterior, para se tornar estacionária (Xing *et al.*, 2024). Uma série é estacionária quando sua média e sua variância não se alteram ao longo do tempo, condição exigida pelas partes autorregressiva e de médias móveis.

Convém registrar que a média móvel do ARIMA não é a mesma média móvel da análise técnica. Na análise técnica, a média é calculada sobre os preços. No ARIMA, o termo de médias móveis é uma combinação dos erros de previsão passados. Os dois conceitos têm o mesmo nome, mas descrevem coisas diferentes.

Representando por y_t a série já diferenciada d vezes, o modelo pode ser escrito como

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \tag{1.1}$$

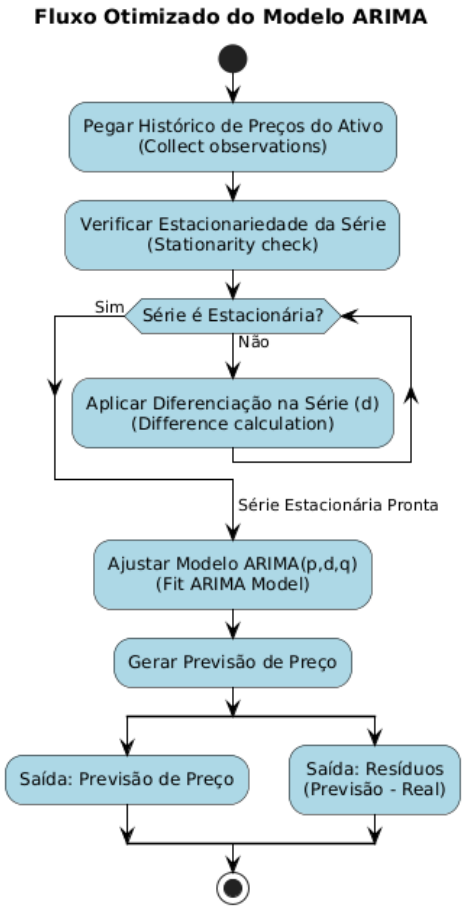
em que c é uma constante, os coeficientes ϕ ponderam os valores passados da série, os coeficientes θ ponderam os erros passados e ε_t é o erro do período atual, que o modelo não consegue prever.

O ARIMA supõe, portanto, que a série diferenciada segue um modelo ARMA(p,q), que tem apenas as partes autorregressiva e de médias móveis (Thomaz, 2019). Quando a série não precisa ser diferenciada ($d = 0$), o próprio ARIMA é um ARMA, e quando também não há termos de médias móveis ($q = 0$), o modelo é chamado de AR(p), ou autorregressivo.

Há uma relação direta entre essa equação e a estratégia de Almeida (2016). A média móvel simples de dez períodos é um filtro linear que atribui pesos fixos, iguais a um décimo, aos últimos preços. A parte autorregressiva do ARIMA também é um filtro linear sobre os valores passados, mas seus pesos ϕ são estimados a partir dos dados, em vez de fixados por convenção. Nesse sentido, o ARIMA pode ser visto como uma generalização da média móvel: mantém a mesma família de operação e ajusta os coeficientes ao ativo e ao período analisados.

A aplicação do modelo segue as etapas representadas na Figura 4.

Figura 4 – Etapas de aplicação do modelo ARIMA



Fonte: Elaboração própria.

A primeira etapa é verificar se a série é estacionária. Uma série estacionária oscila em torno de uma média estável, e um choque que a afasta dessa média tende a se desfazer com o tempo. Os preços de ações, ao contrário, costumam se comportar como um passeio aleatório, em que cada choque se incorpora ao preço e não se desfaz, de modo que a variância da série cresce com o tempo (Thomaz, 2019). Esse comportamento é chamado de raiz unitária. Para identificá-lo, usa-se o teste de Dickey-Fuller aumentado (ADF), que estima, por regressão, o quanto a variação de cada dia depende do nível da série no dia anterior. Se a série tende a voltar à sua média, essa dependência é negativa e forte. Se não tende, ela é próxima de zero, e a série tem raiz unitária (Thomaz, 2019).

A hipótese nula do teste é a existência de raiz unitária. O valor-p indica a probabilidade de se obter um resultado tão favorável à estacionariedade quanto o observado se a série de fato tivesse raiz unitária. Como a estatística do teste não segue as distribuições usuais, os seus valores críticos foram tabelados especialmente para ele, e a hipótese nula é rejeitada quando a estatística fica abaixo do valor crítico, o que corresponde a um valor-p pequeno, em geral menor que 0,05 (Thomaz, 2019). Quando a hipótese não é rejeitada, a série é diferenciada e testada de novo. No estudo de Xing *et al.* (2024) sobre as ações da NVIDIA, o teste aplicado aos preços resultou em valor-p de 0,998773, isto é, sem nenhum indício contra a raiz unitária. Após uma diferenciação,

o valor-p ficou próximo de zero, e a ordem de integração foi definida como $d = 1$.

Definido d, resta escolher p e q. Como várias combinações são possíveis, Xing *et al.* (2024) testaram valores de zero a quatro para cada ordem e escolheram a combinação de menor critério de informação de Akaike (AIC), dado por

$$\text{AIC} = -2\ln\hat{L} + 2k,$$

em que $\hat{L}$ é a verossimilhança do modelo ajustado, que mede o quão provável é a série observada segundo o modelo, e k é o número de parâmetros estimados (Thomaz, 2019). A primeira parcela diminui quanto melhor o ajuste, e a segunda aumenta a cada parâmetro acrescentado. Um modelo com mais parâmetros sempre se ajusta um pouco melhor aos dados passados, mas parte desse ganho é apenas ruído reproduzido, que não ajuda a prever. A penalidade faz com que um parâmetro a mais só compense se melhorar o ajuste mais do que custa. Ajusta-se, então, cada combinação candidata, e escolhe-se a de menor AIC, que é a que melhor equilibra ajuste e simplicidade. Com o modelo escolhido, obtêm-se a previsão para o período seguinte e os resíduos, que são os erros de previsão observados na amostra.

Segundo Xing *et al.* (2024) e Araya, Aduda e Berhane (2024), a principal limitação do ARIMA é tratar apenas relações lineares e supor que a variância dos erros é constante. Em séries financeiras essa segunda suposição raramente se verifica, e é dela que trata o modelo GARCH.

1.4.2 GARCH

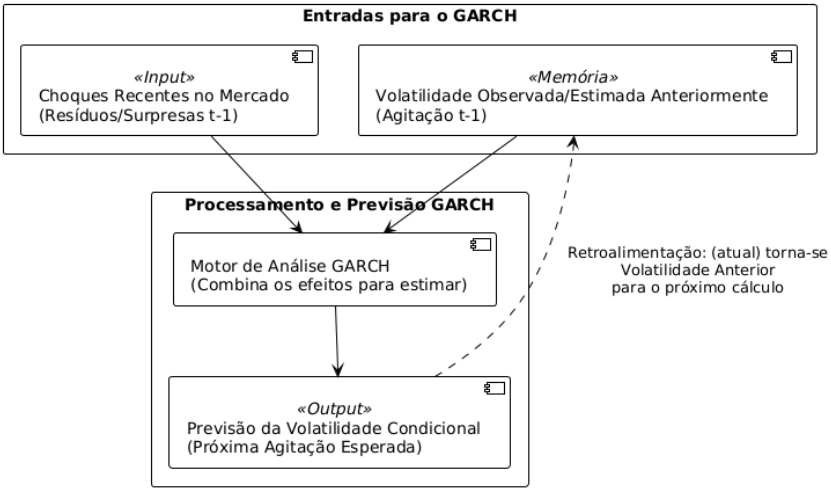
Nas séries de retornos de ações, a volatilidade, que mede o grau de variação dos preços ao longo do tempo, não é constante. Ela costuma vir em ondas, com dias agitados seguidos de outros dias agitados e dias calmos seguidos de dias calmos, e conhecê-la é fundamental para a gestão de risco (Araya; Aduda; Berhane, 2024). Engle (1982) propôs o modelo ARCH, em que a variância do erro de cada período depende dos erros dos períodos anteriores. Bollerslev (1986) generalizou essa proposta no modelo GARCH, do inglês *Generalized Autoregressive Conditional Heteroskedasticity*, em que a variância passa a depender também das próprias variâncias anteriores.

Na especificação GARCH(1,1), adotada neste trabalho, a variância condicional σ_t^2 do erro no período t é dada por

$$\sigma_t^2 = \omega + \alpha\,\varepsilon_{t-1}^2 + \beta\,\sigma_{t-1}^2, \tag{1.2}$$

em que ε_{t-1} é o erro do período anterior, σ_{t-1}^2 é a variância estimada para o período anterior e ω, α e β são os parâmetros do modelo. O termo com α representa a reação da volatilidade a um choque recente, e o termo com β representa a persistência da volatilidade passada (Bollerslev, 1986). A Figura 5 ilustra esse processo de retroalimentação.

Figura 5 – Retroalimentação da variância no modelo GARCH



Fonte: Elaboração própria.

Para que o modelo faça sentido, os parâmetros precisam respeitar restrições: ω deve ser positivo, α e β não podem ser negativos e a soma $\alpha+\beta$ deve ser menor que um. A última condição garante que a variância tenha um valor de longo prazo finito, igual a $\omega/(1-\alpha-\beta)$, para o qual a volatilidade retorna depois de um choque (Bollerslev, 1986).

O GARCH padrão trata de forma simétrica os choques positivos e os negativos de mesma magnitude. Nos mercados de ações, porém, as quedas costumam elevar a volatilidade mais do que as altas. Para representar essa assimetria foram propostas variações do modelo, como o EGARCH e o TGARCH, que acrescentam à equação termos capazes de fazer a volatilidade reagir de forma diferente a choques positivos e negativos (Araya; Aduda; Berhane, 2024). Este trabalho emprega a especificação simétrica.

1.4.3 Integração entre ARIMA e GARCH

Os dois modelos se complementam. O ARIMA estima a média condicional da série, ou seja, o valor esperado para o período seguinte. O GARCH estima a variância condicional dos erros desse valor esperado. Na forma combinada, os resíduos gerados pelo ARIMA servem de entrada para o GARCH, que modela a variância desses resíduos ao longo do tempo (Araya; Aduda; Berhane, 2024).

Em uma estratégia de negociação, essa combinação permite separar duas perguntas. A direção da operação é dada pelo sinal da previsão do ARIMA, e o risco associado a ela é dado pela volatilidade prevista pelo GARCH. Como o GARCH não fornece nenhuma informação sobre a direção dos preços, ele não pode, sozinho, gerar uma ordem de compra ou de venda. O que ele pode fazer é condicionar a operação indicada pelo ARIMA ao nível de risco esperado, impedindo a operação ou reduzindo o seu tamanho quando a volatilidade prevista é alta.

1.4.4 Uso da volatilidade prevista na operação

A volatilidade prevista pelo GARCH pode entrar na decisão de duas maneiras básicas, que respondem a perguntas diferentes.

A primeira é o filtro de volatilidade, que decide se a operação é feita. Define-se um limiar, e a operação indicada pelo ARIMA só é realizada quando a volatilidade prevista está abaixo dele. Nos dias em que se espera uma oscilação acima do limiar, a operação é vetada, e o investidor deixa de se expor justamente quando o risco esperado é maior.

A segunda é o ajuste do tamanho da posição, técnica conhecida como *volatility targeting*, ou volatilidade-alvo, que decide quanto aplicar. Em vez de manter o valor aplicado constante, procura-se manter constante o nível de oscilação da carteira, aumentando a posição quando a volatilidade está baixa e reduzindo-a quando está alta (Harvey *et al.*, 2018). Define-se um nível de oscilação considerado aceitável, o alvo, e o tamanho da posição é multiplicado pela razão entre esse alvo e a volatilidade prevista. Se a volatilidade prevista dobra, a posição cai pela metade. A técnica parte do fato de que a volatilidade é persistente, isto é, períodos de oscilação alta tendem a ser seguidos por oscilação alta, a mesma característica que o GARCH modela. Em um estudo com mais de 60 ativos, Harvey *et al.* (2018) observaram que esse ajuste reduziu a ocorrência de retornos extremos em todos eles e, nas ações, também melhorou a relação entre retorno e risco.

As duas maneiras podem ser combinadas. Nesse caso, o filtro veta a operação nos dias de volatilidade prevista mais alta e, nos dias liberados, a posição é menor quanto maior for a volatilidade prevista.

Existem ainda outras formas de usar a volatilidade prevista, como só operar quando a previsão do ARIMA superar uma fração da oscilação esperada para o dia, o que equivale a um intervalo de confiança em torno da previsão. Este trabalho se limita ao filtro e ao ajuste da posição.

1.5 Métricas de avaliação

Avaliar uma estratégia de negociação apenas pelo lucro final esconde o caminho percorrido até ele. Duas estratégias com o mesmo retorno podem ter exposto o investidor a riscos muito diferentes. Por isso, o relatório do testador de estratégias do MetaTrader 5 apresenta, ao lado do lucro, medidas de risco e índices que relacionam as duas coisas (MetaQuotes Ltd., 2026b). O Quadro 1 resume as métricas usadas neste trabalho para avaliar e comparar os robôs.

Quadro 1 – Métricas de avaliação usadas no trabalho

Métrica	O que indica	Como é calculada
Retorno acumulado	quanto o patrimônio cresceu ou diminuiu no período	patrimônio final dividido pelo inicial, menos um
Queda máxima	o pior tombo que um investidor teria sofrido seguindo a estratégia	maior queda percentual do patrimônio entre um ponto alto e o ponto mais baixo seguinte
Volatilidade	o quanto o patrimônio sobe e desce de um dia para o outro	desvio-padrão dos retornos diários do patrimônio, em base anual
Negociações	quantas operações o robô realizou	contagem do relatório do testador
Taxa de acerto	a proporção de negociações que terminaram com lucro	negociações com lucro divididas pelo total
Sinais vetados	quantas vezes o GARCH impediu uma operação indicada pelo ARIMA	contagem registrada pelo robô
Índice de Sharpe	o ganho além de uma referência por unidade de oscilação	média do retorno diferencial dividida pelo seu desvio-padrão
Índice de Calmar	o ganho por unidade de queda máxima	retorno anualizado dividido pela queda máxima

Fonte: Elaboração própria, com base em MetaQuotes Ltd. (2026b) e Sharpe (1994).

O risco é medido de duas formas complementares. A queda máxima, que o relatório da plataforma chama de rebaixamento relativo e que também é conhecida pelo termo em inglês *drawdown*, é a maior queda percentual entre um máximo local do patrimônio e o mínimo local seguinte (MetaQuotes Ltd., 2026b). Ela responde à pergunta de qual foi o pior tombo do caminho. A volatilidade, por sua vez, é o desvio-padrão dos retornos e mede o quanto o patrimônio oscila no dia a dia.

Como os retornos são diários, a volatilidade é convertida para base anual, o que facilita a leitura e a comparação. Se os retornos de dias diferentes forem independentes entre si, a variância de um período de T dias é T vezes a variância diária, e o desvio-padrão, a raiz de T vezes o diário (Sharpe, 1994). Usou-se $T = 252$, valor próximo da média de 248 pregões por ano observada na série da PETR4 usada neste trabalho. A volatilidade anual é, portanto, o desvio-padrão diário multiplicado pela raiz de 252, e uma oscilação típica de 2% ao dia corresponde a cerca de 32% ao ano.

O índice de Sharpe relaciona o retorno de uma estratégia à sua volatilidade. Ele divide o retorno diferencial, isto é, a diferença entre o retorno da estratégia e o de uma referência, pelo desvio-padrão dessa diferença (Sharpe, 1994),

$$S = \frac{\bar{d}}{\sigma_d}, \tag{1.3}$$

em que $\bar{d}$ é a média do retorno diferencial e σ_d o seu desvio-padrão. O índice indica quanto se ganhou além da referência por unidade de oscilação, e quanto maior, melhor a relação. Um índice negativo indica que a estratégia rendeu menos que a referência. O testador do MetaTrader 5 usa como referência um rendimento livre de risco igual a zero (MetaQuotes Ltd., 2026b), e neste trabalho a referência foi a taxa Selic.

O índice de Calmar relaciona o retorno à queda máxima. Ele divide o retorno anualizado pela queda máxima do período,

$$C = \frac{\text{retorno anualizado}}{\text{queda máxima}}, \tag{1.4}$$

e segue a mesma ideia do fator de recuperação do relatório da plataforma, que divide o lucro obtido pelo rebaixamento máximo (MetaQuotes Ltd., 2026b), com a diferença de usar o retorno anualizado, o que permite comparar períodos de durações diferentes. O índice indica quanto se ganhou por unidade do pior tombo e, por isso, favorece estratégias que evitam perdas grandes. Os dois índices medem coisas diferentes. O Sharpe penaliza toda oscilação, para cima ou para baixo, e o Calmar considera apenas a pior queda.

1.6 Trabalhos relacionados

Os trabalhos relacionados foram selecionados entre pesquisas sobre o desenvolvimento de robôs de negociação na plataforma MetaTrader 5 e sobre a aplicação dos modelos ARIMA e GARCH à previsão de séries de preços de ações.

O estudo de Almeida (2016), desenvolvido na FATEC Indaiatuba, é o ponto de partida deste trabalho. O autor desenvolveu em MQL5 um robô de negociação para a PETR4 baseado no cruzamento de médias móveis simples de dez e vinte períodos e o avaliou por *backtesting* em períodos de crise, entre 2007 e 2011, e fora de crise, entre 2013 e 2016. A estratégia apresentou lucro no período fora de crise e prejuízo no período de crise. Ao discutir os limites do trabalho, o autor indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa. É essa indicação que o presente trabalho retoma, mantendo o ativo, a plataforma e a linguagem.

Batista (2024) também desenvolveu um *Expert Advisor* em MQL5 para a B3, combinando três indicadores técnicos, a média móvel exponencial, a convergência e divergência de médias móveis e o índice de força relativa. Os testes, realizados sobre o ativo BBAS3F em 2023, compararam os indicadores isoladamente, em pares e em conjunto, e a combinação dos três apresentou o melhor resultado. O estudo mostra que a integração de técnicas com funções distintas em um mesmo algoritmo pode melhorar a decisão, ideia que este trabalho aplica aos modelos estatísticos.

Xing *et al.* (2024) compararam o ARIMA, o ARIMA-GARCH e dois modelos de redes neurais na previsão do preço de fechamento das ações da NVIDIA, com dados diários de abril de 2019 a abril de 2024. As ordens dos modelos ARIMA foram definidas pelo teste ADF e pelo menor AIC, com p e q variando de zero a quatro, procedimento semelhante ao adotado neste trabalho. O ARIMA-GARCH apresentou a menor raiz do erro quadrático médio, e o ARIMA com janela expansiva teve o melhor desempenho geral, superando as redes neurais. Os autores atribuem esse resultado, possivelmente, ao comportamento predominantemente linear da série.

Araya, Aduda e Berhane (2024) estudaram a previsão da volatilidade das ações da Apple. No modelo proposto, os resíduos de um modelo SARIMA, versão do ARIMA com componentes

sazonais, alimentam um modelo GARCH, e a volatilidade estimada por essa combinação é depois utilizada como entrada de redes neurais. A etapa que interessa a este trabalho é a primeira, em que os resíduos do modelo de média servem de entrada para o modelo de variância, mesma arquitetura adotada no algoritmo aqui desenvolvido.

O Quadro 2 resume as características desses estudos e as deste trabalho.

Quadro 2 – Características dos estudos relacionados

Estudo	Ativo	Fonte de dados	Periodicidade	Método
Almeida (2016)	PETR4	MetaTrader 5	diário	Cruzamento de médias móveis simples (10 e 20)
Batista (2024)	BBAS3F	MetaTrader 5	30 minutos	Combinação de três indicadores técnicos
Xing *et al.* (2024)	NVIDIA	Yahoo Finance	diário	ARIMA e ARIMA-GARCH, comparados a redes neurais
Araya, Aduda e Berhane (2024)	Apple	Yahoo Finance	diário	Resíduos do SARIMA como entrada do GARCH, seguidos de redes neurais
Este trabalho	PETR4 e outras três ações	B3 (COTAHIST)	diário	ARIMA e ARIMA-GARCH, comparados às médias móveis de Almeida (2016)

Fonte: Elaboração própria.

CAPÍTULO II

2 Percurso metodológico

Este capítulo descreve como a pesquisa foi conduzida. Apresenta a caracterização do estudo, a amostra, a coleta e a análise dos dados, a implementação dos modelos, o plano experimental e os obstáculos encontrados.

2.1 Caracterização da pesquisa

2.1.1 Quanto aos objetivos

Quanto aos objetivos, a pesquisa é explicativa, com uma parte descritiva. Segundo Wazlawick (2021), a pesquisa explicativa busca identificar as causas de determinados fenômenos, aprofundando o conhecimento sobre a relação entre variáveis. Neste trabalho, ela investiga por que a inclusão de um modelo de volatilidade altera o desempenho de uma estratégia cuja previsão de direção permanece a mesma. A parte descritiva está no registro de como cada robô se comportou em diferentes períodos do mercado.

2.1.2 Quanto ao delineamento

Quanto ao delineamento, trata-se de uma pesquisa quase experimental. A pesquisa experimental envolve a manipulação controlada de variáveis e a observação dos efeitos resultantes. Quando os objetos estudados não podem ser selecionados de forma aleatória, trata-se de um quase experimento (Wazlawick, 2021). É o caso deste trabalho, em que a série histórica de um ativo é única e não pode ser sorteada.

O problema e as hipóteses foram formulados na introdução. As variáveis são os parâmetros configuráveis do robô, e o plano experimental foi definido antes da observação dos resultados. Os sujeitos são as séries históricas dos ativos, e o ambiente é a plataforma de simulação.

2.2 Caracterização do lugar e da amostra de pesquisa

O lugar da pesquisa é computacional. Os experimentos foram conduzidos no testador de estratégias do MetaTrader 5, que simula a execução de ordens sobre séries históricas com as mesmas regras de negociação que usaria em tempo real. A plataforma foi escolhida por ser a mesma utilizada no estudo que este trabalho continua (Almeida, 2016). Ela é nativa do sistema Windows, e os experimentos apresentados aqui foram executados em ambiente Linux, por meio da camada de compatibilidade Wine, pelos motivos expostos ao final deste capítulo.

A amostra é composta por séries históricas diárias de ações negociadas na B3. O ativo principal é a PETR4, ação preferencial da Petrobras, escolhida por três motivos. É o ativo estudado por Almeida (2016), o que permite a comparação direta. Apresenta volatilidade

acentuada, característica que dá sentido à aplicação de um modelo de variância condicional. E possui série longa e contínua no arquivo histórico da bolsa, com 5.881 pregões, de 2 de janeiro de 2003 a 21 de setembro de 2026.

Para verificar se os resultados se repetem fora do ativo principal, foram incluídas outras três ações, VALE3, da mineração, USIM5, da siderurgia, e POMO4, de bens de capital. O critério de escolha, definido antes da observação de qualquer resultado, considerou a qualidade dos dados e a diversidade de setores. Cada ação precisava ter série completa de 2003 a 2026 no arquivo da bolsa, sem mudanças na forma de cotação que impedissem a reconstrução dos preços, e preço sempre acima de R$ 3, para que o arredondamento em centavos não distorcesse os retornos. As ações também deveriam pertencer a setores diferentes entre si.

O recorte temporal foi dividido em períodos, e não tratado como um período único, porque o comportamento de uma estratégia depende do momento do mercado. Foram examinados um período de crise, de 2007 a 2011, um de queda prolongada seguida de recuperação, de 2013 a 2016, o intervalo de 2017 a 2024, que inclui a crise da pandemia, o período mais recente, de 2025 a 2026, e o período mais longo disponível, de 2005 a 2026.

2.3 Procedimentos para coleta e análise de dados

2.3.1 Técnicas para coleta de dados

Os dados foram obtidos de fontes públicas oficiais, e não do servidor da corretora, que disponibiliza cotações apenas a partir de setembro de 2021 e pode alterar o histórico sem aviso. As cotações vieram do arquivo COTAHIST, série histórica publicada pela própria B3, que registra, para cada pregão e cada ação, os preços de abertura, máximo, mínimo e fechamento e o volume negociado (B3, 2026). A taxa Selic diária foi obtida da série 11 do Sistema Gerenciador de Séries Temporais do Banco Central (Banco Central do Brasil, 2026).

Sobre as cotações foi aplicada uma única transformação, a correção por desdobramentos. No desdobramento, cada ação é dividida em várias, e o preço cai na mesma proporção, sem que o investidor perca nada, já que passa a ter mais ações. Na PETR4 houve dois desdobramentos no período. Em 1º de setembro de 2005, cada ação virou quatro, e em 28 de abril de 2008, cada ação virou duas. No arquivo da bolsa, esses dias aparecem como quedas de 75,2% e de 49,5%, que não aconteceram de fato e que o modelo interpretaria como dois tombos do mercado. Para corrigir, os preços anteriores a 28 de abril de 2008 foram divididos por dois, e os anteriores a 1º de setembro de 2005, por oito, isto é, por quatro e depois por dois. Com isso, a série passa a registrar apenas as variações reais de preço. Os dois eventos foram confirmados no registro de eventos corporativos da B3 e, para o de 2005, que esse registro não alcança, na base do Yahoo Finance (Yahoo Finance, 2026). Os proventos não foram incorporados à série. Eles foram obtidos da mesma base, que não é oficial, e usados apenas para verificar o efeito de deixá-los de fora.

As séries preparadas foram importadas para a plataforma como símbolos personalizados,

recurso que permite ao testador operar sobre dados próprios.

2.3.2 Natureza da análise de dados

A análise é quantitativa. Os robôs foram comparados pelas métricas apresentadas no Capítulo I. Como o GARCH atua sobre o tamanho das operações, e não sobre a previsão da direção, que continua a cargo do ARIMA, as métricas principais são as de risco, a queda máxima e a volatilidade. O retorno acumulado acompanha essas métricas como resultado complementar. A taxa de acerto verifica se o GARCH melhorou o acerto direcional, como previa a primeira hipótese, e a quantidade de sinais vetados ajuda a explicar o funcionamento do filtro.

Para verificar se as diferenças entre os robôs eram consistentes, e não obra do acaso, observou-se se elas se repetiam entre os períodos, entre as configurações e entre os ativos. Se o GARCH não fizesse diferença, a versão com ele seria melhor em cerca de metade das comparações, como no lançamento de uma moeda.

2.4 Implementação dos modelos

O MetaTrader 5 já oferece, na biblioteca padrão do MQL5, indicadores de análise técnica como médias móveis e osciladores, mas não traz modelos de séries temporais como o ARIMA e o GARCH. Os dois precisaram, portanto, ser implementados para este trabalho. A implementação se apoiou na documentação oficial da linguagem (MetaQuotes Ltd., 2026a) e nos conteúdos compartilhados pela comunidade de desenvolvedores do MetaTrader 5, cujos exemplos e trechos de código serviram de ponto de partida e foram adaptados às necessidades do robô. Para os cálculos numéricos mais pesados, a resolução de sistemas lineares e a otimização com restrições, foram usadas rotinas da ALGLIB, biblioteca numérica que acompanha a instalação da plataforma.

O robô de médias móveis de Almeida (2016) seguiu o mesmo caminho. Ele foi reescrito a partir do algoritmo publicado pelo autor, com o indicador de média móvel da própria plataforma, e compartilha com o ARIMA-GARCH a rotina de envio de ordens e de medição dos resultados, para que os dois sejam avaliados nas mesmas condições.

As subseções a seguir descrevem a implementação do ARIMA-GARCH parte por parte, da preparação dos preços aos parâmetros do robô.

2.4.1 Preparação dos preços

Os modelos foram aplicados ao logaritmo do preço, e não ao preço em reais. A diferença entre os logaritmos de dois preços seguidos é o retorno logarítmico, que mede a variação percentual do dia (Thomaz, 2019). Trabalhar com retornos tem duas vantagens. A primeira é que eles são livres de escala, ou seja, uma alta de 1% significa o mesmo para uma ação cotada a R$ 5 ou a R$ 40, de modo que os parâmetros do robô valem para qualquer ativo e período. A segunda é que os retornos costumam ser estacionários, ao contrário dos preços, condição exigida pelas partes autorregressiva e de médias móveis do ARIMA (Thomaz, 2019).

Como consequência, a volatilidade estimada pelo GARCH também sai em porcentagem. Uma volatilidade de 0,02 indica uma oscilação típica de 2% ao dia, enquanto, com o preço em reais, o mesmo número significaria dois centavos e mudaria de sentido conforme o preço da ação.

2.4.2 Estimação do ARIMA

O ARIMA foi estimado pelo método de Hannan e Rissanen (1982), que divide a estimação em duas regressões de mínimos quadrados. A dificuldade de um modelo com termos de médias móveis é que os erros passados não podem ser observados, pois dependem dos próprios coeficientes que se quer estimar. A primeira regressão ajusta um modelo autorregressivo longo, cujos resíduos servem de estimativa desses erros, e a segunda usa essas estimativas para obter os coeficientes.

A escolha do método foi uma decisão de projeto. Ele não exige taxa de aprendizado nem número de iterações e não depende da escala dos preços, o que o torna estável para um modelo que é reestimado todos os dias. O método também é usado na identificação automática de modelos ARIMA, em que muitas combinações de ordens precisam ser estimadas, por exigir apenas regressões lineares e fornecer estimativas próximas às de máxima verossimilhança (Gómez; Maravall, 1998).

As ordens do modelo foram escolhidas pelo próprio robô. A ordem de integração d foi determinada pela aplicação sequencial do teste ADF (Thomaz, 2019). Testa-se a série e, enquanto a hipótese de raiz unitária não for rejeitada, testa-se a série diferenciada mais uma vez. Com $d = 1$, o ARIMA modela os retornos. Com $d = 0$, escolhido quando o próprio logaritmo do preço se mostra estacionário dentro da janela, ele modela o logaritmo do preço diretamente. As ordens p e q foram escolhidas por busca em grade, de zero a quatro, pelo menor AIC (Thomaz, 2019), procedimento semelhante ao de Xing *et al.* (2024). As ordens são reavaliadas a cada 21 pregões, cerca de um mês, de modo que podem mudar ao longo de um teste.

2.4.3 Estimação do GARCH

O GARCH foi estimado por máxima verossimilhança (Thomaz, 2019) sobre os resíduos do ARIMA, isto é, sobre a parte do retorno que o ARIMA não conseguiu prever. Foi adotada a especificação GARCH(1,1), que exige poucos parâmetros e é a escolha predominante nos estudos de previsão de ações (Xing *et al.*, 2024). As restrições dos parâmetros, apresentadas no Capítulo I, foram impostas dentro da própria rotina de otimização, de modo que o resultado sempre respeita as condições do modelo. O valor usado na decisão é a volatilidade prevista para o pregão seguinte.

2.4.4 Janela de estimação

Os dois modelos são reestimados a cada pregão sobre uma janela deslizante, isto é, sobre os últimos 120 ou 240 pregões já encerrados, conforme a configuração. A cada dia, o pregão mais antigo sai da janela e o mais recente entra, o que permite ao modelo acompanhar as mudanças de comportamento do mercado. A janela nunca inclui o pregão em andamento, para que a decisão do dia não use uma informação que só estaria disponível no seu encerramento.

Xing *et al.* (2024) compararam esse tipo de janela com a janela expansiva, que acumula todo o histórico desde o início, e no seu estudo o ARIMA teve melhor desempenho com a janela expansiva. A janela expansiva não foi testada neste trabalho. O tamanho máximo da janela, de 240 pregões, foi limitado pelo histórico que o testador disponibiliza no início de cada teste, que começa em 1º de janeiro do ano anterior e soma cerca de 250 pregões.

2.4.5 Funcionamento do robô

Os dois modelos foram reunidos em um único *Expert Advisor*, com um parâmetro que liga e desliga o GARCH. Com ele desligado, o programa percorre o mesmo caminho de previsão, a mesma janela de estimação e a mesma rotina de envio de ordens, de modo que qualquer diferença entre as duas execuções só pode vir do GARCH.

A divisão de papéis é estrita. O ARIMA é o único responsável por indicar o lado da operação, e o GARCH nunca gera sinal de direção. A cada novo pregão, o robô carrega a janela, ajusta o ARIMA, obtém a previsão do retorno do dia, ajusta o GARCH sobre os resíduos e obtém a volatilidade prevista. Se o GARCH não vetar a operação, o sinal da previsão do ARIMA determina a direção, e a ordem é executada na abertura do pregão.

2.4.6 Uso do GARCH na decisão

As duas maneiras de usar a volatilidade prevista apresentadas no Capítulo I, o filtro e o ajuste da posição, foram implementadas no robô, cada uma sozinha e as duas combinadas.

No filtro, o limiar pode ser definido de duas formas. Na primeira, ele é um valor fixo de volatilidade diária, como 2% ao dia. Na segunda, ele é um percentil da volatilidade que o próprio GARCH estimou dentro da janela. Com o percentil 70, por exemplo, a operação é vetada quando a volatilidade prevista para o dia supera 70% dos valores estimados na janela. O limiar por percentil se adapta ao ativo e ao período, porque o que é um dia agitado muda com o tempo.

No ajuste da posição, o tamanho da posição é multiplicado pela razão entre o alvo e a volatilidade prevista, dentro de limites mínimo e máximo. Com um alvo de 1% ao dia e uma volatilidade prevista de 2%, o robô compra metade do tamanho normal.

O ajuste da posição sozinho foi testado, mas não foi escolhido em nenhum período nem em nenhuma ação. Todos os robôs escolhidos usam o filtro, sozinho ou combinado com o ajuste da posição.

Nas formas com filtro, resta decidir o que fazer com a posição que já está aberta. Por padrão, o veto só impede novas compras, e o robô continua com o que já tinha comprado. Uma opção do robô permite que o veto também encerre a posição, retirando o capital do mercado enquanto a volatilidade prevista estiver alta. O ajuste do tamanho, por sua vez, vale apenas para as novas compras.

2.4.7 Parâmetros do robô

O comportamento do robô é definido por parâmetros de entrada, que o MetaTrader 5 permite alterar sem modificar o código. Eles se dividem em três grupos.

Os parâmetros do ARIMA são o tamanho da janela de estimação, a inclusão ou não de uma constante no modelo e uma previsão mínima, abaixo da qual o robô não opera mesmo que a previsão indique alta. Os parâmetros do GARCH são a chave que liga e desliga o modelo, a forma de uso, o tipo e o valor do limiar, o alvo de volatilidade e a opção de encerrar a posição no veto. Os parâmetros de execução são a fração do patrimônio aplicada em cada operação e a restrição de operar apenas na ponta compradora.

Alguns parâmetros ficaram fixos em todos os testes, como a ordem máxima de zero a quatro do ARIMA e a reavaliação das ordens a cada 21 pregões. Os demais foram variados na otimização, com os valores apresentados no plano experimental.

2.5 Plano experimental

O plano experimental foi definido antes da observação dos resultados. Esta seção descreve, em partes, as condições das simulações, a forma de medir o resultado, a reprodução do estudo de referência, as configurações testadas, a forma de escolher entre elas, os robôs comparados e os testes complementares.

2.5.1 Condições das simulações

Todas as simulações usaram os preços de abertura de cada pregão, já que o robô decide uma vez por dia e executa na abertura. No cenário principal, partiram de um capital de R$ 100 mil, aplicaram a cada operação 95% do patrimônio e operaram apenas na ponta compradora. A reprodução do estudo de referência usou as condições do autor, descritas mais adiante.

2.5.2 Medição dos resultados

O resultado de cada simulação foi medido em quatro camadas, cada uma acrescentando um fator à anterior. A primeira, chamada de resultado bruto, é o patrimônio da conta simulada pelo testador, sem nenhum ajuste. A segunda desconta, a cada ordem, um custo hipotético de 0,03% do valor negociado. Esse valor é uma premissa do trabalho e não foi conferido com a tabela de tarifas da bolsa. A terceira acrescenta a remuneração pela taxa Selic diária do

capital que fica fora do mercado, para que robôs que passam tempos diferentes fora dele sejam comparados de forma justa. A quarta acrescenta os proventos pagos pela PETR4, obtidos de uma base que não é oficial.

A comparação entre os modelos é feita no resultado bruto, que depende apenas das decisões de cada robô. As demais camadas mostram como esse resultado muda quando os custos, a Selic e os proventos são considerados. A compra e manutenção da ação foi medida pela variação do preço e, na quarta camada, também com os proventos.

2.5.3 Reprodução do estudo de referência

Antes das comparações, a estratégia de médias móveis reproduzida foi submetida aos testes de Almeida (2016), para garantir que a comparação fosse feita com a estratégia dele. Os testes foram repetidos com as mesmas datas, o mesmo capital de R$ 50 mil, as mesmas médias de 10 e 20 períodos, sem custos e com operações de compra e venda.

Duas condições não puderam ser repetidas exatamente. A primeira é a série de preços, pois o autor usou o histórico da corretora sem informar se e como os preços foram ajustados. A segunda é o volume. O autor declara mil ações para o teste de 2013 a 2016, mas não informa o volume dos testes de crise, e, como ele menciona cem ações como volume mínimo, esse foi o volume adotado na reprodução desses testes.

Por fim, o ARIMA e o ARIMA-GARCH foram executados nas condições declaradas pelo autor para 2013 a 2016, com a configuração padrão do robô, que usa o GARCH como filtro, com limiar no percentil 50 da volatilidade estimada, janela de 120 pregões e, no veto, mantém a posição aberta.

2.5.4 Configurações testadas

As configurações testadas foram geradas a partir dos parâmetros descritos na Seção 2.4.7, pelo otimizador do testador de estratégias do MetaTrader 5, no modo de algoritmo completo, em que a própria plataforma executa uma simulação para cada combinação dos valores informados.

Três parâmetros variaram em todas as formas de uso do GARCH. O primeiro foi a inclusão ou não de uma constante no ARIMA. O segundo, a janela de estimação, de 120 ou de 240 pregões. O terceiro, uma previsão mínima, de zero ou de 0,1%, abaixo da qual o robô não opera. Essas três escolhas formam oito combinações, e cada forma de uso do GARCH acrescentou a elas os seus próprios parâmetros e, quando havia veto, a opção de encerrar ou não a posição, como mostra o Quadro 3. Ao todo, foram 304 configurações com o GARCH e oito sem ele, 312 no total.

Quadro 3 – Configurações testadas na otimização

Forma de uso do GARCH	Parâmetros próprios e valores testados	Configurações
Sem GARCH (ARIMA)	nenhum	8
Filtro, limiar fixo	limiar de 2%, 3% ou 4% ao dia, encerrar ou não a posição no veto	$8 \times 3 \times 2 = 48$
Filtro, limiar por percentil	percentil 50, 70 ou 90, encerrar ou não a posição no veto	$8 \times 3 \times 2 = 48$
Filtro e ajuste da posição, limiar fixo	limiar de 2%, 3% ou 4% ao dia, alvo de 1% ou 2% ao dia, encerrar ou não a posição no veto	$8 \times 3 \times 2 \times 2 = 96$
Filtro e ajuste da posição, limiar por percentil	percentil 50, 70 ou 90, alvo de 1% ou 2% ao dia, encerrar ou não a posição no veto	$8 \times 3 \times 2 \times 2 = 96$
Ajuste da posição	alvo de 1% ou 2% ao dia	$8 \times 2 = 16$
Total		312

Fonte: Elaboração própria.

Nota: O número 8 corresponde às combinações comuns a todas as formas: constante no ARIMA (sim ou não), janela de estimação (120 ou 240 pregões) e previsão mínima para operar (zero ou 0,1%).

Cada forma de uso foi otimizada separadamente, para que parâmetros que não se aplicam a ela não gerassem simulações repetidas. Em cada simulação, o próprio robô gravou em arquivo as medidas de desempenho, e o critério de escolha foi aplicado sobre esses arquivos.

2.5.5 Escolha da configuração

Escolher a melhor das 312 configurações no mesmo período em que o desempenho é medido daria uma vantagem falsa, porque, olhando para trás, sempre existe alguma combinação que teria dado certo. Por isso, a escolha seguiu o princípio do teste *forward* do testador de estratégias, em três passos. No primeiro, as 312 configurações foram simuladas nos três anos anteriores ao período de teste. No segundo, a lista de resultados foi ordenada por um critério definido antes, e a primeira configuração da lista foi a escolhida. No terceiro, só a configuração escolhida foi executada no período de teste, que não tinha sido usado na escolha, sem nenhuma alteração. Durante o teste, os coeficientes do ARIMA e do GARCH continuam a ser reestimados a cada pregão, como descrito na seção anterior. O que fica fixo é a configuração.

Para cada período de teste, os três passos foram refeitos do zero, com os três anos anteriores a ele. Por isso, a configuração escolhida, inclusive a forma de uso do GARCH, pode mudar de um período para outro. O Quadro 4 mostra os períodos usados.

Quadro 4 – Períodos de otimização e de teste

Otimização	Teste	Característica do período de teste
2004 a 2006	2007 a 2011	crise financeira de 2008
2010 a 2012	2013 a 2016	queda prolongada da PETR4 e recuperação em 2016
2014 a 2016	2017 a 2024	teste principal, por ser o mais longo, inclui a crise da pandemia em 2020
2022 a 2024	jan. 2025 a set. 2026	período mais recente disponível
2010 a 2012	2005 a 2026 e 2017 a 2024	configurações fixas, mantidas sem nova escolha

Fonte: Elaboração própria.

Foram usados dois critérios para ordenar a lista, porque não existe uma única forma de definir a melhor configuração. O ARIMA-GARCH Sharpe é a primeira configuração da lista ordenada pelo índice de Sharpe, ou seja, a de maior ganho por unidade de oscilação na otimização. O ARIMA-GARCH Calmar é a primeira da lista ordenada pelo índice de Calmar, a de maior ganho por unidade de queda máxima. O nome indica apenas o critério usado para ordenar a lista, e não o resultado obtido no teste. Na otimização, os dois índices foram calculados na terceira camada, e o de Sharpe, sobre o ganho acima da Selic.

2.5.6 Robôs comparados

Em cada período, as versões com GARCH foram comparadas a três referências. A primeira é o melhor robô sem o GARCH, escolhido entre as oito configurações sem o modelo pelo mesmo critério do ARIMA-GARCH Sharpe, e que aparece nas tabelas simplesmente como ARIMA. A segunda é a estratégia de médias móveis de Almeida (2016), reproduzida neste trabalho e executada nos mesmos períodos e nas mesmas condições. A terceira é a compra e manutenção da própria PETR4.

Essas comparações colocam lado a lado robôs com configurações diferentes. Para confirmar que as diferenças vinham do GARCH, e não dos demais parâmetros, cada versão com o GARCH também foi executada com o modelo desligado e todo o resto igual. Como o robô tem um único parâmetro que liga e desliga o GARCH, essa comparação isola o efeito dele.

2.5.7 Testes complementares

Dois testes complementares ampliaram a verificação. No primeiro, o ARIMA-GARCH Sharpe e o ARIMA-GARCH Calmar escolhidos em 2010 a 2012 foram mantidos fixos, sem refazer a escolha, assim como Almeida (2016) manteve fixas as suas médias de 10 e 20 períodos. Eles foram testados em 2017 a 2024, período inteiramente posterior à escolha, e em 2005 a 2026, que inclui os anos da escolha e por isso não é um teste fora da amostra, mas mostra se o comportamento se mantém no prazo mais longo disponível.

No segundo, o mesmo procedimento foi repetido na PETR4, na VALE3, na USIM5 e na POMO4, nos períodos de 2007 a 2011, 2013 a 2016 e 2025 a 2026, e cada configuração com GARCH foi comparada à mesma configuração sem ele. Nesse teste, a grade incluiu também a opção de vender a descoberto, o que elevou o número de configurações para 624 e o total para 14.976 simulações.

2.6 Obstáculos encontrados

O desenvolvimento enfrentou dois obstáculos que alteraram o cronograma original e influenciaram decisões metodológicas.

O primeiro foi a perda do ambiente Windows. O desenvolvimento começou em uma máquina com Windows e MetaTrader 5 instalado nativamente, e a perda desse equipamento

obrigou a migração para Linux, onde a plataforma não tem suporte oficial e precisa ser executada por camada de compatibilidade. A solução funcionou, mas trouxe instabilidades ocasionais e exigiu que a automação dos experimentos fosse refeita em linha de comando.

O segundo foi o acesso aos dados históricos pela corretora. A corretora utilizada inicialmente, a Rico, deixou de oferecer suporte ao MetaTrader 5, o que exigiu a abertura de conta em outra instituição. A segunda corretora, a Clear, oferece a plataforma, mas disponibiliza cotações apenas a partir de setembro de 2021, o que não atendia aos períodos de teste, que retrocedem a 2003. Esse obstáculo levou à adoção do arquivo oficial da bolsa como fonte, o que tornou a série pública, verificável e livre de alterações posteriores.

CAPÍTULO III

3 Análise e discussão dos dados

Este capítulo apresenta os resultados dos experimentos descritos no Capítulo II. Começa pela reprodução do estudo de Almeida (2016) e apresenta, em seguida, cada período de teste separadamente. Depois verifica se o efeito observado vem mesmo do GARCH, mostra de que forma ele protege o capital e, por último, como os resultados mudam quando se consideram os custos, a remuneração do caixa e os proventos, e fecha com o resultado em outras três ações.

3.1 Reprodução do estudo de referência

A Tabela 1 compara os resultados relatados por Almeida (2016) com os da reprodução.

Tabela 1 – Reprodução dos testes de Almeida (2016)

	Almeida (2016)		Reprodução	
Período	Operações	Resultado	Operações	Resultado
2013 a 2016	38	+R$ 10.430	37	+R$ 10.050
2008 a 2010	37	−R$ 1.595	38	−R$ 575
2007 a 2011	52	−R$ 2.542	63	−R$ 1.274

Fonte: Elaboração própria e Almeida (2016).

Nota: Médias móveis simples de 10 e 20 períodos, capital de R$ 50 mil, sem custos, compra e venda. Volume de mil ações em 2013 a 2016 e de cem ações nos testes de crise.

No período fora de crise, a reprodução difere do original em uma operação e em 3,6% do lucro, o que indica que a lógica da estratégia foi reproduzida. Nos testes de crise, a quantidade de operações de 2008 a 2010 praticamente coincide, mas os valores em reais divergem, e em 2007 a 2011 coincidem apenas o sinal e a ordem de grandeza do resultado.

A divergência em reais tem uma explicação provável. Com volume fixo, o resultado em reais acompanha o nível de preço da série, e uma verificação com a série ajustada também por proventos deslocou o lucro bruto de 2008 a 2010 na direção do valor do autor. Já a diferença na contagem de operações de 2007 a 2011 não foi explicada e só poderia ser investigada com os dados originais. A reprodução confirma, portanto, o comportamento do robô de referência, mas não os seus valores financeiros, o que basta para usá-lo como termo de comparação.

Nas mesmas condições declaradas pelo autor para 2013 a 2016, os robôs deste trabalho obtiveram o resultado da Tabela 2.

Tabela 2 – Risco nas condições originais, 2013 a 2016

Robô	Volatilidade	Queda máx.	Operações
Médias móveis reproduzidas	14,6%	15,0%	37
ARIMA	14,9%	30,9%	397
ARIMA-GARCH	12,2%	8,7%	173

Fonte: Elaboração própria.

Nota: Sem custos de execução, conforme o estudo original. O ARIMA-GARCH usa só o filtro, com limiar no percentil 50, e mantém a posição aberta no veto.

O ARIMA-GARCH foi o robô que menos oscilou e o que menos caiu. A sua queda máxima, de 8,7%, foi pouco mais da metade da das médias móveis e menos de um terço da do ARIMA. A diferença de volatilidade foi menor, porque com o volume fixo de mil ações os três robôs aplicavam, em média, cerca de um quarto do capital. Em dinheiro, as médias móveis reproduzidas lucraram R$ 10.050, o ARIMA teve prejuízo de R$ 8.100 e o ARIMA-GARCH lucrou R$ 24.020.

3.2 Como os resultados são apresentados

Cada período de teste é apresentado em uma seção própria, sempre na mesma ordem. Primeiro vem uma tabela com o resultado de cada robô, depois um gráfico com a evolução do patrimônio e, por fim, o saldo registrado pelo próprio MetaTrader 5 para o ARIMA e para o ARIMA-GARCH. Os números dessas seções são o resultado bruto, isto é, o patrimônio da conta simulada, sem custos, sem remuneração do caixa e sem proventos. Assim, a diferença entre os robôs vem apenas das decisões de cada modelo. O efeito dos custos, da Selic e dos proventos é apresentado em uma seção à parte, no fim do capítulo.

Nas tabelas, as médias móveis reproduzidas são a estratégia de Almeida (2016) executada por este trabalho, nas mesmas condições dos demais robôs. O ARIMA é o melhor robô sem o GARCH escolhido na otimização, e não o ARIMA-GARCH Sharpe com o GARCH desligado. A comparação de cada versão com a mesma configuração sem o GARCH, que isola o efeito do modelo, está na Seção 3.8. A PETR4 representa a compra e manutenção da ação, medida pela variação do preço.

Como a escolha foi refeita em cada período, o ARIMA-GARCH Sharpe e o ARIMA-GARCH Calmar não são sempre a mesma configuração. O Quadro 5 mostra o que cada um faz em cada período. Todos usam o filtro, e em alguns ele vem combinado com o ajuste da posição. Em quase todos, o veto também encerra a posição aberta. A exceção é o ARIMA-GARCH Calmar de 2017 a 2024, e essa diferença ajuda a explicar o resultado dele naquele período.

Quadro 5 – Forma de uso do GARCH em cada robô escolhido

Período de teste	ARIMA-GARCH Sharpe	ARIMA-GARCH Calmar
2007 a 2011	filtro e ajuste da posição, encerra a posição no veto	a mesma configuração do Sharpe
2013 a 2016	filtro e ajuste da posição, encerra a posição no veto	filtro e ajuste da posição, encerra a posição no veto
2017 a 2024	filtro, encerra a posição no veto	filtro e ajuste da posição, mantém a posição no veto
2025 a 2026	filtro, encerra a posição no veto	filtro e ajuste da posição, encerra a posição no veto
2005 a 2026 e 2017 a 2024, fixas	filtro e ajuste da posição, encerra a posição no veto	filtro e ajuste da posição, encerra a posição no veto

Fonte: Elaboração própria.

3.3 Crise financeira, 2007 a 2011

O primeiro período de teste inclui a crise financeira de 2008, em que o robô de Almeida (2016) acumulou prejuízo. A Tabela 3 apresenta o resultado.

Tabela 3 – Resultado de 2007 a 2011

Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	−31,6%	64,6%	28,7%	31
ARIMA	−12,7%	45,1%	27,5%	320
ARIMA-GARCH	−8,4%	17,5%	10,5%	263
PETR4	−14,0%	67,2%	43,2%	–

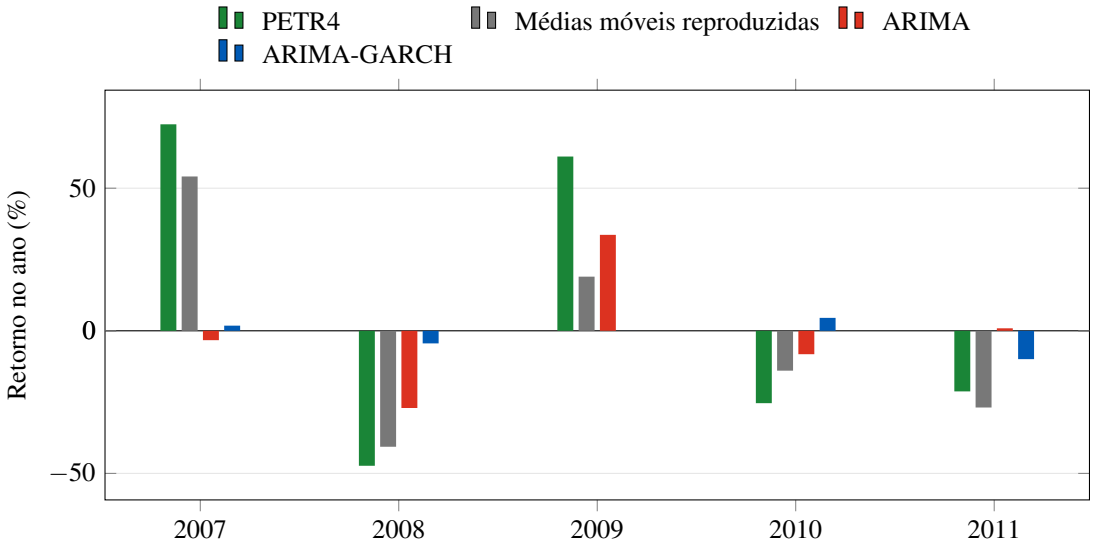
Fonte: Elaboração própria.

Nota: Resultado bruto. Neste período, os dois critérios de escolha resultaram na mesma configuração do ARIMA-GARCH.

Nenhum robô terminou o período com ganho. O ARIMA-GARCH foi o que menos perdeu e, principalmente, o que menos caiu. A sua queda máxima, de 17,5%, foi pouco mais de um quarto da das médias móveis e menos da metade da do ARIMA, e a sua volatilidade, de 10,5% ao ano, ficou abaixo de 40% da dos outros dois. O ARIMA e as médias móveis oscilaram de forma muito parecida, o que mostra que trocar o cruzamento de médias pela previsão do ARIMA, por si só, não reduziu o risco.

O Gráfico 1 mostra o resultado de cada ano. Em 2008, enquanto a PETR4 recuou 47,3%, o ARIMA-GARCH perdeu 4,4%, contra perdas de 27,1% do ARIMA e de 40,7% das médias móveis. Dentro do ano, a maior queda do ARIMA-GARCH foi de 11,3%, contra 45,2% do ARIMA, 52,5% das médias móveis e 67,2% da PETR4. Foi justamente nesse tipo de mercado que Almeida (2016) apontou a limitação das médias móveis e sugeriu os modelos de volatilidade. A proteção teve um custo em 2009, quando a ação subiu 61,1% e o ARIMA-GARCH terminou o ano praticamente no zero, enquanto o ARIMA ganhou 33,6%.

Gráfico 1 – Retorno por ano, 2007 a 2011

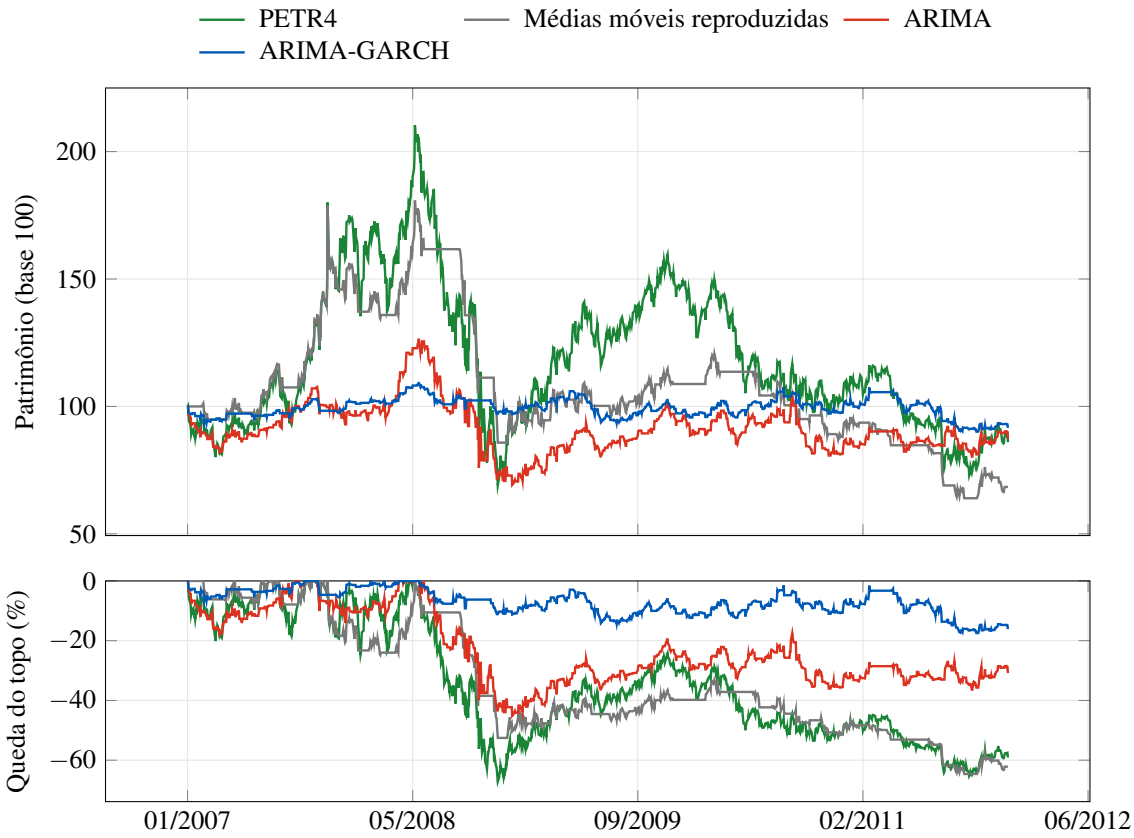


Fonte: Elaboração própria.

Nota: Resultado bruto.

O Gráfico 2 mostra a evolução do patrimônio e a queda acumulada de cada robô a partir do seu ponto mais alto. A linha do ARIMA-GARCH se mantém quase horizontal durante a crise, enquanto as demais acompanham a queda da ação.

Gráfico 2 – Patrimônio e queda acumulada, 2007 a 2011



Fonte: Elaboração própria.

Nota: Resultado bruto, com o capital inicial igual a 100.

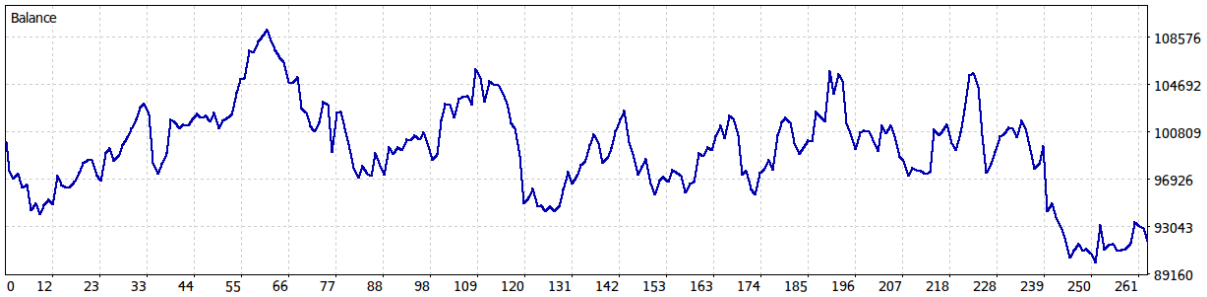
O Gráfico 3 reproduz o saldo registrado pelo testador do MetaTrader 5 ao fim de cada negociação, em uma conta que começou com R$ 100 mil. O saldo do ARIMA subiu até R$ 126 mil em maio de 2008 e desceu a R$ 71 mil em dezembro do mesmo ano, enquanto o do ARIMA-GARCH ficou sempre entre R$ 90 mil e R$ 109 mil.

Gráfico 3 – Saldo registrado pelo MetaTrader 5, 2007 a 2011

ARIMA



ARIMA-GARCH



Fonte: Relatório do testador de estratégias do MetaTrader 5.

Nota: Saldo em reais após cada negociação encerrada. O eixo horizontal é o número da negociação, e as escalas dos dois painéis são diferentes.

3.4 Queda prolongada e recuperação, 2013 a 2016

O segundo período combina a queda prolongada da PETR4 até o início de 2016 com a forte recuperação que veio depois. É também o período em que o robô de Almeida (2016) obteve lucro. A Tabela 4 apresenta o resultado.

Tabela 4 – Resultado de 2013 a 2016

Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	+100,8%	42,0%	40,4%	24
ARIMA	−35,8%	54,5%	37,8%	266
ARIMA-GARCH Sharpe	−13,8%	28,6%	14,1%	140
ARIMA-GARCH Calmar	−6,8%	15,5%	7,1%	140
PETR4	−25,6%	83,1%	59,2%	–

Fonte: Elaboração própria.

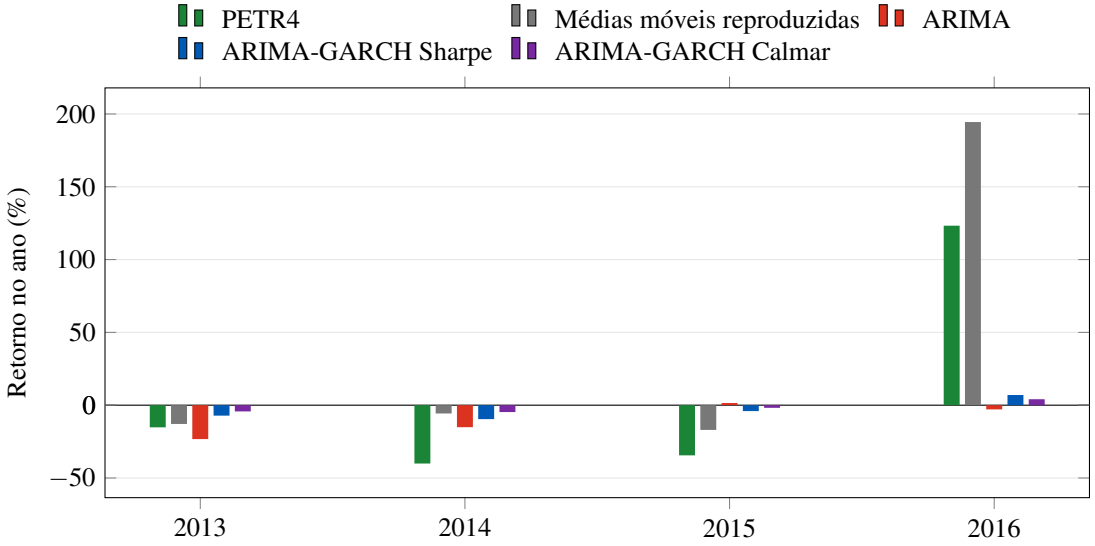
Nota: Resultado bruto.

As médias móveis tiveram o melhor resultado do período, com ganho de 100,8%. As duas versões com GARCH perderam pouco e foram as que menos caíram e menos oscilaram. O ARIMA-GARCH Calmar teve queda máxima de 15,5%, enquanto a PETR4 chegou a perder 83,1% do seu valor no pior momento. O ARIMA, sem o GARCH, teve o pior resultado, com perda de 35,8%.

O Gráfico 4 mostra de onde veio a vantagem das médias móveis. Elas perderam dinheiro em 2013, 2014 e 2015 e ganharam 194,5% em 2016, quando a ação subiu 123,3%. Elas

aproveitaram a recuperação com poucas negociações, e o ARIMA-GARCH, que ficou fora do mercado em boa parte do período, ganhou naquele ano 7,0% na configuração Sharpe e 4,1% na configuração Calmar. No trabalho de Almeida (2016), o lucro desse período também se concentrou em poucas operações, com três negociações lucrativas seguidas somando R$ 7.530 dos R$ 10.430 obtidos.

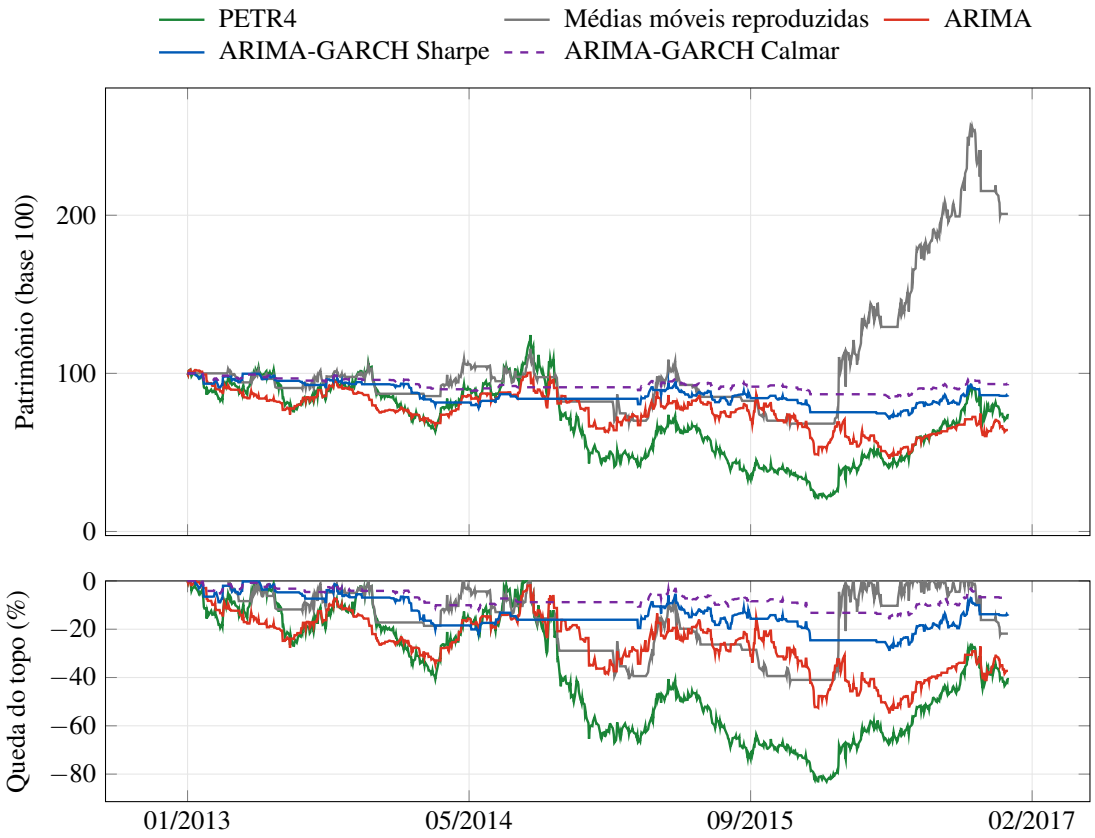
Gráfico 4 – Retorno por ano, 2013 a 2016



Fonte: Elaboração própria.

Nota: Resultado bruto.

Gráfico 5 – Patrimônio e queda acumulada, 2013 a 2016



Fonte: Elaboração própria.

Nota: Resultado bruto, com o capital inicial igual a 100.

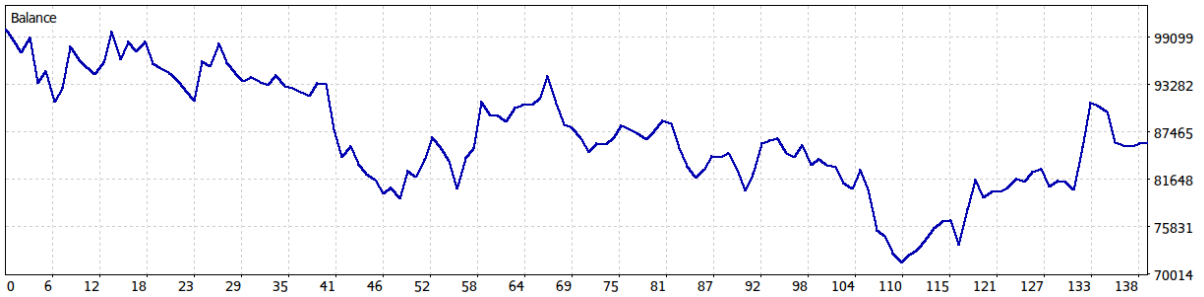
O Gráfico 5 mostra que, até o fim de 2015, todos os robôs e a própria ação estavam abaixo do capital inicial, e que a separação entre as médias móveis e os demais aconteceu só em 2016. No saldo registrado pelo MetaTrader 5, no Gráfico 6, o ARIMA desceu ao longo de quase todo o período e chegou a R$ 47 mil em junho de 2016, enquanto o menor saldo do ARIMA-GARCH Sharpe, no mesmo mês, foi de R$ 71 mil.

Gráfico 6 – Saldo registrado pelo MetaTrader 5, 2013 a 2016

ARIMA



ARIMA-GARCH Sharpe



Fonte: Relatório do testador de estratégias do MetaTrader 5.

Nota: Saldo em reais após cada negociação encerrada. O eixo horizontal é o número da negociação, e as escalas dos dois painéis são diferentes.

3.5 Teste principal, 2017 a 2024

O período de 2017 a 2024 é o teste principal, por ser o mais longo, e inclui a queda provocada pela pandemia em 2020. A Tabela 5 apresenta o resultado.

Tabela 5 – Resultado de 2017 a 2024

Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	+47,8%	37,9%	30,9%	56
ARIMA	+95,7%	40,5%	32,0%	244
ARIMA-GARCH Sharpe	+199,5%	27,2%	24,2%	238
ARIMA-GARCH Calmar	+42,9%	40,2%	16,3%	223
PETR4	+143,6%	64,2%	44,8%	–

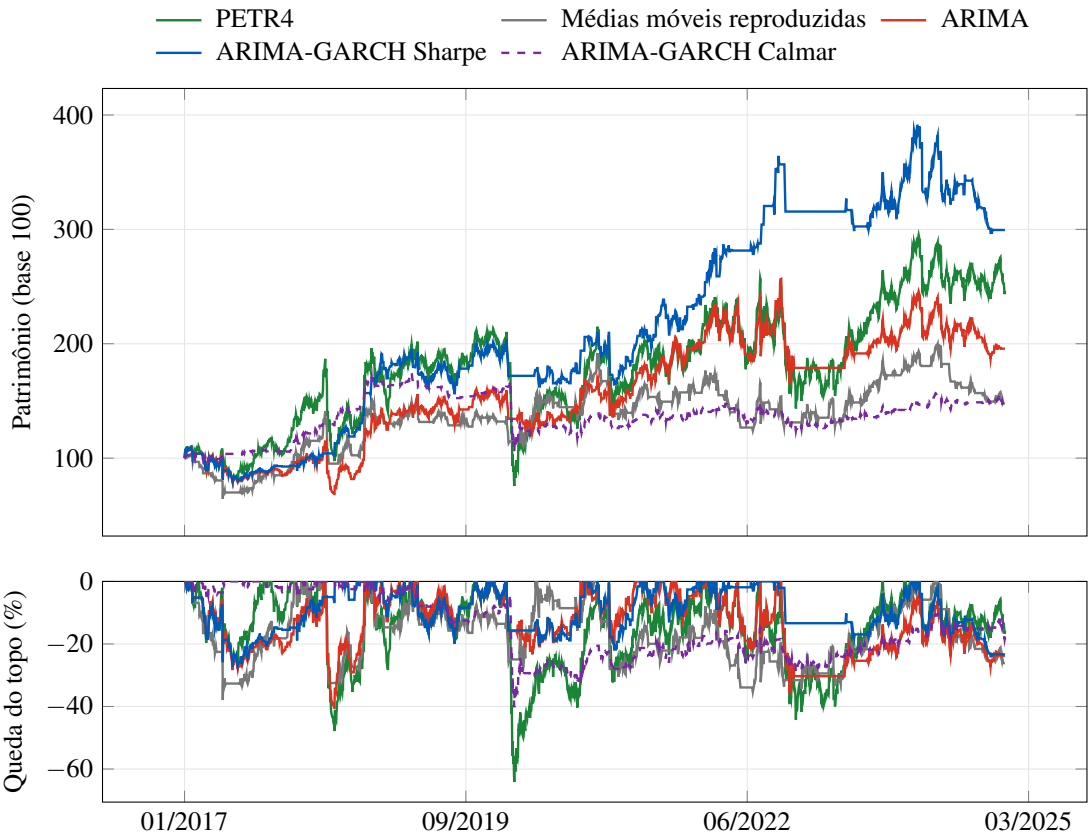
Fonte: Elaboração própria.

Nota: Resultado bruto.

O ARIMA-GARCH Sharpe teve o maior retorno do período, de 199,5%, e a menor queda máxima, de 27,2%. Foi o único robô a render mais que a própria ação, que subiu 143,6% e chegou a perder 64,2% no pior momento. O ARIMA-GARCH Calmar foi o que menos oscilou, mas a sua queda máxima, de 40,2%, ficou no mesmo nível da do ARIMA, de 40,5%, embora ele tivesse sido escolhido justamente por cair pouco na otimização. Ele é o único robô escolhido em que o veto não encerra a posição aberta. Nos dias de volatilidade alta, ele deixa de comprar, mas continua com o que já tinha comprado, e o ajuste do tamanho só vale para as novas compras.

Esse é também um exemplo de por que a escolha precisa ser testada em um período novo. O que funciona no período da otimização nem sempre se repete no seguinte.

Gráfico 7 – Patrimônio e queda acumulada, 2017 a 2024

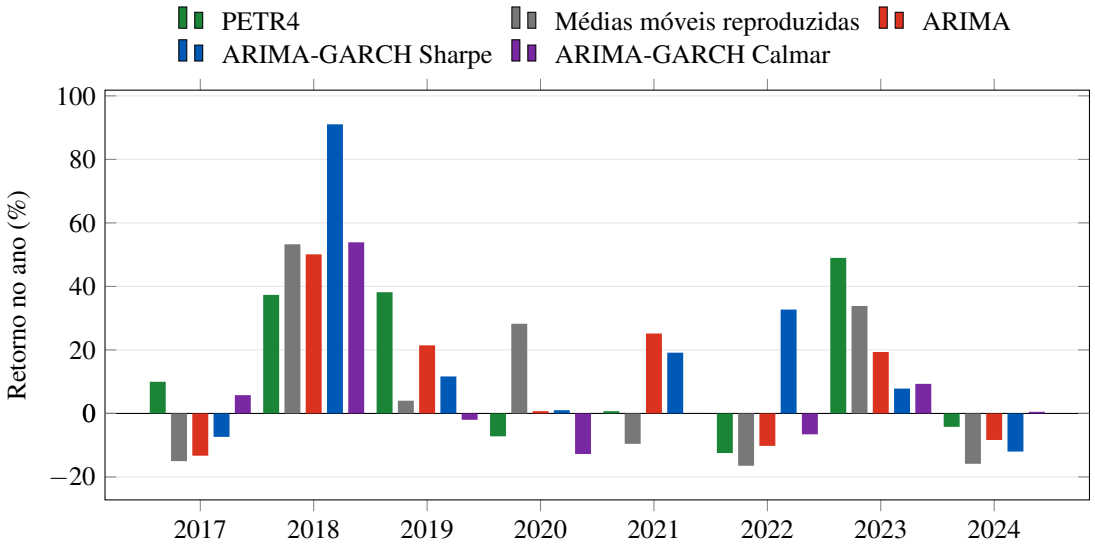


Fonte: Elaboração própria.

Nota: Resultado bruto, com o capital inicial igual a 100.

O Gráfico 7 mostra que a distância entre o ARIMA-GARCH Sharpe e os demais robôs se formou principalmente em dois anos. Pelo Gráfico 8, ele rendeu 91,0% em 2018 e 32,7% em 2022, quando os outros três robôs perderam dinheiro. Nos demais anos, nenhum robô se destacou de forma consistente. As médias móveis, por exemplo, foram as melhores em 2020 e 2023 e as piores em 2017, 2021, 2022 e 2024.

Gráfico 8 – Retorno por ano, 2017 a 2024



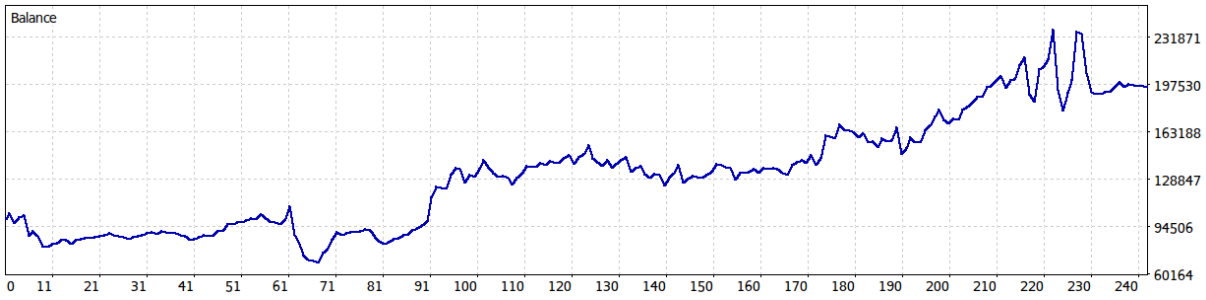
Fonte: Elaboração própria.

Nota: Resultado bruto.

No saldo registrado pelo MetaTrader 5, no Gráfico 9, a queda mais forte do ARIMA aparece por volta da negociação 67. Ela aconteceu em junho de 2018, quando a PETR4 perdeu 47,9% do valor em cerca de um mês, e levou o saldo do ARIMA a R$ 69 mil, o menor do teste. O ARIMA-GARCH atravessou esse trecho sem a mesma queda, já que o seu menor saldo, de R$ 81 mil, foi registrado logo no início do teste, em julho de 2017. Ao fim do período, o seu saldo era de R$ 299 mil, contra R$ 196 mil do ARIMA.

Gráfico 9 – Saldo registrado pelo MetaTrader 5, 2017 a 2024

ARIMA



ARIMA-GARCH Sharpe



Fonte: Relatório do testador de estratégias do MetaTrader 5.

Nota: Saldo em reais após cada negociação encerrada. O eixo horizontal é o número da negociação, e as escalas dos dois painéis são diferentes.

3.6 A crise da pandemia, 2020

A queda provocada pela pandemia, em 2020, permite observar os robôs em uma crise mais recente que a de 2008. Os números da Tabela 6 são um recorte do teste de 2017 a 2024, com as configurações escolhidas em 2014 a 2016, antes da pandemia.

Tabela 6 – Resultado em 2020, ano da pandemia

Robô	Retorno no ano	Queda máx. no ano
Médias móveis reproduzidas	+28,2%	19,1%
ARIMA	+0,7%	23,3%
ARIMA-GARCH Sharpe	+1,0%	20,3%
ARIMA-GARCH Calmar	−12,8%	37,7%
PETR4	−7,2%	64,2%

Fonte: Elaboração própria.

Nota: Resultado bruto. A queda máxima é medida dentro do ano, a partir do fechamento de 2019.

A PETR4 chegou a perder 64,2% do seu valor no pior momento do ano e terminou 2020 com queda de 7,2%, isto é, a recuperação foi quase tão rápida quanto a queda. Nesse cenário, diferentemente de 2008, as médias móveis tiveram o melhor resultado, com ganho de 28,2% e queda máxima de 19,1%. O ARIMA-GARCH Sharpe protegeu de forma parecida, com queda máxima de 20,3%, mas terminou o ano praticamente sem ganho. O ARIMA-GARCH Calmar, que mantém a posição aberta durante o veto, caiu 37,7%, ainda assim bem menos que

a mesma configuração sem o GARCH, que perdeu 49,2% no ano e chegou a cair 59,2%. O resultado mostra que o GARCH protegeu também nessa crise, mas que, em uma queda seguida de recuperação rápida, o cruzamento de médias se saiu tão bem quanto ele na proteção e melhor no retorno.

3.7 Período recente, 2025 a 2026

O último período vai de janeiro de 2025 a setembro de 2026, o mais recente disponível. A Tabela 7 apresenta o resultado.

Tabela 7 – Resultado de 2025 a 2026

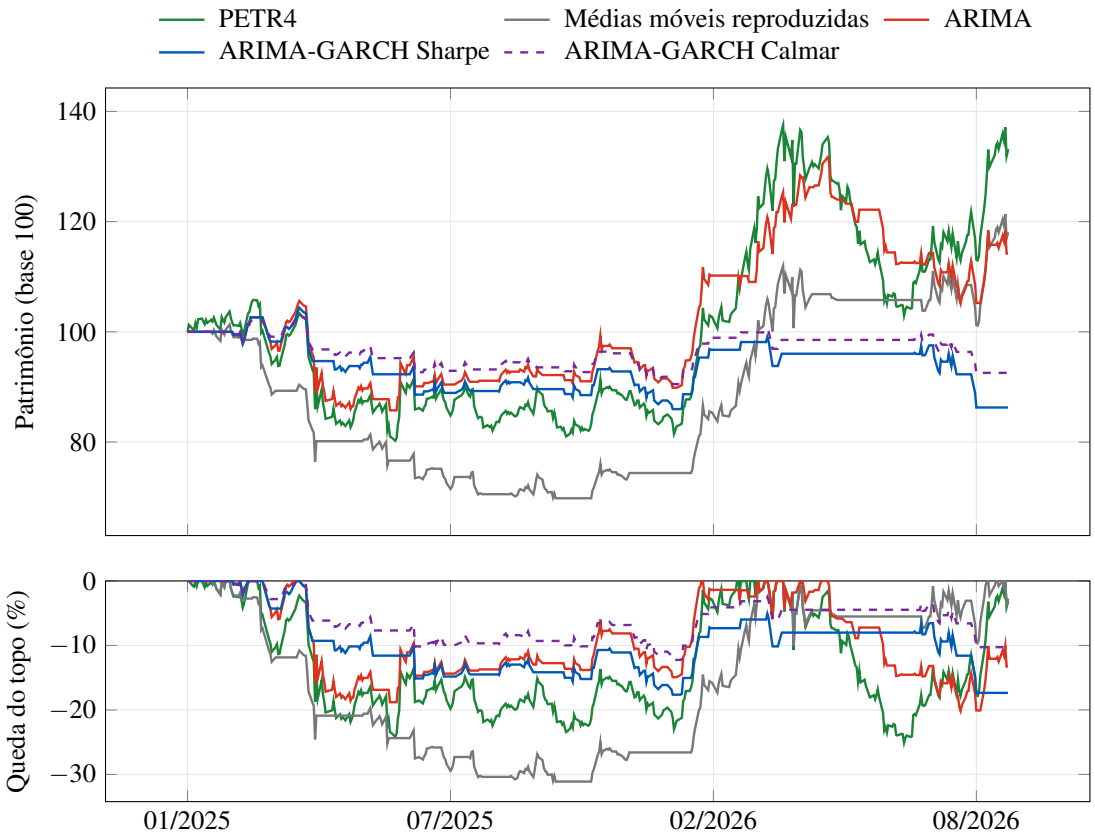
Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	+18,1%	31,1%	22,7%	12
ARIMA	+14,2%	20,1%	22,0%	46
ARIMA-GARCH Sharpe	−13,7%	17,6%	13,5%	37
ARIMA-GARCH Calmar	−7,4%	12,2%	9,2%	37
PETR4	+33,2%	25,1%	29,1%	–

Fonte: Elaboração própria.

Nota: Resultado bruto. O período termina em 18 de setembro de 2026.

As duas versões com GARCH voltaram a ser as que menos caíram e menos oscilaram, mas foram as únicas com perda. A PETR4 caiu 15,4% em 2025 e subiu 57,5% em 2026. Em 2025, o ARIMA-GARCH Sharpe perdeu 12,5%, mais que o ARIMA, que perdeu 8,5%, e em 2026, mais protegido, ele ficou de fora da alta e terminou o ano com perda de 1,5%, enquanto o ARIMA ganhou 24,8%. Neste período, portanto, a proteção custou mais do que evitou.

Gráfico 10 – Patrimônio e queda acumulada, 2025 a 2026

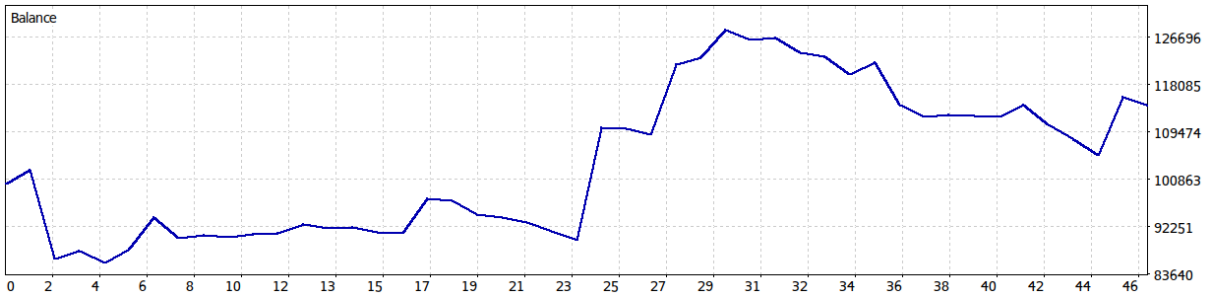


Fonte: Elaboração própria.

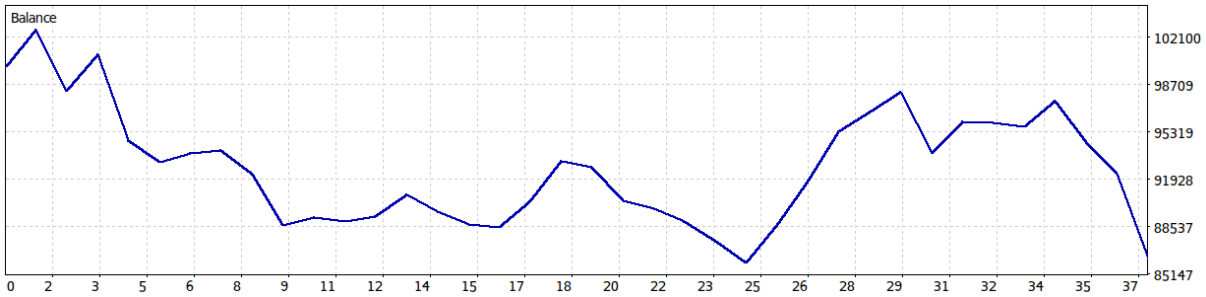
Nota: Resultado bruto, com o capital inicial igual a 100.

Gráfico 11 – Saldo registrado pelo MetaTrader 5, 2025 a 2026

ARIMA



ARIMA-GARCH Sharpe



Fonte: Relatório do testador de estratégias do MetaTrader 5.

Nota: Saldo em reais após cada negociação encerrada. O eixo horizontal é o número da negociação, e as escalas dos dois painéis são diferentes.

O Gráfico 10 mostra a evolução do patrimônio no período, e o Gráfico 11, o saldo registrado pelo MetaTrader 5. O saldo do ARIMA-GARCH desceu ao longo de 2025, chegou a R$ 86 mil em janeiro de 2026 e não se recuperou. O do ARIMA, depois de chegar a R$ 86 mil em junho de 2025, acompanhou a alta e alcançou R$ 128 mil em abril de 2026.

3.8 O efeito vem do GARCH?

As seções anteriores comparam robôs diferentes. Para saber se a diferença vem do GARCH, e não dos demais parâmetros, cada versão foi comparada com a mesma configuração com o GARCH desligado. Contando todas as versões de todos os períodos, inclusive as configurações fixas, são onze comparações, reunidas na Tabela 8.

Tabela 8 – Cada versão com e sem o GARCH

Período	ARIMA-GARCH	Retorno com / sem	Queda máx. com / sem	Volatilidade com / sem
2007 a 2011	Sharpe e Calmar	−8,4% / +7,2%	17,5% / 38,1%	10,5% / 28,2%
2013 a 2016	Sharpe	−13,8% / −9,7%	28,6% / 51,9%	14,1% / 35,1%
2013 a 2016	Calmar	−6,8% / −9,7%	15,5% / 51,9%	7,1% / 35,1%
2017 a 2024	Sharpe	+199,5% / +95,7%	27,2% / 40,5%	24,2% / 32,0%
2017 a 2024	Calmar	+42,9% / −50,1%	40,2% / 79,3%	16,3% / 31,4%
2025 a 2026	Sharpe	−13,7% / +14,2%	17,6% / 20,1%	13,5% / 22,0%
2025 a 2026	Calmar	−7,4% / +14,2%	12,2% / 20,1%	9,2% / 22,0%
2005 a 2026, fixa	Sharpe	+74,2% / +16,6%	36,4% / 82,9%	14,3% / 28,8%
2005 a 2026, fixa	Calmar	+33,5% / +16,6%	24,4% / 82,9%	7,6% / 28,8%
2017 a 2024, fixa	Sharpe	+19,9% / +4,6%	31,9% / 57,7%	17,0% / 32,6%
2017 a 2024, fixa	Calmar	+7,5% / +4,6%	18,4% / 57,7%	8,6% / 32,6%

Fonte: Elaboração própria.

Nota: Resultado bruto. Em cada linha, *com* é a versão escolhida e *sem* é a mesma configuração com o GARCH desligado. As duas versões fixas usam o mesmo ARIMA, de modo que a configuração sem GARCH é a mesma para as duas.

Em todas as onze comparações, a versão com GARCH teve volatilidade e queda máxima menores que as da mesma configuração sem ele. Se o GARCH não fizesse diferença, seria de esperar que a versão com ele ficasse à frente em cerca de metade das comparações, como no lançamento de uma moeda, e não em todas. No retorno, o resultado foi outro. A versão com GARCH rendeu mais em sete das onze comparações e menos nas outras quatro, entre elas as duas de 2025 e 2026.

O efeito sobre o risco se repetiu nas outras três ações, quando se olham todas as configurações da otimização, e não só as escolhidas. Para isso, elas foram separadas em dois grupos. No primeiro estão as que tiram capital do mercado quando a volatilidade sobe, seja porque ajustam o tamanho da posição, seja porque o veto encerra a posição aberta. Nesse grupo, considerando as quatro ações, o GARCH reduziu a queda máxima em 84% a 92% das comparações em 2007 a 2011 e em 91% a 98% em 2013 a 2016, conforme a ação. Em 2025 e 2026, um período mais calmo, o efeito foi menor, de 51% a 95%. No segundo grupo estão as que apenas impedem novas compras e mantêm a posição aberta. Elas não mostraram o mesmo efeito de forma consistente e reduziram a queda máxima em 31% a 68% das comparações, conforme a ação e o período.

Na comparação com as médias móveis, também no resultado bruto, a vantagem do GARCH apareceu no risco, e não no retorno. As versões com GARCH oscilaram menos que as médias móveis em todos os períodos, mas as médias móveis renderam mais que as duas versões em 2013 a 2016 e em 2025 e 2026.

3.9 Como o GARCH protege

O GARCH não informa a direção dos preços, mas poderia melhorar o acerto de forma indireta. Ao vetar as operações nos dias de maior volatilidade prevista, ele deixaria o ARIMA

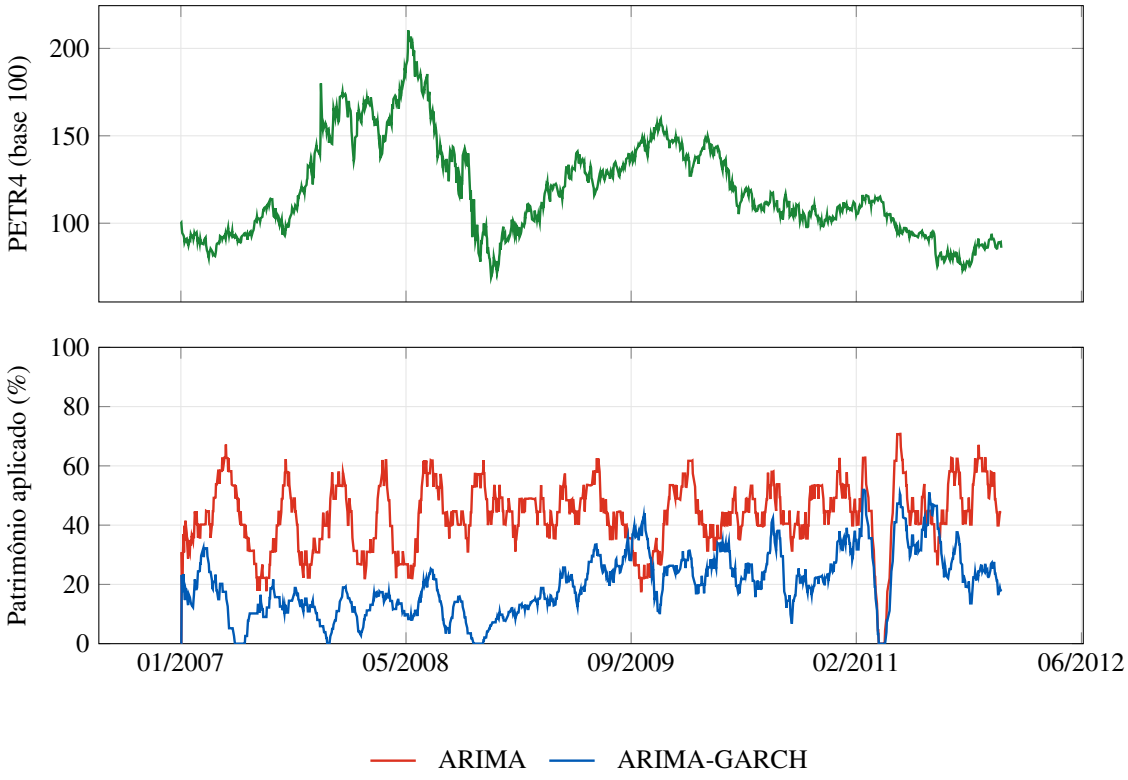
operar apenas quando o seu sinal fosse menos afetado pelo ruído. Os resultados mostram que isso não ocorreu. Em todos os períodos, a taxa de acerto dos robôs com ARIMA, com e sem o GARCH, ficou entre 41% e 59%, perto dos 50% que se teria escolhendo a direção ao acaso, e a diferença entre as versões com e sem o GARCH foi de no máximo quatro pontos percentuais.

O formato do ARIMA também não ficou fixo. Como o teste ADF é refeito a cada reavaliação das ordens, o d escolhido pelo robô variou ao longo dos testes. No acompanhamento diário do ARIMA-GARCH Sharpe entre julho de 2019 e junho de 2021, o teste indicou $d = 1$ em 412 dos 496 pregões, ou 83,1%, e $d = 0$ nos demais.

O que o GARCH mudou foi a quantidade de vezes em que o robô agiu. Em 2017 a 2024, o ARIMA-GARCH Sharpe vetou 657 dos 1.983 sinais do ARIMA e aplicou, em média, 43,9% do patrimônio na ação, contra 62,3% da mesma configuração sem o GARCH. A proteção vem, assim, de ficar menos tempo comprado e de ficar fora justamente nos dias de volatilidade prevista mais alta. É o que se espera de um modelo de volatilidade, que serve à gestão de risco (Araya; Aduda; Berhane, 2024), e não à previsão da direção.

O Gráfico 12 mostra esse comportamento na crise de 2008. Nesse período, o ARIMA-GARCH combina o filtro com o ajuste da posição, e o veto encerra a posição aberta. Ao longo de todo o período, o ARIMA-GARCH manteve aplicada na ação uma parte menor do patrimônio que o ARIMA. Em outubro de 2008, mês em que a ação caiu 32,8%, o ARIMA-GARCH ficou inteiramente fora do mercado, enquanto o ARIMA manteve, em média, 56,4% do patrimônio aplicado.

Gráfico 12 – Preço da PETR4 e patrimônio aplicado na ação, 2007 a 2011



Fonte: Elaboração própria.

Nota: O patrimônio aplicado é a média dos 21 pregões anteriores, cerca de um mês. O preço da PETR4 tem base 100 no início do período.

Um episódio de 2020 mostra o filtro em ação, no ARIMA-GARCH Sharpe de 2017 a 2024, que usa só o filtro. Na abertura de 3 de abril, durante a queda associada à pandemia, o ARIMA previa alta de 2,66% para o dia e, sozinho, teria comprado. A volatilidade prevista pelo GARCH para aquele dia era de 7,58%, cerca de três vezes o limiar vigente, de 2,54%, e a operação foi vetada. Naquele momento, a ação acumulava queda de 48,6% em relação ao fechamento de 2019.

3.10 Efeito dos custos, da Selic e dos proventos

As seções anteriores compararam os modelos pelo resultado bruto. Esta seção mostra como esse resultado muda quando são acrescentados, um de cada vez, os custos das ordens, a remuneração pela Selic do capital que fica fora do mercado e os proventos pagos pela ação. As Tabelas 9 a 12 apresentam o retorno em cada camada, um período por tabela. Na primeira coluna está o resultado bruto, e cada coluna seguinte acrescenta um fator ao resultado da anterior.

Tabela 9 – Retorno por camada, 2007 a 2011

Robô	Bruto	+ custos	+ Selic	+ proventos
Médias móveis reproduzidas	−31,6%	−32,8%	−11,6%	−5,9%
ARIMA	−12,7%	−27,1%	−2,1%	+3,2%
ARIMA-GARCH	−8,4%	−15,2%	+28,7%	+32,9%
PETR4	−14,0%	–	–	−1,2%

Fonte: Elaboração própria.

Nota: Cada coluna acrescenta um fator ao resultado da coluna anterior. A Selic rendeu 68,1% no período. Os proventos vêm de uma base que não é oficial.

Tabela 10 – Retorno por camada, 2013 a 2016

Robô	Bruto	+ custos	+ Selic	+ proventos
Médias móveis reproduzidas	+100,8%	+98,1%	+150,9%	+176,0%
ARIMA	−35,8%	−44,8%	−30,5%	−27,9%
ARIMA-GARCH Sharpe	−13,8%	−18,8%	+15,8%	+15,8%
ARIMA-GARCH Calmar	−6,8%	−9,5%	+34,0%	+34,0%
PETR4	−25,6%	–	–	−17,7%

Fonte: Elaboração própria.

Nota: Cada coluna acrescenta um fator ao resultado da coluna anterior. A Selic rendeu 53,9% no período. Os proventos vêm de uma base que não é oficial.

Tabela 11 – Retorno por camada, 2017 a 2024

Robô	Bruto	+ custos	+ Selic	+ proventos
Médias móveis reproduzidas	+47,8%	+43,2%	+90,4%	+396,1%
ARIMA	+95,7%	+70,5%	+114,6%	+331,1%
ARIMA-GARCH Sharpe	+199,5%	+161,8%	+273,8%	+353,4%
ARIMA-GARCH Calmar	+42,9%	+34,4%	+114,1%	+212,1%
PETR4	+143,6%	–	–	+726,5%

Fonte: Elaboração própria.

Nota: Cada coluna acrescenta um fator ao resultado da coluna anterior. A Selic rendeu 86,1% no período. Os proventos vêm de uma base que não é oficial.

Tabela 12 – Retorno por camada, 2025 a 2026

Robô	Bruto	+ custos	+ Selic	+ proventos
Médias móveis reproduzidas	+18,1%	+17,2%	+31,3%	+39,0%
ARIMA	+14,2%	+11,3%	+24,1%	+34,4%
ARIMA-GARCH Sharpe	−13,7%	−15,5%	−0,4%	+5,5%
ARIMA-GARCH Calmar	−7,4%	−8,8%	+9,6%	+13,9%
PETR4	+33,2%	–	–	+57,6%

Fonte: Elaboração própria.

Nota: Cada coluna acrescenta um fator ao resultado da coluna anterior. A Selic rendeu 25,7% no período. Os proventos vêm de uma base que não é oficial.

Os custos pesaram mais para quem negociou mais. Em 2007 a 2011, o ARIMA, com 320 negociações, passou de uma perda de 12,7% para uma de 27,1%, enquanto as médias móveis, com 31, quase não mudaram.

A Selic favoreceu quem ficou mais tempo fora do mercado, e por isso beneficiou sobretudo o ARIMA-GARCH. No mesmo período, ele passou de uma perda de 15,2% para um ganho de 28,7%, porque manteve, em média, só 20% do patrimônio aplicado, contra 43% do ARIMA e 48% das médias móveis. Mesmo assim, comparado com a própria Selic, o ARIMA-GARCH só rendeu mais no período de 2017 a 2024.

Os proventos favoreceram o contrário, quem ficou mais tempo comprado. Em 2017 a 2024, eles levaram as médias móveis de 90,4% para 396,1% e a PETR4 de 143,6% para 726,5%, acima de todos os robôs.

As camadas mudam o retorno de cada robô, e por isso a ordem entre eles depende de quais fatores se consideram. O risco, por outro lado, quase não muda. A ordem dos robôs na queda máxima é a mesma no resultado bruto e com os custos e a Selic, em todos os períodos, e a volatilidade praticamente não se altera. A conclusão sobre o risco, portanto, não depende dessas escolhas de medida.

3.11 Outras ações

Como complemento, o mesmo procedimento foi repetido em outras três ações, a VALE3, a USIM5 e a POMO4, nos períodos de 2007 a 2011, 2013 a 2016 e 2025 a 2026, com a otimização nos três anos anteriores a cada um. A Tabela 13 mostra o resultado bruto das configurações escolhidas. As médias móveis não foram executadas nessas ações. Como na PETR4, todas as configurações escolhidas usam o filtro, sozinho ou combinado com o ajuste da posição.

Tabela 13 – Retorno e queda máxima em outras ações

Ação	Período	ARIMA	ARIMA-GARCH Sharpe	ARIMA-GARCH Calmar	Ação
VALE3	2007 a 2011	+60,1% / 43,0%	−38,2% / 40,0%	−10,1% / 25,8%	+23,9% / 67,7%
	2013 a 2016	+34,2% / 34,3%	−27,5% / 32,0%	+2,1% / 9,6%	−40,3% / 79,9%
	2025 a 2026	+4,6% / 10,9%	+23,3% / 5,0%	−0,3% / 12,9%	+34,1% / 21,0%
USIM5	2007 a 2011	−28,7% / 67,0%	+36,4% / 19,1%	+3,3% / 6,1%	−42,7% / 79,1%
	2013 a 2016	−4,3% / 66,0%	−21,5% / 80,4%	−0,9% / 0,9%	−68,8% / 94,3%
	2025 a 2026	+9,3% / 25,6%	sem operações	sem operações	+29,2% / 48,1%
POMO4	2007 a 2011	+275,5% / 24,8%	+4,6% / 10,4%	+4,6% / 10,4%	+138,3% / 71,1%
	2013 a 2016	−21,0% / 40,8%	−67,6% / 70,3%	−21,0% / 26,9%	−58,0% / 77,8%
	2025 a 2026	−4,9% / 27,0%	−10,9% / 34,5%	−1,4% / 5,5%	−36,2% / 54,3%

Fonte: Elaboração própria.

Nota: Resultado bruto. Em cada célula, o retorno e a queda máxima. A ação representa a compra e manutenção, pela variação do preço.

O ARIMA-GARCH Calmar teve a menor queda máxima entre os robôs que operaram em sete dos nove casos. Nas duas exceções, no período de 2025 e 2026, o ARIMA-GARCH Sharpe caiu menos na VALE3, e na USIM5 nenhuma das versões com GARCH chegou a operar. O ARIMA-GARCH Sharpe foi menos regular. Ele caiu mais que o ARIMA em três casos, e nos três a configuração escolhida mantinha a posição aberta durante o veto, como já se havia

observado na PETR4. No retorno não houve padrão. Cada robô levou vantagem em casos diferentes, e o maior ganho da tabela foi do ARIMA, na POMO4 de 2007 a 2011.

CONSIDERAÇÕES FINAIS

Este trabalho investigou o efeito de acrescentar um modelo de volatilidade condicional a uma estratégia automatizada de negociação cuja previsão de direção permanece a mesma. A questão norteadora foi em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis.

Quanto ao risco, a resposta é clara. Em todos os períodos analisados, a versão do algoritmo com o GARCH oscilou menos e sofreu quedas menores que a mesma configuração com o GARCH desligado, nas onze comparações feitas, quando o acaso faria a versão com GARCH vencer em cerca de metade delas. O efeito se repetiu nas outras três ações estudadas, sobretudo nos períodos de turbulência. O ano de 2008 resume bem esse comportamento. Enquanto a PETR4 perdia quase metade do seu valor, o ARIMA-GARCH encerrou o ano com uma perda pequena, muito menor que a do ARIMA e a das médias móveis. A proteção veio de o robô ficar menos tempo comprado e de ficar fora justamente nos dias de maior volatilidade prevista, e não de prever melhor a direção dos preços.

Esse resultado responde à sugestão deixada por Almeida (2016). Ao discutir o prejuízo do seu robô no período que inclui a crise de 2008, o autor apontou a limitação das médias móveis em mercados de alta volatilidade e indicou os modelos de volatilidade como caminho para contorná-la. Nos testes deste trabalho, as médias móveis e o ARIMA sem o GARCH oscilaram de forma muito parecida, o que mostra que trocar o indicador de direção não basta para reduzir o risco. Com o GARCH, o algoritmo oscilou menos que as médias móveis em todos os períodos, inclusive nas condições originais do estudo de referência, e sofreu quedas menores em quase todos, com a maior diferença de queda máxima justamente no período de crise em que o robô de Almeida (2016) acumulou prejuízo. Na crise da pandemia, em 2020, a proteção se repetiu, mas as médias móveis protegeram de forma parecida e renderam mais, o que mostra que a vantagem do GARCH sobre elas depende do tipo de crise.

Quanto ao retorno, o efeito foi menos claro. Na maior parte dos testes, a versão com GARCH terminou com retorno maior que o da mesma configuração sem ele, em sete das onze comparações, mas, ao contrário do que ocorreu com o risco, a vantagem não apareceu em todas. Em relação às médias móveis, o ARIMA-GARCH ganhou em alguns períodos e perdeu em outros, sem vantagem consistente para nenhum dos dois. Em relação à taxa Selic, usada neste trabalho como referência de medida e não como meta, o ARIMA-GARCH, considerados os custos e a remuneração do caixa, só rendeu mais no período de 2017 a 2024. Esse resultado se explica pela função do modelo. O GARCH descreve o tamanho das oscilações, e não a direção dos preços, e por isso o seu efeito apareceu no risco, e não no lucro.

A primeira hipótese afirmava que a integração entre ARIMA e GARCH gera sinais mais eficazes que o ARIMA isolado, tanto em acerto direcional quanto em adequação ao risco. Ela foi parcialmente confirmada. A adequação ao risco foi confirmada pela volatilidade e pela queda

máxima menores que as da mesma configuração sem o GARCH, em todas as comparações. O acerto direcional, por outro lado, não melhorou nem piorou. Com e sem o GARCH, a diferença foi de no máximo quatro pontos percentuais, e a taxa de acerto permaneceu próxima do acaso. Esperava-se que, ao deixar de operar nos dias de maior volatilidade prevista, o algoritmo acertasse mais nas operações restantes, o que não ocorreu. O ganho veio de ficar menos tempo exposto nos dias de maior oscilação, e não de acertar mais.

A segunda hipótese afirmava que a combinação representa um avanço em relação às análises baseadas em médias móveis. Ela foi confirmada quanto ao risco. Todas as variantes com GARCH oscilaram menos que as médias móveis, e a queda máxima foi menor em quase todas. A exceção foi a variante que mantém a posição aberta durante o veto, no período de 2017 a 2024, a única escolhida em que o veto não encerra a posição. Isso indica que a proteção é mais consistente quando o GARCH, além de impedir novas compras, tira o capital do mercado nos dias de volatilidade alta. Quanto ao retorno, cada algoritmo levou vantagem em períodos diferentes, e não se pode afirmar avanço nesse sentido.

O objetivo geral, desenvolver em MQL5 um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar experimentalmente o efeito da inclusão do GARCH, foi alcançado. Os dois modelos foram implementados na própria linguagem da plataforma. A escolha das ordens do ARIMA foi automatizada pelo teste ADF e pelo critério de Akaike. A estratégia de Almeida (2016) foi reimplementada, e a reprodução dos seus testes confirmou o comportamento do algoritmo original, embora não os seus valores em reais, que dependem de informações que o estudo original não registra. Por fim, o protocolo com períodos de otimização e de teste separados foi definido antes da observação dos resultados e executado sobre dados oficiais, e os três algoritmos foram comparados quanto a risco e retorno.

Os resultados têm limitações. As diferenças de retorno não se repetiram de forma consistente entre os períodos. A configuração com melhor retorno em um período não tende a repetir o desempenho no seguinte, embora a proteção tenda a se manter, e os ganhos se concentram em poucos anos. A análise se restringe a quatro ativos de um único mercado, com um custo de execução único para todo o período, e com janelas de estimação de no máximo 240 pregões, limitadas pelo histórico que o testador disponibiliza, curtas para a estimação do GARCH. Os proventos entraram apenas como complemento da medida, a partir de uma base que não é oficial, e, quando incluídos, favorecem as estratégias que permanecem mais tempo compradas. Além disso, os experimentos foram realizados por simulação sobre dados históricos, com execução no preço de abertura e sem considerar a falta de liquidez ou a diferença entre o preço pedido e o executado, condições que só podem ser verificadas em operação real.

Como continuação, o resultado indica que o caminho mais promissor está no controle de risco, que foi onde o modelo mostrou efeito. Uma possibilidade é empregar variações assimétricas do GARCH, que reagem mais às quedas do que às altas, comportamento comum nas séries de ações e não capturado pela especificação simétrica utilizada. Outra é testar a janela expansiva, que acumula todo o histórico e que, no estudo de Xing *et al.* (2024), deu ao ARIMA

melhores resultados que a janela deslizante. Outra, ainda, é aplicar o mesmo protocolo a um conjunto maior de ativos e acompanhar o algoritmo em conta de demonstração, em tempo real, o que permitiria também avaliar as ordens de limite de perda e de realização de lucro que Almeida (2016) previu em seu algoritmo, mas não utilizou em seus testes.

No eixo da previsão, a próxima etapa é a que estava prevista no projeto original deste trabalho e foi deixada de lado para que a implementação do ARIMA e do GARCH pudesse ser concluída: substituir o ARIMA por uma rede neural recorrente do tipo LSTM, do inglês *Long Short-Term Memory*, capaz de representar relações não lineares, mantendo o GARCH como filtro de risco. A arquitetura do algoritmo, que separa a previsão da direção da avaliação do risco, permite essa troca sem alterar o restante. Os resultados deste trabalho, porém, recomendam cautela na expectativa, já que a taxa de acerto direcional do ARIMA ficou próxima do acaso e o ganho observado veio do controle de risco, e não da previsão.

REFERÊNCIAS

ALMEIDA, F. L. R. *Técnicas de previsão da bolsa com MetaTrader 5*. Monografia (Graduação em Tecnologia em Banco de Dados) – Faculdade de Tecnologia de Indaiatuba, Indaiatuba, 2016. No Repositório Institucional do Centro Paula Souza o trabalho está catalogado sob o título "Análise da ação PETR4 na Bolsa de Valores de São Paulo com MetaTrader 5". Disponível em: <https://ric.cps.sp.gov.br/handle/123456789/24287>. Acesso em: 20 fev. 2025.

ARAYA, H. T.; ADUDA, J.; BERHANE, T. A hybrid GARCH and deep learning method for volatility prediction. *Journal of Applied Mathematics*, Londres, Reino Unido, v. 2024, 2024. Article ID 6305525.

B3. *Séries históricas de cotações (COTAHIST): arquivos anuais de 2003 a 2026*. São Paulo, 2026. Disponível em: <https://bvmf.bmfbovespa.com.br/InstDados/SerHist/>. Acesso em: 21 set. 2026.

BANCO CENTRAL DO BRASIL. *Bolsas de valores*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/pre/composicao/bv.asp?frame=1>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Corretoras e distribuidoras*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/acessoinformacao/legado?url=https:%2F%2Fwww.bcb.gov.br%2Fpre%2Fcomposicao%2Fcorretoras_distribuidoras.asp>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Taxa Selic*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/estatisticas/detalhamentoGrafico/graficoshome/selic>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Sistema Gerenciador de Séries Temporais: série 11, taxa de juros Selic, % ao dia*. Brasília, DF, 2026. Disponível em: <https://api.bcb.gov.br/dados/serie/bcdata.sgs.11/dados>. Acesso em: 21 set. 2026.

BATISTA, C. B. *Desenvolvimento de robô para automação de investimentos na bolsa de valores utilizando indicadores técnicos*. Monografia (Graduação em Engenharia de Computação) – Pontifícia Universidade Católica de Goiás, Goiânia, 2024. Disponível em: <https://repositorio.pucgoias.edu.br/jspui/handle/123456789/8073>. Acesso em: 30 mar. 2025.

BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, Elsevier, Amsterdam, v. 31, n. 3, p. 307–327, 1986.

ENGLE, R. F. Autoregressive conditional heteroskedasticity with estimates of the variance of the United Kingdom inflation. *Econometrica*, The Econometric Society, New Jersey, EUA, v. 50, n. 4, p. 987–1008, 1982.

FERNANDES, A. *Fundamentos de análise técnica de ações*. 1. ed. Rio de Janeiro: Alexandre Fernandes, 2014.

GÓMEZ, V.; MARAVALL, A. *Automatic modeling methods for univariate series*. Madrid: Banco de España, 1998. (Documento de Trabajo, n. 9808). Disponível em: <https://www.bde.es/f/webbde/SES/Secciones/Publicaciones/PublicacionesSeriadas/DocumentosTrabajo/98/Fic/dt9808e.pdf>. Acesso em: 19 out. 2026.

HANNAN, E. J.; RISSANEN, J. Recursive estimation of mixed autoregressive-moving average order. *Biometrika*, v. 69, n. 1, p. 81–94, 1982.

HARVEY, C. R. et al. The impact of volatility targeting. *The Journal of Portfolio Management*, v. 45, n. 1, p. 14–33, 2018.

MÁXIMO, W. Bolsa cai 30%, e dólar sobe 16% em março com pandemia de coronavírus. *Agência Brasil*, Brasília, 31 mar. 2020. Disponível em: <https://agenciabrasil.ebc.com.br/economia/noticia/2020-03/bolsa-cai-30-e-dolar-sobe-16-em-marco-com-pandemia-de-coronavirus>. Acesso em: 05 out. 2026.

METAQUOTES LTD. *MetaTrader 5: plataforma de negociação para Forex, ações e futuros*. Limassol: MetaQuotes Ltd., 2024. Disponível em: <https://www.metatrader5.com/pt>. Acesso em: 01 mar. 2025.

METAQUOTES LTD. *Manual MQL5*. Limassol, 2026. Referência da linguagem MQL5. Documentação oficial da linguagem, sem data de publicação. Disponível em: <https://www.mql5.com/pt/docs>. Acesso em: 21 out. 2026.

METAQUOTES LTD. *Relatório de teste*. Limassol, 2026. Ajuda para o MetaTrader 5. Página da ajuda da plataforma, sem data de publicação. Disponível em: <https://www.metatrader5.com/pt/terminal/help/algotrading/testing_report>. Acesso em: 05 out. 2026.

SHARPE, W. F. The Sharpe ratio. *The Journal of Portfolio Management*, Nova Iorque, v. 21, n. 1, p. 49–58, 1994. Disponível em: <https://web.stanford.edu/~wfsharpe/art/sr/sr.htm>. Acesso em: 05 out. 2026.

THOMAZ, P. S. *Modelos ARMA-GARCH na modelagem da volatilidade de ações financeiras*. Dissertação (Mestrado em Modelagem Computacional) – Universidade Federal do Rio Grande, Rio Grande, 2019. Disponível em: <http://repositorio.furg.br/handle/1/10204>. Acesso em: 12 out. 2026.

WAZLAWICK, R. S. *Metodologia de pesquisa para ciência da computação*. 3. ed. Rio de Janeiro: LTC, 2021.

XING, Y. et al. *Predicting NVIDIA's next-day stock price: a comparative analysis of LSTM, MLP, ARIMA, and ARIMA-GARCH models*. 2024. ArXiv. Preprint. Disponível em: <https://arxiv.org/abs/2405.08284>. Acesso em: 09 abr. 2025.

YAHOO FINANCE. *PETR4.SA: histórico de dividendos e desdobramentos*. 2026. Disponível em: <https://finance.yahoo.com/quote/PETR4.SA/history/>. Acesso em: 21 set. 2026.

APÊNDICES

APÊNDICE A – Código do *Expert Advisor*

Este apêndice apresenta o código do *Expert Advisor* desenvolvido neste trabalho. As rotinas de estimação do ARIMA e do GARCH, de seleção das ordens e das formas de uso do GARCH estão em arquivos de inclusão próprios, chamados pelas diretivas `#include` do início do código.

```
#property copyright "TG - FATEC Indaiatuba (ADS)"
#property version   "3.00"
#property tester_file "selic_diaria.csv"
#property tester_file "proventos_PETR4.csv"
#property tester_file "proventos_VALE3.csv"
#property tester_file "proventos_USIM5.csv"
#property tester_file "proventos_POMO4.csv"

#include "..\Include\Arima.mqh"
#include "..\Include\Garch.mqh"
#include "..\Include\SelecaoModelo.mqh"
#include "..\Include\Estrategia.mqh"
#include "..\Include\Negociacao.mqh"

enum ENUM_TRANSFORMACAO
  {
   TRANSF_LOG_PRECO = 0,
   TRANSF_PRECO = 1
  };

enum ENUM_MODO_VOLUME
  {
   VOLUME_FIXO = 0,
   VOLUME_CAPITAL = 1
  };

enum ENUM_MODO_ORDENS
  {
   ORDENS_AUTOMATICO = 0,
   ORDENS_MANUAL = 1
  };

input group "=== Modelo ==="
input bool               UsarGARCH            = true;
input ENUM_TRANSFORMACAO Transformacao        = TRANSF_LOG_PRECO;
input ENUM_MODO_ORDENS   ModoOrdens           = ORDENS_AUTOMATICO;

input group "=== Ordens manuais ==="
input int                ARIMA_p              = 1;
input int                ARIMA_d              = 1;
input int                ARIMA_q              = 1;

input group "=== Ordens automaticas ==="
input int                Max_p                = 4;
input int                Max_q                = 4;
input int                Max_d                = 2;
input int                Janela_Selecao       = 240;
input int                Barras_Entre_Reselecao = 21;
input bool               IncluirConstante     = false;

input group "=== Estimacao a cada barra ==="
input int                Janela_Estimacao     = 120;
input int                GARCH_p              = 1;
input int                GARCH_q              = 1;
```

```
55 input int                Iteracoes_GARCH      = 300;
56
57 input group "=== Estrategia de uso do GARCH ==="
58 input ENUM_ESTRATEGIA_GARCH Estrategia        = FILTRO_VOLATILIDADE;
59 input ENUM_MODO_LIMIAR   ModoLimiar           = LIMIAR_PERCENTIL;
60 input double             Limiar_Absoluto      = 0.020;
61 input double             Limiar_Percentil     = 50.0;
62 input double             Vol_Alvo             = 0.015;
63 input double             K_Confianca          = 0.50;
64 input double             Limiar_Sinal         = 0.0;
65
66 input group "=== Negociacao ==="
67 input ENUM_MODO_VOLUME   ModoVolume           = VOLUME_CAPITAL;
68 input double             Fracao_Capital       = 0.95;
69 input double             Volume_Base          = 100;
70 input double             Frac_Volume_Min      = 0.25;
71 input double             Frac_Volume_Max      = 2.00;
72 input int                StopLoss_Points      = 0;
73 input int                TakeProfit_Points    = 0;
74 input bool               PermitirReversao     = true;
75 input bool               SomenteCompra        = true;
76 input bool               ZerarNoVeto          = false;
77
78 input group "=== Sistema ==="
79 input ulong              MagicNumber          = 20260803;
80 input int                Slippage             = 10;
81
82 CArima      g_arima;
83 CGarch      g_garch;
84 CNegociacao g_negociacao;
85
86 int      g_ordem_p = 1, g_ordem_d = 1, g_ordem_q = 1;
87 bool     g_ordens_definidas = false;
88 int      g_barras_desde_selecao = 0;
89 datetime g_ultima_barra = 0;
90
91 int OnInit()
92   {
93    if(Janela_Estimacao < 80 || Frac_Volume_Min <= 0.0 || Frac_Volume_Max <
        Frac_Volume_Min ||
94       (ModoVolume == VOLUME_CAPITAL && (Fracao_Capital <= 0.0 || Fracao_Capital > 1.0))
           ||
95       (ModoLimiar == LIMIAR_PERCENTIL && (Limiar_Percentil <= 0.0 || Limiar_Percentil >=
           100.0)))
96      {
97       Print("Parametros inconsistentes: Janela_Estimacao >= 80, fracoes de volume e
           percentil entre 0 e 100");
98       return(INIT_PARAMETERS_INCORRECT);
99      }
100
101   g_negociacao.Configurar(_Symbol, MagicNumber, Slippage);
102
103   if(ModoOrdens == ORDENS_MANUAL)
104     {
105      g_ordem_p = MathMax(0, ARIMA_p);
106      g_ordem_d = MathMax(0, MathMin(2, ARIMA_d));
107      g_ordem_q = MathMax(0, ARIMA_q);
108      g_ordens_definidas = true;
109     }
110   else
111      SelecionarOrdens();
112
113   g_arima.Definir(g_ordem_p, g_ordem_d, g_ordem_q, IncluirConstante);
```

```
114     g_garch.Definir(GARCH_p, GARCH_q);
115     g_garch.DefinirOtimizador(Iteracoes_GARCH);
116
117     return(INIT_SUCCEEDED);
118    }
119
120  void OnTick()
121    {
122     datetime barra = (datetime)SeriesInfoInteger(_Symbol, _Period, SERIES_LASTBAR_DATE);
123     if(barra == g_ultima_barra)
124        return;
125     g_ultima_barra = barra;
126
127     if(ModoOrdens == ORDENS_AUTOMATICO)
128        ReselecionarOrdensSeVencidas();
129     if(!g_ordens_definidas)
130        return;
131
132     double serie[];
133     if(!CarregarSerie(Janela_Estimacao, serie))
134        return;
135
136     if(!g_arima.Ajustar(serie))
137        return;
138
139     double previsao = PrevisaoDoRetorno(serie);
140     if(!MathIsValidNumber(previsao))
141        return;
142
143     double volatilidade = 0.0;
144     double limiar = Limiar_Absoluto;
145     if(UsarGARCH && !EstimarVolatilidade(volatilidade, limiar))
146        return;
147
148     DecisaoOperacao decisao;
149     DecidirOperacao(previsao, volatilidade, UsarGARCH, Estrategia, limiar, Vol_Alvo,
          K_Confianca,
150                     Volume_Base, Frac_Volume_Min, Frac_Volume_Max, Limiar_Sinal, decisao);
151
152     if(decisao.sinal != 0)
153        Executar(decisao);
154     else if(decisao.vetada_pelo_garch && ZerarNoVeto)
155        FecharPosicaoAberta();
156    }
157
158  bool CarregarSerie(const int quantidade, double &serie[])
159    {
160     double fechamento[];
161     int copiados = CopyClose(_Symbol, _Period, 1, quantidade, fechamento);
162     if(copiados < quantidade)
163        return(false);
164
165     ArrayResize(serie, copiados);
166     for(int i = 0; i < copiados; i++)
167       {
168        if(Transformacao == TRANSF_PRECO)
169           serie[i] = fechamento[i];
170        else if(fechamento[i] > 0.0)
171           serie[i] = MathLog(fechamento[i]);
172        else
173           return(false);
174       }
175     return(true);
```

```
176   }
177
178 bool SelecionarOrdens()
179   {
180    double serie[];
181    int janela = MathMax(Janela_Selecao, Janela_Estimacao);
182    if(!CarregarSerie(janela, serie))
183       return(false);
184
185    ResultadoSelecao selecao;
186    string relatorio = "";
187    bool selecionou = SelecionarModelo(serie, Max_d, Max_p, Max_q, IncluirConstante,
           ADF_CONSTANTE, selecao, relatorio);
188    if(!selecionou)
189       return(false);
190
191    g_ordem_p = selecao.p;
192    g_ordem_d = selecao.d;
193    g_ordem_q = selecao.q;
194    g_ordens_definidas = true;
195    g_barras_desde_selecao = 0;
196    return(true);
197   }
198
199 void ReselecionarOrdensSeVencidas()
200   {
201    bool vencidas = !g_ordens_definidas ||
202                    (Barras_Entre_Reselecao > 0 && g_barras_desde_selecao >=
                        Barras_Entre_Reselecao);
203    if(vencidas && SelecionarOrdens())
204       g_arima.Definir(g_ordem_p, g_ordem_d, g_ordem_q, IncluirConstante);
205    g_barras_desde_selecao++;
206   }
207
208 double PrevisaoDoRetorno(const double &serie[])
209   {
210    if(g_arima.D() == 1)
211       return(g_arima.PreverDiferenciado());
212    return(g_arima.PreverNivel() - serie[ArraySize(serie) - 1]);
213   }
214
215 bool EstimarVolatilidade(double &volatilidade, double &limiar)
216   {
217    double residuos[];
218    if(!g_arima.ObterResiduos(residuos))
219       return(false);
220    if(!g_garch.Ajustar(residuos))
221       return(false);
222
223    volatilidade = g_garch.VolatilidadeProximoPeriodo();
224
225    if(ModoLimiar == LIMIAR_PERCENTIL)
226      {
227       double historico[];
228       limiar = g_garch.ObterSerieVolatilidade(historico) ? Percentil(historico,
              Limiar_Percentil) : Limiar_Absoluto;
229      }
230    return(true);
231   }
232
233 void Executar(const DecisaoOperacao &decisao)
234   {
235    MqlTick tick;
```

```
236    if(!SymbolInfoTick(_Symbol, tick) || tick.ask <= 0.0 || tick.bid <= 0.0)
237       return;
238
239    ENUM_POSITION_TYPE posicao = g_negociacao.PosicaoAtual();
240    if(decisao.sinal < 0 && SomenteCompra)
241      {
242       if(posicao == POSITION_TYPE_BUY)
243          g_negociacao.Fechar(POSITION_TYPE_BUY);
244       return;
245      }
246
247    bool compra = (decisao.sinal > 0);
248    double preco = compra ? tick.ask : tick.bid;
249    double volume = g_negociacao.AjustarVolume(VolumeDesejado(decisao.volume, preco));
250    if(volume <= 0.0)
251       return;
252
253    ENUM_POSITION_TYPE mesma   = compra ? POSITION_TYPE_BUY : POSITION_TYPE_SELL;
254    ENUM_POSITION_TYPE oposta  = compra ? POSITION_TYPE_SELL : POSITION_TYPE_BUY;
255    if(posicao == oposta)
256      {
257       if(!PermitirReversao || !g_negociacao.Fechar(oposta))
258          return;
259       posicao = g_negociacao.PosicaoAtual();
260      }
261    if(posicao == mesma)
262       return;
263
264    double ponto = SymbolInfoDouble(_Symbol, SYMBOL_POINT);
265    int casas = (int)SymbolInfoInteger(_Symbol, SYMBOL_DIGITS);
266    double stop_loss = 0.0, take_profit = 0.0;
267    if(compra)
268      {
269       if(StopLoss_Points > 0)   stop_loss   = NormalizeDouble(preco - StopLoss_Points *
              ponto, casas);
270       if(TakeProfit_Points > 0) take_profit = NormalizeDouble(preco + TakeProfit_Points *
              ponto, casas);
271       g_negociacao.Comprar(volume, preco, stop_loss, take_profit, "ARIMA-GARCH BUY");
272      }
273    else
274      {
275       if(StopLoss_Points > 0)   stop_loss   = NormalizeDouble(preco + StopLoss_Points *
              ponto, casas);
276       if(TakeProfit_Points > 0) take_profit = NormalizeDouble(preco - TakeProfit_Points *
              ponto, casas);
277       g_negociacao.Vender(volume, preco, stop_loss, take_profit, "ARIMA-GARCH SELL");
278      }
279   }
280
281 void FecharPosicaoAberta()
282   {
283    ENUM_POSITION_TYPE posicao = g_negociacao.PosicaoAtual();
284    if(posicao == POSITION_TYPE_BUY || posicao == POSITION_TYPE_SELL)
285       g_negociacao.Fechar(posicao);
286   }
287
288 double VolumeDesejado(const double volume_decisao, const double preco)
289   {
290    if(ModoVolume == VOLUME_FIXO || preco <= 0.0)
291       return(volume_decisao);
292
293    double fator = (Volume_Base > 0.0) ? volume_decisao / Volume_Base : 1.0;
294    return(VolumePorCapital(_Symbol, Fracao_Capital * fator, preco));
```

```
295     }
```