CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA
FACULDADE DE TECNOLOGIA DE INDAIATUBA
DR. ARCHIMEDES LAMOGLIA
CURSO DE TECNOLOGIA
EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Previsão e análise de tendências no mercado de ativos: desenvolvimento de ferramenta algorítmica com modelos estatísticos no MetaTrader 5

Indaiatuba
2026

CENTRO ESTADUAL DE EDUCAÇÃO TECNOLÓGICA PAULA SOUZA

FACULDADE DE TECNOLOGIA DE INDAIATUBA

DR. ARCHIMEDES LAMOGLIA

CURSO DE TECNOLOGIA

EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

BRUNO ROCHA PEREIRA E GIOVANNI SILVA LOOSE

Previsão e análise de tendências no mercado de ativos: desenvolvimento de ferramenta algorítmica com modelos estatísticos no MetaTrader 5

Trabalho de graduação apresentado por Bruno Rocha Pereira e Giovanni Silva Loose como pré-requisito para a conclusão do Curso Superior de Tecnologia em Análise e Desenvolvimento de Sistemas, da Faculdade de Tecnologia de Indaiatuba, elaborado sob a orientação da Profa. Simone Mendes da Silva.

Indaiatuba

2026

RESUMO

Este trabalho retoma um estudo desenvolvido na Faculdade de Tecnologia de Indaiatuba em 2016, no qual um robô de negociação para a plataforma MetaTrader 5, guiado pelo cruzamento de médias móveis, obteve bons resultados em períodos de mercado estável, mas acumulou prejuízo no período que inclui a crise financeira de 2008. Ao final daquele estudo, o autor sugeriu que modelos capazes de medir a volatilidade poderiam ajudar a contornar essa limitação. Partindo dessa sugestão, desenvolveu-se um novo robô que reúne dois modelos estatísticos com papéis distintos. O primeiro, chamado ARIMA, procura antecipar a direção dos preços. O segundo, chamado GARCH, estima o quanto o mercado deve oscilar e decide se vale a pena operar. Os dois modelos foram programados na própria linguagem da plataforma, conferidos em dados com resposta conhecida e testados sobre o histórico oficial da bolsa brasileira, em períodos de crise e de calma, sempre em comparação com a estratégia original e com uma versão do robô sem o controle de volatilidade. Os resultados mostram que esse controle tornou o robô mais seguro. Em todos os períodos analisados, ele oscilou menos que a versão sem o controle e que a estratégia original, e as perdas nos piores momentos foram menores que as da versão sem o controle. Em boa parte dos períodos, o ganho final também foi maior. A capacidade de acertar a direção do mercado, porém, continuou próxima do acaso, e as diferenças de ganho em relação à estratégia original variaram conforme o período, dentro da margem que o próprio acaso também explicaria. Conclui-se que o modelo de volatilidade funciona como um instrumento de proteção, especialmente útil nos períodos de crise, e não como uma forma de prever melhor o mercado.

Palavras-chave: ARIMA-GARCH; negociação algorítmica; MetaTrader 5.

ABSTRACT

This work revisits a study carried out at the Faculdade de Tecnologia de Indaiatuba in 2016, in which a trading robot for the MetaTrader 5 platform, guided by moving average crossovers, performed well in stable market periods but accumulated losses over the period that includes the 2008 financial crisis. At the end of that study, the author suggested that models able to measure volatility could help overcome this limitation. Building on that suggestion, a new robot was developed that brings together two statistical models with distinct roles. The first, called ARIMA, tries to anticipate the direction of prices. The second, called GARCH, estimates how much the market is likely to fluctuate and decides whether it is worth trading. Both models were programmed in the platform's own language, checked on data with known answers and tested on the official history of the Brazilian stock exchange, in periods of crisis and of calm, always in comparison with the original strategy and with a version of the robot without the volatility control. The results show that this control made the robot safer. In every period analysed, it fluctuated less than both the version without the control and the original strategy, and its losses in the worst moments were smaller than those of the version without the control. In many periods the final gain was also larger. The ability to predict market direction, however, remained close to chance, and the differences in gain relative to the original strategy varied from period to period, within the margin that chance alone would also explain. The conclusion is that the volatility model works as a protective instrument, especially useful in times of crisis, and not as a way of predicting the market better.

Keywords: ARIMA-GARCH; algorithmic trading; MetaTrader 5.

LISTA DE ILUSTRAÇÕES

Figura 1 – Cruzamento de médias móveis 13
Figura 2 – Interface do MetaTrader 5 14
Figura 3 – Ciclo de funcionamento de um *Expert Advisor* 14
Figura 4 – Etapas de aplicação do modelo ARIMA 16
Figura 5 – Retroalimentação da variância no modelo GARCH 18
Quadro 1 – Métricas de avaliação usadas no trabalho 19
Quadro 2 – Características dos estudos relacionados 21
Quadro 3 – Períodos de otimização e de teste 27
Gráfico 1 – Retorno por ano, 2007 a 2011 32
Gráfico 2 – Evolução do patrimônio e da queda acumulada, 2007 a 2011 32
Gráfico 3 – Volatilidade por período de teste 35

LISTA DE TABELAS

Tabela 1 – Recuperação de parâmetros em séries sintéticas 29
Tabela 2 – Reprodução dos testes de Almeida (2016) 30
Tabela 3 – Risco nas condições originais, 2013 a 2016 30
Tabela 4 – Resultado durante a crise, 2007 a 2011 31
Tabela 5 – Resultado fora da crise, 2013 a 2016 33
Tabela 6 – Resultado no período recente 34
Tabela 7 – Resultado em 2020, ano da pandemia 34
Tabela 8 – Redução da volatilidade com o GARCH 37
Tabela 9 – Efeito do GARCH sobre o risco nas quatro ações 37
Tabela 10 – Risco das configurações fixas 38

LISTA DE SIGLAS

ADF	*Augmented Dickey-Fuller*
AIC	*Akaike Information Criterion*
AR	Autorregressivo
ARCH	*Autoregressive Conditional Heteroskedasticity*
ARIMA	*Autoregressive Integrated Moving Average*
ARMA	*Autoregressive Moving Average*
B3	Brasil, Bolsa, Balcão
COTAHIST	Arquivo de Cotações Históricas da B3
EA	*Expert Advisor*
EGARCH	*Exponential* GARCH
FATEC	Faculdade de Tecnologia
GARCH	*Generalized Autoregressive Conditional Heteroskedasticity*
LSTM	*Long Short-Term Memory*
MQL5	*MetaQuotes Language* 5
PETR4	Código de negociação das ações preferenciais da Petrobras
SARIMA	*Seasonal Autoregressive Integrated Moving Average*
Selic	Sistema Especial de Liquidação e de Custódia
TGARCH	*Threshold* GARCH

SUMÁRIO

INTRODUÇÃO 9
CAPÍTULO I 11
1 Fundamentação teórica 11
1.1 Mercado de ações 11
1.2 Análise técnica 11
1.2.1 Médias móveis 12
1.3 MetaTrader 5 13
1.4 Modelos estatísticos de séries temporais 15
1.4.1 ARIMA 15
1.4.2 GARCH 17
1.4.3 Integração entre ARIMA e GARCH 18
1.5 Métricas de avaliação 19
1.6 Trabalhos relacionados 20
CAPÍTULO II 22
2 Percurso metodológico 22
2.1 Caracterização da pesquisa 22
2.1.1 Quanto aos objetivos 22
2.1.2 Quanto ao delineamento 22
2.2 Caracterização do lugar e da amostra de pesquisa 22
2.3 Procedimentos para coleta e análise de dados 23
2.3.1 Técnicas para coleta de dados 23
2.3.2 Natureza da análise de dados 24
2.4 Implementação dos modelos 24
2.5 Validação das implementações 26
2.6 Plano experimental 27
2.7 Obstáculos encontrados 28
CAPÍTULO III 29
3 Análise e discussão dos dados 29
3.1 Validação dos modelos 29
3.2 Reprodução do estudo de referência 30
3.3 Comportamento durante a crise, 2007 a 2011 31
3.4 Comportamento fora da crise, 2013 a 2016 33
3.5 Período recente, 2017 a 2024 e 2025 a 2026 33
3.6 A crise da pandemia, 2020 34
3.7 O efeito vem do GARCH? 35
3.8 Como o GARCH protege 36
3.9 Verificação estatística e testes complementares 36

CONSIDERAÇÕES FINAIS 39
REFERÊNCIAS..... 42
APÊNDICE A – Código do *Expert Advisor* 45

INTRODUÇÃO

Este trabalho dá continuidade ao estudo de Almeida (2016), desenvolvido nesta mesma instituição. O autor programou em MQL5, para a plataforma MetaTrader 5, um robô de negociação para a PETR4, chamado na plataforma de *Expert Advisor*, isto é, um programa que compra e vende o ativo automaticamente segundo regras definidas previamente. A regra escolhida foi o cruzamento de duas médias móveis do preço: quando a média de curto prazo cruza a de longo prazo, o robô interpreta o movimento como início de uma tendência e abre a posição. Avaliado sobre dados históricos, o robô obteve lucro entre 2013 e 2016, mas prejuízo entre 2007 e 2011, período que inclui a crise financeira de 2008. Ao discutir esse resultado, o próprio autor alertou para as limitações da técnica em mercados de alta volatilidade e indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa.

A dificuldade apontada por ele continua atual, porque as crises voltam a acontecer, e é nelas que as maiores perdas se concentram. Em março de 2020, no início da pandemia de covid-19, o Ibovespa, principal índice de ações da bolsa brasileira, caiu 29,9% em um único mês (Máximo, 2020). A própria PETR4 perdeu 48,6% do seu valor entre o fim de 2019 e o início de abril de 2020, segundo as cotações oficiais da bolsa (B3, 2026). Uma estratégia baseada apenas no cruzamento de médias responde a uma única pergunta, a de para que lado o preço parece estar indo, e nada diz sobre o quanto ele pode oscilar no caminho. Por isso, ela entra no mercado com a mesma convicção em um dia calmo e em um dia de forte turbulência.

Os modelos estatísticos de séries temporais permitem separar essas duas perguntas. O modelo ARIMA estima a direção esperada do preço a partir do comportamento passado da própria série, de forma parecida com uma média móvel, mas com pesos ajustados aos dados. O modelo GARCH estima a volatilidade esperada para o período seguinte. Reunidos em um mesmo algoritmo, o primeiro indicaria o lado da operação e o segundo poderia atuar como um filtro de risco, evitando operar quando a oscilação esperada fosse alta. É essa a proposta que este trabalho investiga, retomando a sugestão de Almeida (2016) dez anos depois, sobre o mesmo ativo e na mesma plataforma.

Resta saber, porém, o que efetivamente se ganha ao acrescentar essa camada de modelagem. Acrescentar um modelo de volatilidade torna o algoritmo mais complexo, exige a estimação de parâmetros adicionais a cada operação e reduz o número de negócios realizados, e nada garante, de antemão, que o resultado compense esse custo. Coloca-se, assim, a questão norteadora deste trabalho: em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis?

Duas hipóteses foram formuladas antes dos experimentos. A primeira é a de que a integração entre a previsão de séries temporais pelo ARIMA e a modelagem de volatilidade condicional pelo GARCH gera sinais de negociação mais eficazes, tanto em acerto direcional quanto em adequação ao risco, do que o emprego isolado do ARIMA. A ideia de combinar

técnicas com funções distintas para obter resultados superiores encontra respaldo em trabalhos como o de Batista (2024), que integrou indicadores técnicos em um mesmo robô de negociação. A segunda é a de que essa combinação representa um avanço em relação às análises baseadas em médias móveis. Ambas são confrontadas com os resultados nas considerações finais.

O objetivo geral foi desenvolver, em MQL5, um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar o efeito do GARCH sobre o desempenho e o risco das operações, em comparação com o ARIMA isolado e com a estratégia de Almeida (2016). Os objetivos específicos foram implementar e validar os modelos ARIMA e GARCH na própria linguagem da plataforma, automatizar a escolha das ordens do ARIMA, reproduzir a estratégia de médias móveis de Almeida (2016) e comparar os três algoritmos quanto a retorno e risco em diferentes períodos do mercado, incluindo períodos de crise.

A pesquisa se justifica, em primeiro lugar, por retomar uma recomendação deixada em aberto em um estudo da própria instituição. Justifica-se, também, por ter sido conduzida no mercado brasileiro, com o histórico oficial da B3 e atravessando as crises que atingiram a bolsa do país. Há, ainda, uma contribuição técnica. Como a biblioteca padrão da linguagem MQL5 não traz modelos de séries temporais, os estimadores foram construídos e validados para este trabalho, e o controle de risco feito pelo GARCH, separado da previsão de direção, pode ser reaproveitado em outras estratégias para torná-las mais protetivas.

Quanto à natureza, a pesquisa é empírica, por investigar fenômenos observáveis por meio da experiência e da observação (Wazlawick, 2014), e aplicada, por voltar esse conhecimento a um problema concreto de decisão. Quanto aos objetivos, é explicativa, quanto ao delineamento, é quase experimental, e a análise dos dados é quantitativa. Os algoritmos foram testados por simulação no MetaTrader 5, sobre o histórico oficial de preços da B3, conforme detalhado no Capítulo II.

O trabalho está organizado em três capítulos, seguidos das considerações finais. O Capítulo I apresenta a fundamentação teórica, que parte do mercado de ações e da plataforma MetaTrader 5, passa pela análise técnica e pelas médias móveis, chega aos modelos ARIMA e GARCH e às medidas de desempenho e risco, e encerra-se com os trabalhos relacionados. O Capítulo II descreve o percurso metodológico, isto é, a caracterização da pesquisa, a amostra, a coleta dos dados, a implementação e a validação dos modelos, o plano experimental e os obstáculos encontrados. O Capítulo III apresenta a análise e a discussão dos dados. As considerações finais respondem à questão norteadora, retomam as hipóteses e avaliam o cumprimento dos objetivos.

CAPÍTULO I

1 Fundamentação teórica

Este capítulo reúne os conceitos sobre os quais o trabalho se apoia. Parte do ambiente em que as operações acontecem, isto é, a bolsa de valores e a plataforma de negociação, passa pela análise técnica e pelas médias móveis empregadas por Almeida (2016) e chega aos modelos estatísticos ARIMA e GARCH e às medidas usadas para avaliar uma estratégia. Ao final, são apresentados os trabalhos relacionados.

1.1 Mercado de ações

De acordo com o Banco Central do Brasil (2025a), as bolsas de valores são sociedades anônimas ou associações civis que mantêm local ou sistema adequado à realização de operações de compra e venda de títulos e valores mobiliários, em mercado livre e aberto, organizado e fiscalizado por seus membros e pela Comissão de Valores Mobiliários. No Brasil, esse papel é exercido pela B3.

Para a empresa, a abertura de capital é uma forma de obter recursos de terceiros. Em troca do capital recebido, ela cede aos acionistas uma participação no negócio proporcional ao valor investido. Para o investidor, a ação passa a ser um ativo cujo preço varia a cada pregão, isto é, a cada sessão diária de negociação na bolsa, conforme a oferta e a procura, e é essa variação que as estratégias de negociação procuram aproveitar.

O investidor não negocia diretamente na bolsa. O acesso se dá por meio de corretoras, instituições que intermediam as operações e oferecem serviços como plataformas de negociação pela internet, custódia dos títulos e financiamento para a compra de ações, cobrando por isso comissões e taxas (Banco Central do Brasil, 2025b). É pela corretora que uma plataforma como o MetaTrader 5 se conecta ao mercado.

Toda decisão de investimento envolve um compromisso entre risco e retorno, uma vez que os recursos são limitados e precisam ser distribuídos entre alternativas (Elder, 2002). No Brasil, a principal referência para essa comparação é a taxa Selic, a taxa básica de juros da economia, que serve de base para as demais taxas praticadas no mercado e influencia tanto o custo do crédito quanto o retorno das aplicações financeiras (Banco Central do Brasil, 2025c). Por esse motivo, o capital que uma estratégia mantém fora do mercado costuma ser comparado ao que renderia se estivesse aplicado a essa taxa.

1.2 Análise técnica

A análise técnica busca antecipar o comportamento dos preços a partir do estudo do seu próprio histórico, procurando padrões e tendências que possam indicar o movimento seguinte. Sua origem remonta ao comércio de arroz, e hoje ela é aplicada a ações, moedas e outros ativos.

Para essa abordagem, o que importa é o comportamento do preço, sem considerar notícias ou outros fatores que possam influenciar o mercado (Fernandes, 2014).

Fernandes (2014) distingue duas vertentes. A empírica, ou clássica, é a mais antiga: o analista observa o gráfico e identifica tendências, suportes, resistências e padrões que, segundo essa abordagem, tendem a se repetir. Por depender da interpretação de quem observa, ela é sujeita a conclusões diferentes sobre o mesmo ativo. A estatística, ou moderna, substitui a interpretação visual por cálculos aplicados à série de preços, o que torna a análise reproduzível e permite que ela seja executada por um programa de computador.

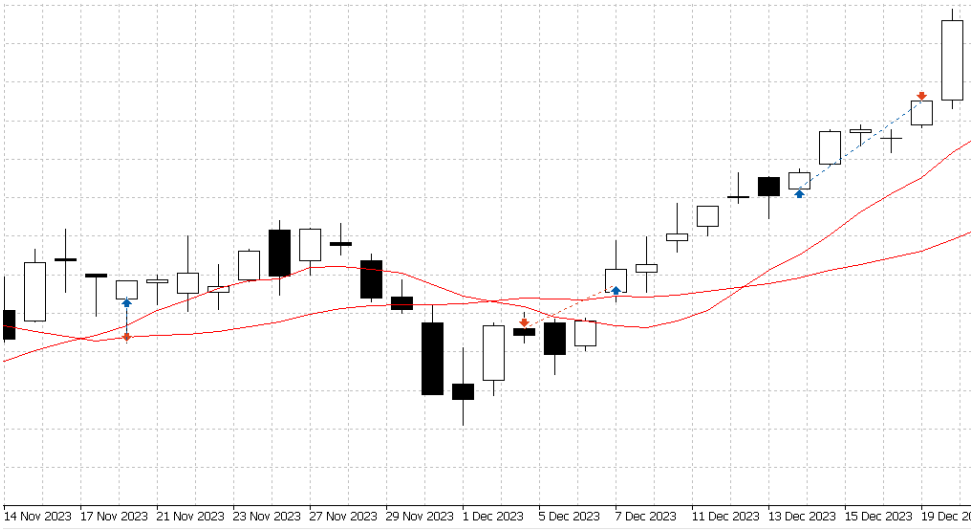
É na segunda vertente que este trabalho se insere. Tanto a estratégia de médias móveis de Almeida (2016) quanto os modelos ARIMA e GARCH são regras matemáticas aplicadas ao histórico de preços, e por isso podem ser programados, testados sobre dados passados e comparados entre si sob as mesmas condições.

1.2.1 Médias móveis

A média móvel é um dos instrumentos mais utilizados da análise técnica. Ela calcula o preço médio de um ativo nos últimos n períodos e é recalculada a cada novo período, descartando o valor mais antigo e incorporando o mais recente. Com isso, suaviza as oscilações de curto prazo e evidencia a direção predominante dos preços (Fernandes, 2014). Na média móvel simples, todos os preços da janela recebem o mesmo peso, de modo que a média de dez períodos atribui peso de um décimo a cada um dos dez últimos fechamentos.

O tamanho da janela determina o comportamento da média. Janelas curtas reagem rapidamente a mudanças de preço, mas produzem mais sinais falsos, enquanto janelas longas filtram melhor o ruído, à custa de reconhecer uma nova tendência com atraso (Fernandes, 2014). A estratégia de cruzamento combina as duas: utiliza uma média rápida, de janela curta, e uma lenta, de janela longa, e interpreta o cruzamento entre elas como sinal de compra ou de venda, como ilustra a Figura 1.

Figura 1 – Cruzamento de médias móveis



Fonte: Elaboração própria com dados e interface do MetaTrader 5.

Foi essa a estratégia adotada por Almeida (2016). O autor utilizou duas médias móveis simples, uma de dez e outra de vinte períodos, calculadas sobre o preço de fechamento, e operou nos dois sentidos, comprando quando a média rápida cruzava a lenta para cima e vendendo no cruzamento inverso. Seu algoritmo previa ainda parâmetros de limite de perda e de realização de lucro, embora os testes relatados tenham sido conduzidos com ambos nulos. O próprio autor alertou para as limitações de se usar apenas essa técnica em mercados de alta volatilidade (Almeida, 2016).

1.3 MetaTrader 5

O MetaTrader 5 é uma plataforma de negociação multimercado desenvolvida pela MetaQuotes, que reúne em um mesmo ambiente a execução de ordens, a análise gráfica e o desenvolvimento de sistemas automatizados para ações, futuros, moedas e outros instrumentos (MetaQuotes Ltd., 2024). Sua interface, mostrada na Figura 2, organiza em janelas as cotações em tempo real, os gráficos de preços e o navegador, que dá acesso às contas, aos indicadores e aos programas instalados.

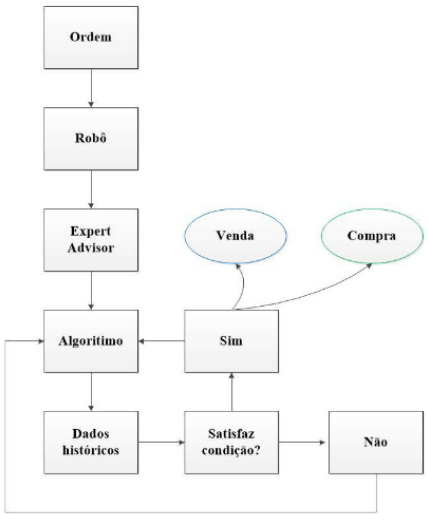
Figura 2 – Interface do MetaTrader 5



Fonte: MetaQuotes Ltd. (2024).

Os programas que negociam de forma automática na plataforma são chamados de *Expert Advisors* (EAs), também conhecidos como robôs de negociação. Um EA abre, modifica e encerra posições segundo regras programadas, sem intervenção manual (Almeida, 2016). A Figura 3 apresenta o ciclo de funcionamento de um EA.

Figura 3 – Ciclo de funcionamento de um *Expert Advisor*



Fonte: Almeida (2016).

Os EAs são escritos em MQL5, linguagem própria da plataforma, de sintaxe próxima à do C++. O ambiente de desenvolvimento, chamado MetaEditor, oferece editor, compilador e depurador integrados. Para avaliar uma estratégia antes de usá-la, a plataforma dispõe do testador de estratégias, o *Strategy Tester*, que executa o EA sobre dados históricos, simulando as

ordens como se o mercado estivesse aberto, e produz relatórios de desempenho (MetaQuotes Ltd., 2024). Esse procedimento é conhecido como *backtesting*, e foi por meio dele que todos os experimentos deste trabalho foram conduzidos.

1.4 Modelos estatísticos de séries temporais

Uma série temporal é uma sequência de observações ordenadas no tempo, como os preços de fechamento diários de uma ação. Os modelos de séries temporais procuram descrever a estrutura dessa sequência, isto é, de que forma cada observação se relaciona com as anteriores, e utilizam essa descrição para projetar valores futuros. Neste trabalho são empregados dois desses modelos, com funções diferentes. O ARIMA descreve o valor esperado da série, e o GARCH descreve o tamanho esperado dos erros em torno desse valor.

1.4.1 ARIMA

O modelo autorregressivo integrado de médias móveis, conhecido pela sigla ARIMA, do inglês *Autoregressive Integrated Moving Average*, é um dos modelos mais empregados na previsão de séries temporais, inclusive em séries financeiras (Xing *et al.*, 2024). Ele é composto por três partes, cada uma associada a uma ordem.

A parte autorregressiva, de ordem p, expressa o valor atual da série como combinação dos seus p valores anteriores. A parte de médias móveis, de ordem q, acrescenta a influência dos q erros de previsão anteriores, isto é, das diferenças entre o que o modelo previu e o que de fato ocorreu. A parte integrada, de ordem d, indica quantas vezes a série precisa ser diferenciada, ou seja, substituída pela variação entre uma observação e a anterior, para se tornar estacionária (Xing *et al.*, 2024). Uma série é estacionária quando sua média e sua variância não se alteram ao longo do tempo, condição exigida pelas partes autorregressiva e de médias móveis.

Convém registrar que a média móvel do ARIMA não é a mesma média móvel da análise técnica. Na análise técnica, a média é calculada sobre os preços. No ARIMA, o termo de médias móveis é uma combinação dos erros de previsão passados. Os dois conceitos têm o mesmo nome, mas descrevem coisas diferentes.

Representando por y_t a série já diferenciada d vezes, o modelo pode ser escrito como

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}, \tag{1.1}$$

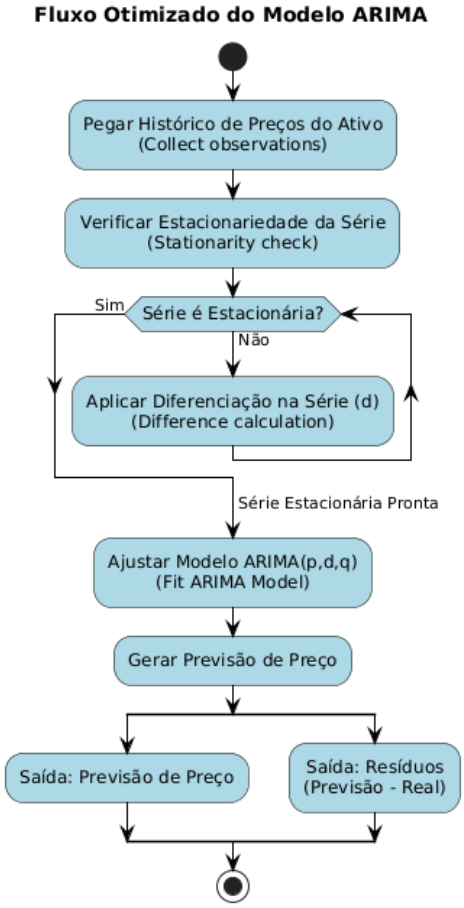
em que c é uma constante, os coeficientes ϕ ponderam os valores passados da série, os coeficientes θ ponderam os erros passados e ε_t é o erro do período atual, que o modelo não consegue prever.

O ARIMA supõe, portanto, que a série diferenciada segue um modelo ARMA(p,q), que tem apenas as partes autorregressiva e de médias móveis (Thomaz, 2019). Quando a série não precisa ser diferenciada ($d = 0$), o próprio ARIMA é um ARMA, e quando também não há termos de médias móveis ($q = 0$), o modelo é chamado de AR(p), ou autorregressivo.

Há uma relação direta entre essa equação e a estratégia de Almeida (2016). A média móvel simples de dez períodos é um filtro linear que atribui pesos fixos, iguais a um décimo, aos últimos preços. A parte autorregressiva do ARIMA também é um filtro linear sobre os valores passados, mas seus pesos ϕ são estimados a partir dos dados, em vez de fixados por convenção. Nesse sentido, o ARIMA pode ser visto como uma generalização da média móvel: mantém a mesma família de operação e ajusta os coeficientes ao ativo e ao período analisados.

A aplicação do modelo segue as etapas representadas na Figura 4.

Figura 4 – Etapas de aplicação do modelo ARIMA



Fonte: Elaboração própria.

A primeira etapa é verificar se a série é estacionária. Uma série estacionária oscila em torno de uma média estável, e um choque que a afasta dessa média tende a se desfazer com o tempo. Os preços de ações, ao contrário, costumam se comportar como um passeio aleatório, em que cada choque se incorpora ao preço e não se desfaz, de modo que a variância da série cresce com o tempo (Thomaz, 2019). Esse comportamento é chamado de raiz unitária. Para identificá-lo, usa-se o teste de Dickey-Fuller aumentado (ADF), que estima, por regressão, o quanto a variação de cada dia depende do nível da série no dia anterior. Se a série tende a voltar à sua média, essa dependência é negativa e forte. Se não tende, ela é próxima de zero, e a série tem raiz unitária (Thomaz, 2019).

A hipótese nula do teste é a existência de raiz unitária. O valor-p indica a probabilidade de se obter um resultado tão favorável à estacionariedade quanto o observado se a série de fato tivesse raiz unitária. Como a estatística do teste não segue as distribuições usuais, os seus valores críticos foram tabelados especialmente para ele, e a hipótese nula é rejeitada quando a estatística fica abaixo do valor crítico, o que corresponde a um valor-p pequeno, em geral menor que 0,05 (Thomaz, 2019). Quando a hipótese não é rejeitada, a série é diferenciada e testada de novo. No estudo de Xing *et al.* (2024) sobre as ações da NVIDIA, o teste aplicado aos preços resultou em valor-p de 0,998773, isto é, sem nenhum indício contra a raiz unitária. Após uma diferenciação, o valor-p ficou próximo de zero, e a ordem de integração foi definida como $d = 1$.

Definido d, resta escolher p e q. Como várias combinações são possíveis, Xing *et al.* (2024) testaram valores de zero a quatro para cada ordem e escolheram a combinação de menor critério de informação de Akaike (AIC), dado por

$$\mathrm{AIC} = -2\ln\hat{L} + 2k,$$

em que $\hat{L}$ é a verossimilhança do modelo ajustado, que mede o quão provável é a série observada segundo o modelo, e k é o número de parâmetros estimados (Thomaz, 2019). A primeira parcela diminui quanto melhor o ajuste, e a segunda aumenta a cada parâmetro acrescentado. Um modelo com mais parâmetros sempre se ajusta um pouco melhor aos dados passados, mas parte desse ganho é apenas ruído reproduzido, que não ajuda a prever. A penalidade faz com que um parâmetro a mais só compense se melhorar o ajuste mais do que custa. Ajusta-se, então, cada combinação candidata, e escolhe-se a de menor AIC, que é a que melhor equilibra ajuste e simplicidade. Com o modelo escolhido, obtêm-se a previsão para o período seguinte e os resíduos, que são os erros de previsão observados na amostra.

Segundo Xing *et al.* (2024) e Araya e Araya (2024), a principal limitação do ARIMA é tratar apenas relações lineares e supor que a variância dos erros é constante. Em séries financeiras essa segunda suposição raramente se verifica, e é dela que trata o modelo GARCH.

1.4.2 GARCH

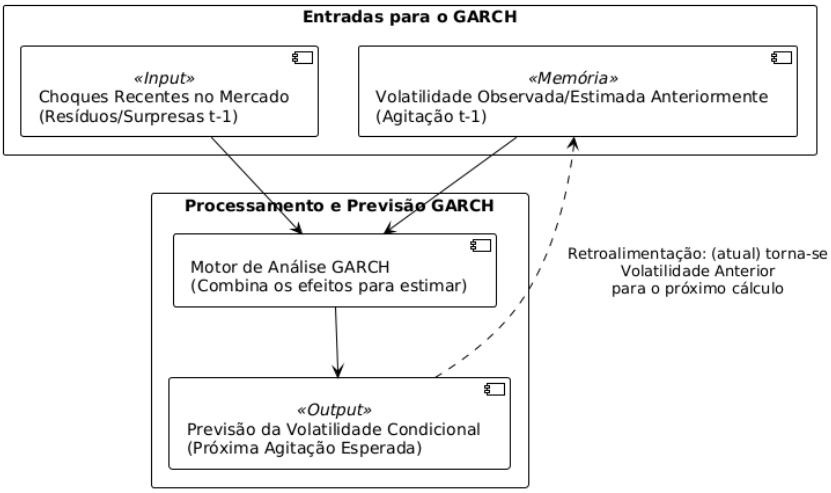
Nas séries de retornos de ações, a volatilidade, que mede o grau de variação dos preços ao longo do tempo, não é constante. Ela costuma vir em ondas, com dias agitados seguidos de outros dias agitados e dias calmos seguidos de dias calmos, e conhecê-la é fundamental para a gestão de risco (Araya; Araya, 2024). Engle (1982) propôs o modelo ARCH, em que a variância do erro de cada período depende dos erros dos períodos anteriores. Bollerslev (1986) generalizou essa proposta no modelo GARCH, do inglês *Generalized Autoregressive Conditional Heteroskedasticity*, em que a variância passa a depender também das próprias variâncias anteriores.

Na especificação GARCH(1,1), adotada neste trabalho, a variância condicional σ_t^2 do erro no período t é dada por

$$\sigma_t^2 = \omega + \alpha\,\varepsilon_{t-1}^2 + \beta\,\sigma_{t-1}^2, \tag{1.2}$$

em que ε_{t-1} é o erro do período anterior, σ^2_{t-1} é a variância estimada para o período anterior e ω, α e β são os parâmetros do modelo. O termo com α representa a reação da volatilidade a um choque recente, e o termo com β representa a persistência da volatilidade passada (Bollerslev, 1986). A Figura 5 ilustra esse processo de retroalimentação.

Figura 5 – Retroalimentação da variância no modelo GARCH



Fonte: Elaboração própria.

Para que o modelo faça sentido, os parâmetros precisam respeitar restrições: ω deve ser positivo, α e β não podem ser negativos e a soma $\alpha+\beta$ deve ser menor que um. A última condição garante que a variância tenha um valor de longo prazo finito, igual a $\omega/(1-\alpha-\beta)$, para o qual a volatilidade retorna depois de um choque (Bollerslev, 1986).

O GARCH padrão trata de forma simétrica os choques positivos e os negativos de mesma magnitude. Nos mercados de ações, porém, as quedas costumam elevar a volatilidade mais do que as altas. Para representar essa assimetria foram propostas variações do modelo, como o EGARCH e o TGARCH, que acrescentam à equação termos capazes de fazer a volatilidade reagir de forma diferente a choques positivos e negativos (Araya; Araya, 2024). Este trabalho emprega a especificação simétrica.

1.4.3 Integração entre ARIMA e GARCH

Os dois modelos se complementam. O ARIMA estima a média condicional da série, ou seja, o valor esperado para o período seguinte. O GARCH estima a variância condicional dos erros desse valor esperado. Na forma combinada, os resíduos gerados pelo ARIMA servem de entrada para o GARCH, que modela a variância desses resíduos ao longo do tempo (Araya; Araya, 2024).

Em uma estratégia de negociação, essa combinação permite separar duas perguntas. A direção da operação é dada pelo sinal da previsão do ARIMA, e o risco associado a ela é dado pela volatilidade prevista pelo GARCH. Como o GARCH não fornece nenhuma informação sobre a direção dos preços, ele não pode, sozinho, gerar uma ordem de compra ou de venda. O

que ele pode fazer é condicionar a operação indicada pelo ARIMA ao nível de risco esperado, impedindo a operação ou reduzindo o seu tamanho quando a volatilidade prevista é alta.

1.5 Métricas de avaliação

Avaliar uma estratégia de negociação apenas pelo lucro final esconde o caminho percorrido até ele. Duas estratégias com o mesmo retorno podem ter exposto o investidor a riscos muito diferentes. Por isso, o relatório do testador de estratégias do MetaTrader 5 apresenta, ao lado do lucro, medidas de risco e índices que relacionam as duas coisas (MetaQuotes Ltd., 2026). O Quadro 1 resume as métricas usadas neste trabalho para avaliar e comparar os robôs.

Quadro 1 – Métricas de avaliação usadas no trabalho

Métrica	O que indica	Como é calculada
Retorno acumulado	quanto o patrimônio cresceu ou diminuiu no período	patrimônio final dividido pelo inicial, menos um
Queda máxima	o pior tombo que um investidor teria sofrido seguindo a estratégia	maior queda percentual do patrimônio entre um ponto alto e o ponto mais baixo seguinte
Volatilidade	o quanto o patrimônio sobe e desce de um dia para o outro	desvio-padrão dos retornos diários do patrimônio, em base anual
Negociações	quantas operações o robô realizou	contagem do relatório do testador
Taxa de acerto	a proporção de negociações que terminaram com lucro	negociações com lucro divididas pelo total
Sinais vetados	quantas vezes o GARCH impediu uma operação indicada pelo ARIMA	contagem registrada pelo robô
Índice de Sharpe	o ganho além de uma referência por unidade de oscilação	média do retorno diferencial dividida pelo seu desvio-padrão
Índice de Calmar	o ganho por unidade de queda máxima	retorno anualizado dividido pela queda máxima

Fonte: Elaboração própria, com base em MetaQuotes Ltd. (2026) e Sharpe (1994).

O risco é medido de duas formas complementares. A queda máxima, que o relatório da plataforma chama de rebaixamento relativo e que também é conhecida pelo termo em inglês *drawdown*, é a maior queda percentual entre um máximo local do patrimônio e o mínimo local seguinte (MetaQuotes Ltd., 2026). Ela responde à pergunta de qual foi o pior tombo do caminho. A volatilidade, por sua vez, é o desvio-padrão dos retornos e mede o quanto o patrimônio oscila no dia a dia.

Como os retornos são diários, a volatilidade é convertida para base anual, o que facilita a leitura e a comparação. Se os retornos de dias diferentes forem independentes entre si, a variância de um período de T dias é T vezes a variância diária, e o desvio-padrão, a raiz de T vezes o diário (Sharpe, 1994). Usou-se $T = 252$, número de dias úteis de um ano adotado por convenção no mercado brasileiro. Na série da PETR4 usada neste trabalho, a média foi de 248 pregões por ano. A volatilidade anual é, portanto, o desvio-padrão diário multiplicado pela raiz de 252, e uma oscilação típica de 2% ao dia corresponde a cerca de 32% ao ano.

O índice de Sharpe relaciona o retorno de uma estratégia à sua volatilidade. Ele divide o retorno diferencial, isto é, a diferença entre o retorno da estratégia e o de uma referência, pelo desvio-padrão dessa diferença (Sharpe, 1994),

$$S = \frac{\bar{d}}{\sigma_d}, \tag{1.3}$$

em que $\bar{d}$ é a média do retorno diferencial e σ_d o seu desvio-padrão. O índice indica quanto se ganhou além da referência por unidade de oscilação, e quanto maior, melhor a relação. Um índice negativo indica que a estratégia rendeu menos que a referência. O testador do MetaTrader 5 usa como referência um rendimento livre de risco igual a zero (MetaQuotes Ltd., 2026), e neste trabalho a referência foi a taxa Selic. O próprio autor observa que o índice está ligado à estatística t da média do retorno diferencial, que é igual a ele multiplicado pela raiz do número de observações (Sharpe, 1994). Por isso, um mesmo valor de índice é estatisticamente mais forte quando medido em um período mais longo.

O índice de Calmar relaciona o retorno à queda máxima. Ele divide o retorno anualizado pela queda máxima do período,

$$C = \frac{\text{retorno anualizado}}{\text{queda máxima}}, \tag{1.4}$$

e segue a mesma ideia do fator de recuperação do relatório da plataforma, que divide o lucro obtido pelo rebaixamento máximo (MetaQuotes Ltd., 2026), com a diferença de usar o retorno anualizado, o que permite comparar períodos de durações diferentes. O índice indica quanto se ganhou por unidade do pior tombo e, por isso, favorece estratégias que evitam perdas grandes. Os dois índices medem coisas diferentes. O Sharpe penaliza toda oscilação, para cima ou para baixo, e o Calmar considera apenas a pior queda.

1.6 Trabalhos relacionados

Os trabalhos relacionados foram selecionados entre pesquisas sobre o desenvolvimento de robôs de negociação na plataforma MetaTrader 5 e sobre a aplicação dos modelos ARIMA e GARCH à previsão de séries de preços de ações.

O estudo de Almeida (2016), desenvolvido na FATEC Indaiatuba, é o ponto de partida deste trabalho. O autor desenvolveu em MQL5 um robô de negociação para a PETR4 baseado no cruzamento de médias móveis simples de dez e vinte períodos e o avaliou por *backtesting* em períodos de crise, entre 2007 e 2011, e fora de crise, entre 2013 e 2016. A estratégia apresentou lucro no período fora de crise e prejuízo no período de crise. Ao discutir os limites do trabalho, o autor indicou a investigação de modelos de volatilidade, entre eles o GARCH, como continuidade da pesquisa. É essa indicação que o presente trabalho retoma, mantendo o ativo, a plataforma e a linguagem.

Batista (2024) também desenvolveu um *Expert Advisor* em MQL5 para a B3, combinando três indicadores técnicos, a média móvel exponencial, a convergência e divergência de médias

móveis e o índice de força relativa. Os testes, realizados sobre o ativo BBAS3F em 2023, compararam os indicadores isoladamente, em pares e em conjunto, e a combinação dos três apresentou o melhor resultado. O estudo mostra que a integração de técnicas com funções distintas em um mesmo algoritmo pode melhorar a decisão, ideia que este trabalho aplica aos modelos estatísticos.

Xing *et al.* (2024) compararam o ARIMA, o ARIMA-GARCH e dois modelos de redes neurais na previsão do preço de fechamento das ações da NVIDIA, com dados diários de abril de 2019 a abril de 2024. As ordens dos modelos ARIMA foram definidas pelo teste ADF e pelo menor AIC, com p e q variando de zero a quatro, procedimento semelhante ao adotado neste trabalho. O ARIMA-GARCH apresentou a menor raiz do erro quadrático médio, e o ARIMA com janela expansiva teve o melhor desempenho geral, superando as redes neurais. Os autores atribuem esse resultado, possivelmente, ao comportamento predominantemente linear da série.

Araya e Araya (2024) estudaram a previsão da volatilidade das ações da Apple. No modelo proposto, os resíduos de um modelo SARIMA, versão do ARIMA com componentes sazonais, alimentam um modelo GARCH, e a volatilidade estimada por essa combinação é depois utilizada como entrada de redes neurais. A etapa que interessa a este trabalho é a primeira, em que os resíduos do modelo de média servem de entrada para o modelo de variância, mesma arquitetura adotada no algoritmo aqui desenvolvido.

O Quadro 2 resume as características desses estudos e as deste trabalho.

Quadro 2 – Características dos estudos relacionados

Estudo	Ativo	Fonte de dados	Periodicidade	Método
Almeida (2016)	PETR4	MetaTrader 5	diário	Cruzamento de médias móveis simples (10 e 20)
Batista (2024)	BBAS3F	MetaTrader 5	30 minutos	Combinação de três indicadores técnicos
Xing *et al.* (2024)	NVIDIA	Yahoo Finance	diário	ARIMA e ARIMA-GARCH, comparados a redes neurais
Araya e Araya (2024)	Apple	Yahoo Finance	diário	Resíduos do SARIMA como entrada do GARCH, seguidos de redes neurais
Este trabalho	PETR4 e outras três ações	B3 (COTAHIST)	diário	ARIMA e ARIMA-GARCH, comparados às médias móveis de Almeida (2016)

Fonte: Elaboração própria.

CAPÍTULO II

2 Percurso metodológico

Este capítulo descreve como a pesquisa foi conduzida. Apresenta a caracterização do estudo, a amostra, a coleta e a análise dos dados, a implementação e a validação dos modelos, o plano experimental e os obstáculos encontrados.

2.1 Caracterização da pesquisa

2.1.1 Quanto aos objetivos

Quanto aos objetivos, a pesquisa é explicativa, com uma parte descritiva. Segundo Wazlawick (2014), a pesquisa explicativa busca identificar as causas de determinados fenômenos, aprofundando o conhecimento sobre a relação entre variáveis. Neste trabalho, ela investiga por que a inclusão de um modelo de volatilidade altera o desempenho de uma estratégia cuja previsão de direção permanece a mesma. A parte descritiva está no registro de como cada robô se comportou em diferentes períodos do mercado.

2.1.2 Quanto ao delineamento

Quanto ao delineamento, trata-se de uma pesquisa quase experimental. A pesquisa experimental envolve a manipulação controlada de variáveis e a observação dos efeitos resultantes (Wazlawick, 2014). Ela é chamada de quase experimental quando não há distribuição aleatória dos sujeitos, como neste trabalho, em que a série histórica de um ativo é única e não pode ser sorteada. Esse delineamento abrange, entre seus casos mais frequentes, o desenvolvimento de softwares e a análise de algoritmos, que é a natureza deste trabalho.

O percurso seguiu as etapas previstas para esse delineamento. O problema e as hipóteses foram formulados na introdução. As variáveis são os parâmetros configuráveis do robô, e o plano experimental foi definido antes da observação dos resultados. Os sujeitos são as séries históricas dos ativos, e o ambiente é a plataforma de simulação.

2.2 Caracterização do lugar e da amostra de pesquisa

O lugar da pesquisa é computacional. Os experimentos foram conduzidos no testador de estratégias do MetaTrader 5, que simula a execução de ordens sobre séries históricas com as mesmas regras de negociação que usaria em tempo real. A plataforma foi escolhida por ser a mesma utilizada no estudo que este trabalho continua (Almeida, 2016). Ela é nativa do sistema Windows, e os experimentos apresentados aqui foram executados em ambiente Linux, por meio da camada de compatibilidade Wine, pelos motivos expostos ao final deste capítulo.

A amostra é composta por séries históricas diárias de ações negociadas na B3. O ativo principal é a PETR4, ação preferencial da Petrobras, escolhida por três motivos. É o ativo estudado por Almeida (2016), o que permite a comparação direta. Apresenta volatilidade acentuada, característica que dá sentido à aplicação de um modelo de variância condicional. E possui série longa e contínua no arquivo histórico da bolsa, com 5.881 pregões, de 2 de janeiro de 2003 a 21 de setembro de 2026.

Para verificar se os resultados se repetem fora do ativo principal, foram incluídas outras três ações, VALE3, da mineração, USIM5, da siderurgia, e POMO4, de bens de capital. O critério de escolha, definido antes da observação de qualquer resultado, considerou a qualidade dos dados e a diversidade de setores. Cada ação precisava ter série completa de 2003 a 2026 no arquivo da bolsa, sem mudanças na forma de cotação que impedissem a reconstrução dos preços, e preço sempre acima de R$ 3, para que o arredondamento em centavos não distorcesse os retornos. As ações também deveriam pertencer a setores diferentes entre si.

O recorte temporal foi dividido em períodos, e não tratado como um período único, porque o comportamento de uma estratégia depende do momento do mercado. Foram examinados um período de crise, de 2007 a 2011, um de queda prolongada seguida de recuperação, de 2013 a 2016, o intervalo de 2017 a 2024, que inclui a crise da pandemia, o período mais recente, de 2025 a 2026, e o período mais longo disponível, de 2005 a 2026.

2.3 Procedimentos para coleta e análise de dados

2.3.1 Técnicas para coleta de dados

Os dados foram obtidos de fontes públicas oficiais, e não do servidor da corretora, que disponibiliza cotações apenas a partir de setembro de 2021 e pode alterar o histórico sem aviso. As cotações vieram do arquivo COTAHIST, série histórica publicada pela própria B3, que registra, para cada pregão e cada ação, os preços de abertura, máximo, mínimo e fechamento e o volume negociado. A taxa Selic diária foi obtida da série 11 do Sistema Gerenciador de Séries Temporais do Banco Central (Banco Central do Brasil, 2026).

Sobre as cotações foi aplicada uma única transformação, a correção por desdobramentos. No desdobramento, cada ação é dividida em várias, e o preço cai na mesma proporção, sem que o investidor perca nada, já que passa a ter mais ações. Na PETR4 houve dois desdobramentos no período. Em 1º de setembro de 2005, cada ação virou quatro, e em 28 de abril de 2008, cada ação virou duas. No arquivo da bolsa, esses dias aparecem como quedas de 75,2% e de 49,5%, que não aconteceram de fato e que o modelo interpretaria como dois tombos do mercado. Para corrigir, os preços anteriores a 28 de abril de 2008 foram divididos por dois, e os anteriores a 1º de setembro de 2005, por oito, isto é, por quatro e depois por dois. Com isso, a série passa a registrar apenas as variações reais de preço. Os dois eventos foram confirmados no registro de eventos corporativos da B3 e, para o de 2005, que esse registro não alcança, na base do Yahoo Finance (Yahoo Finance, 2026). Os proventos não foram incorporados à série. Eles foram

obtidos da mesma base, que não é oficial, e usados apenas para verificar o efeito de deixá-los de fora.

As séries preparadas foram importadas para a plataforma como símbolos personalizados, recurso que permite ao testador operar sobre dados próprios. A conferência consistiu em comparar a quantidade de barras processadas pela plataforma com a de pregões da série de origem e em reconstruir preços isolados a partir das linhas originais do arquivo da bolsa.

2.3.2 Natureza da análise de dados

A análise é quantitativa. Os robôs foram comparados pelas métricas apresentadas no Capítulo I. Como o GARCH foi incluído no algoritmo para controlar o risco, e não para prever a direção dos preços, as métricas principais são as de risco, a queda máxima e a volatilidade. O retorno acumulado acompanha essas métricas como resultado complementar, e a taxa de acerto e a quantidade de sinais vetados ajudam a explicar o funcionamento do filtro.

Para verificar se as diferenças entre os robôs eram consistentes, e não obra do acaso, observou-se se elas se repetiam entre os períodos, entre as configurações e entre os ativos. Se o GARCH não fizesse diferença, a versão com ele seria melhor em cerca de metade das comparações, como no lançamento de uma moeda. Testes estatísticos das diferenças foram aplicados como verificação adicional, ao final da análise dos dados.

2.4 Implementação dos modelos

A biblioteca padrão da linguagem MQL5 oferece médias móveis, osciladores e demais indicadores de análise técnica, mas não traz modelos de séries temporais como o ARIMA e o GARCH. Ambos foram escritos para este trabalho. Da biblioteca numérica ALGLIB, que acompanha a instalação da plataforma, foram aproveitadas apenas as rotinas de álgebra linear e de otimização com restrições.

Os modelos foram aplicados ao logaritmo do preço, e não ao preço em reais. A diferença entre os logaritmos de dois preços seguidos é o retorno logarítmico, que mede a variação percentual do dia (Thomaz, 2019). Trabalhar com retornos tem duas vantagens. A primeira é que eles são livres de escala, ou seja, uma alta de 1% significa o mesmo para uma ação cotada a R$ 5 ou a R$ 40, de modo que os parâmetros do robô valem para qualquer ativo e período. A segunda é que os retornos costumam ser estacionários, ao contrário dos preços, condição exigida pelo ARIMA (Thomaz, 2019). Como consequência, a volatilidade estimada pelo GARCH também sai em porcentagem. Uma volatilidade de 0,02 indica uma oscilação típica de 2% ao dia, enquanto, com o preço em reais, o mesmo número significaria dois centavos e mudaria de sentido conforme o preço da ação.

O ARIMA foi estimado pelo método de Hannan-Rissanen, que divide a estimação em duas regressões de mínimos quadrados. A dificuldade de um modelo com termos de médias móveis é que os erros passados não podem ser observados, pois dependem dos próprios

coeficientes que se quer estimar. A primeira regressão ajusta um modelo autorregressivo longo, cujos resíduos servem de estimativa desses erros, e a segunda usa essas estimativas para obter os coeficientes. A escolha foi uma decisão de projeto. O método não exige taxa de aprendizado nem número de iterações e não depende da escala dos preços, o que o torna estável para um modelo que é reestimado todos os dias.

A ordem de integração d foi determinada pela aplicação sequencial do teste ADF (Thomaz, 2019). Testa-se a série e, enquanto a hipótese de raiz unitária não for rejeitada, testa-se a série diferenciada mais uma vez. As ordens p e q foram escolhidas por busca em grade, de zero a quatro, pelo menor AIC (Thomaz, 2019), procedimento semelhante ao de Xing *et al.* (2024). Todos os candidatos foram avaliados sobre a mesma amostra, porque modelos de ordem maior consomem mais observações iniciais e, sem esse cuidado, os mais simples seriam favorecidos na comparação. As ordens são reavaliadas a cada 21 pregões, de modo que o valor de d escolhido pode mudar ao longo de um teste.

O GARCH foi estimado por máxima verossimilhança (Thomaz, 2019). Foi adotada a especificação GARCH(1,1), que exige poucos parâmetros e é a escolha predominante nos estudos de previsão de ações (Xing *et al.*, 2024). As restrições do modelo foram informadas ao otimizador como limites da região de busca, e não aplicadas como correção depois de cada passo, o que mantém a busca dentro da região válida e permite que ela convirja.

Os dois modelos são reestimados a cada pregão sobre uma janela deslizante, isto é, sobre os últimos 120 ou 240 pregões já encerrados, conforme a configuração. A cada dia, o pregão mais antigo sai da janela e o mais recente entra, o que permite ao modelo acompanhar as mudanças de comportamento do mercado. Xing *et al.* (2024) compararam esse tipo de janela com a janela expansiva, que acumula todo o histórico desde o início, e no seu estudo o ARIMA teve melhor desempenho com a janela expansiva. A janela expansiva não foi testada neste trabalho. O tamanho máximo da janela, de 240 pregões, foi limitado pelo histórico que o testador disponibiliza no início de cada teste, que começa em 1º de janeiro do ano anterior e soma cerca de 250 pregões.

Os dois modelos foram reunidos em um único *Expert Advisor*, com um parâmetro que liga e desliga o GARCH. Com ele desligado, o programa percorre o mesmo caminho de previsão, a mesma janela de estimação e a mesma rotina de envio de ordens, de modo que qualquer diferença entre as duas execuções só pode vir do GARCH. A divisão de papéis é estrita. O ARIMA é o único responsável por indicar o lado da operação, e o GARCH nunca gera sinal de direção.

O GARCH pode atuar na decisão de três formas, definidas para este trabalho e todas implementadas no robô. Na primeira, chamada aqui de filtro de volatilidade, a operação só é realizada quando a volatilidade prevista está abaixo de um limiar, que pode ser um valor fixo ou um percentil da volatilidade estimada dentro da própria janela. Na segunda, o tamanho da posição é ajustado de forma inversamente proporcional à volatilidade prevista, de modo que a posição diminui quando a incerteza aumenta, técnica conhecida como *volatility targeting*. Na

terceira, a volatilidade prevista é usada para construir um intervalo de confiança em torno da previsão do ARIMA, e a operação só é realizada quando a previsão se afasta de zero o suficiente para sair desse intervalo. Há ainda uma quarta forma, que combina o filtro com o ajuste do tamanho da posição.

A cada novo pregão, o robô carrega a janela, ajusta o ARIMA, obtém a previsão do retorno do dia, ajusta o GARCH sobre os resíduos e obtém a volatilidade prevista. Se a forma de uso escolhida não vetar a operação, o sinal da previsão do ARIMA determina a direção, e a ordem é executada na abertura do pregão. A janela nunca inclui o pregão em andamento, para que a decisão do dia não use uma informação que só estaria disponível no seu encerramento. Como a previsão reflete os dias mais recentes e o limiar por percentil vem da janela inteira, em períodos agitados a proporção de sinais vetados pode ser maior que a sugerida pelo percentil.

Por padrão, o veto impede a abertura de uma nova posição, mas não encerra a que já está aberta, e o ajuste do tamanho é feito apenas na entrada. Uma opção do robô permite que o veto também encerre a posição, retirando o capital do mercado enquanto a volatilidade prevista estiver alta. As duas alternativas fizeram parte dos testes.

2.5 Validação das implementações

Como os modelos foram programados do zero, era preciso verificar se os estimadores calculavam corretamente antes de usá-los com dados reais. Para isso, foi feito um teste de recuperação de parâmetros. O programa gera uma série artificial a partir de coeficientes escolhidos, o estimador recebe apenas a série, sem conhecer os coeficientes, e o resultado é comparado com os valores usados na geração. Como a resposta certa é conhecida, o teste distingue um estimador correto de um que apenas produz números plausíveis. As séries artificiais não correspondem a nenhum período do mercado. Elas foram geradas com uma semente fixa de números aleatórios, para que o teste possa ser repetido com o mesmo resultado.

Foram usados três casos, cada um verificando uma parte do código. O primeiro é um AR(2), modelo que tem apenas a parte autorregressiva e verifica o caminho mais simples do estimador do ARIMA, em que uma única regressão basta. O segundo é um ARMA(1,1), que tem também a parte de médias móveis e verifica o caminho completo, em que os erros passados precisam ser estimados antes. Como o ARIMA aplica um ARMA à série já diferenciada, esses dois casos cobrem o estimador do ARIMA. O terceiro é um GARCH(1,1), que verifica o estimador da volatilidade. As séries do AR(2) e do ARMA(1,1) têm 4.000 observações, e a do GARCH, 6.000.

A diferenciação, por sua vez, depende do teste ADF, que foi verificado da mesma forma, em três séries artificiais de 2.000 observações com comportamento conhecido. A primeira é um passeio aleatório, que não é estacionário. A segunda é uma série autorregressiva estacionária. A terceira é a primeira diferença do passeio aleatório, também estacionária.

Por fim, os procedimentos foram aplicados aos 500 pregões da PETR4 encerrados até 18

de setembro de 2026. Além do ADF, os resíduos foram examinados pelo teste de Ljung-Box, que verifica se ainda resta autocorrelação nos erros de um modelo, isto é, algum padrão que ele não capturou. Seguindo o diagnóstico feito por Thomaz (2019) para modelos ARMA-GARCH em ações brasileiras, o teste foi aplicado com dez defasagens em duas etapas, primeiro nos resíduos do ARIMA e depois no quadrado dos resíduos padronizados pelo GARCH.

2.6 Plano experimental

Todas as simulações usaram os preços de abertura de cada pregão, já que o robô decide uma vez por dia e executa na abertura. No cenário principal, partiram de um capital de R$ 100 mil, aplicaram a cada operação 95% do patrimônio e operaram apenas na ponta compradora. A cada ordem foi descontado um custo de 0,03% do valor negociado, adotado como aproximação das taxas praticadas, e o capital fora do mercado foi remunerado pela taxa Selic diária, para que robôs que passam tempos diferentes fora do mercado fossem comparados de forma justa. Os proventos ficaram fora da medida, tanto para os robôs quanto para a compra e manutenção da ação, medida apenas pela variação do preço.

O robô tem parâmetros ajustáveis, como a forma de uso do GARCH, o limiar de veto e o tamanho da janela, que, combinados, resultam em 344 configurações. Escolher a melhor delas no mesmo período em que o desempenho é medido daria uma vantagem falsa, porque, olhando para trás, sempre existe alguma combinação que teria dado certo. Por isso, a escolha seguiu o princípio do teste *forward* do testador de estratégias. As 344 configurações foram otimizadas nos três anos anteriores a cada período de teste, a melhor foi escolhida por um critério definido antes, e só então ela foi aplicada ao período seguinte, que não tinha sido usado na escolha. O Quadro 3 mostra os períodos usados.

Quadro 3 – Períodos de otimização e de teste

Otimização	Teste	Característica do período de teste
2004 a 2006	2007 a 2011	crise financeira de 2008
2010 a 2012	2013 a 2016	queda prolongada da PETR4 e recuperação em 2016
2014 a 2016	2017 a 2024	teste principal, por ser o mais longo, inclui a crise da pandemia em 2020
2022 a 2024	jan. 2025 a set. 2026	período mais recente disponível
2010 a 2012	2005 a 2026 e 2017 a 2024	configurações fixas, mantidas sem nova escolha

Fonte: Elaboração própria.

Foram usados dois critérios de escolha, porque não existe uma única forma de definir a melhor configuração. A versão A é a que teve o maior índice de Sharpe na otimização, ou seja, o maior ganho por unidade de oscilação, e a versão B, a que teve o maior índice de Calmar, isto é, o maior ganho por unidade de queda máxima. Pelo mesmo critério da versão A, foi escolhido também o melhor robô sem o GARCH, chamado nas tabelas simplesmente de ARIMA. A estratégia de médias móveis de Almeida (2016), reproduzida neste trabalho, foi executada nos mesmos períodos e nas mesmas condições.

Para confirmar que as diferenças vinham do GARCH, e não dos demais parâmetros, cada versão também foi executada com o GARCH desligado e todo o resto igual. Como o robô tem um único parâmetro que liga e desliga o modelo, essa comparação isola o efeito dele.

Dois testes complementares ampliaram a verificação. No primeiro, as versões A e B escolhidas em 2010 a 2012 foram mantidas fixas, sem nova escolha, assim como Almeida (2016) manteve fixas as suas médias de 10 e 20 períodos. No segundo, o mesmo procedimento foi repetido na PETR4, na VALE3, na USIM5 e na POMO4, nos períodos de 2007 a 2011, 2013 a 2016 e 2025 a 2026, totalizando 16.512 simulações, e cada configuração com GARCH foi comparada à mesma configuração sem ele.

Antes de tudo isso, a estratégia de médias móveis reproduzida foi submetida aos testes de Almeida (2016), para garantir que a comparação fosse feita com a estratégia dele. Os testes foram repetidos com as mesmas datas, o mesmo capital de R$ 50 mil, as mesmas médias de 10 e 20 períodos, sem custos e com operações de compra e venda. Duas condições não puderam ser repetidas exatamente. A primeira é a série de preços, pois o autor usou o histórico da corretora sem informar se e como os preços foram ajustados. A segunda é o volume. O autor declara mil ações para o teste de 2013 a 2016, mas não informa o volume dos testes de crise, e, como ele menciona cem ações como volume mínimo, esse foi o volume adotado na reprodução desses testes. Por fim, o ARIMA e o ARIMA-GARCH foram executados nas condições declaradas pelo autor para 2013 a 2016, com a configuração padrão do robô, que usa o GARCH como filtro, com limiar no percentil 50 da volatilidade estimada e janela de 120 pregões.

2.7 Obstáculos encontrados

O desenvolvimento enfrentou dois obstáculos que alteraram o cronograma original e influenciaram decisões metodológicas.

O primeiro foi a perda do ambiente Windows. O desenvolvimento começou em uma máquina com Windows e MetaTrader 5 instalado nativamente, e a perda desse equipamento obrigou a migração para Linux, onde a plataforma não tem suporte oficial e precisa ser executada por camada de compatibilidade. A solução funcionou, mas trouxe instabilidades ocasionais e exigiu que a automação dos experimentos fosse refeita em linha de comando.

O segundo foi o acesso aos dados históricos pela corretora. A corretora utilizada inicialmente, a Rico, deixou de oferecer suporte ao MetaTrader 5, o que exigiu a abertura de conta em outra instituição. A segunda corretora, a Clear, oferece a plataforma, mas disponibiliza cotações apenas a partir de setembro de 2021, o que não atendia aos períodos de teste, que retrocedem a 2003. Esse obstáculo levou à adoção do arquivo oficial da bolsa como fonte, o que tornou a série pública, verificável e livre de alterações posteriores.

CAPÍTULO III

3 Análise e discussão dos dados

Este capítulo apresenta os resultados dos experimentos descritos no Capítulo II. Começa pela validação dos modelos e pela reprodução do estudo de Almeida (2016), apresenta o comportamento dos robôs durante a crise de 2008, fora dela, no período recente e na crise da pandemia, verifica se o efeito observado vem mesmo do GARCH e de que forma ele protege o capital e termina com a verificação estatística dos resultados.

3.1 Validação dos modelos

A Tabela 1 apresenta os parâmetros estimados nas séries sintéticas, ao lado dos valores usados para gerá-las.

Tabela 1 – Recuperação de parâmetros em séries sintéticas

Parâmetro	Valor verdadeiro	Valor estimado
ARMA(1,1), ϕ_1	0,600	0,5799
ARMA(1,1), θ_1	0,400	0,4105
AR(2), ϕ_1	0,500	0,4815
AR(2), ϕ_2	$-0{,}300$	$-0{,}2891$
GARCH, ω	$1{,}00 \times 10^{-5}$	$1{,}17 \times 10^{-5}$
GARCH, α	0,090	0,0825
GARCH, β	0,890	0,8941

Fonte: Elaboração própria, a partir da execução do script de validação, com semente fixa.

Os coeficientes do ARIMA foram recuperados com desvio inferior a 4%. No GARCH, o parâmetro β, que responde pela persistência da volatilidade, ficou a menos de 1% do valor verdadeiro, enquanto ω e α se afastaram cerca de 17% e 8%. Ainda assim, a soma $\alpha + \beta$, que determina quanto tempo um choque de volatilidade leva para se dissipar, foi estimada em 0,9765, contra 0,98 do valor verdadeiro. O teste ADF também distinguiu corretamente os três casos. Não rejeitou a raiz unitária no passeio aleatório, com estatística de $-1{,}41$, e a rejeitou na série estacionária e na diferença do passeio, com $-26{,}87$ e $-46{,}19$.

Na PETR4, o ADF não rejeitou a raiz unitária para o logaritmo do preço, com estatística de $-0{,}95$, e a rejeitou para o retorno logarítmico, com $-6{,}14$, o que indica $d = 1$. É o mesmo comportamento descrito por Xing *et al.* (2024) para as ações da NVIDIA, cuja série também se tornou estacionária após uma diferenciação. No teste de Ljung-Box, um ARIMA(1,1,1) de ordens fixas deixou autocorrelação nos resíduos, com valor-p de 0,009, o que reforça a escolha das ordens por busca em grade. No quadrado dos resíduos padronizados pelo GARCH, o valor-p foi de 0,75, sem indício de que os dias agitados continuem vindo em sequência, ou seja, o GARCH capturou a variação da volatilidade presente nos resíduos.

O resultado $d = 1$ vale para essa amostra. Como o teste ADF é refeito a cada reavaliação das ordens, o d escolhido pelo robô variou ao longo dos testes. No acompanhamento diário da versão A entre julho de 2019 e junho de 2021, o teste indicou $d = 1$ em 412 dos 496 pregões, ou 83,1%, e $d = 0$ nos demais.

3.2 Reprodução do estudo de referência

A Tabela 2 compara os resultados relatados por Almeida (2016) com os da reprodução.

Tabela 2 – Reprodução dos testes de Almeida (2016)

	Almeida (2016)		Reprodução	
Período	Operações	Resultado	Operações	Resultado
2013 a 2016	38	+R$ 10.430	37	+R$ 10.050
2008 a 2010	37	−R$ 1.595	38	−R$ 575
2007 a 2011	52	−R$ 2.542	63	−R$ 1.274

Fonte: Elaboração própria e Almeida (2016).

Nota: Médias móveis simples de 10 e 20 períodos, capital de R$ 50 mil, sem custos, compra e venda. Volume de mil ações em 2013 a 2016 e de cem ações nos testes de crise.

No período fora de crise, a reprodução difere do original em uma operação e em 3,6% do lucro, o que indica que a lógica da estratégia foi reproduzida. Nos testes de crise, a quantidade de operações de 2008 a 2010 praticamente coincide, mas os valores em reais divergem, e em 2007 a 2011 coincidem apenas o sinal e a ordem de grandeza do resultado.

A divergência em reais tem uma explicação provável. Com volume fixo, o resultado em reais acompanha o nível de preço da série, e uma verificação com a série ajustada também por proventos deslocou o lucro bruto de 2008 a 2010 na direção do valor do autor. Já a diferença na contagem de operações de 2007 a 2011 não foi explicada e só poderia ser investigada com os dados originais. A reprodução confirma, portanto, o comportamento do robô de referência, mas não os seus valores financeiros, o que basta para usá-lo como termo de comparação.

Nas mesmas condições declaradas pelo autor para 2013 a 2016, os robôs deste trabalho obtiveram o resultado da Tabela 3.

Tabela 3 – Risco nas condições originais, 2013 a 2016

Robô	Volatilidade	Queda máx.	Operações
Médias móveis reproduzidas	14,6%	15,0%	37
ARIMA	14,9%	30,9%	397
ARIMA-GARCH	12,2%	8,7%	173

Fonte: Elaboração própria.

Nota: Sem custos de execução, conforme o estudo original.

O ARIMA-GARCH foi o robô que menos oscilou e o que menos caiu. A sua queda máxima, de 8,7%, foi pouco mais da metade da das médias móveis e menos de um terço da do ARIMA. A diferença de volatilidade foi menor, porque com o volume fixo de mil ações os

três robôs aplicavam, em média, cerca de um quarto do capital. Em dinheiro, as médias móveis reproduzidas lucraram R$ 10.050, o ARIMA teve prejuízo de R$ 8.100 e o ARIMA-GARCH lucrou R$ 24.020.

3.3 Comportamento durante a crise, 2007 a 2011

O primeiro período de teste inclui a crise financeira de 2008, em que o robô de Almeida (2016) acumulou prejuízo. A Tabela 4 apresenta o resultado dos três robôs nas condições do cenário principal. Nesta e nas tabelas seguintes, as médias móveis reproduzidas são a estratégia de Almeida (2016) executada por este trabalho, nas mesmas condições dos demais robôs.

Tabela 4 – Resultado durante a crise, 2007 a 2011

Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	−11,6%	57,5%	28,7%	31
ARIMA	−2,1%	44,3%	27,5%	320
ARIMA-GARCH	+28,7%	13,3%	10,5%	263
Compra e manutenção da PETR4	−14,0%	67,2%	43,2%	–

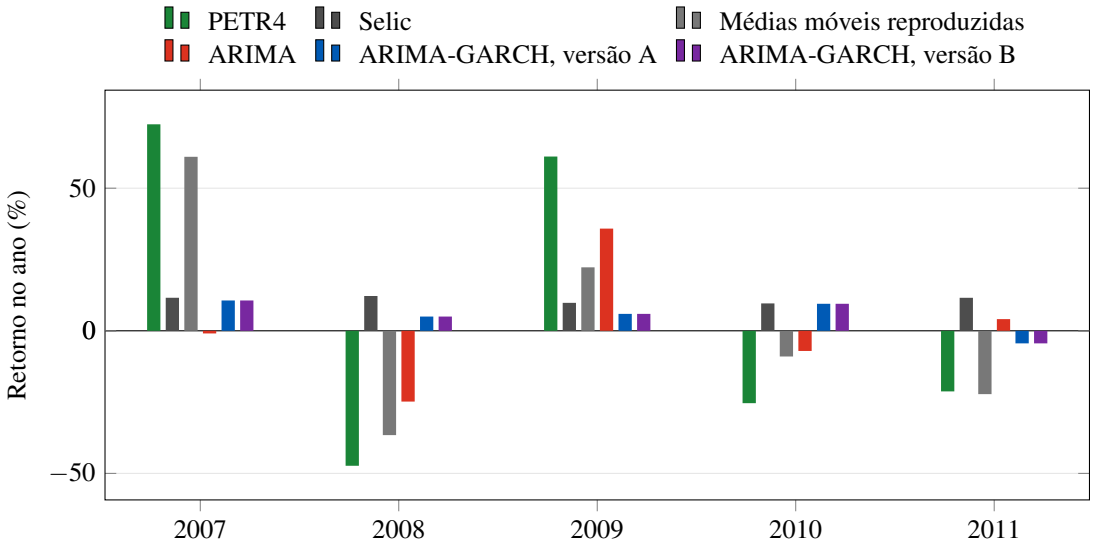
Fonte: Elaboração própria.

Nota: Com custos de execução e com o caixa remunerado pela Selic, que rendeu 68,1% no período. Sem proventos. Os dois critérios de escolha resultaram na mesma configuração do ARIMA-GARCH.

O ARIMA-GARCH foi o único robô com retorno positivo e o que menos caiu. A sua queda máxima, de 13,3%, foi cerca de um quarto da das médias móveis, de 57,5%, e a sua volatilidade, de 10,5% ao ano, foi menos da metade da dos outros dois. O ARIMA e as médias móveis tiveram oscilação muito parecida, o que mostra que trocar o cruzamento de médias pela previsão do ARIMA, por si só, não reduziu o risco.

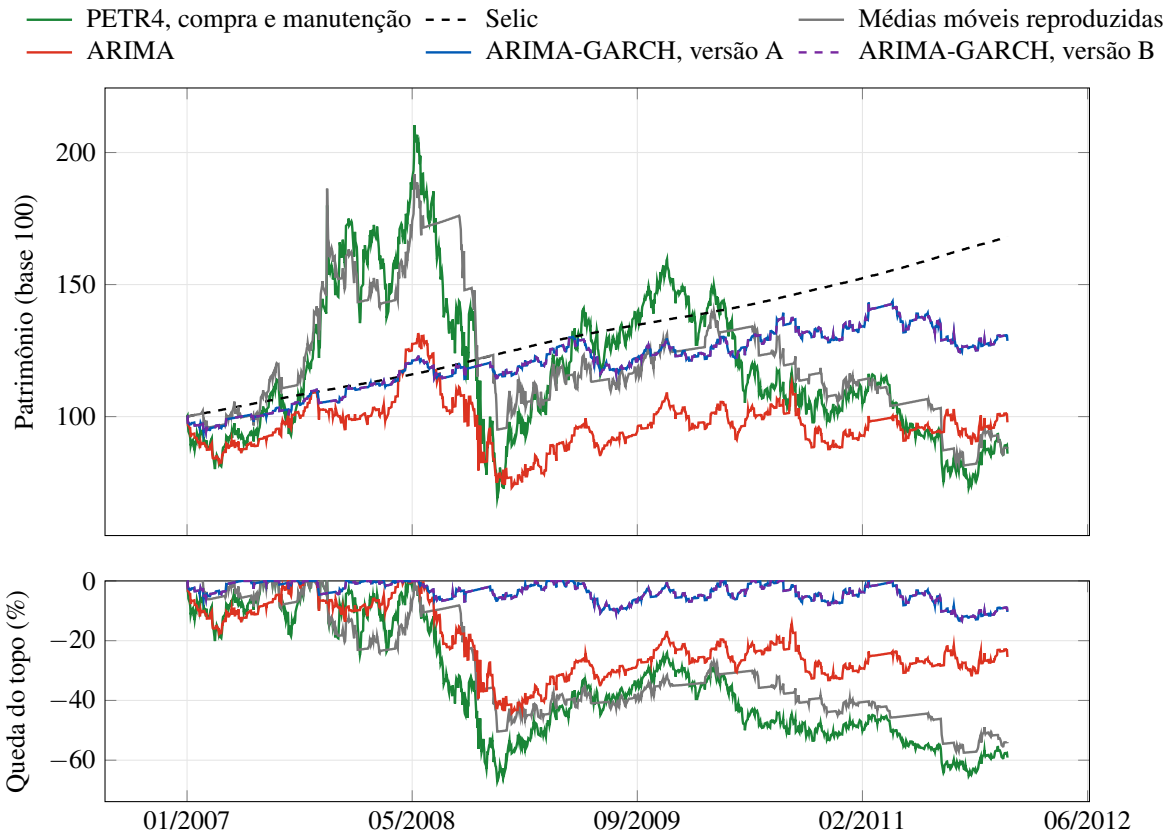
O ano de 2008 resume esse comportamento. Como mostra o Gráfico 1, enquanto a PETR4 recuou 47,3%, o ARIMA-GARCH encerrou o ano com ganho de 5,0%, contra perdas de 24,8% do ARIMA e de 36,6% das médias móveis. Dentro do ano, a maior queda do ARIMA-GARCH foi de 6,9%, contra 44,3% do ARIMA, 50,4% das médias móveis e 67,2% da PETR4. O Gráfico 2 mostra a evolução do patrimônio ao longo de todo o período. Foi justamente nesse tipo de mercado que Almeida (2016) apontou a limitação das médias móveis e sugeriu os modelos de volatilidade.

Gráfico 1 – Retorno por ano, 2007 a 2011



Fonte: Elaboração própria.

Gráfico 2 – Evolução do patrimônio e da queda acumulada, 2007 a 2011



Fonte: Elaboração própria.

A Selic, porém, rendeu 68,1% no período, mais que qualquer um dos robôs. A proteção do GARCH evitou a perda, mas não foi suficiente para superar a renda fixa em um período de ações em queda.

3.4 Comportamento fora da crise, 2013 a 2016

O segundo período combina a queda prolongada da PETR4 até o início de 2016 com a forte recuperação que veio depois. É também o período em que o robô de Almeida (2016) obteve lucro. A Tabela 5 apresenta o resultado.

Tabela 5 – Resultado fora da crise, 2013 a 2016

Robô	Retorno	Queda máx.	Volatilidade	Negociações
Médias móveis reproduzidas	+150,9%	38,4%	40,4%	24
ARIMA	−30,5%	51,9%	37,8%	266
ARIMA-GARCH, versão A	+15,8%	17,7%	14,1%	140
ARIMA-GARCH, versão B	+34,0%	6,8%	7,1%	140
Compra e manutenção da PETR4	−25,6%	83,1%	59,2%	–

Fonte: Elaboração própria.

Nota: Com custos de execução e com o caixa remunerado pela Selic, que rendeu 53,9% no período. Sem proventos.

As duas versões com GARCH foram as que menos caíram e menos oscilaram. A versão B teve queda máxima de apenas 6,8%, enquanto a PETR4 chegou a perder 83,1% do seu valor no pior momento. As médias móveis, por outro lado, tiveram o melhor retorno, de 150,9%, quase todo obtido em 2016, quando renderam 208,1% no ano, depois de três anos negativos. Elas aproveitaram a recuperação com poucas negociações, e o ARIMA-GARCH, que ficou fora do mercado em boa parte do período, ganhou 17,4% na versão A e 16,4% na versão B naquele ano. No trabalho de Almeida (2016), o lucro desse período também se concentrou em poucas operações, com três negociações lucrativas seguidas somando R$ 7.530 dos R$ 10.430 obtidos.

3.5 Período recente, 2017 a 2024 e 2025 a 2026

O período de 2017 a 2024 é o teste principal, por ser o mais longo, e inclui a queda provocada pela pandemia em 2020. O período de 2025 a 2026 é o mais recente disponível. A Tabela 6 apresenta os dois.

Tabela 6 – Resultado no período recente

Período	Robô	Retorno	Queda máx.	Volatilidade	Negociações
2017 a 2024	Médias móveis reproduzidas	+90,4%	36,7%	30,9%	56
	ARIMA	+114,6%	40,6%	32,0%	244
	ARIMA-GARCH, versão A	+273,8%	26,1%	24,2%	238
	ARIMA-GARCH, versão B	+114,1%	38,1%	16,3%	223
	Compra e manutenção da PETR4	+143,6%	64,2%	44,8%	–
2025 a 2026	Médias móveis reproduzidas	+31,3%	28,2%	22,6%	12
	ARIMA	+24,1%	19,0%	22,0%	46
	ARIMA-GARCH, versão A	−0,4%	13,7%	13,6%	37
	ARIMA-GARCH, versão B	+9,6%	8,2%	9,2%	37
	Compra e manutenção da PETR4	+33,2%	25,1%	29,1%	–

Fonte: Elaboração própria.

Nota: Com custos de execução e com o caixa remunerado pela Selic, que rendeu 86,1% em 2017 a 2024 e 25,7% em 2025 e 2026. Sem proventos. Com os proventos, a compra e manutenção da PETR4 teria rendido 726,5% em 2017 a 2024.

Em 2017 a 2024, as duas versões com GARCH foram as que menos oscilaram, e a versão A teve também a menor queda máxima e o maior retorno, de 273,8%. A versão B oscilou menos que todos, mas a sua queda máxima, de 38,1%, ficou um pouco acima da das médias móveis, embora na otimização ela tivesse caído apenas 8,4%. Ela é a única do período que mantém a posição aberta quando o GARCH veta uma operação, o que indica que a proteção depende de o robô reduzir a posição quando a volatilidade sobe. Esse é um exemplo de por que a escolha precisa ser testada em um período novo. O que funciona no período da otimização nem sempre se repete no seguinte.

Em 2025 e 2026, as versões com GARCH voltaram a ser as que menos caíram e menos oscilaram, mas foram as que menos renderam. Nesse período, a PETR4 caiu 15,4% em 2025 e subiu 57,5% em 2026, e as versões com GARCH, mais protegidas, ganharam pouco com a alta.

3.6 A crise da pandemia, 2020

A queda provocada pela pandemia, em 2020, permite observar os robôs em uma crise mais recente que a de 2008. Os números da Tabela 7 são um recorte do teste de 2017 a 2024, com as configurações escolhidas em 2014 a 2016, antes da pandemia.

Tabela 7 – Resultado em 2020, ano da pandemia

Robô	Retorno no ano	Queda máx. no ano
Médias móveis reproduzidas	+29,4%	18,8%
ARIMA	−0,7%	23,2%
ARIMA-GARCH, versão A	+0,6%	19,7%
ARIMA-GARCH, versão B	−12,0%	37,7%
Compra e manutenção da PETR4	−7,2%	64,2%

Fonte: Elaboração própria.

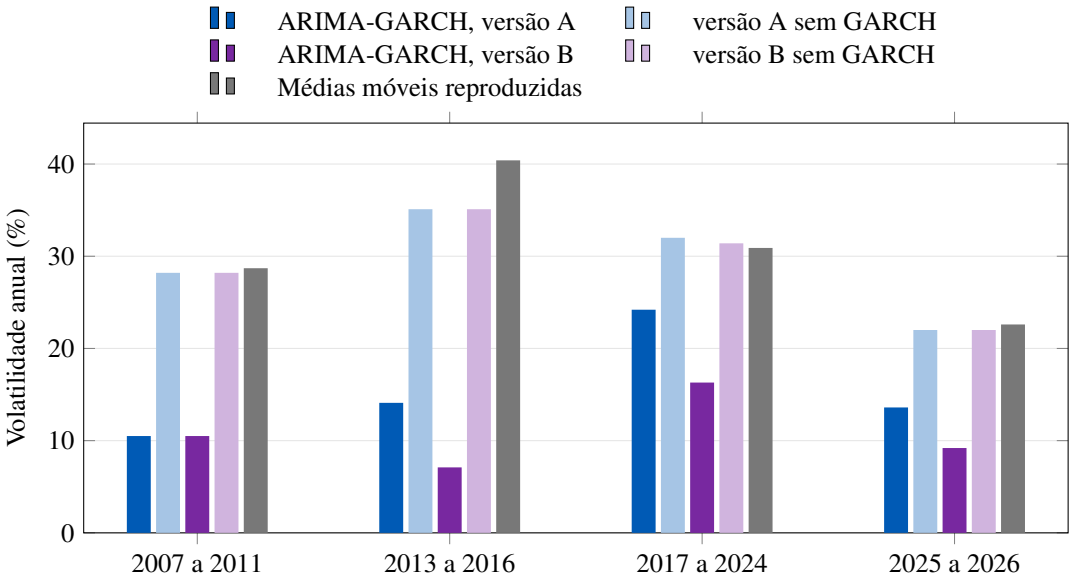
Nota: Com custos de execução e com o caixa remunerado pela Selic, sem proventos. A queda máxima é medida dentro do ano, a partir do fechamento de 2019.

A PETR4 chegou a perder 64,2% do seu valor no pior momento do ano e terminou 2020 com queda de 7,2%, isto é, a recuperação foi quase tão rápida quanto a queda. Nesse cenário, diferentemente de 2008, as médias móveis tiveram o melhor resultado, com ganho de 29,4% e queda máxima de 18,8%. A versão A protegeu de forma parecida, com queda máxima de 19,7%, mas terminou o ano praticamente sem ganho. A versão B, que mantém a posição aberta durante o veto, caiu 37,7%, ainda assim bem menos que a mesma configuração sem o GARCH, que perdeu 50,3% no ano e chegou a cair 59,8%. O resultado mostra que o GARCH protegeu também nessa crise, mas que, em uma queda seguida de recuperação rápida, o cruzamento de médias se saiu tão bem quanto ele na proteção e melhor no retorno.

3.7 O efeito vem do GARCH?

As tabelas anteriores comparam robôs diferentes. Para saber se a diferença vem do GARCH, e não dos demais parâmetros, cada versão foi comparada com a mesma configuração com o GARCH desligado. O Gráfico 3 mostra essa comparação para a volatilidade em cada período.

Gráfico 3 – Volatilidade por período de teste



Fonte: Elaboração própria.

Contando todas as versões de todos os períodos, inclusive as configurações fixas, são onze comparações. Em todas as onze, a versão com GARCH teve volatilidade e queda máxima menores que as da mesma configuração sem ele, e em nove delas teve também retorno maior. Se o GARCH não fizesse diferença, seria de esperar que a versão com ele ficasse à frente em cerca de metade das comparações, como no lançamento de uma moeda, e não em todas.

O efeito se repetiu nas outras três ações. Considerando as quatro, nas configurações que reduzem a posição quando a volatilidade sobe, o GARCH reduziu a queda máxima em 85% a 93% das comparações em 2007 a 2011 e em 92% a 98% em 2013 a 2016, conforme a ação. Em

2025 e 2026, um período mais calmo, o efeito foi menor. As configurações que apenas impedem novas entradas, mantendo a posição aberta, não mostraram o mesmo efeito, o que confirma o que se viu na versão B de 2017 a 2024. As configurações fixas, mantidas sem nova escolha de 2005 a 2026, também protegeram. A queda máxima delas ficou entre 14,2% e 29,7%, contra 80,7% sem o GARCH e 67,5% das médias móveis. Os números completos estão na última seção deste capítulo.

No retorno, o resultado não foi tão consistente. As médias móveis renderam mais que as versões com GARCH em 2013 a 2016 e em 2025 e 2026, e a Selic rendeu mais que elas em três dos quatro períodos. A verificação estatística da última seção deste capítulo mostra a mesma diferença entre risco e retorno. A redução da volatilidade foi significativa em todas as comparações, e as diferenças de retorno, em quase nenhuma.

3.8 Como o GARCH protege

O GARCH não informa a direção dos preços, e os resultados confirmam que ele não melhorou a previsão. Em todos os períodos, a taxa de acerto dos robôs com ARIMA, com e sem o GARCH, ficou entre 41% e 59%, perto dos 50% que se teria escolhendo a direção ao acaso, e a diferença entre as versões com e sem o GARCH foi de no máximo quatro pontos percentuais.

O que o GARCH mudou foi a quantidade de vezes em que o robô agiu. Em 2017 a 2024, a versão A vetou 657 dos 1.983 sinais do ARIMA e aplicou, em média, 43,9% do patrimônio na ação, contra 62,3% da mesma configuração sem o GARCH. A proteção vem, assim, de ficar menos tempo comprado e de ficar fora justamente nos dias de volatilidade prevista mais alta. É o que se espera de um modelo de volatilidade, que serve à gestão de risco (Araya; Araya, 2024), e não à previsão da direção.

Um episódio de 2020 mostra o filtro em ação. Na abertura de 3 de abril, durante a queda associada à pandemia, o ARIMA previa alta de 2,66% para o dia e, sozinho, teria comprado. A volatilidade prevista pelo GARCH para aquele dia era de 7,58%, cerca de três vezes o limiar vigente, de 2,54%, e a operação foi vetada. Naquele momento, a ação acumulava queda de 48,6% em relação ao fechamento de 2019.

3.9 Verificação estatística e testes complementares

Esta seção reúne a verificação estatística das diferenças e os resultados detalhados dos testes complementares resumidos nas seções anteriores.

A redução da volatilidade foi verificada pelo teste de Pitman-Morgan, aplicado aos retornos diários dos mesmos pregões. O teste verifica se duas séries pareadas têm a mesma variância, examinando a correlação entre a soma e a diferença delas, que só é nula quando as duas variâncias são iguais. Ele supõe que os retornos sigam a distribuição normal e que o retorno de um dia não dependa dos anteriores, condições que não valem bem para ações, que têm dias extremos mais frequentes do que a distribuição normal prevê (Thomaz, 2019). Por isso, os

valores-p devem ser lidos como aproximados. A Tabela 8 mostra a redução obtida em cada comparação.

Tabela 8 – Redução da volatilidade com o GARCH

Período	Configuração	Em relação à mesma configuração sem GARCH	Em relação às médias móveis
2007 a 2011	versões A e B	63% menor	64% menor
2013 a 2016	versão A	60% menor	65% menor
2013 a 2016	versão B	80% menor	82% menor
2017 a 2024	versão A	24% menor	22% menor
2017 a 2024	versão B	48% menor	47% menor
2025 a 2026	versão A	38% menor	40% menor
2025 a 2026	versão B	58% menor	59% menor
2005 a 2026	versão A, fixa	50% menor	54% menor
2005 a 2026	versão B, fixa	74% menor	75% menor
2017 a 2024	versão A, fixa	48% menor	45% menor
2017 a 2024	versão B, fixa	73% menor	72% menor
2013 a 2016	condições originais	18% menor	16% menor

Fonte: Elaboração própria.

Nota: Pelo teste de Pitman-Morgan, todas as reduções são estatisticamente significativas, com valor-p inferior a 0,001 e estatística t entre -5 e -157. Nas condições originais, a comparação é com o ARIMA e com as médias móveis reproduzidas.

As estatísticas do teste ficaram tão distantes do esperado para duas estratégias que oscilassem da mesma forma que a conclusão não depende das suposições do teste.

As diferenças de retorno foram verificadas pelo teste de diferença entre índices de Sharpe e pelo teste t pareado dos retornos diários. Em relação à mesma configuração sem o GARCH, a versão com GARCH foi significativamente melhor em uma das onze comparações, a da versão B de 2017 a 2024, com valor-p de 0,020, e em nenhuma foi significativamente pior. Pelo teste t pareado, nenhuma diferença foi significativa, com valores-p entre 0,06 e 0,97. Em relação às médias móveis, nenhuma das doze comparações foi significativa, com valores-p entre 0,11 e 0,95.

A Tabela 9 detalha o efeito do GARCH nas quatro ações, e a Tabela 10, o risco das configurações fixas.

Tabela 9 – Efeito do GARCH sobre o risco nas quatro ações

	2007 a 2011	2013 a 2016	2025 a 2026
Comparações em que reduziu a volatilidade	95% a 97%	97% a 99,6%	51% a 99%
Variação da volatilidade (p.p.)	-9 a -16	-14 a -36	0 a -17
Comparações em que reduziu a queda máxima	85% a 93%	92% a 98%	52% a 96%
Variação da queda máxima (p.p.)	-17 a -29	-20 a -40	0 a -22

Fonte: Elaboração própria.

Nota: Configurações que dimensionam a entrada pela volatilidade prevista ou encerram a posição no veto, cada uma comparada à mesma configuração sem GARCH. As faixas correspondem às quatro ações, PETR4, VALE3, USIM5 e POMO4. As variações são medianas.

Tabela 10 – Risco das configurações fixas

Período	Robô	Volatilidade	Queda máx.
2005 a 2026	ARIMA-GARCH, versão A	14,3%	29,7%
	ARIMA-GARCH, versão B	7,6%	14,2%
	mesma configuração sem GARCH	28,8%	80,7%
	Médias móveis reproduzidas	31,0%	67,5%
2017 a 2024	ARIMA-GARCH, versão A	17,0%	28,1%
	ARIMA-GARCH, versão B	8,6%	12,6%
	mesma configuração sem GARCH	32,6%	57,8%
	Médias móveis reproduzidas	30,9%	36,7%

Fonte: Elaboração própria.

Nota: As duas versões fixas usam o mesmo ARIMA, de modo que a configuração sem GARCH é a mesma para as duas. Compra e manutenção da PETR4, pela variação do preço: volatilidade de 44,9% e queda máxima de 92,0% em 2005 a 2026, e de 44,8% e 64,2% em 2017 a 2024.

CONSIDERAÇÕES FINAIS

Este trabalho investigou o efeito de acrescentar um modelo de volatilidade condicional a uma estratégia automatizada de negociação cuja previsão de direção permanece a mesma. A questão norteadora foi em que medida a integração dos modelos ARIMA e GARCH em um único algoritmo de negociação altera o desempenho e o risco das operações, em comparação com o uso do ARIMA isolado e com uma estratégia de cruzamento de médias móveis.

Quanto ao risco, que é o que o GARCH foi incluído para controlar, a resposta é clara. Em todos os períodos analisados, a versão do algoritmo com o GARCH oscilou menos e sofreu quedas menores que a mesma configuração com o GARCH desligado, e a redução da oscilação foi estatisticamente significativa em todas as comparações. O efeito se repetiu nas outras três ações estudadas, sobretudo nos períodos de turbulência. O ano de 2008 resume bem esse comportamento. Enquanto a PETR4 perdia quase metade do seu valor, o ARIMA-GARCH encerrou o ano com um pequeno ganho. A proteção veio de o robô ficar menos tempo comprado e de ficar fora justamente nos dias de maior volatilidade prevista, e não de prever melhor a direção dos preços.

Esse resultado responde à sugestão deixada por Almeida (2016). Ao discutir o prejuízo do seu robô no período que inclui a crise de 2008, o autor apontou a limitação das médias móveis em mercados de alta volatilidade e indicou os modelos de volatilidade como caminho para contorná-la. Nos testes deste trabalho, as médias móveis e o ARIMA sem o GARCH oscilaram de forma muito parecida, o que mostra que trocar o indicador de direção não basta para reduzir o risco. Com o GARCH, o algoritmo oscilou menos que as médias móveis em todos os períodos, inclusive nas condições originais do estudo de referência, e sofreu quedas menores em quase todos, com a maior diferença de queda máxima justamente no período de crise em que o robô de Almeida (2016) acumulou prejuízo. Na crise da pandemia, em 2020, a proteção se repetiu, mas as médias móveis protegeram de forma parecida e renderam mais, o que mostra que a vantagem do GARCH sobre elas depende do tipo de crise.

Quanto ao retorno, o efeito foi menos claro. Na maior parte dos testes, a versão com GARCH terminou com retorno maior que o da mesma configuração sem ele, mas essa vantagem só foi confirmada estatisticamente em uma das comparações, e em nenhuma delas o GARCH piorou o resultado de forma significativa. Em relação às médias móveis, o ARIMA-GARCH ganhou em alguns períodos e perdeu em outros, por diferenças que ficaram dentro da margem do acaso. Em relação à taxa Selic, usada neste trabalho como referência de medida e não como meta, o ARIMA-GARCH só rendeu mais no período de 2017 a 2024, e por uma margem que o acaso também explicaria. Esse resultado é coerente com a função do modelo. O GARCH descreve o tamanho das oscilações, e não a direção dos preços, e por isso o efeito que se espera dele é sobre o risco, e não sobre o lucro.

A primeira hipótese afirmava que a integração entre ARIMA e GARCH gera sinais mais eficazes que o ARIMA isolado, tanto em acerto direcional quanto em adequação ao risco. Ela foi

parcialmente confirmada. A adequação ao risco foi confirmada pela volatilidade e pelas quedas menores em todos os períodos, com significância estatística na volatilidade. O acerto direcional, por outro lado, não melhorou e permaneceu próximo do acaso. O ganho veio de operar com mais critério. Ao deixar de operar nos dias de maior volatilidade prevista, o algoritmo agiu menos vezes e em condições mais regulares.

A segunda hipótese afirmava que a combinação representa um avanço em relação às análises baseadas em médias móveis. Ela foi confirmada quanto ao risco. Todas as variantes com GARCH oscilaram menos que as médias móveis, com diferença significativa em todos os períodos, e a queda máxima foi menor em quase todas. A exceção foi a variante que mantém a posição aberta durante o veto, no período de 2017 a 2024, o que indica que a proteção depende de o algoritmo reduzir a posição quando a volatilidade sobe. Quanto ao retorno, as diferenças entre os dois algoritmos ficaram dentro da margem do acaso, e não se pode afirmar avanço nesse sentido.

O objetivo geral, desenvolver em MQL5 um *Expert Advisor* que integra os modelos ARIMA e GARCH e avaliar experimentalmente o efeito da inclusão do GARCH, foi alcançado. Os dois modelos foram implementados na própria linguagem da plataforma e validados por recuperação de parâmetros em séries com resposta conhecida. A escolha das ordens do ARIMA foi automatizada pelo teste ADF e pelo critério de Akaike. A estratégia de Almeida (2016) foi reimplementada, e a reprodução dos seus testes confirmou o comportamento do algoritmo original, embora não os seus valores em reais, que dependem de informações que o estudo original não registra. Por fim, o protocolo com períodos de calibração e de teste separados foi definido antes da observação dos resultados e executado sobre dados oficiais, e os três algoritmos foram comparados quanto a risco e retorno, com testes estatísticos.

Os resultados têm limitações. As diferenças de retorno, em sua maior parte, não atingem significância estatística, e o teste da volatilidade supõe retornos normais e independentes ao longo do tempo, o que torna os seus valores-p otimistas, ainda que a distância das estatísticas obtidas torne improvável que a conclusão mude. A configuração com melhor retorno em um período não tende a repetir o desempenho no seguinte, embora a proteção tenda a se manter, e os ganhos se concentram em poucos anos. A análise se restringe a quatro ativos de um único mercado, com um custo de execução único para todo o período, e com janelas de estimação de no máximo 240 pregões, limitadas pelo histórico que o testador disponibiliza, curtas para a estimação do GARCH. A medida de desempenho não inclui os proventos, que, quando incluídos, favorecem as estratégias que permanecem mais tempo compradas. Além disso, os experimentos foram realizados por simulação sobre dados históricos, com execução no preço de abertura e sem considerar a falta de liquidez ou a diferença entre o preço pedido e o executado, condições que só podem ser verificadas em operação real.

Como continuação, o resultado indica que o caminho mais promissor está no controle de risco, que foi onde o modelo mostrou efeito. Uma possibilidade é empregar variações assimétricas do GARCH, que reagem mais às quedas do que às altas, comportamento comum

nas séries de ações e não capturado pela especificação simétrica utilizada. Outra é testar a janela expansiva, que acumula todo o histórico e que, no estudo de Xing *et al.* (2024), deu ao ARIMA melhores resultados que a janela deslizante. Outra, ainda, é aplicar o mesmo protocolo a um conjunto maior de ativos e acompanhar o algoritmo em conta de demonstração, em tempo real, o que permitiria também avaliar as ordens de limite de perda e de realização de lucro que Almeida (2016) previu em seu algoritmo, mas não utilizou em seus testes.

No eixo da previsão, a próxima etapa é a que estava prevista no projeto original deste trabalho e foi deixada de lado para que a implementação do ARIMA e do GARCH pudesse ser concluída e validada: substituir o ARIMA por uma rede neural recorrente do tipo LSTM, do inglês *Long Short-Term Memory*, capaz de representar relações não lineares, mantendo o GARCH como filtro de risco. A arquitetura do algoritmo, que separa a previsão da direção da avaliação do risco, permite essa troca sem alterar o restante. Os resultados deste trabalho, porém, recomendam cautela na expectativa, já que a taxa de acerto direcional do ARIMA ficou próxima do acaso e o ganho observado veio do controle de risco, e não da previsão.

REFERÊNCIAS

ALMEIDA, F. L. R. *Técnicas de previsão da bolsa com MetaTrader 5*. Monografia (Graduação em Tecnologia em Banco de Dados) – Faculdade de Tecnologia de Indaiatuba, Indaiatuba, 2016. No Repositório Institucional do Centro Paula Souza o trabalho está catalogado sob o título "Análise da ação PETR4 na Bolsa de Valores de São Paulo com MetaTrader 5". Disponível em: <https://ric.cps.sp.gov.br/handle/123456789/24287>. Acesso em: 20 fev. 2025.

ARAYA, T. H.; ARAYA, J. A. A hybrid GARCH and deep learning method for volatility prediction. *Journal of Mathematics*, Londres, Reino Unido, v. 2024, 2024. Article ID 6305525.

B3. *Séries históricas de cotações (COTAHIST): arquivos anuais de 2003 a 2026*. São Paulo, 2026. Disponível em: <https://bvmf.bmfbovespa.com.br/InstDados/SerHist/>. Acesso em: 21 set. 2026.

BANCO CENTRAL DO BRASIL. *Bolsas de valores*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/pre/composicao/bv.asp?frame=1>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Corretoras e distribuidoras*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/acessoinformacao/legado?url=https:%2F%2Fwww.bcb.gov.br%2Fpre%2Fcomposicao%2Fcorretoras_distribuidoras.asp>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Taxa Selic*. Brasília, DF, 2025. Disponível em: <https://www.bcb.gov.br/estatisticas/detalhamentoGrafico/graficoshome/selic>. Acesso em: 22 abr. 2025.

BANCO CENTRAL DO BRASIL. *Sistema Gerenciador de Séries Temporais: série 11, taxa de juros Selic, % ao dia*. Brasília, DF, 2026. Disponível em: <https://api.bcb.gov.br/dados/serie/bcdata.sgs.11/dados>. Acesso em: 21 set. 2026.

BATISTA, C. B. *Desenvolvimento de robô para automação de investimentos na bolsa de valores utilizando indicadores técnicos*. Monografia (Graduação em Engenharia de Computação) – Pontifícia Universidade Católica de Goiás, Goiânia, 2024. Disponível em: <https://repositorio.pucgoias.edu.br/jspui/handle/123456789/8073>. Acesso em: 30 mar. 2025.

BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, Elsevier, Amsterdam, v. 31, n. 3, p. 307–327, 1986.

ELDER, A. *Come into my trading room: a complete guide to trading*. Nova Iorque, EUA: Wiley, 2002.

ENGLE, R. F. Autoregressive conditional heteroskedasticity with estimates of the variance of the United Kingdom inflation. *Econometrica*, The Econometric Society, New Jersey, EUA, v. 50, n. 4, p. 987–1008, 1982.

FERNANDES, A. *Fundamentos de análise técnica de ações*. 1. ed. Rio de Janeiro: Campus, 2014.

MÁXIMO, W. Bolsa cai 30%, e dólar sobe 16% em março com pandemia de coronavírus. *Agência Brasil*, Brasília, 31 mar. 2020. Disponível em: <https://agenciabrasil.ebc.com.br/economia/noticia/2020-03/bolsa-cai-30-e-dolar-sobe-16-em-marco-com-pandemia-de-coronavirus>. Acesso em: 05 out. 2026.

METAQUOTES LTD. *MetaTrader 5: plataforma de negociação para Forex, ações e futuros*. Limassol: MetaQuotes Ltd., 2024. Disponível em: <https://www.metatrader5.com/pt>. Acesso em: 01 mar. 2025.

METAQUOTES LTD. *Relatório de teste*. Limassol, 2026. Ajuda para o MetaTrader 5. Página da ajuda da plataforma, sem data de publicação. Disponível em: <https://www.metatrader5.com/pt/terminal/help/algotrading/testing_report>. Acesso em: 05 out. 2026.

SHARPE, W. F. The Sharpe ratio. *The Journal of Portfolio Management*, Nova Iorque, v. 21, n. 1, p. 49–58, 1994. Disponível em: <https://web.stanford.edu/~wfsharpe/art/sr/sr.htm>. Acesso em: 05 out. 2026.

THOMAZ, P. S. *Modelos ARMA-GARCH na modelagem da volatilidade de ações financeiras*. Dissertação (Mestrado em Modelagem Computacional) – Universidade Federal do Rio Grande, Rio Grande, 2019. Disponível em: <http://repositorio.furg.br/handle/1/10204>. Acesso em: 12 out. 2026.

WAZLAWICK, R. S. *Metodologia de pesquisa para ciência da computação*. 2. ed. Rio de Janeiro: Elsevier, 2014.

XING, Y. et al. *Predicting NVIDIA's next-day stock price: a comparative analysis of LSTM, MLP, ARIMA, and ARIMA-GARCH models*. 2024. ArXiv. Preprint. Disponível em: <https://arxiv.org/abs/2405.08284>. Acesso em: 09 abr. 2025.

YAHOO FINANCE. *PETR4.SA: histórico de dividendos e desdobramentos*. 2026. Disponível em: <https://finance.yahoo.com/quote/PETR4.SA/history/>. Acesso em: 21 set. 2026.

APÊNDICES

APÊNDICE A – Código do *Expert Advisor*

Este apêndice apresenta o código do *Expert Advisor* desenvolvido neste trabalho. Para facilitar a leitura, foram retirados os comentários e as rotinas que não participam da decisão de operar, isto é, as mensagens de registro, o diagnóstico por pregão e o cálculo das medidas de desempenho no testador de estratégias. A versão reduzida continua sendo um programa completo e compila sem erros. As rotinas de estimação do ARIMA e do GARCH, de seleção das ordens e das formas de uso do GARCH estão em arquivos de inclusão próprios, chamados pelas diretivas `#include` do início do código.

```
#include <Trade\Trade.mqh>
#include "..\Include\Arima.mqh"
#include "..\Include\Garch.mqh"
#include "..\Include\SelecaoModelo.mqh"
#include "..\Include\Estrategia.mqh"

enum ENUM_TRANSFORMACAO
  {
   TRANSF_LOG_PRECO = 0,
   TRANSF_PRECO = 1
  };

enum ENUM_MODO_VOLUME
  {
   VOLUME_FIXO = 0,
   VOLUME_CAPITAL = 1
  };

enum ENUM_MODO_ORDENS
  {
   ORDENS_AUTOMATICO = 0,
   ORDENS_MANUAL = 1
  };

input group "=== Modelo ==="
input bool               UsarGARCH            = true;
input ENUM_TRANSFORMACAO Transformacao        = TRANSF_LOG_PRECO;
input ENUM_MODO_ORDENS   ModoOrdens           = ORDENS_AUTOMATICO;

input group "=== Ordens manuais ==="
input int                ARIMA_p              = 1;
input int                ARIMA_d              = 1;
input int                ARIMA_q              = 1;

input group "=== Ordens automaticas ==="
input int                Max_p                = 4;
input int                Max_q                = 4;
input int                Max_d                = 2;
input int                Janela_Selecao       = 240;
input int                Barras_Entre_Reselecao = 21;
input bool               IncluirConstante     = false;

input group "=== Estimacao a cada barra ==="
input int                Janela_Estimacao     = 120;
input int                GARCH_p              = 1;
input int                GARCH_q              = 1;
input int                Iteracoes_GARCH      = 300;

input group "=== Estrategia de uso do GARCH ==="
```

```
50  input ENUM_ESTRATEGIA_GARCH Estrategia        = EST_FILTRO_VOLATILIDADE;
51  input ENUM_MODO_LIMIAR   ModoLimiar           = LIMIAR_PERCENTIL;
52  input double             Limiar_Absoluto      = 0.020;
53  input double             Limiar_Percentil     = 50.0;
54  input double             Vol_Alvo             = 0.015;
55  input double             K_Confianca          = 0.50;
56  input double             Limiar_Sinal         = 0.0;
57
58  input group "=== Negociacao ==="
59  input ENUM_MODO_VOLUME   ModoVolume           = VOLUME_CAPITAL;
60  input double             Fracao_Capital       = 0.95;
61  input double             Volume_Base          = 100;
62  input double             Frac_Volume_Min      = 0.25;
63  input double             Frac_Volume_Max      = 2.00;
64  input int                StopLoss_Points      = 0;
65  input int                TakeProfit_Points    = 0;
66  input bool               PermitirReversao     = true;
67  input bool               SomenteCompra        = true;
68  input bool               ZerarNoVeto          = false;
69
70  input group "=== Sistema ==="
71  input ulong              MagicNumber          = 20260803;
72  input int                Slippage             = 10;
73
74  CTrade   g_trade;
75  CArima   g_arima;
76  CGarch   g_garch;
77
78  int      g_p = 1, g_d = 1, g_q = 1;
79  int      g_digits;
80  double   g_ponto;
81  datetime g_ultima_barra = 0;
82  int      g_barras_desde_selecao = 0;
83  bool     g_ordens_definidas = false;
84
85  bool CarregarSerie(const int quantidade, double &saida[])
86    {
87     double fechamento[];
88     int copiados = CopyClose(_Symbol, _Period, 1, quantidade, fechamento);
89
90     if(copiados < quantidade)
91        return(false);
92
93     ArrayResize(saida, copiados);
94
95     for(int i = 0; i < copiados; i++)
96       {
97        if(Transformacao == TRANSF_LOG_PRECO)
98          {
99           if(fechamento[i] <= 0.0)
100             return(false);
101          saida[i] = MathLog(fechamento[i]);
102          }
103       else
104          saida[i] = fechamento[i];
105     }
106
107    return(true);
108  }
109
110 bool SelecionarOrdens()
111   {
112    double serie[];
```

```
113    int janela = MathMax(Janela_Selecao, Janela_Estimacao);
114
115    if(!CarregarSerie(janela, serie))
116      {
117       return(false);
118      }
119
120    ResultadoSelecao res;
121    string relatorio = "";
122
123    bool ok = SelecionarModelo(serie, Max_d, Max_p, Max_q,
124                               IncluirConstante, ADF_CONSTANTE,
125                               res, relatorio);
126
127    if(!ok)
128       return(false);
129
130    g_p = res.p;
131    g_d = res.d;
132    g_q = res.q;
133    g_ordens_definidas = true;
134    g_barras_desde_selecao = 0;
135
136    return(true);
137   }
138
139 int OnInit()
140   {
141    g_digits = (int)SymbolInfoInteger(_Symbol, SYMBOL_DIGITS);
142    g_ponto  = SymbolInfoDouble(_Symbol, SYMBOL_POINT);
143
144    g_trade.SetExpertMagicNumber(MagicNumber);
145    g_trade.SetDeviationInPoints(Slippage);
146    g_trade.SetTypeFillingBySymbol(_Symbol);
147
148    if(Janela_Estimacao < 80)
149      {
150       return(INIT_PARAMETERS_INCORRECT);
151      }
152
153    if(Frac_Volume_Min <= 0.0 || Frac_Volume_Max < Frac_Volume_Min)
154      {
155       return(INIT_PARAMETERS_INCORRECT);
156      }
157
158    if(ModoVolume == VOLUME_CAPITAL && (Fracao_Capital <= 0.0 || Fracao_Capital > 1.0))
159      {
160       return(INIT_PARAMETERS_INCORRECT);
161      }
162
163    if(ModoLimiar == LIMIAR_PERCENTIL &&
164       (Limiar_Percentil <= 0.0 || Limiar_Percentil >= 100.0))
165      {
166       return(INIT_PARAMETERS_INCORRECT);
167      }
168
169    if(ModoOrdens == ORDENS_MANUAL)
170      {
171       g_p = MathMax(0, ARIMA_p);
172       g_d = MathMax(0, MathMin(2, ARIMA_d));
173       g_q = MathMax(0, ARIMA_q);
174       g_ordens_definidas = true;
175      }
```

```
176     else
177       {
178
179        SelecionarOrdens();
180       }
181
182     g_arima.Definir(g_p, g_d, g_q, IncluirConstante);
183     g_garch.Definir(GARCH_p, GARCH_q);
184     g_garch.DefinirOtimizador(Iteracoes_GARCH);
185
186     return(INIT_SUCCEEDED);
187    }
188
189  void OnTick()
190    {
191
192     datetime barra = (datetime)SeriesInfoInteger(_Symbol, _Period, SERIES_LASTBAR_DATE);
193     if(barra == g_ultima_barra)
194        return;
195     g_ultima_barra = barra;
196
197     if(ModoOrdens == ORDENS_AUTOMATICO)
198       {
199        bool precisa = (!g_ordens_definidas) ||
200                       (Barras_Entre_Reselecao > 0 &&
201                        g_barras_desde_selecao >= Barras_Entre_Reselecao);
202
203        if(precisa)
204          {
205           if(SelecionarOrdens())
206             {
207              g_arima.Definir(g_p, g_d, g_q, IncluirConstante);
208             }
209          }
210        g_barras_desde_selecao++;
211       }
212
213     if(!g_ordens_definidas)
214        return;
215
216     double serie[];
217     if(!CarregarSerie(Janela_Estimacao, serie))
218        return;
219
220     if(!g_arima.Ajustar(serie))
221       {
222        return;
223       }
224
225     double previsao = (g_arima.D() == 1)
226                       ? g_arima.PreverDiferenciado()
227                       : g_arima.PreverNivel() - serie[ArraySize(serie) - 1];
228
229     if(!MathIsValidNumber(previsao))
230       {
231        return;
232       }
233
234     double vol_prevista = 0.0;
235     double limiar = Limiar_Absoluto;
236     bool   garch_ok = false;
237
238     if(UsarGARCH)
```

```
239       {
240        double residuos[];
241
242        if(!g_arima.ObterResiduos(residuos))
243          {
244           return;
245          }
246
247        if(g_garch.Ajustar(residuos))
248          {
249           vol_prevista = g_garch.VolatilidadeProximoPeriodo();
250           garch_ok = true;
251
252           if(ModoLimiar == LIMIAR_PERCENTIL)
253             {
254              double serie_vol[];
255              if(g_garch.ObterSerieVolatilidade(serie_vol))
256                 limiar = Percentil(serie_vol, Limiar_Percentil);
257              else
258                 limiar = Limiar_Absoluto;
259             }
260          }
261        else
262          {
263
264           return;
265          }
266       }
267
268     DecisaoOperacao dec;
269     DecidirOperacao(previsao, vol_prevista, UsarGARCH, Estrategia,
270                     limiar, Vol_Alvo, K_Confianca,
271                     Volume_Base, Frac_Volume_Min, Frac_Volume_Max,
272                     Limiar_Sinal, dec);
273
274     if(dec.sinal != 0)
275        Executar(dec);
276     else if(dec.bloqueou_garch && ZerarNoVeto)
277       {
278
279        ENUM_POSITION_TYPE posicao = PosicaoAtual();
280        if(posicao == POSITION_TYPE_BUY || posicao == POSITION_TYPE_SELL)
281           FecharPosicao(posicao);
282       }
283
284   }
285
286 void Executar(const DecisaoOperacao &dec)
287   {
288    MqlTick tick;
289    if(!SymbolInfoTick(_Symbol, tick) || tick.ask <= 0.0 || tick.bid <= 0.0)
290       return;
291
292    ENUM_POSITION_TYPE posicao = PosicaoAtual();
293
294    if(dec.sinal < 0 && SomenteCompra)
295      {
296       if(posicao == POSITION_TYPE_BUY)
297          FecharPosicao(POSITION_TYPE_BUY);
298       return;
299      }
300
301    double volume = AjustarVolume(VolumeDesejado(dec.volume,
```

```
302                                 (dec.sinal > 0) ? tick.ask : tick.bid));
303
304    if(volume <= 0.0)
305       return;
306
307    if(dec.sinal > 0)
308      {
309       if(posicao == POSITION_TYPE_SELL)
310         {
311          if(!PermitirReversao)
312             return;
313
314          if(!FecharPosicao(POSITION_TYPE_SELL))
315             return;
316          posicao = PosicaoAtual();
317         }
318
319       if(posicao == POSITION_TYPE_BUY)
320          return;
321
322       double sl = (StopLoss_Points > 0)
323                   ? NormalizeDouble(tick.ask - StopLoss_Points * g_ponto, g_digits) :
                        0.0;
324       double tp = (TakeProfit_Points > 0)
325                   ? NormalizeDouble(tick.ask + TakeProfit_Points * g_ponto, g_digits) :
                        0.0;
326
327       g_trade.Buy(volume, _Symbol, tick.ask, sl, tp, "ARIMA-GARCH BUY");
328
329       return;
330      }
331
332    if(posicao == POSITION_TYPE_BUY)
333      {
334       if(!PermitirReversao)
335          return;
336       if(!FecharPosicao(POSITION_TYPE_BUY))
337          return;
338       posicao = PosicaoAtual();
339      }
340
341    if(posicao == POSITION_TYPE_SELL)
342       return;
343
344    double sl = (StopLoss_Points > 0)
345                ? NormalizeDouble(tick.bid + StopLoss_Points * g_ponto, g_digits) : 0.0;
346    double tp = (TakeProfit_Points > 0)
347                ? NormalizeDouble(tick.bid - TakeProfit_Points * g_ponto, g_digits) : 0.0;
348
349    g_trade.Sell(volume, _Symbol, tick.bid, sl, tp, "ARIMA-GARCH SELL");
350   }
351
352 ENUM_POSITION_TYPE PosicaoAtual()
353   {
354    for(int i = PositionsTotal() - 1; i >= 0; i--)
355      {
356       ulong ticket = PositionGetTicket(i);
357       if(ticket == 0 || !PositionSelectByTicket(ticket))
358          continue;
359
360       if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
361          (ulong)PositionGetInteger(POSITION_MAGIC) == MagicNumber)
362          return((ENUM_POSITION_TYPE)PositionGetInteger(POSITION_TYPE));
```

```
363       }
364
365     return((ENUM_POSITION_TYPE)-1);
366    }
367
368  bool FecharPosicao(const ENUM_POSITION_TYPE tipo)
369    {
370     for(int i = PositionsTotal() - 1; i >= 0; i--)
371       {
372        ulong ticket = PositionGetTicket(i);
373        if(ticket == 0 || !PositionSelectByTicket(ticket))
374           continue;
375
376        if(PositionGetString(POSITION_SYMBOL) == _Symbol &&
377           (ulong)PositionGetInteger(POSITION_MAGIC) == MagicNumber &&
378           PositionGetInteger(POSITION_TYPE) == tipo)
379          {
380           if(g_trade.PositionClose(ticket, Slippage))
381              return(true);
382
383           return(false);
384          }
385       }
386
387     return(true);
388    }
389
390  double VolumeDesejado(const double volume_decisao, const double preco)
391    {
392     if(ModoVolume == VOLUME_FIXO || preco <= 0.0)
393        return(volume_decisao);
394
395     double fator = (Volume_Base > 0.0) ? volume_decisao / Volume_Base : 1.0;
396     return(VolumePorCapital(_Symbol, Fracao_Capital * fator, preco));
397    }
398
399  double AjustarVolume(double volume)
400    {
401     double v_min  = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MIN);
402     double v_max  = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_MAX);
403     double v_step = SymbolInfoDouble(_Symbol, SYMBOL_VOLUME_STEP);
404
405     if(v_step > 0.0)
406        volume = MathRound(volume / v_step) * v_step;
407
408     if(volume < v_min) volume = v_min;
409     if(v_max > 0.0 && volume > v_max) volume = v_max;
410
411     int casas = 0;
412     if(v_step > 0.0 && v_step < 1.0)
413        casas = (int)MathCeil(-MathLog10(v_step));
414
415     return(NormalizeDouble(volume, casas));
416    }
```